

GreenWest: inteligencia artificial para la predicción de créditos de carbono en proyectos de (re)forestación en España

Jaime Gabriel-Vegas^{a,*}, Maider Araceli Urbón Jiménez^a, Ana de Luis Reboredo^a, Belén Pérez Lancho^a and Ana-Belén Gil-González^a

^aGrupo B1, Equipo de investigación BISITE, Universidad de Salamanca, Facultad de Ciencias, Salamanca, España

ARTICLE INFO

Keywords:

créditos de carbono
inteligencia artificial
forestación
reforestación
modelado predictivo
cambio climático

Resumen

Este trabajo presenta **GreenWest**, un modelo de inteligencia artificial diseñado para predecir la cantidad de carbono capturado en proyectos de forestación y reforestación en España. El modelo se entrena con datos multifuente: registros del **Inventario Forestal Nacional (IFN3–IFN4, MITECO)**, variables climáticas derivadas de **Copernicus/ERA5-Land** e índices espectrales procedentes de **imágenes Landsat** (Collection 2, Level 2, USGS). Estos datos se integran en una base de datos relacional jerárquica que organiza la información por parcela, especie y clase diamétrica, manteniendo trazabilidad y coherencia estructural entre inventarios.

El modelo desarrollado responde a la pregunta: *Dado un cultivo forestal con características concretas de vegetación, clima y terreno, ¿cuánto CO₂ contendrá pasados unos años?* Esta capacidad predictiva permite su integración en marcos de optimización forestal, abordando cuestiones como la selección de especies o la asignación óptima de terrenos para maximizar la fijación de carbono.

Se evaluaron múltiples enfoques de aprendizaje supervisado, destacando **CatBoost** como el modelo con mejor rendimiento ($R^2 > 0,80$, RMSE<15), con alta capacidad de generalización temporal mediante validación cruzada por grupos. Los resultados demuestran el potencial del enfoque para estimar la absorción futura de CO₂ y optimizar decisiones de gestión forestal sostenible, contribuyendo a la transición hacia una economía baja en emisiones.

*Autor de correspondencia



JaimeGabrielVegas@usal.es (J. Gabriel-Vegas); murbon001@usal.es

(M.A.U. Jiménez); adeluis@usal.es (A.d.L. Reboredo); lancho@usal.es

(B.P. Lancho); abg@usal.es (A. Gil-González)

ORCID(s):

Índice

1. Introducción	4
2. Objetivos y Justificación	4
2.1. Objetivos específicos	5
2.2. Justificación	5
3. Revisión de la Literatura	5
4. Estado del Arte	7
5. Metodología	7
5.1. Origen y estructura de los datos	8
5.1.1. Estructura de la base de datos	8
5.1.2. Diccionario resumido de variables	9
5.1.3. Cardinalidad y completitud	11
5.2. Variables objetivo	11
5.3. Supuestos de elegibilidad y verificación externa	11
5.4. Preparación y tratamiento de los datos	12
5.4.1. Filtrado de registros	12
5.4.2. Cálculo y agregación de variables	13
5.4.3. Reclasificación de las variables pendiente y orientacion	13
5.4.4. Agrupación de la variable periodo	13
5.5. Partición y validación	14
5.5.1. Codificación y normalización	15
5.6. Selección de variables explicativas	15
5.6.1. Selección automática mediante Featurewiz	15
5.6.2. Selección mediante mRMR	15
5.6.3. Selección manual basada en criterios estadísticos y conceptuales	15
5.6.4. Selección Secuencial Supervisada basada en Rendimiento Predictivo (SSSRP)	15
5.7. Modelos evaluados	15
5.7.1. Modelos ensemble	15
5.7.2. Boosting y aprendizaje secuencial	16
5.7.3. Bagging	16
5.7.4. Otros modelos evaluados	16
5.7.5. Configuración del <i>stacking</i>	16
5.7.6. Comparación y justificación de modelos	16
6. Implementación del <i>pipeline</i>	16
6.1. Ingeniería práctica del entrenamiento y la validación	17
6.2. Implementación del <i>stacking</i>	17
6.3. Datos finales de entrenamiento	18
6.3.1. Efecto del periodo sobre el carbono	18
7. Entrenamiento y validación	18
7.1. Elección de variables	19
7.1.1. Resultados de la selección de variables manual	19
7.1.2. Selección de variables mediante <i>Featurewiz</i>	20
7.1.3. Selección de variables mediante <i>mRMR</i>	20
7.1.4. Discusión de la selección de variables	20
7.2. Ensamblado tipo <i>stacking</i> de modelos de regresión	20

8. Resultados	21
8.1. Resultados IFN2	21
8.1.1. Toneladas de carbono por hectárea	21
8.1.2. Toneladas de carbono	21
8.2. Resultados IFN3	21
8.2.1. Toneladas de carbono por hectárea	21
8.2.2. Toneladas de carbono	22
8.3. Resultados IFN2 e IFN3	22
8.3.1. Toneladas de carbono por hectárea	22
8.3.2. Toneladas de carbono	22
9. Discusión	32
9.1. Modelos globales	32
9.1.1. Variable c4 (en toneladas de carbono por hectárea)	32
9.1.2. Variable carbono_bruto4 (en toneladas de carbono)	34
9.2. Modelos individuales entrenados solo con el IFN2 o IFN3.	35
9.2.1. Asimilación del comportamiento de las variables objetivo	35
9.2.2. Rendimiento de los modelos en función del valor de la variable objetivo	37
9.3. Interpretabilidad de los modelos: análisis SHAP	38
10. Conclusiones	39
11. Recomendaciones para Futuras Investigaciones	39
A. Apéndices	42
A.1. Origen y cálculo de las variables ca y cr	42
A.2. Estado de las Poblaciones (estado_id)	42
A.3. Forma Principal de Masa (IFN3 e IFN4: fpmasa_id)	42
A.4. Tratamiento de la Masa (IFN3 e IFN4: tratmasa_id)	43
A.5. Origen de la Masa (IFN3 e IFN4: orgmasa_id)	43
A.6. Tipo de Suelo (tipsuelo1_id, tipsuelo2_id, tipsuelo3_id)	43
A.7. Rocosidad (rocosidad_id)	44
A.8. Textura del Suelo (textura_id)	44
A.9. Contenido en Materia Orgánica (IFN3 e IFN4: matorg_id)	44
A.10. Modelo de Combustible (IFN3 e IFN4: modcomb_id)	44
A.11. Distribución Espacial (disesp_id)	45
A.12. Composición Específica (comesp_id)	45
A.13. Manifestaciones Erosivas (merosiva_id)	45
A.14. Nivel de usos del suelo (IFN3 e IFN4: nivel1_id)	45
A.15. Nivel morfoestructural (IFN3 e IFN4: nivel2_id)	45
A.16. Código de los grupos taxonómicos de las especies (grupo_id)	46
A.17. Código de las especies (especie_id)	46
A.18. Resultados	49
A.18.1. IFN2 e IFN3 como explicativos para carbono_bruto4 (tC)	49
A.18.2. IFN2 e IFN3 como explicativos para c4 (tC/ha)	49
A.18.3. IFN3 como explicativo para carbono_bruto4 (tC)	50
A.18.4. IFN3 como explicativo para c4 (tC/ha)	50

1. Introducción

El cambio climático es uno de los mayores desafíos globales y su manifestación más directa es el aumento de las concentraciones atmosféricas de dióxido de carbono (CO_2), con impactos sobre la criosfera, los extremos climáticos y los ecosistemas [1]. Los bosques actúan como sumideros naturales al fijar CO_2 en biomasa vía fotosíntesis, por lo que su gestión resulta clave para la mitigación.

A lo largo de las últimas décadas, instrumentos internacionales como la *Convención Marco de las Naciones Unidas sobre el Cambio Climático (CMNUCC)* y el *Protocolo de Kioto* [2, 3] han establecido los marcos regulatorios para reducir las emisiones de gases de efecto invernadero mediante mecanismos basados en el mercado. En este contexto surgen los *créditos de carbono*, unidades que representan la cantidad de dióxido de carbono (CO_2), habitualmente una tonelada, que ha sido capturada o cuya emisión ha sido evitada a través de proyectos certificados de mitigación.

Entre las actividades elegibles, la forestación y reforestación destacan por su capacidad de actuar como sumideros naturales de carbono, fijando CO_2 en la biomasa y el suelo. No obstante, para que estas actuaciones puedan generar créditos de carbono válidos, deben cumplir una serie de criterios técnicos y legales establecidos en la normativa internacional sobre cambio climático y en su aplicación a nivel nacional. En particular, estos requisitos derivan de las reglas de contabilidad de sumideros forestales adoptadas en el marco de la Convención Marco de las Naciones Unidas sobre el Cambio Climático (CMNUCC) y del Protocolo de Kioto, concretadas en los Acuerdos de Marrakech, así como de la definición nacional de bosque comunicada por España para estos fines [4, 5]. Dichos criterios incluyen:

- **Intervención humana directa:** Los árboles deben ser el resultado de actividades de intervención humana directa, tales como la plantación, la siembra o el fomento deliberado de la regeneración natural. Este requisito se deriva de la definición de *forestación* y *reforestación* establecida en el Protocolo de Kioto, que excluye expresamente la regeneración natural no inducida por la acción humana [4].
- **Período mínimo de permanencia:** El proyecto debe garantizar la permanencia del sumidero de carbono durante un período prolongado (habitualmente del orden de 20-30 años), con el fin de asegurar que el carbono capturado no sea liberado de forma prematura a la atmósfera. Este criterio responde al principio de permanencia exigido en la contabilidad de sumideros forestales del régimen LULUCF y en los marcos de aplicación nacionales y europeos, lo que excluye cultivos de corta rotación cuyo carbono se libera tras la cosecha [4, 6].
- **Superficie mínima de 1 hectárea:** El área objeto del proyecto debe tener una extensión mínima de 1 hectárea. Este umbral procede de la definición nacional de bosque adoptada por España dentro de los rangos

permitidos por los Acuerdos de Marrakech (0,05–1 ha), comunicada oficialmente a la CMNUCC [5].

- **Fracción mínima de cabida cubierta del 20 %:** Para que un terreno sea considerado bosque, la cobertura de copas de las especies arbóreas debe alcanzar al menos el 20 % de la superficie. Este valor corresponde a la elección nacional realizada por España para la definición de bosque a efectos de contabilidad climática [5].
- **Altura mínima de los árboles maduros de 3 metros:** Las especies arbóreas deben ser capaces de alcanzar una altura mínima de 3 metros en su madurez. No es necesario que dicha altura se alcance en el momento inicial del proyecto, pero sí que sea alcanzable bajo condiciones normales de crecimiento. Este criterio forma igualmente parte de la definición nacional de bosque comunicada por España conforme a las decisiones adoptadas bajo la CMNUCC [5].

Este trabajo presenta **GreenWest**, un modelo de inteligencia artificial para estimar la cantidad de carbono que capturará un cultivo forestal en España a partir de variables de vegetación, clima y terreno en un período de 20 a 30 años. Este enfoque innovador tiene el potencial de transformar la gestión de proyectos de forestación y reforestación, optimizando las prácticas de plantación y maximizando la cantidad de carbono que se puede capturar en estos ecosistemas.

La pregunta operativa es: *dadas las características iniciales de una plantación, ¿cuánto CO_2 contendrá tras t años?, donde t es un número natural*. Para responderla, se integran datos del **Inventario Forestal Nacional** (IFN2–IFN4, MITECO) [7], reanálisis **ERA5-Land** [8] e **índices espectrales Landsat** (Collection 2, L2) [9] en una base de datos relacional jerárquica descrita en un trabajo complementario [10].

Este modelo no solo mejorará la comprensión del comportamiento de los sumideros de carbono, sino que también proporcionará herramientas útiles para la toma de decisiones estratégicas tanto en el ámbito empresarial como en el ambiental. De esta forma, el proyecto *GreenWest* contribuye a la transición hacia una economía baja en carbono, alineándose con los objetivos globales de sostenibilidad establecidos en el marco de la CMNUCC y el *Protocolo de Kioto*, y promoviendo la creación de un mercado de créditos de carbono más eficiente y accesible para los actores económicos involucrados en la gestión de los recursos naturales.

2. Objetivos y Justificación

El presente estudio tiene como objetivo principal desarrollar un modelo de inteligencia artificial capaz de predecir con precisión la capacidad de absorción de dióxido de carbono (CO_2) en cultivos forestales españoles. Este modelo se basa en variables que describen la especie arbórea, las características del terreno y las condiciones climáticas. A partir de este objetivo general se derivan varias metas específicas, que en conjunto justifican la relevancia y aplicabilidad del proyecto.

2.1. Objetivos específicos

- **Desarrollar un modelo predictivo robusto:** Construir un modelo de aprendizaje automático que estime la cantidad de CO_2 que será capturado a lo largo del tiempo por un cultivo forestal, a partir de datos como especie, tipo de suelo, clase diamétrica, clima y otras variables relevantes.
- **Optimizar la captura de carbono:** Utilizar el modelo para identificar combinaciones óptimas de especies y terrenos que maximicen la fijación de carbono, contribuyendo a la planificación eficiente de proyectos de (re)forestación.
- **Asegurar la compatibilidad con las normativas internacionales:** Garantizar que las predicciones y salidas del modelo sean compatibles con los marcos normativos definidos por la *Convención Marco de las Naciones Unidas sobre el Cambio Climático* (CMNUCC) y el *Protocolo de Kioto*, cumpliendo así los criterios necesarios para la validación de créditos de carbono.
- **Analizar los factores determinantes del desarrollo forestal:** Estudiar la influencia de variables climáticas (como la temperatura y la precipitación) y edáficas (como el tipo de suelo o la pendiente) sobre el crecimiento forestal y su capacidad de capturar carbono.
- **Apoyar la toma de decisiones ambientales y empresariales:** Proporcionar una herramienta práctica y validada que permita a técnicos, gestores y empresas seleccionar las especies más adecuadas y planificar actuaciones de forestación con la mayor eficiencia posible en términos de secuestro de carbono.

2.2. Justificación

La necesidad de contar con herramientas predictivas para estimar la captura de CO_2 se ha intensificado ante el crecimiento del mercado voluntario de créditos de carbono, y las obligaciones adquiridas: cada país debe reportar sus emisiones y absorciones de gases de efecto invernadero, y puede utilizar actividades de (re)forestación como mecanismos de compensación.

Para que estos proyectos sean elegibles, deben cumplir criterios específicos, los cuales hacen imprescindible disponer de modelos que no solo estimen el carbono actual, sino que sean capaces de prever su evolución a futuro con base en condiciones iniciales y variables predictoras.

Este trabajo busca cubrir ese vacío mediante el uso de inteligencia artificial aplicada a datos reales y multifuente. Integrar su manejo dentro del sistema de créditos de carbono puede representar una importante oportunidad para la economía local y para la mitigación del cambio climático.

3. Revisión de la Literatura

La cuantificación precisa de los recursos forestales ha constituido, históricamente, una de las piedras angulares de la gestión territorial y la economía de recursos naturales. La evolución de las técnicas para medir el crecimiento de los árboles y, más recientemente, para estimar su biomasa y




Figura 3.1: Relación entre la biomasa total en kilogramos y el diámetro a la altura del pecho en centímetros para el bambú moso (*Phyllostachys edulis*). Visto en [12], siendo [14] la fuente original.

contenido de carbono, refleja una transformación profunda en las prioridades de la sociedad humana respecto a los ecosistemas forestales. Lo que comenzó en la Europa medieval como una necesidad logística para asegurar el suministro de leña y madera estructural ante el temor de la escasez, se ha metamorfoseado en el siglo XXI en una disciplina científica de alta tecnología impulsada por la urgencia climática global [11].

La dendrometría tradicional, pilar de los inventarios forestales modernos, se fundamenta en el uso de relaciones alométricas para estimar la biomasa (w) y otros parámetros ecológicos a partir de variables de fácil medición en campo, principalmente el diámetro a la altura del pecho (D) y la altura total (H). Estas estimaciones suelen articularse mediante ecuaciones de la forma:

$$w = aD^bH^c \quad (3.1)$$

o sus transformaciones logarítmicas:

$$\lg w = a + b \lg D + c \lg H \quad (3.2)$$

donde los parámetros a , b y c son coeficientes de regresión empíricos [12]. En este contexto, la precisión de las mediciones primarias es crítica, ya que, dada la naturaleza potencial de estas funciones, los errores en la toma de datos de D y H se propagan y magnifican en el cálculo final del volumen y el contenido de carbono. Pese a la aparente sencillez del ajuste, los resultados pueden llegar a ser muy buenos, como se muestra en la Figura 3.1. No obstante, existe una tensión en la literatura entre el uso de ecuaciones “pantropicales” o generalizadas y ecuaciones específicas de especie o sitio, ya que se pueden introducir sesgos si la arquitectura de los árboles locales difiere de la global [13].

La medición de la altura de los árboles ha supuesto históricamente un desafío mayor que la del diámetro. Hasta la década de 1990, predominaron hipsómetros mecánicos




Figura 3.2: Diagrama de el escaneo de un árbol por un sistema LiDAR aerotransportado y los diversos pulsos reflejados. Imagen obtenida de [17].

basados en trigonometría, que requerían medir manualmente la distancia al árbol y una línea de visión despejada [15]. Estos métodos sufrían limitaciones de precisión y ergonomía. La introducción de la electrónica marcó un punto de inflexión al utilizar ultrasonidos para medir distancias automáticamente, permitiendo trabajar en sotobosques densos y mejorando la precisión por debajo del 1 % [15]. Paralelamente, las forcípulas (aparato de medición de la distancia lineal entre dos tangentes paralelas al fuste del árbol) electrónicas modernas han digitalizado la toma de datos, integrando medición y registro de metadatos para minimizar errores de transcripción [15].

Posteriormente, la introducción de la tecnología de escaneo láser supuso una revolución en la mensura forestal, superando las limitaciones logísticas y de precisión de los métodos tradicionales. Esta tecnología se despliega principalmente en dos modalidades: el escaneo láser terrestre (TLS, por sus siglas en inglés), que captura la estructura tridimensional del bosque desde el suelo con detalle milimétrico [16], y el LiDAR aerotransportado. Este último consiste es un método que usa pulsos de luz para medir distancias. Los mapeos masivos suelen consistir en un sistema LiDAR montado en un avión, helicóptero, dron o satélite, el cuál mide la distancia a los objetos debajo de él. Una ventaja es que, al igual que la luz puede llegar al suelo a través de los huecos de las copas de los árboles, los pulsos láser del LiDAR también lo hacen, como podemos observar en la Figura 3.2. Esto hace que mediante un solo sobrevuelo se puedan captar diversas capas a varias alturas, lo que permite realizar reconstrucciones en 3D de las zona escaneada. El detalle que se puede lograr es tan alto que se pueden identificar los árboles individuales, como se ve en la 3.3.

Las principales limitaciones del LiDAR aerotransportado residen en su elevado coste y complejidad logística. Estos factores dificultan la obtención de coberturas a gran escala con una periodicidad óptima, generando además una latencia significativa en la disponibilidad de datos regionales. Asimismo, el procesamiento de esta información es




Figura 3.3: Visualización de un bosque escaneado con LiDAR. Vemos las posibilidades de identificar árboles individuales en un entorno forestal denso [18].




Figura 3.4: Plan de adquisición de datos del Tercer ciclo del proyecto PNOA-LiDAR del Instituto Geográfico Nacional de España [19].

más exigente que en métodos previos, a lo que se suma el desafío técnico de gestionar y almacenar grandes volúmenes de datos. En la Figura 3.4 se muestra el plan de adquisición de datos del Tercer ciclo del proyecto PNOA-LiDAR del Instituto Geográfico Nacional de España, donde se puede apreciar la cadencia con la que se hacen los mapeos.

La integración de estos datos estructurales, junto a la teledetección satelital y la capacidad de procesado de grandes volúmenes de datos que ofrecen los algoritmos de aprendizaje automático ha inaugurado un nuevo paradigma: la capacidad de monitorear los recursos forestales a escala global con una precisión sin precedentes. Es en este contexto de “forestería de precisión” y observación terrestre a gran escala donde se enmarca la investigación actual, habiéndose logrado resultados muy prometedores que permiten abordar la complejidad de los ecosistemas forestales con una granularidad antes inalcanzable.

4. Estado del Arte

El secuestro de carbono en ecosistemas forestales ha cobrado una importancia creciente en la literatura científica, impulsada tanto por los compromisos internacionales en materia de cambio climático como por el auge de los mercados de créditos de carbono. Esto ha motivado el desarrollo de modelos orientados a cuantificar la biomasa forestal y estimar el contenido de carbono, aprovechando avances recientes en sensores remotos y técnicas de inteligencia artificial.

Una de las estrategias más consolidadas para la cuantificación del carbono forestal es la estimación del carbono almacenado en un momento dado a partir de datos de teledetección. Goetz et al. (2009) [20] revisan el uso de observaciones satelitales, incluyendo sensores ópticos como MODIS y Landsat, en modelos empíricos de biomasa aérea, destacando su aplicabilidad a escala regional, especialmente en ecosistemas boreales. Este tipo de estimaciones suele basarse en regresiones lineales o modelos de mínimos cuadrados generalizados, con coeficientes de determinación habitualmente entre 0.6 y 0.8, dependiendo de la resolución espacial y la heterogeneidad del ecosistema.

La aplicación de aprendizaje profundo ha permitido mejorar sustancialmente la precisión y resolución espacial de estas estimaciones. Por ejemplo, Zhang et al. (2022) [21] integran imágenes Sentinel-2 con redes neuronales convolucionales, alcanzando un R^2 de 0.84 para estimar el carbono en bosques subtropicales. Del mismo modo, Jiang et al. (2022) [22] desarrollan el modelo *ForestCarbonAI*, entrenado con datos multispectrales y LiDAR, con el que generan mapas de carbono forestal de alta resolución (10 m), reportando errores medios absolutos (MAE) inferiores a 3.5 tC/ha en zonas templadas. Otros trabajos recientes, como Reiersen et al. (2022) [23] o Dong et al. (2023) [24], también demuestran la eficacia del *deep learning* para estimaciones estáticas, aunque se centran en contextos tropicales y no consideran el componente temporal.

Frente a estos enfoques descriptivos, algunas iniciativas han intentado proyectar la evolución del carbono a futuro. En el ámbito nacional, el Ministerio para la Transición Ecológica (MITECO) ha implementado herramientas como la calculadora *ex ante* de absorciones [25], que permite obtener estimaciones simplificadas del carbono que puede fijarse en una plantación forestal en función de la especie y la zona agroclimática. No obstante, este instrumento se basa en coeficientes tabulados y no incorpora variables edafoclimáticas reales ni técnicas de modelización basadas en datos, lo que limita su precisión y capacidad de adaptación a contextos específicos.

En el ámbito europeo destaca el trabajo de Fasihi et al. (2024) [26], que aplica un enfoque afín al propuesto en este estudio en la región de Friuli-Venezia Giulia (Italia). Su objetivo es estimar tanto el *stock* actual de carbono como su tasa de absorción anual (secuestro), basándose en datos de dendrocronología del Inventario Forestal Nacional italiano. Estas mediciones, realizadas entre 2017 y 2019, cuantifican el crecimiento radial de los últimos cinco años para estimar

la biomasa mediante ecuaciones alométricas y su conversión a carbono según directrices del IPCC. Luego, entrenan modelos predictivos utilizando variables meteorológicas, geomorfológicas, índices de vegetación y un modelo de las copas de los árboles (CHM) LiDAR, intentando predecir los valores obtenidos con datos de campo.

Los autores evalúan diversos modelos de conjunto (*ensemble*), reportando que combinaciones de algoritmos como Random Forest, AdaBoost y CatBoost ofrecen el mejor rendimiento. En la predicción del *stock* de carbono, alcanzan un R^2 de $0,73 \pm 0,07$ y un RMSE de $31,55 \pm 9,35$ tC/ha. Para la tasa de secuestro, los resultados son más modestos, con un R^2 de $0,42 \pm 0,08$ y un RMSE de $0,90 \pm 0,08$ tC/ha/año. Un hallazgo clave del estudio es que la inclusión de datos LiDAR mejora drásticamente la precisión de las estimaciones.

En este escenario, el presente trabajo propone una metodología innovadora centrada en la predicción dinámica de carbono a largo plazo. A diferencia de los modelos anteriores, que estiman el carbono ya almacenado, este estudio se enfoca en anticipar cuánto carbono capturará un cultivo forestal en un horizonte temporal concreto. Para ello, se estudian diversos modelos de aprendizaje supervisado entrenados con datos históricos del Inventario Forestal Nacional (IFN2, IFN3 e IFN4) [7] incluyendo características edáficas, variables climáticas de Copernicus [27, 28] y métricas espectrales derivadas de imágenes Landsat [29]. Los detalles sobre la arquitectura del modelo, las variables utilizadas, los algoritmos implementados y las métricas de evaluación se desarrollan en las siguientes secciones.

5. Metodología

Esta sección describe el procedimiento seguido para el entrenamiento y validación de los modelos predictivos desarrollados. La metodología se fundamenta en la identificación de los factores que determinan el crecimiento forestal y, en consecuencia, la capacidad de los ecosistemas para capturar carbono a lo largo del tiempo. El enfoque integra información estructural, climática y espectral procedente del Inventario Forestal Nacional (IFN) y de otras fuentes ambientales, con el propósito de construir modelos robustos que permitan predecir el contenido de carbono acumulado en la biomasa viva.

El carbono fijado por los árboles se acumula progresivamente en su biomasa, en función del tamaño y vigor de los individuos, los cuales están condicionados por variables ambientales, topográficas y de competencia intraespecífica. Las condiciones meteorológicas, como la temperatura y la precipitación, inciden directamente en la fotosíntesis y en la disponibilidad hídrica; la orientación, la pendiente y la altitud modifican la radiación incidente y el microclima local; mientras que la densidad de árboles por unidad de superficie determina el nivel de competencia por los recursos, variando según la especie y su tolerancia ecológica [30].

A partir de estos fundamentos, se construyó una base de datos relacional que integra información forestal, climática y

espectral a nivel de parcela, especie y clase diamétrica. Esta estructura permite caracterizar con precisión la dinámica del bosque entre inventarios sucesivos y alimentar modelos predictivos capaces de estimar el contenido futuro de carbono a partir de las condiciones observadas en el pasado.

5.1. Origen y estructura de los datos

La base de datos empleada en este trabajo integra información forestal, climática y espectral estructurada en torno a la parcela como unidad básica. Cada parcela se describe mediante sus coordenadas geográficas, características edáficas y su evolución a través de distintos inventarios (IFN2, IFN3, IFN4).

Los datos forestales incluyen información por especie y clase diamétrica, como número de pies o carbono aéreo, radical y total. Estos valores permiten caracterizar con precisión la estructura y crecimiento de la vegetación.

A cada parcela se asocian también estadísticas climáticas agregadas por estación e inventario: temperaturas (superficie, aire y subsuelo) y precipitaciones, resumidas mediante métricas como media, máxima, mínima y desviación típica.

Finalmente, se incorporan índices espectrales derivados de imágenes satelitales (NDVI, EVI, NDII, GNDVI), que permiten cuantificar propiedades biofísicas de la vegetación:

- **NDVI (Normalized Difference Vegetation Index):** estima la actividad fotosintética.
- **EVI (Enhanced Vegetation Index):** mejora la sensibilidad en zonas densamente vegetadas.
- **NDII (Normalized Difference Infrared Index):** refleja el contenido hídrico de la vegetación.
- **GNDVI (Green NDVI):** variante del NDVI basada en la banda verde, sensible a la cantidad de clorofila.

5.1.1. Estructura de la base de datos

Estos datos se organizan en las siguientes entidades troncales (tablas):

- **parcelas:** contiene la información básica ligada a la localización de cada parcela (características edáficas y climáticas).
- **parcela_inventario:** describe el estado de cada parcela en un inventario determinado, incluyendo atributos edáficos y de contexto (p. ej., textura del suelo, fracción de cabida cubierta...).
- **parcela_inventario_especie:** detalla la presencia y condición de cada especie dentro de una parcela e inventario, incorporando descriptores de masa y tratamientos silvícolas.
- **parcela_inventario_especie_cd:** describe las poblaciones arbóreas por parcela, especie y *clase diamétrica*: n.º de pies, área basimétrica, volúmenes, altura de los especímenes, carbono capturado...
- **parcela_especie_arbol:** caracteriza los pies mayores identificados por parcela y especie en el cuarto inventario. Recoge las características particulares de cada pie como altura, diámetros, ubicación respecto del centro de la parcela, volumen y carbono capturado.




Figura 5.1: Esquema relacional de las tablas principales de la base de datos. Tabla extraída de [10], donde se pueden consultar más detalles sobre las variables.

- **parcela_inventario_estacion:** almacena agregados climático-biofísicos por estación en la misma granularidad parcela-inventario, incluyendo variables como precipitación y temperatura, junto a índices de vegetación (NDVI, EVI, NDII, GNDVI).
- **especies y grupos:** recogen la información taxonómica y su clasificación jerárquica, estableciendo la relación entre especies individuales y grupos funcionales.

Cada variable categórica posee una tabla de catálogo propia (cat_), donde se definen los valores posibles y sus descripciones. Por ejemplo, cat_textura, cat_nivel1, cat_tratmasa o cat_origen. Todas siguen un patrón uniforme: la clave primaria es el identificador de la variable (<variable>_id), y las tablas troncales referencian este mismo campo como clave foránea. Además la base de datos incluye una tabla llamada meta_variables que recoge los metadatos.

La Figura 5.1 muestra el esquema general de las tablas troncales y sus principales relaciones. Este diagrama resume la estructura interna de la base de datos y su jerarquía de dependencias.

5.1.2. Diccionario resumido de variables

Tabla 5.1: Resumen de variables principales por entidad. Tabla extraída de [10].

Variable	Descripción	Unidad	Tipo de dato
parcelas			
parcela_id	Identificador único de parcela (IFN).	—	Identificador
latitud, longitud	Coordenadas geográficas (WGS84).	°	Geográfico
coorx, coory	Coordenadas UTM; huso especifica zona.	m (UTM)	Geográfico
elevacion	Cota sobre el nivel del mar (NASADEM).	m	Númérico
pendiente	Inclinación del terreno.	°	Númérico
orientacion	Orientación del terreno (0–360).	°	Númérico
presencia_id	Presencia en IFN → cat_presencia.	—	Categorico
tipsuelo1_id,	Tipos de suelo → cat_tipsuelo*.	—	Categorico
tipsuelo2_id,			
tipsuelo3_id			
rocosidad_id	Rocosisdad → cat_rocosidad.	—	Categorico
radio, superficie	Radio de parcela y superficie derivada.	m; ha	Númérico
parcela_inventario			
parcela_id, inventario_id	Clave compuesta (parcela-inventario).	—	Identificador
ano	Año de apeo.	año	Númérico
nivel1_id, nivel2_id	Morfoestructura. → cat_nivel*.	—	Categorico
textura_id	Textura de suelo → cat_textura.	—	Categorico
merosiva_id	Manifestaciones erosivas → cat_merosiva.	—	Categorico
matorg_id	Materia orgánica → cat_matorg.	—	Categorico
modcomb_id	Modelo de combustible → cat_modcomb.	—	Categorico
diesp_id	Distribución espacial → cat_diesp.	—	Categorico
comesp_id	Composición específica → cat_comesp.	—	Categorico
fccarb, fcctot	Fracción de cabida cubierta (árboles).	%	Númérico
parcela_inventario_especie			
parcela_id, inventario_id, especie_id	Clave compuesta (parcela-inventario-especie).	—	Identificador
ocupa	Grado de ocupación de la especie.	(0–10)	Númérico
estado_id	Estado de desarrollo. → cat_estado.	—	Categorico
fpmasa_id	Forma principal de masa → cat_fpmasa.	—	Categorico
tratmasa_id	Tratamientos selvícolas → cat_tratmasa.	—	Categorico
orgmasa1_id	Origen de masa (IFN3/4) → cat_orgmasa1.	—	Categorico
masa_id	Clasificación de masa → cat_masa.	—	Categorico
origen_id	Origen de la masa (IFN2) → cat_origen.	—	Categorico
parcela_inventario_especie_cd			
parcela_id, inventario_id, especie_id	Clave compuesta (parcela-inventario-especie-cd).	—	Identificador
cd_id	Clase diamétrica (CD) reglamento IFN.	cm	Númérico discreto
npies	Número de pies.	pies/ha	Númérico
abas	Área basimétrica.	m ² /ha	Númérico
vcc, vsc, vle	Volúmenes (con/sin corteza; leñas).	m ³ /ha	Númérico
iavc	Incremento anual del volumen con corteza.	m ³ /ha-año	Númérico
ca, cr	Carbono aéreo y radical.	t/ha	Númérico
ht	Altura media (modelo CatBoost).	m	Númérico
carbono_bruto	Carbono total estimado (alometrías).	t	Númérico
parcela_especie_arbol			
parcela_id, especie_id	Clave compuesta (parcela-especie-árbol).	—	Identificador
arbol_id	Identificador del árbol dentro de parcela y especie.	—	Entero
rumbo	Rumbo desde el centro de la parcela al árbol.	grados centesimales	Númérico
distancia	Distancia desde el centro de la parcela al árbol.	m	Númérico
cd	Clase diamétrica (reglamento IFN).	cm	Númérico discreto
ht	Altura total del árbol inventariado.	m	Númérico
dn1, dn2	Diámetros normales perpendiculares.	mm	Númérico
abas	Área basimétrica del pie medido.	m ²	Númérico
iavc	Incremento anual del volumen con corteza.	dm ³ /año	Númérico
vcc, vsc, vle	Volúmenes (con corteza, sin corteza, leñas).	dm ³	Númérico
ca, cr	Carbono aéreo y radical del árbol.	t	Númérico
parcela_inventario_estacion			

Continúa en la siguiente página

Variable	Descripción	Unidad	Tipo de dato
parcela_id, inventario_id, estacion_id	Clave compuesta (agregado estacional).	—	Identificador
PR_*	Estadísticos de precipitación (mean, max, min, std, sum).	mm/(m ² ·día), mm/m ²	Numérico
T2M_*, SKT_*	Aire 2 m y temperatura superficial (mean, max, min, std).	°C	Numérico
STL1_*–STL4_*	Temperatura del suelo por niveles (mean, max, min, std).	°C	Numérico
NDVI_*, EVI_*, NDII_*, GNDVI_*	Índices de vegetación (max, mean, median, min, std).	adimensional	Numérico
especies y grupos			
especie_id	Identificador de especie IFN.	—	Identificador
nombre, sinonimia	Denominación IFN y sinónimos.	—	Texto
tipo_especie	0 = conífera; 1 = frondosa.	—	Categorico
grupo_id	Grupo funcional → grupos.	—	Identificador
grupos.nombregrupo	Nombre del grupo.	—	Texto

5.1.3. Cardinalidad y completitud

El volumen de entradas por tabla es:

Tabla	Número de registros
parcelas	52,298
parcela_inventario	147,995
parcela_inventario_especie	417,119
parcela_inventario_especie_cd	1,191,070
parcela_especie_arbol	855,860
parcela_inventario_estacion	470,056
especies	195
grupos	33

5.2. Variables objetivo

El objetivo del modelo es estimar el **carbono total** que una parcela forestal capturará en un horizonte temporal de 20–30 años, a partir de las condiciones observadas en inventarios previos. Para ello se contemplan dos variables de respuesta complementarias, ambas derivadas de los datos del Inventario Forestal Nacional (IFN), que permiten analizar el contenido de carbono desde perspectivas distintas: una normalizada por superficie y otra en términos absolutos.

1. **c (tC/ha)**: representa el **carbono total contenido en la biomasa viva aérea y subterránea** por unidad de superficie, expresado en *toneladas de carbono por hectárea*. Su cálculo se basa en la suma de las estimaciones de carbono aéreo (c_a) y radical (c_r) reportadas por el IFN. En los casos con valores faltantes, se completó la información mediante un modelo de *Random Forest Regressor* ajustado sobre variables dendrométricas observadas (Especie, CD, VSC, NPies, ABas, IAVC, VCC y VLE), alcanzando un rendimiento satisfactorio ($R^2_{test} > 0,90$). Esta variable es coherente con los formatos internacionales de reporte de inventarios forestales y permite comparar el contenido de carbono entre parcelas o especies.
2. **carbono_bruto (tC)**: corresponde al **carbono total capturado por parcela y especie**, expresado en *toneladas de carbono totales*. Su estimación se realiza de forma trazable y físicamente interpretable a partir de variables medidas directamente en campo: número de pies ($npies$), altura media (ht), tipo de especie ($clase_especie$) y clase diamétrica (cd_id). El cálculo sigue un modelo alométrico adaptado de [31] y las directrices del IPCC [30], incorporando tanto la biomasa aérea como la biomasa radical mediante la relación Parte Radical:Parte Aérea (R). El resultado se expresa en toneladas de carbono totales por parcela, sin normalizar por superficie, lo que facilita la trazabilidad del proceso y la comparación entre inventarios sin depender de factores de expansión específicos del IFN. En coherencia con los criterios de proyectos de forestación y reforestación, las observaciones correspondientes a brinzales o plantones se consideran con valor de carbono nulo, dado que las fases tempranas de desarrollo no se contabilizan oficialmente como carbono capturado.

Estas dos variables resumen el contenido de carbono forestal desde enfoques complementarios: c (tC/ha) permite la comparación espacial y temporal entre masas forestales, mientras que **carbono_bruto** (tC) ofrece una medida absoluta y directamente derivada de las observaciones de campo. Ambas constituyen los objetivos principales del modelado predictivo, orientado a estimar el carbono acumulado en el **IFN4** a partir de las condiciones registradas en los inventarios anteriores (**IFN2** e **IFN3**).

Para mayor detalle sobre el origen de estas variables consultar [10].

5.3. Supuestos de elegibilidad y verificación externa

Como ya se ha introducido, para que un proyecto forestal sea elegible en programas de *créditos de carbono* en España debe cumplir algunos requisitos técnicos [30, 32]. A continuación se resume cada criterio y la forma en que se aborda en este estudio:

- **Intervención humana directa.** El incremento de carbono debe proceder de actuaciones planificadas (reforestación, restauración o manejo sostenible). En nuestro caso, el modelo se entrena sobre datos observacionales (IFN2–IFN3–IFN4); por tanto, la *verificación de intervención* no se deduce del modelo, sino que se contempla como *condición externa* de elegibilidad del proyecto a evaluar.
- **Permanencia mínima.** Para caracterizar el crecimiento de las parcelas forestales en los datos que alimentan el modelo, es necesario disponer de dos mediciones sucesivas de cada parcela, separadas por un intervalo temporal conocido. Estas mediciones permiten cuantificar la evolución de las variables forestales y, por tanto, estimar el incremento de carbono asociado al crecimiento del arbolado durante dicho periodo.

En este trabajo, el objetivo es predecir el contenido de carbono correspondiente al **IFN4**, utilizando como información explicativa las variables observadas en inventarios anteriores. Dado que los inventarios tercero y cuarto comparten una estructura homogénea y un conjunto de variables comparable, la elección más directa para el entrenamiento del modelo sería emplear exclusivamente estos dos inventarios. Esta estrategia aprovecha la coherencia estructural de los inventarios más recientes, que incluyen un mayor número de variables y una caracterización más detallada del terreno.

El intervalo de tiempo entre los inventarios **IFN3** e **IFN4** es relativamente corto: la Figura 5.2 muestra la distribución de la diferencia de años entre las mediciones del IFN3 y el IFN4. Como puede observarse, la mayoría de las parcelas presentan intervalos comprendidos entre 6 y 17 años, un rango demasiado estrecho para evaluar la estabilidad del modelo en horizontes más amplios.




Figura 5.2: Distribución de la diferencia de años entre los inventarios tercero y cuarto.




Figura 5.3: Distribución de la diferencia de años entre los inventarios IFN2-IFN3 e IFN3-IFN4.

TODO: indicar con colores cuántos elementos proceden de cada inventario. hacer la figura más pequeña

Para ampliar la cobertura temporal y mejorar la capacidad de generalización del modelo, se optó por unificar la información de los inventarios **IFN2** e **IFN3** como base explicativa para la predicción del **IFN4**. Esta integración permite disponer de pares de mediciones de parcelas separadas por intervalos que oscilan entre 6 y 29 años, lo que constituye un rango mucho más representativo del horizonte de 20–30 años establecido como referencia.

De esta forma, el modelo se entrena y valida sobre un conjunto de datos más diverso y equilibrado, tanto en estructura como en amplitud temporal, manteniendo la coherencia metodológica y la trazabilidad de las estimaciones.

- **Superficie mínima de 1 ha.** Este criterio se considera externo al alcance del modelo predictivo, ya que el aprendizaje se realiza a nivel de parcela e inventario y no sobre polígonos de superficie total. En la práctica, la verificación de la superficie se realiza *ex ante*, sobre la geometría declarada del proyecto forestal. En los terrenos forestales generados a partir de intervención humana directa, como plantaciones o repoblaciones, la extensión suele presentar una estructura homogénea, con una especie dominante, edades coetáneas y

densidades estandarizadas. Bajo estas condiciones, el carbono total es proporcional a la superficie: duplicar el área de una masa forestal homogénea implica aproximadamente duplicar su carbono almacenado. Por tanto, la variable de superficie no afecta al ajuste interno del modelo y su cumplimiento puede evaluarse fácilmente a nivel de proyecto, sin comprometer la validez de las predicciones.

- **Fracción mínima de cabida cubierta del 20 %.** La base de datos dispone de *fccarb* (arbórea) y *fcctot* (total). Este umbral se aplica como *filtro de elegibilidad* previo o posterior al modelado, sin modificar la arquitectura del modelo (*fccarb* > 20).
- **Altura mínima de 3 m en la madurez.** Este requisito se refiere a la altura que alcanzan los árboles en su fase de pleno desarrollo, y no a la altura inicial de los plantones. Por tanto, las mediciones realizadas durante las etapas tempranas de crecimiento no determinan la elegibilidad del proyecto, siempre que las especies seleccionadas sean capaces de superar los 3 metros en la madurez. Este criterio se evalúa de forma externa al modelo, mediante la selección de especies forestales adecuadas y la verificación con fuentes auxiliares (catálogos silvícolas o tipologías de masa). En la práctica, el cumplimiento del requisito depende de una decisión de diseño del proyecto: no plantar especies cuyo tamaño adulto sea inferior a 3 metros. Por ello, la altura no interviene directamente en el entrenamiento, aunque sí condiciona la elegibilidad final del proyecto forestal.

5.4. Preparación y tratamiento de los datos

Como ya se ha introducido, el entrenamiento se realiza en dos líneas según la variable objetivo: carbono en toneladas por hectárea (*c* de **IFN4**) o carbono en toneladas (carbono_bruto de **IFN4**); y según la información que se usa como explicativa: **IFN3** o **IFN3** e **IFN2**. Se plantea la preparación y filtrado de los datos en términos generales.

5.4.1. Filtrado de registros

Se descartan todas aquellas parcelas en las que el valor de carbono total (variable objetivo) en la segunda inventariación es inferior a la primera. Estos casos suelen deberse a episodios de deforestación, incendios u otras perturbaciones, y no representan un crecimiento forestal neto.

El conjunto de datos se restringe únicamente a las parcelas que presentan una *fccarb* (fracción de cabida cubierta arbórea) igual o superior al 20 % en el inventario explicativo. Este umbral define la proporción mínima de superficie ocupada por copas de árboles respecto al área total de la parcela, y constituye una de las condiciones esenciales para considerar una superficie como terreno forestal. La exclusión de parcelas con *fccarb* inferior al 20 % permite asegurar que las estimaciones de carbono se realicen sobre masas forestales consolidadas, evitando sesgos asociados a áreas agrícolas o matorrales. A los datos del **IFN2** no se les aplica dicho filtro porque no disponen de la variable *fccarb*.

Resumen de Datos de Entrada del Modelo			
Variable	Tipo	Descripción	Anexo
parcela_id	varchar	Identificador único de parcela.	–
especie_id, tipo_especie, grupo_id	int (CF)	Especie, tipo y grupo taxonómico.	A.17, A.16
ocupa	int	Grado de ocupación (0–10).	–
estado_id, fpmasa_id, tratmasa_id, orgmasa_1_id	int (CF)	Estado, forma de masa, tratamiento, organización.	A.2, A.3, A.4, A.5
tipsuelo1-3_id	int (CF)	Tipos de suelo.	Anexo A.6
rocosidad_id, textura_id, matorg_id, modcomb_id, disesp_id, comesp_id, merosiva_id	int (CF)	Variables edáficas y estructurales.	Apéndices varios
radio, orientacion, elevacion, pendiente	float	Topografía y geometría de parcela.	–
nivel1_id, nivel2_id, fccarb, fcctot	int/float	Niveles jerárquicos y cabida cubierta.	A.14, A.15
npies_{CD}	float	N.º de pies por clase diamétrica.	–
periodo	int	Años entre inventarios.	–
evi, gndvi, ndii, ndvi_{stat}_{est}	float	Índices de vegetación por estación.	–
pr, skt, stl1-4, t2m_{stat}_{est}	float	Variables climáticas por estación.	–
c4, carbono_bruto4	float	Carbono IFN4 (t/ha y t).	–

Tabla 5.2

Variables de entrada del modelo. Las variables en verde están disponibles en IFN2 e IFN3; el resto solo en IFN3.

5.4.2. Cálculo y agregación de variables

Cada registro de entrada se genera a nivel de combinación parcela-especie, incorporando las variables correspondientes de la primera medición y la variable objetivo (carbono) de la segunda medición (IFN4). Las variables de parcela y parcela_inventario se desdoblan para cada especie. Las entradas de la tabla parcela_inventario_especie_cd se agrupan por parcela y especie y se comprimen en una única entrada creando un conjunto de variables para cada clase diamétrica.

La Tabla 5.2 resume las variables empleadas como entrada al modelo, integradas desde las distintas tablas que conforman la base de datos relacional.

5.4.3. Reclasificación de las variables pendiente y orientacion

Las variables topográficas originales pendiente (en grados) y orientacion (acimut en grados) se registran de forma continua en las parcelas del IFN. Sin embargo, desde el punto de vista ecológico su efecto sobre la acumulación de carbono suele ser no lineal y está asociado a clases discretas (e.g. laderas suaves frente a escarpadas, exposición norte frente a sur), por lo que resulta más adecuado tratarlas como factores categóricos.

A partir de la distribución empírica y de criterios habituales en estudios de fisiografía forestal, se definió una variable categórica pendiente_cat mediante cortes en grados:

- < 5°: *muy suave*,
- 5–10°: *suave*,
- 10–15°: *moderada*,
- 15–20°: *fuerte*,
- 20–30°: *muy fuerte*,
- 30–50°: *escarpada*,
- > 50°: *extrema*.

Esta reclasificación permite capturar diferencias funcionales relevantes (accesibilidad, estabilidad del suelo, escorrenia, profundidad efectiva del suelo) sin asumir una relación lineal entre la pendiente y el carbono almacenado.

De forma análoga, la variable orientacion se reclasificó en ocho sectores cardinales equiángulos: N, NE, E, SE, S, SO, O y NO. La nueva variable orientacion_cat agrupa orientaciones con condiciones de insolación y balance hídrico similares, lo que facilita la interpretación ecológica y reduce el ruido asociado a pequeñas variaciones angulares.

5.4.4. Agrupación de la variable periodo

Como se puede observar en la Figura 5.3, la distribución de la variable periodo, definida como el número de años transcurridos entre la medición de las variables explicativas y la observación de la variable objetivo, presenta cierta heterogeneidad en su frecuencia. Aunque el rango total de valores se extiende aproximadamente entre 0 y 34 años, algunos intervalos temporales aparecen representados por un número muy reducido de observaciones.

Esta escasez de datos en determinados valores de periodo puede introducir inestabilidad en el entrenamiento de los modelos, al forzar al algoritmo a aprender patrones a partir de muestras poco representativas. Para mitigar este efecto y mejorar la robustez de las predicciones, se optó por agrupar ciertos valores de periodo en categorías temporales más amplias, dando lugar a una nueva variable denominada periodo_agrupado.

El procedimiento de agrupación se diseñó de forma conservadora, manteniendo sin modificar aquellos valores con suficiente soporte muestral y agrupando únicamente los intervalos más escasos. En concreto, los valores inferiores a 6 años se agruparon en la categoría 5; los periodos entre 7 y 10 años se agruparon en 10; los comprendidos entre 18 y 21 años se agruparon en 20; y los valores iguales o superiores a 29 años se agruparon en 30. El resto de valores intermedios se mantuvieron sin modificación.

Cabe destacar que la variable periodo_agrupado no conserva la granularidad completa de la variable original, pero sí retiene su significado temporal esencial. Los experimentos realizados muestran que esta representación resulta más estable desde el punto de vista estadístico y conduce a modelos con un comportamiento predictivo más robusto, al reducir la sensibilidad a intervalos temporales con baja frecuencia de observaciones.

5.5. Partición y validación

Para obtener una estimación imparcial del rendimiento y evitar *fugas de información* derivadas de la estructura jerárquica de los datos, el proceso de entrenamiento se organiza en dos niveles: (i) una partición externa *hold-out* para la evaluación final y (ii) una validación cruzada interna para la selección de hiperparámetros.

Partición entrenamiento/test. Los datos, ya filtrados, se separan en un 80 % para entrenamiento y un 20 % para test. Dicha separación se hace de forma que todas las observaciones asociadas a una misma parcela queden asignadas íntegramente a uno de los subconjuntos.

Validación cruzada para selección de hiperparámetros. La selección de hiperparámetros se lleva a cabo exclusivamente sobre el conjunto de entrenamiento mediante GridSearchCV con métrica de optimización R^2 . Se utiliza GroupKFold con $k = 5$ pliegues, imponiendo que no exista solape de parcelas entre pliegues (esto es, la agrupación se respeta tanto en el *hold-out* como en la validación interna).

Métricas de evaluación. En este estudio se emplea un conjunto de métricas complementarias para evaluar el rendimiento desde distintas perspectivas (precisión, sesgo, ajuste relativo). En las siguientes expresiones, y_i denota el valor observado, $\hat{y}_i$ el valor predicho, $\bar{y}$ la media de los valores observados y n el número de observaciones:

- **RMSE (Root Mean Squared Error):** raíz del error cuadrático medio. Mide la magnitud promedio de los errores penalizando fuertemente las grandes desviaciones. Se expresa en las mismas unidades que la

variable objetivo.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (5.1)$$

- **RMSE Porcentual (RMSE %):** expresa el RMSE como porcentaje respecto a la media de los valores observados. Facilita la interpretación relativa del error independientemente de la escala.

$$\text{RMSE}_{\%} = \frac{\text{RMSE}}{\bar{y}} \times 100 \quad (5.2)$$

- **R^2 (Coeficiente de determinación):** proporción de la varianza total de la variable objetivo que es explicada por el modelo. Valores cercanos a 1 indican un alto poder explicativo.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (5.3)$$

- **MAE (Mean Absolute Error):** media aritmética de las diferencias absolutas entre predicciones y observaciones. Es una métrica de error lineal, más robusta frente a valores atípicos que el RMSE y de fácil interpretación directa.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5.4)$$

- **MAPE (Mean Absolute Percentage Error):** promedio del error absoluto relativo al valor real, expresado en porcentaje. Permite evaluar la calidad de la predicción en términos relativos.

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \quad (5.5)$$

- **wMAPE (Weighted Mean Absolute Percentage Error):** variante ponderada del MAPE donde el error se normaliza por el volumen total de la variable real. Evita problemas de inestabilidad cuando los valores observados son cercanos a cero.

$$\text{wMAPE} = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{\sum_{i=1}^n |y_i|} \times 100 \quad (5.6)$$

- **SMAPE (Symmetric Mean Absolute Percentage Error):** error porcentual simétrico que normaliza la discrepancia por la magnitud media de los valores observados y predichos. Reduce la asimetría del MAPE y está acotado.

$$\text{SMAPE} = \frac{100}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2} \quad (5.7)$$

- **MedAE (Median Absolute Error):** mediana de los errores absolutos. Proporciona una medida de error robusta y resistente a la presencia de valores atípicos (*outliers*).

$$\text{MedAE} = \text{mediana}(|y_1 - \hat{y}_1|, \dots, |y_n - \hat{y}_n|) \quad (5.8)$$

- **Bias (Sesgo Medio):** evalúa la tendencia sistemática del modelo a sobreestimar (valor positivo) o subestimar (valor negativo) las observaciones reales.

$$\text{Bias} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i) \quad (5.9)$$

5.5.1. Codificación y normalización

Con el fin de garantizar coherencia metodológica y evitar fugas de información durante la validación cruzada, todas las etapas de preprocesado se integran explícitamente dentro de un Pipeline junto con el modelo de regresión. De este modo, los parámetros asociados al preprocesado se estiman *exclusivamente* a partir de los datos de entrenamiento de cada pliegue, y se aplican posteriormente a los datos de validación o test.

Las variables se tratan de acuerdo con su naturaleza:

- **Variables numéricas continuas:** se imputan mediante la mediana para reducir la influencia de valores extremos y, posteriormente, se estandarizan mediante normalización *z-score* (media cero y desviación estándar unitaria). Este paso resulta especialmente relevante para modelos sensibles a la escala de las variables, como regresiones lineales, SVR o redes neuronales.
- **Variables estructurales de densidad** (*npies_**): al representar recuentos por clase diamétrica, se imputan con valor cero cuando están ausentes y se estandarizan de forma análoga a las variables numéricas, preservando su contribución relativa en el modelo.
- **Variables categóricas:** se imputan mediante la moda, se convierten explícitamente a tipo cadena y se codifican mediante *one-hot encoding*. Se utiliza la opción `handle_unknown='ignore'` para garantizar la robustez del modelo frente a categorías no observadas durante el entrenamiento.

Esta estrategia asegura que la codificación, imputación y escalado de las variables se realicen de forma consistente en todos los modelos evaluados y que el rendimiento estimado refleje fielmente la capacidad de generalización del sistema, sin introducir sesgos derivados del acceso indebido a información del conjunto de evaluación.

5.6. Selección de variables explicativas

La selección de predictores se abordó mediante tres estrategias complementarias: (1) selección automática mediante *Featurewiz*, (2) selección basada en el criterio de mínima redundancia y máxima relevancia (*mRMR*) y (3) selección manual basada en criterios estadísticos y conceptuales.

5.6.1. Selección automática mediante *Featurewiz*

El algoritmo *Featurewiz* aplica un enfoque híbrido orientado a la relevancia predictiva. Primero ejecuta un filtrado por correlación, eliminando predictores altamente colineales (umbral $|r| > 0,70$), y posteriormente refina el conjunto mediante modelos de *Gradient Boosting* para estimar la importancia relativa de cada variable. El resultado es un

subconjunto compacto de predictores con contribución significativa al rendimiento del modelo.

5.6.2. Selección mediante *mRMR*

El método *mRMR* (minimum Redundancy–maximum Relevance) selecciona las variables que mejor explican la variabilidad del objetivo a la vez que minimizan la redundancia informativa entre ellas. Para ello emplea información mutua, permitiendo capturar relaciones potencialmente no lineales. Este enfoque prioriza predictores que aportan información complementaria sobre el proceso ecológico modelado, evitando duplicidades entre atributos altamente correlacionados.

5.6.3. Selección manual basada en criterios estadísticos y conceptuales

La selección manual integró criterios estadísticos (correlaciones, ANOVA y análisis de redundancia) con criterios ecológicos y de interpretabilidad. Se descartaron predictores sin asociación significativa con la variable objetivo y se redujo la colinealidad reteniendo un único representante por cada grupo altamente correlacionado. Asimismo, se garantizaron variables que describieran dimensiones esenciales del sistema (estructura del arbolado, topografía, suelo, clima e índices espectrales), asegurando un equilibrio entre precisión predictiva y coherencia biogeográfica.

5.6.4. Selección Secuencial Supervisada basada en Rendimiento Predictivo (SSSRP)

El método SSSRP complementó las estrategias anteriores mediante un enfoque explícitamente orientado al rendimiento predictivo. Se partió de un *bloque base* de variables estructurales y se evaluó el impacto marginal de cada candidato añadiéndolo individualmente y comparando el cambio en R^2 y RMSE mediante un modelo CatBoost con validación holdout estratificada por parcela. A continuación, se aplicó una estrategia de *forward selection* codiciosa, incorporando en cada iteración la variable que proporcionaba la mayor mejora y deteniendo el proceso cuando la ganancia resultaba inferior a un umbral predefinido ($\Delta R^2 > 10^{-5}$). Este procedimiento produjo un conjunto final de predictores reducido, no redundante y específicamente optimizado para maximizar el rendimiento del modelo.

5.7. Modelos evaluados

A continuación se describe el procedimiento seguido para la selección, optimización y combinación de modelos. El objetivo es construir un conjunto de predictores base sólidos y posteriormente integrarlos en un *stack-ensemble* capaz de mejorar la capacidad de generalización.

5.7.1. Modelos ensemble

Se utilizaron diversos métodos de *ensemble learning* con el fin de aumentar la precisión y robustez del sistema predictivo. El principio fundamental consiste en combinar predicciones de múltiples modelos, aprovechando su diversidad para reducir varianza, sesgo o ambos.

Técnicas empleadas:

- **Bagging:** entrena modelos independientes sobre subconjuntos generados mediante muestreo bootstrap. Reduce varianza y mejora estabilidad.
- **Boosting:** construye modelos secuenciales donde cada uno corrige los errores del anterior. Tiende a reducir el sesgo y producir modelos altamente precisos.
- **Stacking:** integra múltiples modelos base mediante un meta-modelo entrenado sobre sus predicciones. Permite capturar relaciones no lineales entre las salidas de los modelos base.

5.7.2. Boosting y aprendizaje secuencial

El conjunto de modelos de boosting evaluados incluye:

- **XGBoost:** implementación avanzada del *gradient boosting*, que incorpora regularización L1/L2, optimización mediante segundo orden y manejo interno de valores faltantes.
- **LightGBM:** algoritmo especialmente eficiente, basado en crecimiento *leaf-wise*, capaz de manejar grandes volúmenes de datos y con soporte nativo para variables categóricas.
- **CatBoost:** optimizado para variables categóricas y robusto frente a ruido mediante técnicas como *ordered boosting*.
- **Gradient Boosting Decision Trees (GBDT):** implementación clásica del algoritmo basado en descenso por gradiente sobre residuos.
- **AdaBoost:** técnica que ajusta modelos simples (stumps) secuencialmente, asignando más peso a observaciones difíciles.

5.7.3. Bagging

Los modelos basados en bootstrap empleados fueron:

- **Random Forest:** conjunto de árboles de decisión que introduce aleatoriedad tanto en datos como en características. Suele ser robusto y relativamente estable.
- **Bagged Decision Trees (BaggedDT):** árboles no podados entrenados sobre muestras bootstrap, cuyas predicciones se promedian para reducir varianza.

5.7.4. Otros modelos evaluados

Además de los métodos ensemble, se evaluaron modelos representativos de paradigmas adicionales:

- **Support Vector Regression (SVR):** modelo de márgenes para regresión, evaluado con kernel lineal.
- **K-Nearest Neighbors (KNN):** modelo basado en vecinos más próximos; útil como referencia no paramétrica, aunque sensible a la escala.
- **Multi-Layer Perceptron (MLP):** red neuronal densa capaz de capturar relaciones no lineales.
- **Bayesian Neural Network (BayesianNN):** aproximación probabilística que permite cuantificar incertidumbre a través de regularización bayesiana.

5.7.5. Configuración del stacking

Tras evaluar todos los modelos anteriores, se construyeron diferentes configuraciones de modelos base (*base learners*) que se combinan mediante un meta-modelo. Estas combinaciones se diseñaron con dos criterios principales:

1. **Diversidad estructural:** mezclar métodos de boosting y bagging, así como variantes de boosting con distintas estrategias de crecimiento y regularización.
2. **Rendimiento individual:** incluir preferentemente los modelos con mayor R^2 y menor error (RMSE, MAE) en las pruebas individuales.

Los meta-modelos utilizados para integrar las predicciones fueron:

- **Modelos lineales:** Regresión Lineal, Ridge.
- **Modelos basados en árboles:** Random Forest, Gradient Boosting Regressor.
- **Modelos kernel:** SVR lineal.
- **Red neuronal:** MLP con una capa oculta.

Esta selección permite comparar desde combinadores lineales simples hasta integradores no lineales capaces de capturar interacciones complejas entre predicciones.

5.7.6. Comparación y justificación de modelos

La evaluación exhaustiva de múltiples algoritmos permite identificar no solo el modelo individual con mejor rendimiento, sino también combinaciones sinérgicas para el *stacking*. La Tabla 5.3 resume los modelos finalmente entrenados y evaluados.

6. Implementación del pipeline

El desarrollo y la evaluación de los modelos predictivos se realizaron íntegramente en **Python**, utilizando librerías como *scikit-learn*, *cuML* y *PyTorch*, junto con implementaciones específicas de *gradient boosting* como *XGBoost*, *LightGBM* y *CatBoost*. El proceso de entrenamiento se llevó a cabo en dos fases diferenciadas.

Para los modelos entrenados exclusivamente con datos del IFN3 se utilizó un equipo local equipado con un procesador Intel Core i7 y 32 GB de memoria RAM. En cambio, los modelos que empleaban conjuntamente datos del IFN2 e IFN3 se entrenaron en el sistema de computación de alto rendimiento (HPC) de la Universidad de Salamanca. Esta elección se debió a la disponibilidad de tarjetas gráficas Nvidia H100, que permiten acelerar de forma significativa el entrenamiento de aquellos modelos compatibles con ejecución en GPU gracias a su elevada capacidad de paralelización.

No obstante, cabe señalar que el entrenamiento también podría haberse realizado en un equipo de escritorio convencional equipado con una tarjeta gráfica comercial, ya que los requisitos computacionales del problema no son especialmente elevados.

Modelo	Tipo	Características	Observaciones
Random Forest	Bagging	Bootstrap con selección aleatoria de atributos	Robusto y estable
BaggedDT	Bagging	Árboles sin poda sobre muestras bootstrap	Mejora por agregación
XGBoost	Boosting	Regularización L1/L2, segundo orden	Muy preciso; sensible a tuning
LightGBM	Boosting	Crecimiento leaf-wise, muy eficiente	Rápido; riesgo de sobreajuste
CatBoost	Boosting	Codificación ordenada; robusto al ruido	Excelente sin gran tuning
GBDT	Boosting	Árboles secuenciales ajustados a residuos	Buen rendimiento
AdaBoost	Boosting	Aumenta peso de obs. mal predichas	Menos robusto
KNN	Instancia	Predicción por proximidad	Sensible a escala y ruido
MLP	Red neuronal	Captura relaciones no lineales	Requiere normalización
SVR	Márgenes	Kernel lineal, gran margen	Robusto al sobreajuste
BayesianNN	Probabilístico	Cuantifica incertidumbre	Reduce sobreajuste

Tabla 5.3

Resumen de los modelos de aprendizaje supervisado evaluados.

6.1. Ingeniería práctica del entrenamiento y la validación

Desde el punto de vista de la implementación, el proceso de entrenamiento y validación se apoyó fundamentalmente en el ecosistema de `scikit-learn`, complementado con librerías especializadas para modelos de *gradient boosting*. La gestión de los datos se realizó mediante `pandas` y `numpy`, mientras que el cálculo de métricas y estadísticas adicionales del error se apoyó en `scipy` y los módulos de evaluación de `sklearn.metrics`.

A partir del conjunto de datos original, se aplicaron filtros de calidad sobre la variable objetivo utilizando operaciones vectorizadas de `pandas`, eliminando observaciones con valores nulos, inconsistentes o que no cumplieran los criterios definidos en la Sección 5.4.1.

La partición de los datos en conjuntos de entrenamiento y prueba se realizó mediante `GroupShuffleSplit` del módulo `sklearn.model_selection`, con una proporción 80/20. Este esquema garantizó que todas las observaciones asociadas a una misma parcela se asignaran íntegramente a un único subconjunto, evitando fugas de información derivadas de la correlación espacial intra-parcela. Sobre el conjunto de entrenamiento se definió una validación cruzada de cinco pliegues utilizando `GroupKFold`.

El preprocesado de las variables y el ajuste de los modelos se integraron en un único objeto `Pipeline`, combinando `ColumnTransformer`, `SimpleImputer`, `StandardScaler` y `OneHotEncoder`. Esta integración aseguró que todas las transformaciones se estimaran exclusivamente con los datos de entrenamiento de cada pliegue durante la validación cruzada. El ajuste de hiperparámetros se llevó a cabo mediante `GridSearchCV`, definiendo rejillas específicas para cada algoritmo y utilizando el coeficiente de determinación (R^2) como métrica de selección.

Los modelos evaluados incluyen implementaciones de *gradient boosting* (`XGBoost`, `LightGBM`, `CatBoost` y `GradientBoostingRegressor`), métodos basados en *bagging*

(`RandomForestRegressor`, `BaggingRegressor`), así como modelos de distinta naturaleza como `MLPRegressor`, `KNeighborsRegressor`, `LinearSVR`, `AdaBoostRegressor` y `BayesianRidge`. Para cada modelo se calcularon de forma sistemática las métricas de rendimiento sobre el conjunto de prueba: R^2 , RMSE y MAE, junto con estadísticas adicionales del error absoluto (mediana y moda), almacenándose los resultados en estructuras tabulares para su análisis comparativo.

6.2. Implementación del *stacking*

La agregación de modelos mediante *stacking* se implementó de forma manual utilizando utilidades básicas de `scikit-learn`, con el objetivo de mantener un control estricto sobre el flujo de entrenamiento y validación. A partir de los mejores modelos individuales se generaron predicciones fuera de pliegue (*out-of-fold*, OOF) sobre el conjunto de entrenamiento, empleando el mismo esquema de validación cruzada (`GroupKFold`).

Estas predicciones OOF se organizaron en matrices de meta-variables mediante `numpy` y se utilizaron como entrada para el entrenamiento de los metamodelos. En paralelo, cada modelo base se reentrenó sobre la totalidad del conjunto de entrenamiento para generar las correspondientes predicciones sobre el conjunto de test, que se emplearon posteriormente para la evaluación final del *stack*.

Los metamodelos considerados incluyen `LinearRegression`, `Ridge`, `GradientBoostingRegressor`, `RandomForestRegressor`, `SVR` con kernel lineal y `MLPRegressor`. Antes de su ajuste, las meta-variables se estandarizaron mediante `StandardScaler`, integrando este paso en un `Pipeline` específico del segundo nivel. La evaluación del *stacking* se realizó exclusivamente sobre el conjunto de test independiente, calculando las métricas habituales (R^2 , RMSE y MAE) para cada combinación de modelos base y metamodelo.

Tabla 6.1

Estadísticos descriptivos del conjunto de datos depurado.

Variable	N	Media	Desv. estándar	Mín.	Máx.
carbono_bruto4	133 119	20.79	35.09	0.00	420.50
carbono_bruto	111 923	12.27	24.80	0.00	359.81
c4	103 790	38.83	47.27	0.48	883.46
c	90 802	23.78	35.15	0.00	842.74
periodo_agrupado	103 785	18.47	6.47	5.00	30.00

6.3. Datos finales de entrenamiento

Tras aplicar los criterios de elegibilidad y filtrado descritos en la Sección ??, el conjunto de datos final utilizado para el ajuste de los modelos queda compuesto por:

- **IFN2:** Total de parcelas = **88.696**
 - Casos con $c4 > c$: **31.428**
 - Casos con $\text{carbono_bruto4} > \text{carbono_bruto}$: **32.403**
- **IFN3:** Total de parcelas = **171.157**
 - Casos con $f_{ccarb} > 20$: **158.434**
 - Casos con $f_{ccarb} > 20$ y $c4 > c$: **57.401**
 - Casos con $f_{ccarb} > 20$ y $\text{carbono_bruto4} > \text{carbono_bruto}$: **76.617**

La Tabla 6.1 resume las principales estadísticas descriptivas de las variables objetivo utilizadas en el modelado.



Se observa que la variable `carbono_bruto4` presenta una media de 20.79 y una desviación estándar de 35.09, mientras que la variable `c4` muestra valores notablemente superiores (media de 38.83 y desviación estándar de 47.27). Podemos encontrar un histograma de la distribución de las variables objetivo en la Figura 6.1.

En la Figura 6.2 podemos ver las distribuciones de las variables objetivo separadas por inventarios, y podemos ver que la variable `c4` es más dispersa y heterogénea que `carbono_bruto4`. En general, una mayor variabilidad en la variable objetivo se traduce en un problema de predicción más complejo, ya que el modelo debe capturar relaciones más inestables y sujetas a mayor ruido.

Por tanto, incluso antes de evaluar los modelos, es razonable esperar que una misma familia de algoritmos obtenga valores de R^2 más elevados y errores más bajos (RMSE, MAE) al predecir `carbono_bruto4`, cuya estructura estadística es menos dispersa, que al predecir `c4`.



6.3.1. Efecto del periodo sobre el carbono

La influencia del *periodo* sobre las variables de carbono se evaluó mediante ANOVA de un factor. Los análisis realizados muestran que el *periodo* ejerce un efecto significativo sobre ambas variables. En `c4` se obtuvo un estadístico $F = 143.49$ ($p < 0,001$), mientras que en `carbono_bruto4` el valor fue $F = 161,08$ ($p < 0,001$). Estos resultados indican que las diferencias observadas entre periodos no son aleatorias, sino que reflejan variaciones sistemáticas asociadas al momento de muestreo, confirmando que el *periodo* constituye un factor explicativo relevante en la dinámica del carbono forestal.

(a) Histograma de la variable `c4` en escala logarítmica.(b) Histograma de la variable `carbono_bruto4` en escala logarítmica.**Figura 6.1:** Histograma de las variables `c4` y `carbono_bruto4` en el conjunto depurado.

7. Entrenamiento y validación

El proceso de entrenamiento se estructuró en varias fases orientadas a optimizar tanto la selección de variables predictoras como la robustez del modelo final. En primer lugar, se llevó a cabo una etapa de **selección de variables**, en la que se evaluaron distintos subconjuntos de características definidos por bloques temáticos con significado ecológico y funcional. Para esta tarea se adoptó un enfoque sistemático basado en la comparación del desempeño predictivo de las distintas combinaciones mediante el algoritmo CatBoost, seleccionado tras pruebas preliminares que mostraron su alta capacidad de ajuste y estabilidad frente a la heterogeneidad de los datos. En todas las configuraciones se mantuvo constante la variable objetivo (carbono capturado) y los parámetros del modelo, de modo que las variaciones en el coeficiente de determinación (R^2) y el error cuadrático medio (RMSE) reflejaran exclusivamente la contribución informativa de cada bloque. Los resultados de esta fase son preliminares ya que se emplearon entrenamientos más sencillos (sin validación cruzada para la selección de hiperparámetros).

(a) Distribución de la variable c_4 en escala logarítmica.(b) Distribución de la variable carbono_bruto4 en escala logarítmica.**Figura 6.2:** Distribución de las variables c_4 y carbono_bruto4 en el conjunto depurado separadas por inventario.

Las configuraciones analizadas incorporaron progresivamente variables relacionadas con las características de la especie, las propiedades edáficas, el terreno, las condiciones climáticas y los índices de vegetación. A partir de los resultados obtenidos, se identificaron los bloques con mayor aporte marginal al rendimiento del modelo, priorizando aquellos cuya inclusión mejoró consistentemente el R^2 sin aumentar de forma significativa la complejidad o redundancia del conjunto de predictores.

En una segunda fase, se procedió al **entrenamiento comparativo de modelos**, implementando un conjunto de algoritmos de aprendizaje supervisado con el fin de contrastar su capacidad predictiva. Cada modelo fue entrenado bajo las mismas condiciones experimentales, utilizando las configuraciones de variables seleccionadas en la fase anterior. Esta comparación permitió identificar los algoritmos con mejor ajuste global y menor error de predicción, destacando de nuevo el desempeño de CatBoost.

Posteriormente, se implementó una estrategia de **stacking**, combinando las predicciones de los modelos individuales mediante un metamodelo de segundo nivel, con el objetivo de aprovechar la complementariedad entre los distintos enfoques y mejorar la capacidad de generalización.

7.1. Elección de variables

7.1.1. Resultados de la selección de variables manual

La selección manual de variables partió de una organización temática del conjunto de predictores, agrupando las variables según el tipo de información ecológica, estructural o climática que representan. Esta clasificación permitió estructurar el proceso de reducción dimensional en torno a los siguientes bloques conceptuales:

- **Bloque de variables fijas:** describe la estructura básica de la masa forestal y los atributos esenciales de identificación y caracterización general de cada parcela.
- **Bloque de variables de especie:** recoge información relativa a la composición, estado y características específicas de las formaciones forestales.
- **Bloque sustrato:** integra variables edáficas y de manejo susceptibles de variar en el tiempo.
- **Bloque de terreno:** agrupa propiedades físicas del medio que permanecen estables a escala temporal de inventarios (pendiente, orientación, tipo de suelo, etc.).
- **Bloque climático resumido:** representado por el índice de aridez de Martonne, que sintetiza la interacción entre temperatura y precipitación.
- **Bloque climático detallado:** incluye métricas estacionales explícitas de temperatura y precipitación.
- **Bloque de índices de vegetación:** recoge información espectral relacionada con el estado hídrico, vigor y actividad fotosintética de la vegetación.

En total, la base de datos contenía inicialmente 445 variables candidatas distribuidas entre estos bloques temáticos. Tras aplicar el procedimiento de selección manual, apoyado en criterios estadísticos, ecológicos y en la comparación del rendimiento del modelo, el conjunto se redujo a 44 variables representativas. Las variables finalmente seleccionadas dentro de cada bloque fueron las siguientes:

- **Bloque de variables fijas:** `especie_id`, `tipo_especie`, `grupo_id`, `periodo`, `radio`, `ocupa`, `npies_1`, `npies_2`, `npies_5`, `npies_10`, `npies_15`, `npies_20`, `npies_25`, `npies_30`, `npies_35`, `npies_40`, `npies_45`, `npies_50`, `npies_55`, `npies_60`, `npies_65`, `npies_70`.
- **Bloque de variables de especie:** `estado_id`, `fccarb`, `disesp_id`.
- **Bloque sustrato (dinámico):** `modcomb_id`, `nivel2_id`, `tratmasa_id`.
- **Bloque de terreno:** `rocosidad_id`, `orientacion_cat`, `elevacion`, `pendiente_cat`.
- **Bloque climático resumido (Martonne):** `martonneidx_id`.

- **Bloque climático detallado (temperatura y precipitación):** skt_mean_primavera, skt_mean_verano, skt_std_primavera, skt_std_verano, pr_sum_invierno, pr_sum_otoño, pr_sum_primavera, pr_sum_verano.
- **Bloque de índices de vegetación:** gndvi_mean_verano, ndii_mean_primavera, gndvi_std_primavera, evi_mean_primavera.

Este proceso permitió sintetizar la información original manteniendo una representación equilibrada de todos los ámbitos ecológicos implicados en la estimación del carbono.

La comparación de modelos entrenados con combinaciones incrementales de bloques mostró que todos ellos aportan información relevante, siguiendo el orden de contribución aproximado: *variables fijas* > *variables de especie* > *sustrato* > *terreno* > *índices de vegetación* > *Martonne* > *temperatura y precipitación*. Es decir, la mayor parte de la capacidad predictiva se explica por la estructura y composición de la masa forestal, mientras que las condiciones edáficas, topográficas y climáticas actúan como moduladores adicionales de la acumulación de carbono.

7.1.2. Selección de variables mediante Featurewiz

Aplicado al conjunto completo de predictores, *Featurewiz* seleccionó **67 variables**. El patrón resultante muestra una clara preferencia por dos grandes grupos: (i) **índices de vegetación** derivados de Sentinel-2 y (ii) **variables térmicas estacionales**. El algoritmo retuvo numerosas estadísticas de NDII, EVI, GNDVI y NDVI (medias, máximos, mínimos, medianas y desviaciones estándar), especialmente durante primavera y verano, reflejando la relevancia del estado hídrico y el vigor fotosintético en la estimación del carbono.

Asimismo, se seleccionaron múltiples métricas de temperatura del aire y del suelo (t2m_*, skt_*, stl_*) y diversas variables de precipitación (pr_sum_*, pr_max_*, pr_min_*), lo que muestra sensibilidad del método a las condiciones climáticas estacionales. El índice de aridez de Martonne también fue seleccionado, aportando una medida sintetizada del balance térmico-hídrico.

Finalmente, el algoritmo incluyó un conjunto contenido pero representativo de variables estructurales (número de pies por clase diamétrica), de especie y de terreno, indicando que dichas variables aportan información complementaria necesaria para la predicción.

7.1.3. Selección de variables mediante mRMR

El método *mRMR* seleccionó un total de **50 variables**, priorizando aquellas con alta información mutua respecto al carbono y baja redundancia entre sí. El conjunto final integra predictores estructurales (identificación de especie, radio, clases diamétricas, orientación y pendiente), variables topográficas y edáficas (rocosidad, tipos de suelo), métricas climáticas estacionales (temperatura del aire y del suelo, índice de Martonne) e índices de vegetación representativos del estado estacional de la copa.

La presencia sistemática de valores medios, máximos y medianos de NDII, GNDVI y EVI en verano y primavera confirma que la actividad fotosintética y el estado hídrico

Tabla 7.1

Comparación de configuraciones de selección de variables y rendimiento del modelo CatBoost sobre los datos del IFN 2-3 y 4 para predecir c4.

Configuración	Modelo	n_{vars}	R^2	RMSE	MAE	Moda error (aprox.)
Manual	CatBoost	44	0.80	21.77	11.48	1
mRMR	CatBoost	67	0.79	21.91	11.69	1
FeatureWiz	CatBoost	50	0.72	25.65	13.08	2

Tabla 7.2

Configuraciones de modelos base para *stacking*.

Config.	Modelos base
1	LightGBM, Random Forest
2	CatBoost, Random Forest, GBDT
3	LightGBM, XGBoost, GBDT
4	CatBoost, LightGBM, Random Forest, GBDT
5	CatBoost, LightGBM, XGBoost, Random Forest, GBDT, BaggedDT

son predictores directos del carbono almacenado. De igual modo, la selección de múltiples métricas térmicas refleja la relevancia de los pulsos climáticos sobre la productividad forestal.

En conjunto, mRMR produjo un conjunto compacto y equilibrado, asegurando diversidad informativa y evitando redundancias, lo que lo convierte en un complemento eficaz a los métodos anteriores.

7.1.4. Discusión de la selección de variables

De los tres conjuntos de variables seleccionados se mantuvo la selección manual al demostrar un mejor rendimiento con mayor simplicidad como se aprecia en la tabla 7.1.

TODO: Esto igual debería ir en resultados?

7.2. Ensamblado tipo *stacking* de modelos de regresión

Con el objetivo de estudiar el compromiso entre diversidad del ensamble, coste computacional y rendimiento, se definieron cinco configuraciones de modelos base (Tabla 7.2). Los modelos AdaBoost, BayesianNN, SVR, MLP y KNN se descartaron como candidatos.

- **Configuración 1:** es la configuración más simple. LightGBM compite con CatBoost en rendimiento, mientras que Random Forest aporta un sesgo diferente al basarse en bagging en lugar de boosting. Esta configuración sirve como referencia de un ensamble muy ligero, con bajo coste computacional y, al mismo tiempo, razonablemente diverso.
- **Configuración 2:** combina un modelo de boosting basado en manejo robusto de variables categóricas (CatBoost) con Random Forest (bagging de árboles) y GBDT (boosting clásico). La idea es mezclar enfoques de bagging y boosting, manteniendo un número moderado de modelos y una buena diversidad estructural.
- **Configuración 3:** agrupa únicamente modelos de la familia de *gradient boosting*. El objetivo es analizar el efecto de combinar variantes de un mismo paradigma

Tabla 7.3

Meta-modelos utilizados en el *stacking* junto con sus parámetros.

Meta-modelo	Parámetros
Gradient Boosting	Configuración por defecto
Regresión Lineal	Sin regularización
Ridge	Regularización L2 con validación cruzada ($\alpha \in \{0.01, 0.1, 1, 10, 100\}$)
Random Forest	50 árboles
SVR	Kernel lineal
MLP	Una capa oculta con 50 neuronas, 500 iteraciones máximas

y evaluar hasta qué punto diferentes implementaciones de boosting proporcionan suficiente diversidad como para ser beneficiosa en un ensamble.

- **Configuración 4:** reduce el número de modelos en comparación con la configuración siguiente (que incluye todos los modelos competitivos), eliminando XGBoost y BaggedDT, que aportan menos mejora marginal respecto a sus alternativas (LightGBM y Random Forest). Esta combinación mantiene una buena diversidad con menor complejidad y coste computacional.
- **Configuración 5:** incluye todos los modelos con rendimiento competitivo. Esta configuración es la más rica en términos de variedad de arquitecturas, aunque también la más costosa computacionalmente y potencialmente más propensa al sobreajuste si no se controla adecuadamente.

El objetivo es que el meta-modelo reciba como entradas predicciones de alta calidad y suficientemente diversas, en lugar de introducir ruido procedente de modelos débiles.

Sobre las predicciones apiladas de cada configuración se entrenan distintos meta-modelos $g(\cdot)$, definidos en la Tabla 7.3.

Estos meta-modelos representan diferentes formas de combinar las predicciones de los modelos base:

- **Modelos lineales** (Regresión Lineal y Ridge): permiten comprobar si una combinación lineal de las predicciones base es suficiente para mejorar el rendimiento. Ridge añade regularización L2 para controlar el sobreajuste.
- **Modelos no lineales basados en árboles** (Gradient-BoostingRegressor, RandomForestRegressor): pueden capturar interacciones complejas entre las predicciones de los modelos base, a costa de una mayor complejidad.
- **Modelos de kernel** (SVR con kernel lineal): permiten una combinación robusta y, en algunos casos, menos sensible a valores extremos en las predicciones.
- **Red neuronal (MLPRegressor):** introduce una capa adicional de flexibilidad, capaz de aproximar combinaciones no lineales complejas entre las salidas de los modelos base.

Al evaluar todas las combinaciones de `stack_configs` con los diferentes `meta_models`, se obtiene un conjunto de

ensambles apilados que permiten estudiar de forma sistemática: (i) qué subconjuntos de modelos base son más complementarios, y (ii) qué tipo de meta-modelo aprovecha mejor la información contenida en sus predicciones.

8. Resultados

A continuación expondremos los resultados obtenidos a partir de varias métricas de evaluación de los modelos sobre el conjunto de datos de test. Dividiremos la sección según el origen de los datos de entrenamiento (IFN2, IFN3 o IFN2 e IFN3) y según la variable a predecir (toneladas de carbono o toneladas de carbono por hectárea).

8.1. Resultados IFN2

8.1.1. Toneladas de carbono por hectárea

Modelos base

Una vez entrenados los modelos, algunos parámetros globales como el R^2 , RMSE y MAE se presentan en la Tabla 8.1.

Modelos con stacking

En la Tabla 8.2 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN2 como explicativo.

8.1.2. Toneladas de carbono

Modelos base

En la Tabla 8.3 se muestra el resumen del rendimiento de los modelos para la predicción de la variable de carbono en toneladas (carbono_bruto4) con el conjunto de datos que emplea IFN2 como explicativo.

Modelos con stacking

En la Tabla 8.4 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en toneladas (carbono_bruto4) con el conjunto de datos que emplea IFN2 como explicativo.

8.2. Resultados IFN3

8.2.1. Toneladas de carbono por hectárea

Modelos base

Una vez entrenados los modelos, algunos parámetros globales como el R^2 , RMSE y MAE se presentan en la Tabla 8.5.

Modelos con stacking

En la Tabla 8.6 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN3 como explicativo.

Tabla 8.1
Comparativa Modelos Base en IFN2 (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
LightGBM_{global}	0.719	26.806	14.689	35.364	47.104	-0.021
LightGBM	0.712	26.435	14.755	35.823	47.593	-0.401
CatBoost _{global}	0.708	27.359	14.832	35.710	47.895	-0.135
XGBoost _{global}	0.708	27.361	14.620	35.198	46.910	-0.171
GBDT _{global}	0.705	27.504	14.772	35.564	46.941	-0.142
XGBoost	0.704	26.779	14.773	35.867	47.452	-0.434
CatBoost	0.701	26.927	15.066	36.578	49.284	-0.753
MLP _{global}	0.686	28.335	15.668	37.722	50.547	0.280
BaggedDT	0.676	28.036	15.683	38.075	49.869	-0.195
GBDT	0.673	28.161	15.614	37.907	50.513	-0.699
RandomForest	0.663	28.595	15.807	38.378	49.750	-0.376
BaggedDT _{global}	0.658	29.574	15.933	38.361	50.974	-0.599
RandomForest _{global}	0.653	29.803	15.577	37.502	48.386	-1.499
MLP	0.637	29.650	15.543	37.735	49.907	-7.176
BayesianNN	0.606	30.904	17.384	42.205	56.359	-0.697
BayesianNN _{global}	0.588	32.482	17.725	42.675	56.630	-0.732
KNN	0.565	32.480	17.610	42.755	54.696	-5.373
SVR _{global}	0.465	37.013	16.674	40.145	49.745	-8.320
SVR	0.445	36.667	17.361	42.150	52.112	-8.338
AdaBoost	-2.126	87.062	81.700	198.354	118.313	78.210

8.2.2. Toneladas de carbono Modelos base

En la Tabla 8.7 se muestra el resumen del rendimiento de los modelos para la predicción de la variable de carbono en toneladas (carbono_bruto4) con el conjunto de datos que emplea IFN3 como explicativo.

Modelos con stacking

En la Tabla 8.8 se muestra el resumen del rendimiento de los modelos con stacking para la predicción de la variable de carbono en toneladas (carbono_bruto4) con el conjunto de datos que emplea IFN3 como explicativo.

8.3. Resultados IFN2 e IFN3

8.3.1. Toneladas de carbono por hectárea

Modelos base

Una vez entrenados los modelos, algunos parámetros globales como el R^2 , RMSE y MAE se presentan en la Tabla 8.9

Modelos con stacking

En la Tabla 8.10 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN2 e IFN3 como explicativos.

8.3.2. Toneladas de carbono

Modelos base

En la Tabla 8.11 se muestra el resumen del rendimiento de los modelos para la predicción de la variable de carbono

en toneladas con el conjunto de datos que emplea el IFN2 e IFN3 como explicativos.

Modelos con stacking

En la Tabla 8.12 se muestra el resumen del rendimiento de los modelos con stacking para la predicción de la variable de carbono en toneladas con el conjunto de datos que emplea el IFN2 e IFN3 como explicativos.

Tabla 8.2

Comparativa Modelos Stacking en IFN2 (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
Stack5 GradientBoosting	0.724	25.889	14.531	35.280	47.157	-0.579
Stack1 MLP _{global}	0.722	26.683	14.582	35.106	46.515	0.117
Stack2 MLP _{global}	0.721	26.726	14.475	34.848	46.320	-0.131
Stack5 MLP _{global}	0.721	26.742	14.502	34.913	46.347	0.077
Stack3 GradientBoosting	0.720	26.054	14.847	36.045	48.023	-0.747
Stack1 LinearRegression _{global}	0.719	26.827	14.609	35.173	46.712	-0.140
Stack1 Ridge _{global}	0.719	26.829	14.609	35.172	46.709	-0.142
Stack5 MLP	0.718	26.127	14.452	35.088	46.430	-0.607
Stack4 MLP _{global}	0.718	26.852	14.479	34.859	46.260	-0.328
Stack2 LinearRegression _{global}	0.718	26.877	14.505	34.922	46.440	-0.112
Stack2 Ridge _{global}	0.718	26.883	14.507	34.927	46.440	-0.114
Stack4 MLP	0.717	26.177	14.550	35.326	46.579	-0.495
Stack5 LinearRegression _{global}	0.717	26.905	14.552	35.034	46.852	-0.053
Stack5 Ridge _{global}	0.717	26.910	14.547	35.022	46.818	-0.064
Stack4 LinearRegression _{global}	0.717	26.912	14.590	35.127	46.948	-0.056
Stack4 Ridge _{global}	0.717	26.913	14.584	35.112	46.912	-0.066
Stack5 LinearRegression	0.716	26.247	14.600	35.445	47.345	-0.545
Stack5 Ridge	0.716	26.247	14.599	35.445	47.344	-0.545
Stack1 MLP	0.716	26.257	14.669	35.614	47.371	-0.555
Stack4 LinearRegression	0.715	26.271	14.621	35.498	47.385	-0.553
Stack4 Ridge	0.715	26.271	14.621	35.498	47.385	-0.553
Stack2 GradientBoosting _{global}	0.715	27.001	14.536	34.996	46.544	-0.181
Stack1 Ridge	0.714	26.339	14.689	35.663	47.140	-0.500
Stack1 LinearRegression	0.714	26.339	14.689	35.663	47.140	-0.500
Stack4 GradientBoosting	0.713	26.383	14.607	35.464	47.377	-0.674
Stack2 MLP	0.712	26.401	14.587	35.414	46.924	-0.528
Stack3 LinearRegression _{global}	0.712	27.155	14.647	35.265	47.109	-0.126
Stack3 Ridge _{global}	0.712	27.157	14.640	35.248	47.066	-0.138
Stack2 LinearRegression	0.712	26.429	14.632	35.523	47.316	-0.535
Stack2 Ridge	0.712	26.429	14.632	35.523	47.316	-0.535
Stack3 MLP _{global}	0.711	27.212	14.529	34.979	46.365	-0.705
Stack2 SVR _{global}	0.711	27.212	14.225	34.247	45.732	-2.514
Stack4 SVR _{global}	0.711	27.225	14.249	34.305	46.002	-2.559
Stack5 SVR _{global}	0.710	27.237	14.218	34.232	45.909	-2.549
Stack1 SVR _{global}	0.710	27.240	14.307	34.445	45.502	-2.747
Stack3 MLP	0.709	26.544	14.875	36.114	47.914	-0.401
Stack5 SVR	0.709	26.550	14.241	34.575	47.201	-4.012
Stack5 RandomForest	0.708	26.594	15.177	36.847	48.063	0.095
Stack4 SVR	0.708	26.599	14.320	34.766	47.387	-4.112
Stack3 SVR _{global}	0.706	27.453	14.305	34.441	46.147	-2.626
Stack1 SVR	0.705	26.729	14.400	34.961	46.958	-3.988
Stack2 SVR	0.704	26.784	14.279	34.667	47.082	-4.027
Stack3 LinearRegression	0.703	26.832	14.942	36.276	48.431	-0.664
Stack3 Ridge	0.703	26.832	14.942	36.276	48.431	-0.664
Stack4 RandomForest	0.702	26.897	15.442	37.490	48.861	-0.050
Stack5 GradientBoosting _{global}	0.701	27.690	14.571	35.081	46.490	-0.240
Stack1 GradientBoosting _{global}	0.699	27.740	14.641	35.250	46.608	-0.367
Stack3 GradientBoosting _{global}	0.699	27.770	14.642	35.253	46.471	-0.282
Stack3 SVR	0.696	27.146	14.613	35.477	48.257	-4.409
Stack1 GradientBoosting	0.695	27.176	14.815	35.967	47.547	-0.476
Stack4 GradientBoosting _{global}	0.693	28.026	14.640	35.247	46.441	-0.166
Stack2 RandomForest _{global}	0.690	28.187	15.317	36.876	47.788	0.139
Stack2 GradientBoosting	0.690	27.429	14.710	35.714	47.413	-0.599
Stack2 RandomForest	0.688	27.488	15.562	37.782	48.807	-0.134
Stack3 RandomForest	0.685	27.622	15.914	38.636	49.763	-0.395
Stack1 RandomForest _{global}	0.681	28.578	15.738	37.891	48.764	-0.085
Stack5 RandomForest _{global}	0.679	28.674	15.225	36.656	47.660	0.534
Stack4 RandomForest _{global}	0.673	28.956	15.339	36.929	47.706	0.394
Stack1 RandomForest	0.672	28.193	16.193	39.314	50.293	-0.396
Stack3 RandomForest _{global}	0.667	29.218	15.575	37.499	48.075	0.408

Tabla 8.3

Comparativa Modelos Base en IFN2 (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
CatBoost_{global}	0.765	18.533	10.402	35.470	69.561	-0.342
LightGBM _{global}	0.762	18.627	10.417	35.522	69.531	-0.313
XGBoost _{global}	0.762	18.644	10.428	35.559	69.353	-0.384
GBDT _{global}	0.759	18.765	10.474	35.716	69.410	-0.407
CatBoost	0.748	19.071	11.036	38.035	72.181	0.034
MLP _{global}	0.747	19.220	10.732	36.597	71.377	-1.309
LightGBM	0.747	19.121	10.858	37.423	71.698	0.042
XGBoost	0.742	19.300	10.962	37.780	71.609	-0.004
BaggedDT _{global}	0.738	19.550	11.216	38.246	71.630	-0.749
RandomForest _{global}	0.734	19.694	10.928	37.264	68.279	-1.503
GBDT	0.732	19.692	11.550	39.809	73.147	0.016
RandomForest	0.729	19.770	11.294	38.925	70.570	0.013
BaggedDT	0.728	19.832	11.349	39.114	70.434	0.182
BayesianNN	0.693	21.069	12.830	44.220	79.896	-0.076
MLP	0.690	21.162	11.419	39.356	76.074	-3.511
BayesianNN _{global}	0.683	21.530	12.827	43.741	78.379	-0.859
KNN	0.632	23.046	12.994	44.784	76.109	-3.677
SVR _{global}	0.577	24.861	12.305	41.961	75.324	-7.293
SVR	0.566	25.034	12.818	44.177	77.708	-6.476
AdaBoost	-0.538	47.138	41.856	144.261	114.694	37.323

Tabla 8.4

Comparativa Modelos Stacking en IFN2 (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
Stack5 MLP_{global}	0.768	18.405	10.210	34.817	68.129	-0.195
Stack5 LinearRegression _{global}	0.768	18.418	10.306	35.144	69.309	-0.169
Stack5 Ridge _{global}	0.768	18.418	10.306	35.143	69.320	-0.170
Stack4 MLP _{global}	0.767	18.433	10.229	34.881	68.095	0.030
Stack4 LinearRegression _{global}	0.767	18.435	10.297	35.112	69.291	-0.232
Stack4 Ridge _{global}	0.767	18.435	10.296	35.111	69.288	-0.233
Stack3 MLP _{global}	0.767	18.450	10.184	34.726	67.782	-0.295
Stack5 GradientBoosting _{global}	0.767	18.457	10.224	34.863	68.228	-0.393
Stack3 Ridge _{global}	0.767	18.466	10.318	35.185	69.212	-0.277
Stack3 LinearRegression _{global}	0.767	18.466	10.318	35.185	69.212	-0.277
Stack4 GradientBoosting _{global}	0.766	18.485	10.216	34.837	68.125	-0.407
Stack2 LinearRegression _{global}	0.765	18.521	10.333	35.236	69.359	-0.252
Stack2 Ridge _{global}	0.765	18.521	10.333	35.236	69.360	-0.253
Stack3 GradientBoosting _{global}	0.765	18.529	10.230	34.886	68.141	-0.463
Stack2 MLP _{global}	0.765	18.531	10.285	35.071	68.797	-0.207
Stack5 SVR _{global}	0.763	18.595	10.155	34.628	68.878	-1.814
Stack4 SVR _{global}	0.763	18.601	10.169	34.676	68.822	-1.826
Stack1 MLP _{global}	0.763	18.602	10.261	34.989	67.896	-0.730
Stack1 Ridge _{global}	0.763	18.606	10.377	35.385	69.330	-0.345
Stack1 LinearRegression _{global}	0.763	18.606	10.377	35.385	69.330	-0.345
Stack2 GradientBoosting _{global}	0.763	18.616	10.297	35.114	68.617	-0.412
Stack3 SVR _{global}	0.762	18.643	10.193	34.758	68.689	-1.883
Stack1 GradientBoosting _{global}	0.761	18.676	10.316	35.177	68.372	-0.484
Stack2 SVR _{global}	0.761	18.678	10.222	34.856	68.947	-1.763
Stack1 SVR _{global}	0.758	18.821	10.260	34.986	68.943	-2.023
Stack5 RandomForest _{global}	0.756	18.879	10.606	36.167	66.996	0.138
Stack4 RandomForest _{global}	0.756	18.886	10.704	36.501	67.217	0.084
Stack4 MLP	0.755	18.828	10.636	36.658	70.675	0.274
Stack4 Ridge	0.754	18.860	10.734	36.997	71.361	0.044
Stack4 LinearRegression	0.754	18.860	10.734	36.997	71.364	0.044
Stack5 GradientBoosting	0.753	18.880	10.692	36.852	70.603	-0.022
Stack5 MLP	0.753	18.890	10.632	36.643	71.389	0.045
Stack5 Ridge	0.753	18.893	10.746	37.038	71.326	0.016
Stack5 LinearRegression	0.753	18.893	10.747	37.039	71.327	-0.016
Stack3 MLP	0.753	18.896	10.746	37.036	71.008	0.081
Stack4 GradientBoosting	0.752	18.921	10.654	36.720	70.494	0.029
Stack2 MLP	0.751	18.954	10.765	37.102	70.755	-0.001
Stack3 Ridge	0.751	18.977	10.873	37.473	71.697	0.076
Stack3 LinearRegression	0.751	18.978	10.873	37.474	71.695	0.076
Stack2 GradientBoosting	0.751	18.978	10.769	37.116	70.909	0.002
Stack4 SVR	0.750	18.988	10.523	36.267	72.240	-2.179
Stack2 Ridge	0.750	18.989	10.793	37.200	71.359	-0.048
Stack2 LinearRegression	0.750	18.989	10.793	37.200	71.357	-0.048
Stack5 SVR	0.750	18.993	10.530	36.293	72.199	-2.129
Stack3 GradientBoosting	0.749	19.027	10.783	37.164	70.757	0.076
Stack1 MLP	0.749	19.043	10.736	37.001	70.468	-0.031
Stack1 Ridge	0.749	19.048	10.777	37.145	71.433	-0.008
Stack1 LinearRegression	0.749	19.048	10.777	37.145	71.434	-0.008
Stack3 SVR	0.747	19.116	10.656	36.726	72.643	-2.243
Stack2 SVR	0.747	19.116	10.602	36.542	72.634	-2.230
Stack1 GradientBoosting	0.746	19.174	10.778	37.146	70.768	-0.046
Stack3 RandomForest _{global}	0.745	19.286	10.840	36.965	67.152	-0.105
Stack1 SVR	0.745	19.187	10.596	36.521	72.624	-2.197
Stack2 RandomForest _{global}	0.741	19.455	10.979	37.440	69.244	-0.110
Stack5 RandomForest	0.734	19.588	11.135	38.377	68.643	0.589
Stack1 RandomForest _{global}	0.734	19.711	11.235	38.313	68.420	-0.278
Stack3 RandomForest	0.727	19.848	11.483	39.578	69.750	0.543
Stack4 RandomForest	0.727	19.848	11.194	38.580	68.556	0.550
Stack2 RandomForest	0.720	20.098	11.538	39.768	71.966	0.196
Stack1 RandomForest	0.713	20.375	11.767	40.555	70.731	0.068

Tabla 8.5
Comparativa Modelos Base en IFN3 (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
LightGBM	0.858	17.816	9.246	24.609	37.327	0.017
XGBoost	0.851	18.232	9.203	24.494	37.033	-0.021
CatBoost	0.849	18.385	9.746	25.941	40.139	-0.114
GBDT	0.843	18.718	9.893	26.330	40.046	0.005
MLP	0.840	18.947	9.296	24.743	36.827	-3.555
GBDT _{global}	0.839	19.408	9.559	25.792	38.647	0.378
XGBoost _{global}	0.839	19.424	9.548	25.763	39.032	0.206
CatBoost _{global}	0.838	19.500	9.433	25.451	39.540	0.056
LightGBM _{global}	0.836	19.580	9.602	25.909	39.178	0.237
MLP _{global}	0.833	19.791	10.008	27.005	44.150	0.107
BaggedDT	0.820	20.085	10.699	28.476	40.585	0.098
BaggedDT _{global}	0.800	21.649	11.058	29.838	44.515	1.538
RandomForest	0.796	21.353	10.839	28.849	40.827	-0.092
RandomForest _{global}	0.789	22.223	11.109	29.974	41.901	1.399
BayesianNN	0.774	22.507	12.332	32.823	55.074	0.201
KNN	0.756	23.357	12.585	33.495	48.029	-5.178
BayesianNN _{global}	0.743	24.561	12.643	34.113	56.226	0.572
SVR	0.737	24.279	9.877	26.289	37.234	-3.632
SVR _{global}	0.613	30.113	11.708	31.590	42.962	-4.778
AdaBoost	0.314	39.189	33.180	88.310	91.289	22.855

Tabla 8.6
Comparativa Modelos Stacking en IFN3 (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
Stack4 GradientBoosting	0.866	17.303	9.134	24.310	37.215	-0.009
Stack5 GradientBoosting	0.865	17.369	9.037	24.052	36.846	-0.007
Stack2 GradientBoosting	0.863	17.537	9.097	24.211	37.106	0.005
Stack5 MLP	0.862	17.572	8.950	23.822	36.332	-0.335
Stack5 LinearRegression	0.861	17.644	9.049	24.083	37.004	-0.013
Stack5 Ridge	0.861	17.646	9.050	24.087	37.003	-0.012
Stack4 MLP	0.861	17.647	9.147	24.346	36.813	0.171
Stack2 MLP	0.860	17.704	9.038	24.054	36.404	-0.294
Stack4 LinearRegression	0.860	17.718	9.190	24.459	37.349	0.011
Stack4 Ridge	0.860	17.720	9.191	24.463	37.351	0.011
Stack1 GradientBoosting	0.859	17.740	9.273	24.681	37.369	0.029
Stack2 LinearRegression	0.859	17.767	9.097	24.213	36.750	-0.004
Stack2 Ridge	0.859	17.773	9.107	24.240	36.785	-0.004
Stack5 SVR	0.858	17.816	8.879	23.631	37.125	-1.871
Stack5 RandomForest	0.858	17.819	9.445	25.139	37.517	0.362
Stack1 MLP	0.858	17.834	9.264	24.657	37.281	0.119
Stack4 SVR	0.858	17.851	9.011	23.984	37.554	-1.902
Stack1 LinearRegression	0.857	17.873	9.244	24.604	36.837	0.023
Stack1 Ridge	0.857	17.875	9.245	24.606	36.831	0.023
Stack2 SVR	0.856	17.954	8.935	23.781	37.175	-1.851
Stack3 GradientBoosting	0.855	18.026	9.534	25.375	38.431	0.002
Stack1 SVR	0.854	18.053	9.114	24.257	37.328	-1.845
Stack3 MLP	0.852	18.171	9.500	25.285	37.589	0.001
Stack4 RandomForest	0.852	18.199	9.748	25.946	38.468	0.330
Stack3 LinearRegression	0.850	18.309	9.580	25.498	38.816	0.007
Stack3 Ridge	0.850	18.316	9.581	25.500	38.784	0.008
Stack3 RandomForest	0.849	18.375	10.159	27.039	39.787	0.336
Stack5 MLP _{global}	0.848	18.892	9.178	24.763	36.606	0.347
Stack2 MLP _{global}	0.847	18.943	9.332	25.180	37.530	0.382
Stack3 SVR	0.846	18.552	9.397	25.010	38.601	-2.106
Stack4 MLP _{global}	0.845	19.067	9.180	24.770	36.741	0.146
Stack5 Ridge _{global}	0.844	19.100	9.252	24.965	38.537	0.140
Stack5 LinearRegression _{global}	0.844	19.102	9.253	24.966	38.597	0.131
Stack2 Ridge _{global}	0.844	19.115	9.355	25.241	38.497	0.193
Stack2 LinearRegression _{global}	0.844	19.117	9.356	25.244	38.525	0.191
Stack4 Ridge _{global}	0.843	19.154	9.278	25.033	38.451	0.184
Stack4 LinearRegression _{global}	0.843	19.156	9.277	25.030	38.505	0.173
Stack3 Ridge _{global}	0.843	19.187	9.305	25.107	38.570	0.218
Stack3 LinearRegression _{global}	0.843	19.188	9.304	25.104	38.641	0.205
Stack3 MLP _{global}	0.842	19.216	9.188	24.790	36.845	-0.169
Stack5 SVR _{global}	0.840	19.367	9.101	24.557	40.002	-2.063
Stack2 SVR _{global}	0.840	19.369	9.185	24.783	39.985	-2.057
Stack4 SVR _{global}	0.839	19.400	9.116	24.597	39.978	-2.045
Stack3 SVR _{global}	0.839	19.423	9.137	24.655	40.013	-2.018
Stack2 RandomForest	0.839	18.988	9.887	26.314	38.705	0.293
Stack1 MLP _{global}	0.839	19.436	9.564	25.804	37.443	0.770
Stack3 GradientBoosting _{global}	0.837	19.547	9.290	25.067	37.493	0.310
Stack1 LinearRegression _{global}	0.837	19.564	9.582	25.854	38.721	0.337
Stack1 Ridge _{global}	0.837	19.565	9.582	25.854	38.714	0.339
Stack1 RandomForest	0.835	19.224	10.450	27.814	40.024	0.233
Stack5 GradientBoosting _{global}	0.833	19.768	9.291	25.069	37.539	0.270
Stack1 GradientBoosting _{global}	0.832	19.820	9.600	25.903	38.177	0.508
Stack1 SVR _{global}	0.832	19.852	9.388	25.330	39.687	-1.927
Stack4 GradientBoosting _{global}	0.830	19.940	9.344	25.213	37.491	0.304
Stack2 GradientBoosting _{global}	0.826	20.206	9.499	25.631	38.253	0.331
Stack5 RandomForest _{global}	0.820	20.540	9.871	26.635	38.299	0.692
Stack3 RandomForest _{global}	0.807	21.266	10.271	27.713	39.177	0.574
Stack4 RandomForest _{global}	0.804	21.415	10.123	27.314	38.710	0.763
Stack2 RandomForest _{global}	0.802	21.562	10.342	27.905	39.864	0.540
Stack1 RandomForest _{global}	0.792	22.090	10.962	29.576	40.925	0.731

Tabla 8.7
Comparativa Modelos Base en IFN3 (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
LightGBM	0.898	10.641	4.687	27.801	110.183	-0.007
CatBoost	0.896	10.737	4.789	28.405	110.952	-0.059
XGBoost	0.895	10.761	4.713	27.957	109.669	-0.008
CatBoost _{global}	0.889	10.931	4.812	28.723	111.600	-0.059
GBDT	0.888	11.134	5.044	29.920	111.422	-0.042
MLP	0.885	11.287	4.803	28.488	111.603	-0.544
LightGBM _{global}	0.884	11.153	4.863	29.023	111.679	-0.073
XGBoost _{global}	0.883	11.230	4.859	28.999	111.190	-0.036
GBDT _{global}	0.881	11.327	4.937	29.463	111.656	-0.002
MLP _{global}	0.879	11.431	5.122	30.573	114.182	-0.326
BaggedDT	0.873	11.830	5.183	30.745	99.986	-0.135
RandomForest	0.870	11.965	5.217	30.944	109.139	-0.239
BaggedDT _{global}	0.866	11.997	5.410	32.287	110.035	0.589
RandomForest _{global}	0.865	12.053	5.330	31.814	105.593	0.434
BayesianNN	0.836	13.455	6.773	40.173	120.931	0.010
BayesianNN _{global}	0.824	13.774	7.040	42.020	121.650	0.265
SVR	0.810	14.504	5.269	31.256	112.607	-2.176
KNN	0.793	15.128	6.251	37.078	102.871	-2.897
SVR _{global}	0.730	17.033	6.154	36.728	114.785	-2.987
AdaBoost	0.349	26.829	23.857	141.512	139.341	20.684

Tabla 8.8

Comparativa Modelos Stacking en IFN3 (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
Stack4 MLP	0.902	10.407	4.517	26.795	107.868	0.049
Stack5 GradientBoosting	0.901	10.433	4.540	26.930	109.331	0.030
Stack5 MLP	0.901	10.447	4.454	26.417	107.446	-0.368
Stack4 GradientBoosting	0.901	10.450	4.541	26.936	109.286	0.037
Stack5 LinearRegression	0.900	10.492	4.624	27.426	110.839	0.025
Stack5 Ridge	0.900	10.494	4.624	27.428	110.757	0.022
Stack4 LinearRegression	0.900	10.511	4.648	27.570	110.932	0.020
Stack4 Ridge	0.900	10.511	4.648	27.570	110.941	0.020
Stack2 MLP	0.899	10.540	4.581	27.173	108.573	-0.035
Stack2 LinearRegression	0.899	10.572	4.651	27.590	110.865	0.011
Stack3 MLP	0.899	10.572	4.611	27.348	106.609	0.170
Stack2 Ridge	0.899	10.573	4.654	27.604	110.866	0.010
Stack2 GradientBoosting	0.899	10.582	4.610	27.343	109.772	0.004
Stack1 MLP	0.898	10.617	4.579	27.162	107.666	-0.163
Stack1 LinearRegression	0.898	10.625	4.667	27.682	111.022	0.011
Stack1 Ridge	0.898	10.625	4.667	27.682	111.022	0.011
Stack5 SVR	0.898	10.638	4.541	26.938	110.810	-0.758
Stack4 SVR	0.897	10.655	4.556	27.027	111.084	-0.788
Stack1 GradientBoosting	0.897	10.660	4.620	27.406	109.313	0.021
Stack3 GradientBoosting	0.897	10.671	4.637	27.506	109.803	0.028
Stack3 LinearRegression	0.897	10.674	4.757	28.218	111.578	0.014
Stack3 Ridge	0.897	10.675	4.757	28.217	111.563	0.013
Stack2 SVR	0.896	10.706	4.580	27.167	110.761	-0.744
Stack5 RandomForest	0.895	10.755	4.721	28.006	96.178	0.266
Stack4 RandomForest	0.895	10.782	4.775	28.322	98.323	0.216
Stack1 SVR	0.895	10.787	4.613	27.364	110.982	-0.740
Stack3 SVR	0.893	10.865	4.672	27.712	111.457	-0.870
Stack4 MLP _{global}	0.890	10.862	4.621	27.580	109.222	0.226
Stack5 MLP _{global}	0.890	10.866	4.586	27.369	107.939	0.041
Stack3 MLP _{global}	0.890	10.880	4.544	27.119	106.128	-0.009
Stack4 LinearRegression _{global}	0.890	10.890	4.741	28.298	111.854	-0.075
Stack4 Ridge _{global}	0.890	10.891	4.741	28.297	111.872	-0.075
Stack5 GradientBoosting _{global}	0.890	10.905	4.612	27.525	109.827	-0.006
Stack5 LinearRegression _{global}	0.889	10.908	4.747	28.330	112.364	-0.113
Stack5 Ridge _{global}	0.889	10.909	4.747	28.330	112.377	-0.113
Stack3 LinearRegression _{global}	0.889	10.921	4.766	28.443	112.073	-0.047
Stack3 Ridge _{global}	0.889	10.921	4.766	28.443	112.073	-0.047
Stack3 GradientBoosting _{global}	0.888	10.959	4.626	27.612	109.664	0.036
Stack4 GradientBoosting _{global}	0.888	10.978	4.625	27.605	109.591	0.007
Stack3 RandomForest	0.887	11.157	4.967	29.463	98.766	0.152
Stack2 RandomForest	0.887	11.165	4.916	29.157	98.358	0.133
Stack4 SVR _{global}	0.887	11.053	4.682	27.941	112.576	-0.961
Stack5 SVR _{global}	0.886	11.056	4.687	27.976	112.536	-0.956
Stack2 MLP _{global}	0.886	11.058	4.709	28.105	109.662	0.075
Stack2 LinearRegression _{global}	0.886	11.065	4.803	28.663	112.597	-0.094
Stack2 Ridge _{global}	0.886	11.065	4.802	28.662	112.594	-0.094
Stack3 SVR _{global}	0.886	11.088	4.701	28.059	112.546	-0.948
Stack1 MLP _{global}	0.885	11.102	4.680	27.934	107.602	-0.133
Stack2 GradientBoosting _{global}	0.885	11.108	4.729	28.224	110.752	-0.005
Stack1 Ridge _{global}	0.885	11.111	4.833	28.842	112.219	-0.040
Stack1 LinearRegression _{global}	0.885	11.111	4.833	28.842	112.219	-0.040
Stack1 GradientBoosting _{global}	0.884	11.171	4.732	28.242	109.678	0.048
Stack2 SVR _{global}	0.883	11.220	4.745	28.321	112.576	-0.971
Stack1 SVR _{global}	0.882	11.271	4.760	28.409	112.572	-0.951
Stack1 RandomForest	0.881	11.483	5.127	30.409	95.521	0.089
Stack5 RandomForest _{global}	0.880	11.347	4.848	28.932	96.971	0.259
Stack4 RandomForest _{global}	0.879	11.429	4.919	29.356	96.704	0.192
Stack3 RandomForest _{global}	0.875	11.586	5.023	29.976	95.997	0.204
Stack2 RandomForest _{global}	0.873	11.692	5.131	30.625	102.247	0.209
Stack1 RandomForest _{global}	0.858	12.368	5.383	32.129	94.456	0.154

Tabla 8.9
Modelos Base Globales (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
LightGBM_{global}	0.787	22.767	11.650	29.978	42.370	0.134
XGBoost _{global}	0.784	22.952	11.590	29.824	42.204	0.055
CatBoost _{global}	0.783	22.990	11.607	29.866	42.904	-0.021
GBDT _{global}	0.783	23.014	11.658	29.998	41.987	0.169
MLP _{global}	0.771	23.606	12.287	31.617	46.726	0.177
BaggedDT _{global}	0.740	25.142	13.021	33.506	47.116	0.678
RandomForest _{global}	0.732	25.547	12.908	33.214	44.513	0.232
BayesianNN _{global}	0.678	28.021	14.689	37.797	56.389	0.047
SVR _{global}	0.551	33.065	13.708	35.272	45.693	-6.204

Tabla 8.10
Modelos Stacking Globales (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
Stack5 MLP_{global}	0.794	22.387	11.321	29.132	40.529	0.238
Stack2 MLP _{global}	0.794	22.405	11.403	29.341	41.069	0.176
Stack4 MLP _{global}	0.792	22.527	11.314	29.112	40.574	-0.045
Stack2 LinearRegression _{global}	0.791	22.565	11.429	29.409	41.712	0.069
Stack2 Ridge _{global}	0.791	22.566	11.429	29.409	41.696	0.069
Stack5 LinearRegression _{global}	0.791	22.571	11.387	29.299	41.921	0.057
Stack5 Ridge _{global}	0.791	22.572	11.384	29.293	41.871	0.058
Stack4 Ridge _{global}	0.790	22.601	11.414	29.371	41.858	0.083
Stack4 LinearRegression _{global}	0.790	22.602	11.416	29.375	41.905	0.081
Stack1 MLP _{global}	0.790	22.635	11.584	29.808	41.096	0.507
Stack3 LinearRegression _{global}	0.788	22.735	11.456	29.477	42.051	0.072
Stack3 Ridge _{global}	0.788	22.735	11.453	29.471	41.991	0.074
Stack1 LinearRegression _{global}	0.787	22.769	11.606	29.864	41.939	0.145
Stack1 Ridge _{global}	0.787	22.770	11.606	29.864	41.933	0.145
Stack3 MLP _{global}	0.787	22.776	11.338	29.175	40.679	-0.384
Stack2 SVR _{global}	0.786	22.853	11.214	28.856	42.299	-2.241
Stack5 SVR _{global}	0.785	22.864	11.162	28.721	42.381	-2.258
Stack4 SVR _{global}	0.785	22.875	11.183	28.775	42.403	-2.252
Stack3 SVR _{global}	0.783	22.996	11.218	28.866	42.483	-2.263
Stack1 SVR _{global}	0.781	23.113	11.369	29.253	42.029	-2.257
Stack2 GradientBoosting _{global}	0.779	23.183	11.527	29.661	41.592	0.125
Stack3 GradientBoosting _{global}	0.779	23.211	11.445	29.450	41.108	0.072
Stack5 GradientBoosting _{global}	0.777	23.284	11.417	29.378	41.143	0.064
Stack1 GradientBoosting _{global}	0.776	23.334	11.630	29.926	41.572	0.156
Stack4 GradientBoosting _{global}	0.773	23.532	11.477	29.531	41.095	0.115
Stack5 RandomForest _{global}	0.761	24.147	12.027	30.947	42.068	0.628
Stack2 RandomForest _{global}	0.755	24.446	12.345	31.766	43.055	0.378
Stack4 RandomForest _{global}	0.749	24.730	12.223	31.452	42.332	0.614
Stack3 RandomForest _{global}	0.748	24.777	12.407	31.924	42.760	0.507
Stack1 RandomForest _{global}	0.745	24.907	12.885	33.155	44.082	0.402

Tabla 8.11

Modelos Base Globales (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
CatBoost_{global}	0.845	13.846	6.615	31.789	98.044	-0.150
LightGBM _{global}	0.841	14.006	6.654	31.977	98.088	-0.150
XGBoost _{global}	0.840	14.054	6.655	31.980	97.699	-0.148
GBDT _{global}	0.838	14.159	6.722	32.304	98.033	-0.132
MLP _{global}	0.832	14.410	6.931	33.311	100.379	-0.643
BaggedDT _{global}	0.821	14.858	7.282	34.995	97.651	0.158
RandomForest _{global}	0.819	14.950	7.135	34.291	93.561	-0.191
BayesianNN _{global}	0.775	16.674	8.906	42.802	107.697	-0.097
SVR _{global}	0.679	19.897	8.137	39.106	102.061	-4.376

Tabla 8.12

Modelos Stacking Globales (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
Stack5 MLP_{global}	0.847	13.756	6.399	30.754	95.102	-0.035
Stack4 MLP _{global}	0.847	13.766	6.429	30.898	95.960	0.163
Stack4 LinearRegression _{global}	0.846	13.782	6.533	31.394	98.129	-0.126
Stack4 Ridge _{global}	0.846	13.782	6.533	31.394	98.140	-0.126
Stack3 MLP _{global}	0.846	13.783	6.362	30.576	93.763	-0.101
Stack5 LinearRegression _{global}	0.846	13.785	6.539	31.426	98.481	-0.131
Stack5 Ridge _{global}	0.846	13.785	6.539	31.426	98.493	-0.131
Stack5 GradientBoosting _{global}	0.846	13.799	6.421	30.860	96.413	-0.131
Stack3 LinearRegression _{global}	0.846	13.812	6.556	31.506	98.252	-0.121
Stack3 Ridge _{global}	0.846	13.812	6.556	31.506	98.252	-0.121
Stack4 GradientBoosting _{global}	0.845	13.850	6.428	30.891	96.220	-0.126
Stack3 GradientBoosting _{global}	0.844	13.860	6.433	30.917	96.274	-0.125
Stack2 LinearRegression _{global}	0.843	13.913	6.586	31.650	98.655	-0.145
Stack2 Ridge _{global}	0.843	13.913	6.586	31.650	98.653	-0.145
Stack2 MLP _{global}	0.843	13.913	6.507	31.270	96.485	-0.016
Stack5 SVR _{global}	0.843	13.940	6.450	30.999	98.458	-1.233
Stack4 SVR _{global}	0.843	13.941	6.451	31.002	98.467	-1.240
Stack1 MLP _{global}	0.842	13.968	6.480	31.140	94.798	-0.326
Stack1 Ridge _{global}	0.842	13.974	6.620	31.816	98.389	-0.138
Stack1 LinearRegression _{global}	0.842	13.974	6.620	31.816	98.389	-0.138
Stack2 GradientBoosting _{global}	0.842	13.977	6.524	31.355	97.165	-0.136
Stack3 SVR _{global}	0.842	13.977	6.472	31.103	98.404	-1.249
Stack1 GradientBoosting _{global}	0.840	14.037	6.532	31.393	96.359	-0.123
Stack2 SVR _{global}	0.840	14.064	6.511	31.290	98.508	-1.226
Stack1 SVR _{global}	0.838	14.153	6.533	31.398	98.503	-1.297
Stack5 RandomForest _{global}	0.836	14.218	6.705	32.220	87.305	0.220
Stack4 RandomForest _{global}	0.835	14.266	6.784	32.603	87.196	0.157
Stack3 RandomForest _{global}	0.829	14.522	6.898	33.152	86.696	0.104
Stack2 RandomForest _{global}	0.826	14.652	7.017	33.722	91.605	0.106
Stack1 RandomForest _{global}	0.815	15.130	7.270	34.939	86.061	0.015

9. Discusión

En primer lugar se analizarán los modelos “globales”, es decir, aquellos entrenados con todos los datos (IFN2 e IFN3) al mismo tiempo. Posteriormente se analizarán los modelos entrenados solo con un inventario y se compararán con los globales.

9.1. Modelos globales

9.1.1. Variable c_4 (en toneladas de carbono por hectárea)

Modelos base

La variable periodo (el número de años entre la medición y la predicción) tiene una gran importancia en el estudio de los modelos. Es por esto que en la Figura 9.1 se incluyen métricas en función de esta variable, donde se muestra la evolución del RMSE y el %RMSE en cuantiles en función de la variable periodo, junto con un histograma que nos permite visualizar la cantidad de datos en el conjunto de entrenamiento para cada valor de periodo.

Podemos observar algo que podíamos prever: la dificultad de la predicción depende de una combinación entre cuán lejos se desea realizar la predicción y la calidad y cantidad de los datos de entrenamiento. Empezando en terreno del IFN3, podemos observar que para los primeros años (5, y 6), pese a tener pocos datos, los errores son comedidos. A medida que aumenta el periodo (entre 10 y 17 años) los errores medios y medianos se mantienen relativamente estables pese a disponer de, en general, más datos de entrenamiento. Los errores grandes extremos (cuantil 90) experimentan un aumento generalizado. Cuando entramos en el rango de




Figura 9.1: Evolución del error absoluto y el error absoluto porcentual en cuantiles en función del periodo para el modelo LightGBM (c_4).




Figura 9.2: Densidad de predicciones frente a valores reales para el modelo LightGBM (c_4).

años donde los datos de entrenamiento proceden del IFN2 principalmente (el rango entre 20 y 30 años), aunque la mediana y los valores pequeños - medios (cuantil 25) se mantienen estables, los valores grandes - medios (cuantil 75) y los grandes (cuantil 90) aumentan en gran medida. Esto es un indicativo de que, aun disponiendo de una gran cantidad de datos de entrenamiento (especialmente para los años 27 y 28), la combinación entre la peor calidad de los datos (comparando siempre con el IFN3) y la predicción a valores lejanos dificultan la predicción del modelo. Además, como podemos observar en la Figura 6.2, los valores de los primeros años del IFN2 presentan una gran variabilidad,

siendo en su mayoría valores más altos que los del IFN3 para esos mismos años, y con una mayor variabilidad. Esto, unido a que la cantidad de datos para esos años no es excesivamente grande, hace que el modelo obtenga peores predicciones.

El hecho de que los valores medianos se mantengan relativamente estables a lo largo de todos los periodos indica que el modelo asimila correctamente el comportamiento de la variable objetivo tanto con datos del IFN2 como del IFN3. Por otro lado, que los errores del cuantil 90 sean tan elevados se explica por varios factores: la alta variabilidad del conjunto de datos, el menor número de variables de campo recogidas en el IFN2 (lo que reduce la información disponible) y la mayor dificultad inherente a predecir a horizontes temporales lejanos. Esta combinación hace que los casos particulares o atípicos sean menos reconocibles por el modelo, especialmente cuando proceden del IFN2, donde la capacidad de discriminación es menor que en el IFN3. La variabilidad mencionada se observa claramente en la Figura 9.2, que muestra los valores predichos frente a los reales para el modelo con mejores métricas, junto con un histograma de distribución.

Modelos de stacking

La incorporación de esquemas de *stacking* no produce incrementos sustanciales, aunque sí sistemáticos, en el coeficiente de determinación respecto a los mejores modelos individuales. Fijándonos en la Tabla 8.10 podemos observar que los modelos de stacking presentan mejores métricas en la gran mayoría de casos, siempre comparando con los modelos bases. Los mejores parámetros los obtiene el modelo de stacking con configuración 5, que mantiene todos los modelos con rendimiento competitivo, junto con el metamodelo de la red neuronal.

El hecho de que todos los ensembles mejoren a los modelos base es un síntoma de que esta mejora no es una excepción estadística, sino una mejora real. Esto es, no se trata de que las métricas sean mejores por estocasticidad de los parámetros del metamodelo, sino porque el montaje realmente mejora el resultado final. Obviamente, reentrenar los metamodelos con otros parámetros haría variar las métricas, pero el hecho es que la función de mejorar las predicciones realmente se alcanza con los ensembles. No obstante, la mejora es pequeña, lo que puede hacer que según el caso se prefiera la simplicidad de emplear uno de los modelos base en comparación con uno de los ensembles.

En la Figura 9.3 se muestra la evolución del RMSE y el RMSE porcentual en cuantiles para el modelo ensemble con mejores métricas, el stacking con configuración 5 y metamodelo MLP. Podemos observar que el comportamiento es prácticamente idéntico a aquel del LightGBM, el que obtuvo mejores métricas de los modelos base. Por otro lado, en la Figura 9.4 podemos observar el gráfico de puntos de las predicciones frente a los valores reales para el modelo de stacking con configuración 5 y metamodelo MLP para la variable c_4 (tC/ha).

En cuanto a la estructura de los ensembles, los mejores resultados se obtienen cuando se combinan modelos base de




Figura 9.3: Evolución del error absoluto y el error absoluto porcentual en cuantiles en función del periodo para el modelo Stacking (Conf. 5, MLP) (c4).




Figura 9.4: Gráfico de puntos de las predicciones frente a los valores reales para el modelo Stacking (Conf. 5, MLP) (c4).

alta calidad y naturaleza similar (principalmente variantes de *gradient boosting*) y se emplean metamodelos con complejidad moderada, como MLP o SVR lineal. Por el contrario, los *stacks* con pocos modelos base o aquellos que incorporan metamodelos excesivamente flexibles, como Random Forest en el segundo nivel, tienden a ofrecer un rendimiento inferior, probablemente debido a la baja dimensionalidad del espacio de meta-predictores o a un sobreajuste innecesario del ruido residual.




Figura 9.5: Evolución del error absoluto y el error absoluto porcentual en cuantiles en función del periodo para el modelo CatBoost (carbono_bruto4).

9.1.2. Variable carbono_bruto4 (en toneladas de carbono)

Modelos base

De igual forma que en los apartados anteriores, en la Figura 9.5 se muestra la evolución del RMSE y el %RMSE en cuantiles en función de la variable periodo para el modelo CatBoost (aquel que obtuvo mejores métricas entre los modelos base) con IFN2 e IFN3 como explicativos para la variable en toneladas de carbono, junto con el histograma de distribución de los datos de entrenamiento en función de la variable periodo.

Atendiendo a la Figura 9.5 observamos el mismo comportamiento cualitativo que en el caso de la variable c_4 (con la particularidad de que cambian las unidades y el rango de valores): el error entre los cuantiles 25 y 75 se mantiene en valores relativamente pequeños y constantes, si bien es verdad que empieza siendo menor y va aumentando ligeramente a medida que lo hace la variable periodo. Los errores extremos (cuantil 90) siguen siendo altos. De hecho, si nos fijamos en los valores más altos del RMSE porcentual para el cuantil 90, observamos que se alcanzan valores notablemente más altos que en el caso de la variable c_4 , llegando hasta el 130 % cuando para c_4 apenas se superó el 100 % para el peor de los casos. Esto es de destacar, ya que las métricas globales para las predicciones de la variable carbono_bruto4 (ver Tabla 8.11) son sistemáticamente mejores que las de la variable c_4 (ver Tabla 8.9). Esto es, la variable carbono_bruto4 (toneladas) es más fácil de predecir en general para los modelos que la variable c_4 (toneladas por hectárea), pero ocurre lo contrario en los casos particulares, donde los errores más altos se disparan de una manera más exagerada que en el mismo caso para la variable c_4 . También




Figura 9.6: Gráfico de puntos de las predicciones frente a los valores reales para el modelo CatBoost (carbono_bruto4).

se observa el aumento del error al pasar del rango de años del IFN2 a IFN3, causado por el aumento de la variabilidad de los datos del segundo inventario (ver Figura 6.2).

Al igual que en los apartados anteriores, en la Figura 9.6 podemos observar un scatter plot de las predicciones frente a los valores reales para el modelo CatBoost del caso que estamos considerando.

Modelos con stacking

Los resultados obtenidos en este apartado son muy similares a aquellos que se han obtenido con los modelos stacking para la variable c_4 (tC/ha). Esto es, encontramos una mejora sistemática en todos los modelos de stacking frente a los base, pero esa mejora es pequeña. Esto causa que los resultados sean estrictamente mejores, como se puede ver en la Tabla 8.12 comparando con las métricas de los modelos base de la Tabla 8.11. De nuevo, que la mejora de los modelos stacking respecto a los base sea sistemática indica que no nos encontramos frente a un incidente estadístico, sino que el formato del stacking es capaz de mejorar las predicciones de los modelos escogiendo las mejores decisiones de cada uno de ellos. No obstante, como ya se comentó anteriormente, la complejidad de entrenar cinco modelos además del metamodelo puede resultar incómoda frente a la posibilidad de usar, por ejemplo, el mejor de los modelos individuales.

El modelo ensemble que mejores métricas proporciona para la predicción de la variable carbono_bruto4 (tC) es la configuración 5 y metamodelo MLP, al igual que ocurrió con la variable c_4 (tC/ha). La evolución del RMSE y el RMSE porcentual en cuantiles en función de la variable periodo para este modelo se puede visualizar en la Figura 9.7.

Por otro lado, en la Figura 9.8 se muestra un scatter plot de las predicciones frente a los valores reales para el modelo




Figura 9.7: Evolución del error absoluto y el error absoluto porcentual en cuantiles en función del periodo para el modelo Stacking (Conf. 5, MLP) (carbono_bruto4).




Figura 9.8: Gráfico de puntos de las predicciones frente a los valores reales para el modelo Stacking (Conf. 5, MLP) (carbono_bruto4).

de stacking con configuración 5 y metamodelo MLP y la variable carbono_bruto4 (tC).

9.2. Modelos individuales entrenados solo con el IFN2 o IFN3.

Al comparar el rendimiento de los modelos “globales” (entrenados con el conjunto combinado de IFN2 e IFN3) frente a los modelos “locales” (entrenados exclusivamente con IFN2 o IFN3), se observa un comportamiento diferenciado según el inventario de prueba. En el caso del IFN3, los modelos locales superan a los globales en términos de




Figura 9.9: Comparación del error absoluto para c_4 en el IFN2: mejores modelos base globales vs. locales, stacking globales vs. locales, y mejor modelo base vs. mejor stacking.

métricas de precisión. Por el contrario, para el IFN2, los modelos globales muestran un desempeño superior.

Una posible explicación para este fenómeno radica en la calidad y cantidad de información contenida en cada inventario. Los datos del IFN2, al ser menos informativos o presentar menos variables, parecen beneficiarse del aprendizaje conjunto con los del IFN3, lo que permite a los modelos capturar patrones adicionales y mejorar su capacidad de generalización sobre el segundo inventario. En cambio, para el IFN3, cuyos datos poseen una mayor calidad intrínseca, la inclusión de registros del IFN2 durante el entrenamiento podría estar introduciendo ruido o variabilidad no deseada, lo que acaba penalizando la precisión de las predicciones del modelo final sobre este conjunto.

En la Figura 9.9 se muestra una comparativa entre los mejores modelos base globales vs. locales (arriba), mejores modelos de stacking globales vs. locales (medio) y mejor modelo base vs. mejor modelo de stacking (abajo). Observamos que en general los errores menores para el IFN2 los cometen los modelos globales, mientras que para el IFN3 son los locales los que realizan un mejor trabajo.

9.2.1. Asimilación del comportamiento de las variables objetivo

Con las métricas que hemos planteado y el análisis que se ha hecho en esta sección parece claro que, si bien los resultados no son ni mucho menos perfectos, los modelos son capaces de entender la lógica y el significado de cada variable para obtener una predicción con un grado de acierto que depende de la naturaleza de la instancia que se trate. Otra prueba que podemos hacer para comprobar si los resultados de los modelos son lógicos es la que mostramos en las Figuras 9.13 y 9.14. Estas figuras muestran la evolución de varios casos particulares a medida que avanza el tiempo




Figura 9.10: Comparación del error absoluto para c4 en el IFN3: mejores modelos base globales vs. locales, stacking globales vs. locales, y mejor modelo base vs. mejor stacking.




Figura 9.12: Comparación del error absoluto para carbono_bruto4 en el IFN3: mejores modelos base globales vs. locales, stacking globales vs. locales, y mejor modelo base vs. mejor stacking.




Figura 9.11: Comparación del error absoluto para carbono_bruto4 en el IFN2: mejores modelos base globales vs. locales, stacking globales vs. locales, y mejor modelo base vs. mejor stacking.




Figura 9.13: Evolución de la cantidad de carbono en toneladas por hectárea (c4) para varios escenarios.

entre medida y predicción. Los casos seleccionados son reales dentro de los datos disponibles. Se seleccionaron con la idea de mostrar cómo se comportan los modelos para configuraciones de carbono inicial más o menos comunes. Para ello se sumaron, para cada instancia de los datos, las variables `npies_x`, y luego se seleccionaron los valores más cercanos a los percentiles 10, 35, 65 y 90 para la variable resultante. Así evitamos posibles problemas fruto de seleccionar ejemplos poco realistas.

Podemos señalar las siguientes características:

- Las líneas de los modelos base y los ensembles para cada caso están muy cerca una de la otra, lo que concuerda con las métricas obtenidas, que eran muy similares entre sí.
- La tendencia general es ascendente, es decir, los modelos capturan de forma correcta el comportamiento del crecimiento de los árboles con el tiempo para los años estudiados.




Figura 9.14: Evolución de la cantidad de carbono en toneladas (carbono_bruto4) para varios escenarios.

- En el año 17 tenemos un crecimiento abrupto generalizado, el cual es más exagerado cuanto más pequeño es el percentil del caso de estudio. Esto es sencillo de entender mirando a los datos, ya que los valores de la variable a predecir experimentan un aumento generalizado al pasar de los años del IFN2 a aquellos del IFN3, como se puede ver en la Figura 6.2. Este cambio (que el modelo empiece a ingerir datos del IFN2 en lugar del IFN3) ocurre principalmente en el año 17. Esto puede verse en el histograma de la Figura 9.7, por ejemplo. La razón por la que ocurre el salto a percentiles pequeños es porque estos valores pequeños en los datos del IFN2 apenas existen o son menos comunes. El modelo ha visto que para esos años los valores de carbono son, en general, mayores, y eso es lo que predice. De hecho, en la Figura 6.2 se observa que para los años iniciales de los datos del IFN2 los valores de carbono aumentan para luego disminuir, y esto es justo lo que vemos en las predicciones: un aumento y una posterior disminución.
- También podemos ver una subida abrupta en muchos casos al pasar del año 29 al 30, sobre todo en el caso de la variable en toneladas de carbono bruto (Figura 9.14). Estos años coinciden con una carencia de datos, como podemos ver en el histograma de la Figura 6.2. Es de esperar que las predicciones de esos años sean menos fiables, sobre todo siendo un valor extremo.

9.2.2. Rendimiento de los modelos en función del valor de la variable objetivo

Si se analizan las métricas globales de las tablas de la sección 8 nos damos cuenta de que los valores del RMSE son




Figura 9.15: Distribución del SMAPE y RMSE en función de la variable objetivo para c4 en deciles.




Figura 9.16: Distribución del SMAPE y RMSE en función de la variable objetivo para carbono_bruto4 en deciles.

notablemente mayores que los valores de MAE, concretamente cerca del doble en la mayoría de casos. Debido a que el RMSE penaliza mucho más los errores grandes que el MAE, esto es indicativo de la presencia de outliers en el error. Ya hemos visto a lo largo de esta sección que los mayores errores ocurren en el rango de años en que el IFN2 es la principal fuente de datos como podemos ver en las Figuras 9.1, 9.3, 9.5 y 9.7, y la principal conclusión que podemos sacar es que la calidad o cantidad de información contenida en este inventario es peor. No obstante, esto no responde del todo a la pregunta de en qué casos el modelo predice mejor, salvo la obviedad de que la predicción será mejor cuanto más cerca esté en el tiempo y más datos haya de ese año. Es por esto que las Figuras 9.15 y 9.16 no pueden ser útiles. Estas figuras muestran la distribución de errores, concretamente el RMSE y el SMAPE, en función de la variable objetivo para c4 y carbono_bruto4 respectivamente, en deciles para los modelos base.




Figura 9.17: Bee swarm plot de LightGBM para la variable carbono_bruto4.




Figura 9.18: Bee swarm plot de CatBoost para la variable carbono_bruto4.

Rápidamente nos damos cuenta de lo siguiente: las predicciones para valores pequeños de carbono objetivo (primeros deciles) son malas (SMAPE grande) pese a ser aquellas con un error absoluto menor (RMSE pequeño). Luego, a medida que aumenta el carbono objetivo, el RMSE aumenta ligeramente mientras que el SMAPE disminuye mucho más rápido, llegando a valores cercanos al 25 %. En ambos casos los mejores resultados se logran cuando el carbono objetivo es mayor, pese a que observamos un aumento significativo del RMSE entre el penúltimo y último decil. Como esto se produce para todos los modelos, sugiere que la dificultad de predicción no es homogénea para todas las situaciones o cantidades de carbono, y que pese a ser los percentiles de menor carbono aquellos con un RMSE menor, la precisión de los modelos no es la suficiente como para hacer una predicción decente en situaciones con poca biomasa. Esto era predecible, ya que un error absoluto mayor para una parcela de bosque mayor no implica necesariamente un peor error relativo.

También es llamativo el hecho de que los deciles iniciales tienen unos rangos de carbono muy cercanos, sobre todo en el caso de la variable carbono_bruto4, donde el primer decil abarca desde 0,0003 tC hasta 0,0020 tC. Esta gran cantidad de valores no sirve a los modelos para obtener una buena predicción, por otra parte. Las densidades mayores para valores pequeños de carbono se ven claramente en las Figuras 9.2, 9.4, 9.6 y 9.8.

9.3. Interpretabilidad de los modelos: análisis SHAP

[Texto de ejemplo. Las figuras enlazadas son reales. El resto están en el repositorio de los modelos. Daltaría comentar el resto de casos.]

Los diagramas de dispersión SHAP (*beeswarm plots*) de LightGBM (figura 9.17) y CatBoost (figura 9.18) revelan patrones coincidentes y divergentes en la interpretación del modelo para c4:

- **Dominancia de la densidad arbórea.** En ambos modelos, npies* (Densidad) es la variable más influyente con diferencia. Sin embargo, LightGBM (figura 9.17) produce valores SHAP extremos de hasta ~260 tC/ha, frente a los ~160 tC/ha de CatBoost (figura 9.18), lo que indica que LightGBM amplifica más el efecto de las parcelas de alta densidad.
- **Importancia de la especie.** especie_id* ocupa la segunda posición en ambas figuras, con una cola derecha pronunciada que refleja el efecto diferencial de determinadas especies sobre la acumulación de carbono. La dispersión es comparable entre modelos.
- **Variables de estructura forestal frente a climáticas.** LightGBM (figura 9.17) otorga mayor peso relativo a tipo_especie* y periodo_agrupado*, mientras que CatBoost (figura 9.18) incorpora pr_sum_otoño entre las variables más relevantes, sugiriendo una mayor sensibilidad a señales climáticas.
- **Efecto del período.** periodo_agrupado* aparece en quinta posición en LightGBM (figura 9.17), con valores rojos (IFN2) que empujan la predicción hasta +50 tC/ha. En CatBoost (figura 9.18) este efecto es menos pronunciado, lo que sugiere que LightGBM captura con mayor intensidad el crecimiento forestal acumulado entre inventarios.
- **Consistencia en variables secundarias.** Variables climáticas y edáficas como gndvi_mean_verano, skt_mean_verano y evi_mean_primavera aparecen en ambas figuras con efectos SHAP pequeños y simétricos, lo que indica que su contribución marginal es robusta entre modelos pero de segundo orden respecto a los factores estructurales del arbolado.

10. Conclusiones

Cosas que comentar (informal, hay que ponerlo a limpio):

- Las métricas son bastante buenas, sobre todo para los modelos que se han entrenado solo con el IFN3 y sobre todo para la predicción del carbono total.
- Igualmente, los datos son muy poco uniformes. Por ejemplo, hay muchos datos de un año, muy pocos de otros. Esto es de esperar por la naturaleza de los datos: cubren una extensión muy grande con mucho detalle en cada parcela (sobre todo el IFN3).
- Esta es la principal limitación del estudio, porque queda claro que los modelos son capaces de entender el comportamiento de los sistemas.
- En el paper [26] hacen una cosa similar a la que hacemos nosotros aquí. Además es en una región muy cercana, del norte de Italia. Aunque no hacen exactamente lo mismo que nosotros, ya que ellos predicen el carbono presente en el mismo momento de la medición mediante observaciones del bosque “desde fuera”, es decir, sin utilizar como entrada datos medidos en el propio bosque (datos meteorológicos, del terreno y LiDAR), los resultados que obtienen tienen un error notablemente mayor que los nuestros. Sobre todo para predicción más temprana que hacemos (a 5 años), que es lo más parecido a ellos.
- Los modelos stacking sacan métricas muy ligeramente mejores que los mejores modelos base. Por otro lado, el esfuerzo necesario para obtenerlos y usarlos es notablemente mayor, así que puede que no esté justificado el uso de modelos tan complejos en un hipotético sistema en producción. No obstante, esta bien haber podido subir un poco las métricas.
- Para su uso en producción como sistema de recomendación de proyectos de carbono habría que hacer algunas comprobaciones. Esto es, los datos están cogidos de los bosques. Hay que comprobar cómo se parece un bosque a una plantación de un proyecto de carbono (por tema de densidades principalmente). Por otro lado, el “recomendador de especies” (la idea que teníamos de tener un sitio para plantar y que el sistema recomedase una u otra en función de qué podría absorber más carbono) debería poder usarse igualmente bien.
- Como idea para un futuro trabajo, podría estar muy interesante usar medidas LiDAR. En otros estudios las usan y obtienen muy buenos resultados.

de Recuperación y Resiliencia de la UE (*NextGenerationEU/PRTR*).

11. Recomendaciones para Futuras Investigaciones

Agradecimientos

Investigación financiada por la subvención **TSI-100933-2023-1** de la **Convocatoria de Cátedras Universidad-Empresa (Cátedras ENIA 2022)**, **Ministerio de Transformación Digital y Función Pública de España**, y el **Plan**

Referencias

- [1] I. P. on Climate Change, Climate Change 2007: Mitigation of Climate Change, Cambridge University Press, Cambridge, UK, 2007.
- [2] U. N. F. C. on Climate Change, The Kyoto protocol, 1997. URL: <https://unfccc.int/resource/docs/convkp/kpeng.pdf>.
- [3] U. N. F. C. on Climate Change, Paris agreement, 2015. URL: <https://unfccc.int/process-and-meetings/the-paris-agreement/the-paris-agreement>.
- [4] U. N. F. C. on Climate Change, Decision 16/cmp.1: Land use, land-use change and forestry, Conference of the Parties serving as the meeting of the Parties to the Kyoto Protocol, 2005. URL: <https://unfccc.int/resource/docs/2005/cmp1/eng/08a03.pdf>, acuerdos de Marrakech.
- [5] U. N. F. C. on Climate Change, Report of the individual review of the initial report of Spain under the Kyoto protocol, UNFCCC Secretariat, 2010. URL: https://unfccc.int/files/kyoto_protocol/compliance/plenary/application/pdf/cc-ert-irr-2007-14_report_of_the_review_of_ir_of_spain.pdf, incluye la definición nacional de bosque de España: 1 ha, 20 % de cabida cubierta, 3 m de altura.
- [6] E. Union, Regulation (eu) 2018/841 on the inclusion of greenhouse gas emissions and removals from land use, land use change and forestry, Official Journal of the European Union, 2018. URL: <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX:32018R0841>, marco LULUCF y principios de permanencia y contabilidad de sumideros.
- [7] MITECO, Inventario forestal nacional (ifn2, ifn3, ifn4): metodología y bases de datos, Ministerio para la Transición Ecológica y el Reto Demográfico (España), 2023. URL: <https://www.miteco.gob.es/es/biodiversidad/servicios/banco-datos-naturaleza/informacion-disponible/ifn.aspx>.
- [8] J. Muñoz-Sabater, E. Dutra, A. Agustí-Panareda, C. Albergel, G. Arduini, G. Balsamo, et al., Era5-land: A state-of-the-art global reanalysis at land surfaces, EGU General Assembly / ECMWF (Copernicus Climate Data Store) (2021).
- [9] USGS, Landsat collection 2 level-2 science products: Surface reflectance, U.S. Geological Survey, 2021. URL: <https://www.usgs.gov/landsat-missions/landsat-collection-2-level-2-science-products>.
- [10] M. A. U. Jiménez, J. G. Vegas, A. de Luis Reboledo, B. P. Lancho, Greenwest-db: Base de datos integrada de atributos forestales, climáticos y espectrales para España, 2025. Manuscrito en preparación. Universidad de Salamanca, Grupo BISITE.
- [11] C. Brack, History of inventory, 2000. URL: <https://fennerschool-associated.anu.edu.au/mensuration/history.htm>, accessed: 2026-01-22.
- [12] L. Shi, S. Liu, Methods of estimating forest biomass: A review, Biomass Volume Estimation and Valorization for Energy 10 (2017) 65733.
- [13] Y. Shang, Y. Xia, X. Ran, X. Zheng, H. Ding, Y. Fang, Allometric equations for aboveground biomass estimation in natural forest trees: Generalized or species-specific?, Diversity 17 (2025) 493.
- [14] L. Qi, X. Liu, Z. Jiang, X. Yue, Z. Li, J. Fu, G. Liu, B. Guo, L. Shi, Combining diameter-distribution function with allometric equation in biomass estimates: a case study of *Phyllostachys edulis* forests in south anhui, China, Agroforestry Systems 90 (2016) 1113–1121.
- [15] J. Nyakudanga, The treemes story, 2018. URL: <https://saforestryonline.co.za/articles/the-treemes-story/>.
- [16] A. Kristiansen, The terrestrial laser scanning revolution in forest ecology, Royal Society Blog, 2018. URL: <https://royalsociety.org/blog/2018/02/the-terrestrial-laser-scanning-revolution-in-forest-ecology/>.
- [17] OpenTopography, What is lidar?, OpenTopography, 2024. URL: https://opentopography.org/lidar_basics.
- [18] J.-R. Roussel, T. R. Goodbody, P. Tompalski, Individual tree detection and segmentation, 2024. URL: <https://r-lidar.github.io/lidRbook/itd.html>.
- [19] Instituto Geográfico Nacional, Tercera cobertura PNOA-LiDAR, Plan Nacional de Ortofotografía Aérea, 2023. URL: <https://pnoa.ign.es/web/portal/pnoa-lidar/tercera-cobertura>.
- [20] S. J. Goetz, A. Baccini, N. T. Laporte, T. Johns, W. Walker, J. Kellndorfer, R. A. Houghton, M. Sun, Mapping and monitoring carbon stocks with satellite observations: a comparison of methods, Carbon Balance and Management 4 (2009) 2.
- [21] J. Ren, L. Liu, Y. Wu, L. Ouyang, Z. Yu, Estimating forest carbon stock using enhanced resnet and sentinel-2 imagery, Forests 16 (2025) 1198. Submission received: 13 June 2025 / Revised: 15 July 2025 / Accepted: 18 July 2025 / Published: 20 July 2025.
- [22] F. Jiang, M. Deng, J. Tang, L. Fu, H. Sun, Integrating spaceborne lidar and sentinel-2 images to estimate forest aboveground biomass in northern China, Carbon Balance and Management 17 (2022) 12.
- [23] G. Reiersen, D. Dao, B. Lütjens, K. Klemmer, K. Amara, A. Steinegger, C. Zhang, X. Zhu, Reforestree: A dataset for estimating tropical forest carbon stock with deep learning and aerial imagery, arXiv preprint arXiv:2201.11192 (2022).
- [24] W. Dong, E. T. Mitchard, H. Yu, S. Hancock, C. M. Ryan, Forest aboveground biomass estimation using GEDI and earth observation data through attention-based deep learning, arXiv preprint arXiv:2311.03067 (2023).
- [25] Ministerio para la Transición Ecológica y el Reto Demográfico, Instrucciones de uso de la calculadora de absorciones de CO₂ ex ante de las especies forestales arbóreas españolas del Ministerio para la Transición Ecológica y el Reto Demográfico, 2023. URL: https://www.miteco.gob.es/content/dam/miteco/es/cambio-climatico/temas/mitigacion-politicas-y-medidas/instruccionescalculadoraabaxante_tcm30-485629.pdf, accedido: 2025-07-16.
- [26] M. Fasihi, B. Portelli, L. Cadez, A. Tomao, A. Falcon, G. Alberti, G. Serra, Assessing ensemble models for carbon sequestration and storage estimation in forests using remote sensing data, Ecological Informatics 83 (2024) 102828.
- [27] J. Muñoz Sabater, Era5-land hourly data from 1950 to present, Copernicus Climate Change Service (C3S) Climate Data Store (CDS), 2019. URL: <https://cds.climate.copernicus.eu/cdsapp#!/dataset/reanalysis-era5-land?tab=overview>. doi:10.24381/cds.e2161bac, accedido: 07-07-2025.
- [28] P. Berg, C. Photiadou, L. Simonsson, E. Sjökvist, J. Thureson, R. Mook, Temperature and precipitation climate impact indicators from 1970 to 2100 derived from European climate projections, Copernicus Climate Change Service (C3S) Climate Data Store (CDS), 2021. URL: <https://cds.climate.copernicus.eu/cdsapp#!/dataset/sis-water-quantity-change?tab=overview>. doi:10.24381/cds.9eed87d5, accedido: 07-07-2025.
- [29] USGS, Usgs Landsat 5 level 2, collection 2, tier 1, 2025. URL: https://developers.google.com/earth-engine/datasets/catalog/LANDSAT_LT05_C02_T1_L2, accedido: 2025-07-08.
- [30] I. P. on Climate Change, 2006 IPCC Guidelines for National Greenhouse Gas Inventories, IPCC, Geneva, Switzerland, 2006.
- [31] J. Chave, M. Réjou-Méchain, A. Búrquez, E. Chidumayo, M. S. Colgan, W. B. C. Delitti, A. Duque, T. Eid, P. M. Fearnside, R. C. Goodman, M. Henry, A. Martínez-Yrizar, W. A. Mugasha, H. C. Muller-Landau, M. Mencuccini, B. W. Nelson, A. Ngomanda, E. M. Nogueira, E. Ortiz-Malavassi, R. Pélissier, P. Ploton, C. M. Ryan, J. G. Saldarriaga, G. Vieilledent, Improved allometric models to estimate the aboveground biomass of tropical trees, Global Change Biology 20 (2014) 3177–3190.
- [32] M. para la Transición Ecológica y el Reto Demográfico (MITECO), Guía para la estimación de absorciones de dióxido de carbono, 2021. URL: https://www.miteco.gob.es/content/dam/miteco/es/cambio-climatico/temas/mitigacion-politicas-y-medidas/guiapa_tcm30-479094.pdf.
- [33] G. M. R. R.-P. y M. Muñoz, Producción de biomasa y fijación de CO₂ por los bosques españoles, Instituto Nacional de Investigación y Tecnología Agraria y Alimentaria (INIA), Madrid, España, 2009. Serie Forestal, 23.
- [34] M. d. R. y G. M. Ricardo Ruiz-Peinado, New models for estimating the carbon sink capacity of Spanish softwood species, Forest Systems 20 (2011) 176–188.

- [35] Ministerio para la Transición Ecológica y el Reto Demográfico (MITECO), Manual de campo y base de datos del cuarto inventario forestal nacional (ifn4), 2017. URL: https://www.miteco.gob.es/es/biodiversidad/temas/inventarios-nacionales/inventario-forestal-nacional/cuarto_inventario.html, subdirección General de Política Forestal y Lucha contra la Desertificación.

A. Apéndices

A.1. Origen y cálculo de las variables ca y cr

Las variables ca (carbono arbóreo) y cr (carbono radical) incluidas en la base de datos del *Inventario Forestal Nacional* (IFN4) derivan de las ecuaciones alométricas de biomasa desarrolladas por el *Instituto Nacional de Investigación y Tecnología Agraria y Alimentaria* (INIA), en particular por *Gregorio Montero y Ricardo Ruiz-Peinado* [33, 34]. Estas ecuaciones fueron elaboradas a partir de datos de campo obtenidos mediante talas y pesadas directas de árboles de distintas especies representativas de la flora forestal española.

Cada ecuación estima la biomasa seca (en kilogramos) de los diferentes componentes del árbol en función del diámetro normal (D , en cm, medido a 1,3 m del suelo) y la altura total (H , en m). Para cada especie o grupo de especies similares se dispone de ecuaciones específicas de la forma:

$$W_i = a_i \cdot D^{b_i} \cdot H^{c_i}$$

donde W_i representa la biomasa del componente i (fuste, corteza, ramas, hojas, raíces, etc.), y a_i , b_i y c_i son coeficientes empíricos obtenidos mediante regresión no lineal. En los casos en que una especie no dispone de ecuación propia, se utiliza la de otra especie considerada análoga por similitud morfológica o ecológica.

Los componentes de biomasa definidos en el IFN4 incluyen [35]:

- W_s : biomasa del fuste (kg),
- W_c : biomasa de la corteza del fuste (kg),
- W_{b7} : biomasa de ramas mayores de 7 cm de diámetro (kg),
- W_{b2-7} : biomasa de ramas entre 2 y 7 cm de diámetro (kg),
- $W_{b0,5-2}$: biomasa de ramas entre 0,5 y 2 cm de diámetro (kg),
- W_r : biomasa de ramas menores de 0,5 cm de diámetro (kg),
- W_h : biomasa de hojas (kg),
- W_{db} : biomasa de ramas muertas (kg),
- $W_T = W_s + W_c + W_{b7} + W_{b2-7} + W_{b0,5-2} + W_r + W_h$: biomasa aérea total (kg),
- W_r : biomasa radical (raíces, kg).

A partir de estas ecuaciones, el cálculo de biomasa y carbono en el IFN4 se realiza de la siguiente forma:

1. **Biomasa por árbol (kg):** en la tabla *Mayores_exs* se incluyen las medidas de diámetro y altura de cada pie. Aplicando las ecuaciones alométricas correspondientes se obtiene la biomasa aérea (W_T) y radical (W_r) para cada árbol.
2. **Conversión a carbono (kg):** se aplica un factor de conversión estándar de 0,5, según las directrices del IPCC [30], de forma que:

$$CA = 0,5 \times W_T, \quad CR = 0,5 \times W_r$$

3. **Expansión a valores por hectárea (t/ha):** los valores por árbol se convierten a toneladas por hectárea mediante un *factor de expansión* (Fac), que refleja la densidad de árboles por unidad de superficie dentro de cada clase diamétrica y especie. Este factor se calcula en función del número de pies inventariados y la superficie de muestreo, permitiendo expresar los resultados en términos comparables de biomasa o carbono por hectárea.
4. **Agregación por clases diamétricas y especie:** finalmente, en la tabla *Parcelas_exs* se agrupan los valores por parcela, especie y clase diamétrica (CD), sumando las contribuciones individuales ya expandidas. El resultado son los valores medios de biomasa y carbono por hectárea (t/ha) para cada combinación de parcela y especie.

El mismo procedimiento se aplica tanto a la biomasa aérea (para obtener ca) como a la biomasa radical (para cr). De esta forma, **ca y cr representan el carbono almacenado en la biomasa viva, aérea y subterránea respectivamente, expresado en toneladas de carbono por hectárea (t/ha).**

Este enfoque metodológico se ajusta a las recomendaciones del *IPCC Guidelines for National Greenhouse Gas Inventories* [30], garantizando la coherencia con los métodos de reporte de carbono a nivel internacional y facilitando la comparación de los resultados con otros estudios y marcos regulatorios.

A.2. Estado de las Poblaciones (*estado_id*)

Se determinarán las fases de desarrollo de las *poblaciones* codificándose de la siguiente forma:

1. **Replantado.** Conjunto de pies que desde el estrato herbáceo llega hasta el subarborescente y los pies inician la tangencia de copas.
2. **Monte bravo.** Comprende desde el estrato y clase de edad anterior hasta el momento en que por efecto del crecimiento, los pies empiezan a perder las ramas inferiores; es decir que en esta clase de edad, las ramas se encuentran a lo largo de todo el fuste.
3. **Latizal.** Comprende desde la clase anterior hasta que los pies tienen 20 cm de diámetro normal; es decir, el diámetro de su fuste, medido a la altura de 1,30 m del suelo.
4. **Fustal.** Se caracteriza esta clase de edad, porque sus pies tienen diámetros normales superiores a 20 cm.

A.3. Forma Principal de Masa (IFN3 e IFN4: *fpmasa_id*)

1. **Coetánea.** Cuando al menos el 90 % de sus pies tienen la misma edad individual. Ejemplo típico: las repoblaciones.
2. **Regular.** Cuando al menos el 90 % de sus pies pertenecen a la misma clase artificial de edad o misma clase diamétrica en su defecto.
3. **Semirregular.** Cuando al menos el 90 % de sus pies pertenecen a dos clases artificiales de edad cíclicamente contiguas o dos clases diamétricas contiguas en su defecto.

4. **Irregular.** Cuando no se cumplen las condiciones anteriores, es decir, cuando en cualquier parte de la masa existen pies más o menos mezclados, de todas las clases de edad que tiene la masa o de varias clases diamétricas en su defecto.

A.4. Tratamiento de la Masa (IFN3 e IFN4: *tratmasa_id*)

1. **Monte alto.** Cuando todos los pies proceden de semilla.
2. **Monte medio.** Cuando coexisten pies de la misma especie, unos procedentes de semilla (brinzales) y otros de brote (chirpiales).
3. **Monte bajo.** Cuando todos los pies proceden de brote de cepa o de raíz.

A.5. Origen de la Masa (IFN3 e IFN4: *orgmasa_id*)

1. **Natural.** Bosque desarrollado espontáneamente, sin intervención humana directa.
2. **Artificial.** Plantado intencionadamente por el ser humano.
3. **Naturalizado.** Bosque originalmente plantado pero que ha evolucionado hacia una estructura más similar a un bosque natural.

A.6. Tipo de Suelo (*tipsuelo1_id*, *tipsuelo2_id*, *tipsuelo3_id*)

Se utilizará la siguiente codificación para el tipo de suelo, diferenciando tres variables:

Tipo de suelo (I): Presencia de sales, yesos o hidromorfía

1. **No se observan sales, yesos ni procesos de hidromorfía.**
2. **Suelo salino.** Si presenta al menos dos de las siguientes características:
 - Presencia de eflorescencias en la superficie o a distintas profundidades.
 - Existencia de plantas halófitas.
 - Zonas llanas o endorreicas con climas secos que provocan gran evaporación.
3. **Suelo yesífero.** Si presenta alguna de las siguientes características:
 - Presencia de materia yesífera en superficie o a distintas profundidades.
 - Existencia de plantas gipsófilas.
4. **Suelo hidromorfo.** Si el suelo presenta síntomas de hidromorfía acusada, cumpliendo al menos dos de las siguientes:
 - Zona encharcada permanente o casi permanentemente de forma natural.
 - Zona llana o endorreica con climas húmedos.
 - Grietas en verano si no hay encharcamiento.
 - Presencia de vegetación indicadora de hidromorfismo.

Identificándose las siguientes:

- Formaciones vegetales indicadoras de hidromorfía:
 - Ribereñas: *saucedas*, *mimbreras*, *alisedas*.
 - Brezales con *Erica ciliaris*, *Erica tetralix*.
 - Turberas arboladas (excepto Cornisa Cantábrica y Pirineos).
 - Turberas de montaña con *Sphagnum*, *Erica tetralix*.
 - Cervunales con *Nardus stricta*.
 - Carrizales y espadañares (*Phragmites*, *Tipha*, *Cladium*).
 - Juncuales (*Scirpus*, *Juncus*).
 - Pastizales con cárices (*Carex spp.*).
 - Marismas.
- Formaciones vegetales gipsófilas:
 - Aznallar: matorral de *Ononis tridentata*.
 - Tomillares gipsófilos con:
 - *Lepidium subulatum*
 - *Gypsophila spp.*
 - *Matthiola fruticulosa*
- Formaciones vegetales indicadoras de suelos salinos:
 - Salicorniales: matas leñosas crasas (*Salicornia*, *Arthrocnemum*, *Halozyton*).
 - Bosques halófitos del género *Tamarix*.
 - Saladar o sosar: predominio de *Suaeda vera*.
 - Saladar blanco: predominio de *Atriplex halimus*.

Tipo de suelo (II y III): Composición del suelo (calizo o silíceo)

1. **Suelo calizo.** Más del 50 % de la vertical del perfil da efervescencia con ácido clorhídrico.
 - **Moderadamente básico:** pH en superficie ≤ 8.5 .
 - **Fuertemente básico:** pH en superficie > 8.5 .

2. **Suelo silíceo.** Menos del 50 % de la vertical del perfil da efervescencia.

- **Moderadamente ácido:** pH ≥ 5.5 .
- **Fuertemente ácido:** pH < 5.5 .

A.7. Rocosidad (rocosidad_id)

Se considerará el conjunto de la parcela clasificando la rocosidad según la siguiente codificación:

1. **Sin pedregosidad:** la superficie de la parcela está completamente cubierta de vegetación.
2. **Poco pedregoso:** cuando la superficie de la parcela cubierta por rocas coherentes es menor del 25 %.
3. **Pedregoso:** cuando la superficie rocosa está comprendida entre el 25 % y el 50 %.
4. **Muy pedregoso:** cuando la superficie rocosa se sitúa entre el 50 % y el 75 %.
5. **Roquedo:** cuando la superficie de rocas es mayor del 75 %. En este caso, no se tomará ningún dato adicional correspondiente a suelos.

A.8. Textura del Suelo (textura_id)

Se clasificará en función de la siguiente codificación:

1. **Suelo arenoso.** Si los cilindros se deshacen sin apenas formarse.
2. **Suelo franco.** Es posible hacer cilindros gruesos pero no delgados.
3. **Suelo arcilloso.** Se consiguen cilindros de unos 5 mm de diámetro.

A.9. Contenido en Materia Orgánica (IFN3 e IFN4: matorg_id)

Según la siguiente clasificación:

1. **Suelo muy húmifero.** Cuando a 15 cm la pureza es menor de 4, o cuando la capa de broza sea de espesor mayor de 5 cm y a 15 cm de profundidad la pureza sea menor de 6.
2. **Suelo moderadamente húmifero.** Cuando a 15 cm la pureza sea menor de 6 con capa de broza nula o de escaso espesor, o cuando dicha capa tenga espesor mayor de 5 cm y a 15 cm de profundidad la pureza sea igual o mayor de 6.
3. **Suelo poco húmifero.** En los restantes casos.

A.10. Modelo de Combustible (IFN3 e IFN4: modcomb_id)

Se determinará la clase de combustible que es más probable que propague el fuego si hubiese un incendio en la zona, hasta un máximo de 60m: pasto, matorral, hojarasca de bosque o deshechos o restos de corta. Se determinará el modelo de combustible a partir de la siguiente clave:

Tabla A.1: Descripción de los modelos de combustible del Inventario Forestal Nacional, clasificados por grupo funcional.

GRUPO	MOD.	DESCRIPCIÓN DEL MODELO
Pastos	1	Pasto fino, seco y bajo, que recubre completamente el suelo. Puede aparecer algunas plantas leñosas dispersas ocupando menos de 1/3 de la superficie.
	2	Pasto fino, seco y bajo, que recubre completamente el suelo. Las plantas leñosas dispersas cubren de 1/3 a 2/3 de la superficie; pero la propagación del fuego se realiza por el pasto.
	3	Pasto grueso, denso, seco y alto (>1 m). Puede haber algunas plantas leñosas dispersas. Los campos de cereales son representativos de este modelo.
Matorral	4	Matorral o plantación joven muy densa; de más de 2 m de altura; con ramas muertas en su interior. Propagación del fuego por las copas de las plantas.
	5	Matorral disperso, denso y verde, de menos de 1 m de altura. Propagación del fuego por la hojarasca, el pasto, las ramillas y el matorral.
	6	Parecido al modelo 5, pero con especies más inflamables, de mayor talla, pudiéndose encontrar ramas gruesas en el suelo. Propagación del fuego con vientos moderados a fuertes.
	7	Matorral de especies muy inflamables; de 0.5 a 2 m de altura, situado como sotobosque en masas de coníferas.
Hojarasca bajo arbolado	8	Bosque denso, sin matorral. Propagación del fuego por la hojarasca muy compacta, formada por acículas cortas (5 cm o menos) o por hojas planas no muy grandes.
	9	Parecido al modelo 8, pero con hojarasca menos compacta, formada por acículas largas y rígidas (P. pinaster) o follaje de frondosas de hoja grande, caducas (castaño o robles).
	10	Bosque con gran cantidad de leña y árboles caídos, como consecuencia de vendavales, plagas intensas, etc.
Restos de corta y operaciones selvícolas	11	Bosque claro y fuertemente aclarado. Restos de poda o aclareo ligeros (diámetro <7.5 cm).
	12	Predominio de los restos sobre el arbolado. La hojarasca y el matorral presente ayudarán a la propagación del fuego.
	13	Grandes acumulaciones de restos gruesos y pesados, cubriendo todo el suelo.

A.11. Distribución Espacial (disesp_id)

La disposición de la vegetación en el espacio se clasificará según la siguiente codificación:

1. **Uniforme.** Cuando el estrato arbóreo presenta continuidad en el espacio.
2. **Diseminada en bosquetes aislados.** Cuando la masa arbórea se encuentra dividida en porciones que tienen una superficie inferior a 0,5 ha.
3. **Diseminada en individuos aislados.** Cuando se trata de dehesas.
9. **Otras o no se sabe.** En caso diferente a los anteriores o si se desconoce el dato exacto.

A.12. Composición Específica (comesp_id)

En función de las especies presentes:

1. **Masas homogéneas o puras.** Masas monoespecíficas con una única especie arbórea. La normativa española precisa que una masa es monoespecífica o pura cuando al menos el 90 % de los pies pertenecen a la misma especie.
2. **Masas heterogéneas o mezcladas pie a pie.** Masas de diferentes especies que se juntan o bien se entremezclan por golpes o grupos, siempre que tengan una altura similar.
3. **Masas heterogéneas o mezcladas con subpiso.** Las dos o más especies mezcladas, cuando alcancen el estado adulto y la estabilidad, presentarán alturas diferentes.
9. **Otras o no se sabe.** En caso diferente a los anteriores o desconocer el dato exacto.

A.13. Manifestaciones Erosivas (merosiva_id)

Se observará la parcela y sus alrededores hasta una distancia de 60 metros desde el centro, y se codificará la existencia de manifestaciones erosivas según la siguiente clave:

1. **No hay ninguna manifestación.**
2. **Cuellos de raíces al descubierto:** los cuellos de las raíces están visibles, con acumulación de residuos aguas arriba de los tallos y obstáculos, así como abundancia superficial de piedras.
3. **Presencia de regueros:** canales paralelos de erosión con una profundidad máxima de un palmo (aproximadamente 20 cm).
4. **Cárcavas y barrancos en V:** erosión lineal más profunda que los regueros, con forma de “V”.
5. **Cárcavas y barrancos en U:** erosión avanzada con formas suavizadas y amplias en “U”.
6. **Deslizamientos del terreno:** desplazamientos de masas de tierra, ladera o materiales del suelo.

A.14. Nivel de usos del suelo (IFN3 e IFN4: nivel1_id)

1. **Monte.** Toda superficie en la que vegetan especies arbóreas, arbustivas, de matorral o herbáceas, ya sea espontáneamente o procedan de siembra o plantación, siempre que no sean características de cultivo agrícola o fueran objeto del mismo.
2. **Agrícola.** Territorio o ecosistema poblado con siembras o plantaciones de herbáceas y/o leñosas, anuales o plurianuales que se laborean con una fuerte intervención humana, puede estar poblado por especies forestales de fruto (flor, hojas o en el futuro biomasa) siempre que la intervención humana sea importante. Incluye las dehesas, montes huecos o montes adehesados de base cultivo, siempre que la fracción de cabida cubierta de los árboles sea inferior al 5 %.
3. **Artificial.** Territorio o ecosistemas dominado por edificios, parques urbanos (aunque estén poblados de árboles), viveros fuera de los montes (aunque sean de especies forestales), carreteras (salvo las vías de servicio de los montes) u otras construcciones humanas que tengan superficies continuas.
4. **Humedal.** Lo constituyen las lagunas, charcas, zonas húmedas, marismas y corrientes discontinuas de agua en las que, al menos durante 6 meses del año, esté presente dicho líquido.
5. **Agua.** Es la parte de la tierra constituida por ríos, lagos, embalses, canales o estanques con superficies continuas de más de 0.26 ha y con agua prácticamente todo el año.

A.15. Nivel morfoestructural (IFN3 e IFN4: nivel2_id)

Para el nivel de usos del suelo Monte se definirán los siguientes niveles morfoestructurales.

1. **Monte arbolado.** Territorio o ecosistema con especies forestales arbóreas como manifestación vegetal de estructura vertical dominante y con una fracción de cabida cubierta igual o superior al 20 %; incluye dehesas con base cultivo o pastizal con labores siempre que la fracción arbolada supere el 20 %, y excluye terrenos con fuerte intervención humana para obtener frutos, hojas, flores o varas.
2. **Monte arbolado ralo.** Terreno de uso forestal con especies arbóreas forestales dominantes y fracción de cabida cubierta entre el 10 % y 20 % (incluido el 10 %, excluido el 20 %); también aplica a terrenos con matorral o pastizal natural como dominantes, pero con presencia importante de árboles forestales, incluyendo dehesas de base de cultivo.

Tabla A.2

Relación de códigos de grupo taxonómico utilizados en la variable grupo_id.

Código	Grupo taxonómico	Código	Grupo taxonómico
7	Acacia	69	Phoenix
15	Crataegus	73	Betula
19	Coníferas	77	Tilia
20	Pinos	78	Sorbus
31	Abies	79	Platanus
35	Larix	80	Laurisilva
40	Quercus	91	Buxus
53	Tamarix	93	Pistacia
57	Salix	94	Laurus
58	Populus	95	Prunus
60	Eucalyptus	99	Frondosas
65	Ilex	399	Morus
68	Arbutus	455	Fraxinus
917	Cedrus	936	Cupressus
937	Juniperus	956	Ulmus
975	Juglans	976	Acer
997	Sambucus		

3. **Monte temporalmente desarbolado.** Terreno que fue monte arbolado recientemente y que casi con seguridad volverá a estar cubierto de árboles en un futuro próximo.
4. **Monte desarbolado.** Terreno con matorral y/o pastizal natural o débil intervención humana como cobertura dominante, con fracción de cabida cubierta por árboles forestales inferior al 5 %.
5. **Monte sin vegetación superior.** Terreno de uso forestal que no está poblado por vegetales superiores debido a condiciones actuales de suelo, clima o topografía, aunque podría estarlo en otras circunstancias.
6. **Árboles fuera del monte.** Incluye riberas arboladas no estructuradas con los montes, bosquetes de menos de 2.500 m², alineaciones de especies arbóreas o arbustivas de menos de 25 m de anchura, y árboles sueltos en terreno forestal.
7. **Monte arbolado disperso.** Terreno forestal con especies arbóreas dominantes y fracción de cabida cubierta entre el 5 % y el 10 % (incluido el 5 %, excluido el 10 %); también terrenos con matorral o pastizal como cobertura dominante pero con presencia significativa de árboles forestales, incluyendo dehesas de base cultivo.

A.16. Código de los grupos taxonómicos de las especies (grupo_id)**A.17. Código de las especies (especie_id)**

Tabla A.3: Relación de especies empleadas en el estudio y metadatos asociados.

Cód.	Nombre	Sinonimia	Tipo	Grupo
307	Acacia dealbata	Acacia dealbata	1	7
207	Acacia melanoxylon	Acacia melanoxylon	1	7
7	Acacia spp.	-	1	7
392	Gleditsia triacanthos	Acacia gleditsia	1	7
92	Robinia pseudoacacia	Acacia robinia	1	7
292	Sophora japonica	Acacia sofora	1	7
515	Crataegus azarolus	Espino	1	15
415	Crataegus laciniata	Majoleto	1	15
315	Crataegus laevigata	Espino majuelo	1	15
215	Crataegus monogyna	Majuelo	1	15
15	Crataegus spp.	-	1	15
30	Mezcla de coníferas	Coníferas l excepto pinos	0	19
19	Otras coníferas	-	0	19
29	Otros pinos	-	0	20
20	Pinos	-	0	20
27	Pinus canariensis	-	0	20
24	Pinus halepensis	-	0	20
25	Pinus nigra	Pinus laricio l Pinus clusiana	0	20
26	Pinus pinaster	Pinus maritima	0	20

Continúa en la siguiente página

Tabla A.3: Relación de especies (continuación).

Cód.	Nombre	Sinonimia	Tipo	Grupo
23	Pinus pinea	-	0	20
28	Pinus radiata	Pinus insignis	0	20
21	Pinus sylvestris	-	0	20
22	Pinus uncinata	Pinus montana Pinus mugo	0	20
31	Abies alba	Abies pectinata	0	31
32	Abies pinsapo	-	0	31
235	Larix decidua	Alerce común	0	35
335	Larix leptolepis	Larix kaempferi Alerce leptolepis	0	35
35	Larix spp.	-	0	35
435	Larix x eurolepis	Alerce híbrido	0	35
49	Otros quercus	-	1	40
344	Quercus alpestris	-	1	40
47	Quercus canariensis	Quercus lusitanica var. baetica	1	40
44	Quercus faginea	Quercus lusitanica var. faginea	1	40
45	Quercus ilex ssp. ballota	Quercus rotundifolia	1	40
245	Quercus ilex ssp. ilex	-	1	40
244	Quercus lusitanica	Quercus fruticosa Quejigueta	1	40
42	Quercus petraea	Quercus sessiliflora	1	40
243	Quercus pubescens	Quercus pubescens Quercus humilis	1	40
43	Quercus pyrenaica	Quercus toza	1	40
41	Quercus robur	Quercus pedunculata	1	40
48	Quercus rubra	Quercus borealis	1	40
46	Quercus suber	-	1	40
253	Tamarix canariensis	Tarajal	1	53
53	Tamarix spp.	-	1	53
257	Salix alba	Sauce blanco	1	57
357	Salix atrocinerea	Bardaguera	1	57
858	Salix canariensis	Sauce canario	1	57
557	Salix cantabrica	Sauce cantábrico	1	57
657	Salix caprea	Sauce cabruno	1	57
757	Salix elaeagnos	Sarga	1	57
857	Salix fragilis	Mimbre	1	57
957	Salix purpurea	Mimbrera	1	57
57	Salix spp.	-	1	57
51	Populus alba	-	1	58
58	Populus nigra	-	1	58
52	Populus tremula	-	1	58
258	Populus x canadensis	Populus x euroamericana	1	58
62	Eucalyptus camaldulensis	Eucalyptus rostrata	1	60
61	Eucalyptus globulus	-	1	60
364	Eucalyptus gomphocephalus	Eucalipto gonfo	1	60
64	Eucalyptus nitens	-	1	60
464	Eucalyptus robusta	-	1	60
264	Eucalyptus viminalis	Eucalipto viminalis	1	60
63	Otros eucaliptos	-	1	60
65	Ilex aquifolium	-	1	65
82	Ilex canariensis	-	1	65
282	Ilex platyphylla	Naranjero	1	65
268	Arbutus canariensis	Madroño canario	1	68
68	Arbutus unedo	-	1	68
469	Phoenix canariensis	Palmera	1	69
69	Phoenix spp.	-	1	69
273	Betula alba	Betula verrucosa Abedul pubescens	1	73
373	Betula pendula	Betula hispanica Abedul péndula	1	73
73	Betula spp.	-	1	73
277	Tilia cordata	Tilo cordata	1	77
377	Tilia platyphyllos	Tilo común	1	77
77	Tilia spp.	-	1	77
278	Sorbus aria	Mostajo	1	78
378	Sorbus aucuparia	Serbal de cazadores	1	78
778	Sorbus chamaemespilus	Serbal chame	1	78
478	Sorbus domestica	Serbal común	1	78
678	Sorbus latifolia	Serbal de hoja ancha	1	78
78	Sorbus spp.	-	1	78
578	Sorbus torminalis	Serbal torminal	1	78
79	Platanus hispanica	Platanus hybrida	1	79
279	Platanus orientalis	Plátano oriental	1	79

Continúa en la siguiente página

Tabla A.3: Relación de especies (continuación).

Cód.	Nombre	Sinonimia	Tipo	Grupo
80	Laurisilva	-	1	80
89	Otras laurisilvas	-	1	80
291	Buxus balearica	Boj de Baleares	1	91
91	Buxus sempervirens	-	1	91
293	Pistacia atlantica	Cornicabra canaria	1	93
93	Pistacia terebinthus	Cornicabra	1	93
294	Laurus azorica	Laurel canario	1	94
94	Laurus nobilis	Laurel	1	94
395	Prunus avium	Cerezo silvestre	1	95
495	Prunus lusitanica	Loro l hija	1	95
595	Prunus padus	Prunus	1	95
295	Prunus spinosa	Espino negro	1	95
95	Prunus spp.	Prunus	1	95
70	Mezcla de frondosas de gran porte	Frondosas de gran porte (H.t. >10 m)	1	99
90	Mezcla de pequeñas frondosas	Frondosas de pequeño porte (H.t. ≤ 10 m)	1	99
99	Otras frondosas	Otras frondosas	1	99
499	Morus alba	Morera	1	399
599	Morus nigra	Morera	1	399
399	Morus spp.	Morera	1	399
55	Fraxinus angustifolia	-	1	455
255	Fraxinus excelsior	Fresno excelsior	1	455
355	Fraxinus ornus	Fresno orno	1	455
955	Fraxinus spp.	Fresnos	1	455
17	Cedrus atlantica	-	0	917
217	Cedrus deodara	Cedrus deodara	0	917
317	Cedrus libani	Cedrus libani	0	917
917	Cedrus spp.	Cedrus spp.	0	917
337	Juniperus cedrus	Enebro canario	0	917
236	Cupressus arizonica	Ciprés arizónica	0	936
336	Cupressus lusitanica	Ciprés lambertiana	0	936
436	Cupressus macrocarpa	Ciprés americano	0	936
36	Cupressus sempervirens	-	0	936
936	Cupressus spp.	Cipres	0	936
37	Juniperus communis	-	0	937
237	Juniperus oxycedrus	Enebro oxicedro	0	937
39	Juniperus phoenicea	-	0	937
239	Juniperus sabina	Sabina rastrera	0	937
937	Juniperus spp.	Enebro y sabinas	0	937
38	Juniperus thurifera	-	0	937
238	Juniperus turbinata	Sabina canaria	0	937
256	Ulmus glabra	Ulmus montana	1	956
56	Ulmus minor	Ulmus campestris	1	956
356	Ulmus pumila	Olmo pumilo	1	956
956	Ulmus spp.	Olmo	1	956
275	Juglans nigra	Nogal	1	975
75	Juglans regia	-	1	975
975	Juglans spp.	-	1	975
76	Acer campestre	-	1	976
276	Acer monspessulanum	Arce de Montpellier	1	976
376	Acer negundo	Negundo fraxinifolia l Arce negundo	1	976
476	Acer opalus	Arce ópalus	1	976
676	Acer platanoides	Arce platanoides	1	976
576	Acer pseudoplatanus	Arce pseudoplátano	1	976
976	Acer spp.	Arces	1	976
97	Sambucus nigra	Saúco negro	1	997
297	Sambucus racemosa	Saúco racemosa	1	997
997	Sambucus spp.	-	1	997
11	Ailanthus altissima	Ailanthus glandulosa	1	-
54	Alnus glutinosa	-	1	-
2	Amelanchier ovalis	Guillomo	1	-
88	Apollonias barbuiana	Apollonias canariensis	1	-
98	Carpinus betulus	Carpe	1	-
72	Castanea sativa	Castanea vesca	1	-
13	Celtis australis	-	1	-
67	Ceratonía siliqua	-	1	-
18	Chamaecyparis lawsoniana	-	0	-
369	Chamaerops humilis	Palmito	1	-

Continúa en la siguiente página

Tabla A.4

Resumen del rendimiento de los modelos para la predicción de la variable de carbono en toneladas (carbono_bruto4) con el conjunto de datos que emplea IFN2 e IFN3 como explicativos.

Modelo	R^2_{test}	RMSE _{test}	MAE _{test}
CatBoost	0.845	13.846	6.615
LightGBM	0.841	14.006	6.654
XGBoost	0.840	14.054	6.655
GBDT	0.838	14.159	6.722
MLP	0.832	14.410	6.931
BaggedDT	0.821	14.858	7.282
Random Forest	0.819	14.950	7.135
BayesianNN	0.775	16.674	8.906
SVR	0.679	19.897	8.137

Tabla A.3: Relación de especies (continuación).

Cód.	Nombre	Sinonimia	Tipo	Grupo
9	Cornus sanguinea	-	1	-
74	Corylus avellana	-	1	-
569	Dracaena draco	Drago	1	-
83	Erica arborea	-	1	-
283	Erica scoparia	Tejo l brezo arbóreo escopario	1	-
5	Euonymus europaeus	-	1	-
71	Fagus sylvatica	-	1	-
299	Ficus carica	Higuera	1	-
3	Frangula alnus	Rhamnus frangula	1	-
1	Heberdenia bahamensis	Heberdenia excelsa	1	-
12	Malus sylvestris	-	1	-
60	Mezcla de eucaliptos	Eucaliptos	1	-
50	Mezcla de árboles de ribera	Árboles ripícolas	1	-
81	Myrica faya	-	1	-
281	Myrica rivasmartinezii	-	1	-
6	Myrtus communis	-	1	-
87	Ocotea phoetens	-	1	-
66	Olea europaea	Olea oleaster	1	-
59	Otros árboles ripícolas	-	1	-
84	Persea indica	-	1	-
8	Phillyrea latifolia	-	1	-
86	Picconia excelsa	Notelaea excelsa	1	-
33	Picea abies	Picea excelsa	0	-
289	Pleiomeris canariensis	Delfino	1	-
34	Pseudotsuga menziesii	Pseudotsuga douglasii	0	-
16	Pyrus spp.	-	1	-
40	Quercus	-	1	-
4	Rhamnus alaternus	Aladierno	1	-
389	Rhamnus glandulosa	Sanguino	1	-
96	Rhus coriaria	Zumaque	1	-
457	Salix babylonica	Sauce llorón	1	-
85	Sideroxylon marmulano	-	1	-
10	Sin asignar	Sin asignar	1	-
14	Taxus baccata	-	0	-
219	Tetraclinis articulata	Tetraclinis articulata	0	-
319	Thuja spp.	Thuja	0	-
489	Visnea mocanera	Mocan	1	-

A.18. Resultados

A.18.1. IFN2 e IFN3 como explicativos para carbono_bruto4 (tC)

TODO: corregir las combinaciones para el stack. No coinciden con las descritas arriba ni con las entrenadas para IFN3 como explicativo. Debería ser stack1-6 modelos, satck2-4 modelos, stack3-3 modelos, stack4-3 modelos, stack5-2 modelos

A.18.2. IFN2 e IFN3 como explicativos para c4 (tC/ha)

TODO: corregir las combinaciones para el stack. No coinciden con las descritas arriba ni con las entrenadas para IFN3 como explicativo. Debería ser stack1-6 modelos, satck2-4 modelos, stack3-3 modelos, stack4-3 modelos, stack5-2 modelos

Stack	Metamodelo	Bases	R^2_{test}	RMSE _{test}	MAE _{test}
stack1	GradientBoosting	2	0.840	14.042	6.532
stack1	LinearRegression	2	0.842	13.974	6.621
stack1	Ridge	2	0.842	13.974	6.621
stack1	RandomForest	2	0.815	15.108	7.254
stack1	SVR	2	0.838	14.150	6.534
stack1	MLP	2	0.842	13.969	6.482
stack2	GradientBoosting	3	0.842	13.977	6.525
stack2	LinearRegression	3	0.843	13.913	6.586
stack2	Ridge	3	0.843	13.913	6.586
stack2	RandomForest	3	0.826	14.652	7.017
stack2	SVR	3	0.840	14.064	6.511
stack2	MLP	3	0.843	13.913	6.507
stack3	GradientBoosting	4	0.844	13.862	6.440
stack3	LinearRegression	4	0.846	13.813	6.557
stack3	Ridge	4	0.846	13.813	6.557
stack3	RandomForest	4	0.829	14.545	6.920
stack3	SVR	4	0.842	13.978	6.473
stack3	MLP	4	0.846	13.785	6.364
stack4	GradientBoosting	5	0.845	13.827	6.428
stack4	LinearRegression	5	0.846	13.784	6.533
stack4	Ridge	5	0.846	13.784	6.533
stack4	RandomForest	5	0.834	14.309	6.771
stack4	SVR	5	0.843	13.943	6.452
stack4	MLP	5	0.847	13.768	6.458
stack5	GradientBoosting	6	0.846	13.812	6.423
stack5	LinearRegression	6	0.846	13.787	6.541
stack5	Ridge	6	0.846	13.787	6.541
stack5	RandomForest	6	0.836	14.212	6.716
stack5	SVR	6	0.843	13.940	6.451
stack5	MLP	6	0.847	13.759	6.401

Tabla A.5

Resultados de las diferentes configuraciones de stacking utilizando IFN2 e IFN3 como explicativos de la variable en toneladas de carbono.

Tabla A.6

Resumen del rendimiento de los modelos para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN2 e IFN3 como explicativos.

Modelo	R^2_{test}	RMSE _{test}	MAE _{test}
LightGBM	0.787	22.767	11.650
XGBoost	0.784	22.952	11.590
CatBoost	0.783	22.990	11.607
GBDT	0.783	23.014	11.658
MLP	0.771	23.607	12.287
BaggedDT	0.740	25.142	13.021
Random Forest	0.732	25.547	12.908
BayesianNN	0.678	28.021	14.689
SVR	0.551	33.065	13.708

A.18.3. IFN3 como explicativo para carbono_bruto4 (tC)

A.18.4. IFN3 como explicativo para c4 (tC/ha)

Stack	Metamodelo	Bases	R^2_{test}	RMSE _{test}	MAE _{test}
stack1	GradientBoosting	2	0.770	23.648	11.663
stack1	LinearRegression	2	0.787	22.768	11.607
stack1	Ridge	2	0.787	22.769	11.607
stack1	RandomForest	2	0.740	25.152	12.875
stack1	SVR	2	0.781	23.109	11.368
stack1	MLP	2	0.789	22.650	11.556
stack2	GradientBoosting	3	0.779	23.183	11.527
stack2	LinearRegression	3	0.791	22.565	11.429
stack2	Ridge	3	0.791	22.566	11.429
stack2	RandomForest	3	0.755	24.446	12.345
stack2	SVR	3	0.786	22.853	11.214
stack2	MLP	3	0.794	22.405	11.403
stack3	GradientBoosting	4	0.774	23.442	11.477
stack3	LinearRegression	4	0.788	22.735	11.456
stack3	Ridge	4	0.788	22.735	11.454
stack3	RandomForest	4	0.748	24.768	12.394
stack3	SVR	4	0.783	22.995	11.218
stack3	MLP	4	0.787	22.774	11.333
stack4	GradientBoosting	5	0.772	23.553	11.476
stack4	LinearRegression	5	0.790	22.602	11.416
stack4	Ridge	5	0.790	22.601	11.415
stack4	RandomForest	5	0.751	24.650	12.208
stack4	SVR	5	0.785	22.873	11.183
stack4	MLP	5	0.792	22.531	11.315
stack5	GradientBoosting	6	0.773	23.492	11.421
stack5	LinearRegression	6	0.791	22.571	11.387
stack5	Ridge	6	0.791	22.572	11.384
stack5	RandomForest	6	0.760	24.187	12.029
stack5	SVR	6	0.785	22.864	11.162
stack5	MLP	6	0.794	22.387	11.307

Tabla A.7

Resultados de las diferentes configuraciones de stacking utilizando IFN2 e IFN3 como explicativos de la variable en tC/ha.

Tabla A.8

Resumen del rendimiento de los modelos para la predicción de la variable de carbono en tC con el conjunto de datos que emplea IFN3 como explicativo.

Modelo	R^2_{test}	RMSE _{test}	MAE _{test}
LightGBM	0.909	10.662	5.477
XGBoost	0.907	10.772	5.580
CatBoost	0.907	10.807	5.570
GBDT	0.904	10.942	5.732
MLP	0.896	11.392	6.382
BaggedDT	0.882	12.154	6.420
Random Forest	0.872	12.643	6.533
BayesianNN	0.842	14.079	7.890
SVR	0.825	14.797	7.124
KNN	0.788	16.270	8.166
AdaBoost	0.575	23.056	19.535

Stack	Metamodelo	Bases	Test R^2	RMSE	MAE
stack1	GradientBoosting	6	0.9121	10.4852	5.2841
stack1	LinearRegression	6	0.9122	10.4816	5.3798
stack1	Ridge	6	0.9122	10.4815	5.3798
stack1	RandomForest	6	0.9057	10.8580	5.5726
stack1	SVR	6	0.9098	10.6226	5.3112
stack1	MLP	6	0.9140	10.3723	5.2515
stack2	GradientBoosting	4	0.9124	10.4693	5.2930
stack2	LinearRegression	4	0.9120	10.4914	5.3853
stack2	Ridge	4	0.9120	10.4914	5.3853
stack2	RandomForest	4	0.9050	10.9015	5.6023
stack2	SVR	4	0.9096	10.6341	5.3147
stack2	MLP	4	0.9136	10.3941	5.2625
stack3	GradientBoosting	3	0.9105	10.5796	5.3948
stack3	LinearRegression	3	0.9112	10.5411	5.4317
stack3	Ridge	3	0.9112	10.5411	5.4317
stack3	RandomForest	3	0.8999	11.1916	5.8307
stack3	SVR	3	0.9089	10.6775	5.3694
stack3	MLP	3	0.9122	10.4789	5.3739
stack4	GradientBoosting	3	0.9084	10.7041	5.4036
stack4	LinearRegression	3	0.9088	10.6822	5.5379
stack4	Ridge	3	0.9088	10.6822	5.5379
stack4	RandomForest	3	0.8983	11.2777	5.8314
stack4	SVR	3	0.9060	10.8425	5.4644
stack4	MLP	3	0.9103	10.5951	5.3681
stack5	GradientBoosting	2	0.9098	10.6245	5.4007
stack5	LinearRegression	2	0.9092	10.6546	5.4719
stack5	Ridge	2	0.9092	10.6546	5.4718
stack5	RandomForest	2	0.8920	11.6247	6.1032
stack5	SVR	2	0.9069	10.7932	5.4151
stack5	MLP	2	0.9101	10.6019	5.3545

Tabla A.9

Resultados de las diferentes configuraciones de stacking con el conjunto que emplea IFN3 como explicativo de la variable en tC.

Tabla A.10

Resumen del rendimiento de los modelos para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN3 como explicativo.

Modelo	R^2_{test}	RMSE _{test}	MAE _{test}
CatBoost	0.860	17.709	9.250
XGBoost	0.858	17.828	9.207
LightGBM	0.858	17.841	9.159
GBDT	0.853	18.141	9.463
MLP	0.837	19.086	10.917
BaggedDT	0.826	19.726	10.402
Random Forest	0.826	19.730	10.489
BayesianNN	0.775	22.454	12.260
KNN	0.769	22.755	12.252
SVR	0.734	24.403	11.219
AdaBoost	0.473	34.336	26.295

Stack	Metamodelo	Bases	Test R^2	RMSE	MAE
stack1	GradientBoosting	6	0.8682	17.1742	8.9546
stack1	LinearRegression	6	0.8639	17.4508	8.9676
stack1	Ridge	6	0.8639	17.4510	8.9677
stack1	RandomForest	6	0.8592	17.7459	9.3749
stack1	SVR	6	0.8612	17.6207	8.8012
stack1	MLP	6	0.8656	17.3380	8.8789
stack2	GradientBoosting	4	0.8599	17.7069	8.9856
stack2	LinearRegression	4	0.8635	17.4725	8.9908
stack2	Ridge	4	0.8635	17.4727	8.9908
stack2	RandomForest	4	0.8523	18.1766	9.5079
stack2	SVR	4	0.8613	17.6142	8.8209
stack2	MLP	4	0.8645	17.4083	8.8888
stack3	GradientBoosting	3	0.8590	17.7638	9.0799
stack3	LinearRegression	3	0.8615	17.6005	9.0450
stack3	Ridge	3	0.8615	17.6005	9.0450
stack3	RandomForest	3	0.8449	18.6308	9.7939
stack3	SVR	3	0.8592	17.7490	8.8749
stack3	MLP	3	0.8619	17.5765	8.9734
stack4	GradientBoosting	3	0.8520	18.1962	9.2188
stack4	LinearRegression	3	0.8604	17.6722	9.1764
stack4	Ridge	3	0.8604	17.6723	9.1765
stack4	RandomForest	3	0.8396	18.9435	9.8789
stack4	SVR	3	0.8574	17.8597	9.0159
stack4	MLP	3	0.8620	17.5712	9.0898
stack5	GradientBoosting	2	0.8446	18.6435	9.1995
stack5	LinearRegression	2	0.8578	17.8360	9.1252
stack5	Ridge	2	0.8578	17.8361	9.1252
stack5	RandomForest	2	0.8332	19.3163	10.2404
stack5	SVR	2	0.8552	17.9992	9.0003
stack5	MLP	2	0.8579	17.8333	9.1459

Tabla A.11

Resultados de las diferentes configuraciones de stacking con el conjunto que emplea IFN3 como explicativo de la variable en tC/ha.