

# GreenWest: inteligencia artificial para la predicción de créditos de carbono en proyectos de (re)forestación en España

Jaime Gabriel-Vegas<sup>a,\*</sup>, Maider Araceli Urbón Jiménez<sup>a</sup>, Ana de Luis Reboredo<sup>a</sup>, Belén Pérez Lancho<sup>a</sup> and Ana-Belén Gil-González<sup>a</sup>

<sup>a</sup>Grupo B1, Equipo de investigación BISITE, Universidad de Salamanca, Facultad de Ciencias, Salamanca, España

## ARTICLE INFO

### Keywords:

créditos de carbono  
inteligencia artificial  
forestación  
reforestación  
modelado predictivo  
cambio climático

## Resumen

Este trabajo presenta **GreenWest**, un modelo de inteligencia artificial diseñado para predecir la cantidad de carbono capturado en proyectos de forestación y reforestación en España. El modelo se entrena con datos multifuente: registros del **Inventario Forestal Nacional (IFN3–IFN4, MITECO)**, variables climáticas derivadas de **Copernicus/ERA5-Land** e índices espectrales procedentes de **imágenes Landsat** (Collection 2, Level 2, USGS). Estos datos se integran en una base de datos relacional jerárquica que organiza la información por parcela, especie y clase diamétrica, manteniendo trazabilidad y coherencia estructural entre inventarios.

El modelo desarrollado responde a la pregunta: *Dado un cultivo forestal con características concretas de vegetación, clima y terreno, ¿cuánto CO<sub>2</sub> contendrá pasados unos años?* Esta capacidad predictiva permite su integración en marcos de optimización forestal, abordando cuestiones como la selección de especies o la asignación óptima de terrenos para maximizar la fijación de carbono.

Se evaluaron múltiples enfoques de aprendizaje supervisado, destacando **CatBoost** como el modelo con mejor rendimiento ( $R^2 > 0,80$ , RMSE<15), con alta capacidad de generalización temporal mediante validación cruzada por grupos. Los resultados demuestran el potencial del enfoque para estimar la absorción futura de CO<sub>2</sub> y optimizar decisiones de gestión forestal sostenible, contribuyendo a la transición hacia una economía baja en emisiones.

\*Autor de correspondencia



JaimeGabrielVegas@usal.es (J. Gabriel-Vegas); murbon001@usal.es

(M.A.U. Jiménez); adeluis@usal.es (A.d.L. Reboredo); lancho@usal.es

(B.P. Lancho); abg@usal.es (A. Gil-González)

ORCID(s):

# Índice

|                                                                                  |           |
|----------------------------------------------------------------------------------|-----------|
| <b>1. Introducción</b>                                                           | <b>4</b>  |
| <b>2. Objetivos y Justificación</b>                                              | <b>4</b>  |
| 2.1. Objetivos específicos                                                       | 5         |
| 2.2. Justificación                                                               | 5         |
| <b>3. Revisión de la Literatura</b>                                              | <b>5</b>  |
| <b>4. Estado del Arte</b>                                                        | <b>7</b>  |
| <b>5. Metodología</b>                                                            | <b>7</b>  |
| 5.1. Origen y estructura de los datos                                            | 8         |
| 5.1.1. Estructura de la base de datos                                            | 8         |
| 5.2. Variables objetivo                                                          | 8         |
| 5.3. Supuestos de elegibilidad y verificación externa                            | 9         |
| 5.4. Preparación y tratamiento de los datos                                      | 10        |
| 5.4.1. Filtrado de registros                                                     | 10        |
| 5.4.2. Cálculo y agregación de variables                                         | 10        |
| 5.4.3. Reclasificación de las variables pendiente y orientacion                  | 11        |
| 5.4.4. Agrupación de la variable periodo                                         | 11        |
| 5.5. Partición y validación                                                      | 12        |
| 5.5.1. Codificación y normalización                                              | 13        |
| 5.6. Selección de variables explicativas                                         | 13        |
| 5.6.1. Selección automática mediante Featurewiz                                  | 13        |
| 5.6.2. Selección mediante mRMR                                                   | 13        |
| 5.6.3. Selección manual basada en criterios estadísticos y conceptuales          | 13        |
| 5.6.4. Selección Secuencial Supervisada basada en Rendimiento Predictivo (SSSRP) | 13        |
| 5.7. Modelos evaluados                                                           | 13        |
| 5.7.1. Modelos ensemble                                                          | 13        |
| 5.7.2. Boosting y aprendizaje secuencial                                         | 14        |
| 5.7.3. Bagging                                                                   | 14        |
| 5.7.4. Otros modelos evaluados                                                   | 14        |
| 5.7.5. Configuración del <i>stacking</i>                                         | 14        |
| 5.7.6. Comparación y justificación de modelos                                    | 14        |
| <b>6. Implementación del <i>pipeline</i></b>                                     | <b>14</b> |
| 6.1. Ingeniería práctica del entrenamiento y la validación                       | 14        |
| 6.2. Implementación del <i>stacking</i>                                          | 15        |
| 6.3. Datos finales de entrenamiento                                              | 15        |
| 6.3.1. Efecto del periodo sobre el carbono                                       | 16        |
| <b>7. Entrenamiento y validación</b>                                             | <b>17</b> |
| 7.1. Elección de variables                                                       | 17        |
| 7.1.1. Resultados de la selección de variables manual                            | 17        |
| 7.1.2. Selección de variables mediante <i>Featurewiz</i>                         | 18        |
| 7.1.3. Selección de variables mediante <i>mRMR</i>                               | 18        |
| 7.1.4. Discusión de la selección de variables                                    | 18        |
| 7.2. Ensamblado tipo <i>stacking</i> de modelos de regresión                     | 18        |
| <b>8. Resultados</b>                                                             | <b>19</b> |
| 8.1. Resultados IFN2                                                             | 19        |
| 8.1.1. Toneladas de carbono por hectárea                                         | 19        |
| 8.1.2. Toneladas de carbono                                                      | 19        |
| 8.2. Resultados IFN3                                                             | 19        |
| 8.2.1. Toneladas de carbono por hectárea                                         | 19        |
| 8.2.2. Toneladas de carbono                                                      | 19        |

|            |                                                                                   |           |
|------------|-----------------------------------------------------------------------------------|-----------|
| 8.3.       | Resultados IFN2 e IFN3 . . . . .                                                  | 19        |
| 8.3.1.     | Toneladas de carbono por hectárea . . . . .                                       | 19        |
| 8.3.2.     | Toneladas de carbono . . . . .                                                    | 20        |
| <b>9.</b>  | <b>Discusión</b>                                                                  | <b>30</b> |
| 9.1.       | Modelos globales . . . . .                                                        | 30        |
| 9.1.1.     | Variable c4 (en toneladas de carbono por hectárea) . . . . .                      | 30        |
| 9.1.2.     | Variable carbono_bruto4 (en toneladas de carbono) . . . . .                       | 31        |
| 9.2.       | Modelos individuales entrenados solo con el IFN2 o IFN3. . . . .                  | 33        |
| 9.2.1.     | Asimilación del comportamiento de las variables objetivo . . . . .                | 33        |
| 9.2.2.     | Rendimiento de los modelos en función del valor de la variable objetivo . . . . . | 35        |
| 9.3.       | Interpretabilidad de los modelos: análisis SHAP . . . . .                         | 36        |
| <b>10.</b> | <b>Conclusiones</b>                                                               | <b>38</b> |
| <b>11.</b> | <b>Recomendaciones para Futuras Investigaciones</b>                               | <b>40</b> |
| <b>A.</b>  | <b>Apéndices</b>                                                                  | <b>43</b> |
| A.1.       | Origen y cálculo de las variables ca y cr . . . . .                               | 43        |
| A.2.       | Estado de las Poblaciones (estado_id) . . . . .                                   | 43        |
| A.3.       | Forma Principal de Masa (IFN3 e IFN4: fpmasa_id) . . . . .                        | 43        |
| A.4.       | Tratamiento de la Masa (IFN3 e IFN4: tratmasa_id) . . . . .                       | 44        |
| A.5.       | Origen de la Masa (IFN3 e IFN4: orgmasa_id) . . . . .                             | 44        |
| A.6.       | Tipo de Suelo (tipsuelo1_id, tipsuelo2_id, tipsuelo3_id) . . . . .                | 44        |
| A.7.       | Rocosisdad (rocosidad_id) . . . . .                                               | 45        |
| A.8.       | Textura del Suelo (textura_id) . . . . .                                          | 45        |
| A.9.       | Contenido en Materia Orgánica (IFN3 e IFN4: matorg_id) . . . . .                  | 45        |
| A.10.      | Modelo de Combustible (IFN3 e IFN4: modcomb_id) . . . . .                         | 45        |
| A.11.      | Distribución Espacial (disesp_id) . . . . .                                       | 46        |
| A.12.      | Composición Específica (comesp_id) . . . . .                                      | 46        |
| A.13.      | Manifestaciones Erosivas (merosiva_id) . . . . .                                  | 46        |
| A.14.      | Nivel de usos del suelo (IFN3 e IFN4: nivel1_id) . . . . .                        | 46        |
| A.15.      | Nivel morfoestructural (IFN3 e IFN4: nivel2_id) . . . . .                         | 46        |
| A.16.      | Código de los grupos taxonómicos de las especies (grupo_id) . . . . .             | 47        |
| A.17.      | Código de las especies (especie_id) . . . . .                                     | 47        |
| A.18.      | Resultados . . . . .                                                              | 50        |
| A.18.1.    | IFN2 e IFN3 como explicativos para carbono_bruto4 (tC) . . . . .                  | 50        |
| A.18.2.    | IFN2 e IFN3 como explicativos para c4 (tC/ha) . . . . .                           | 50        |
| A.18.3.    | IFN3 como explicativo para carbono_bruto4 (tC) . . . . .                          | 51        |
| A.18.4.    | IFN3 como explicativo para c4 (tC/ha) . . . . .                                   | 51        |
| <b>B.</b>  | <b>Base de datos: diccionario de variables y cardinalidad</b>                     | <b>51</b> |
| B.1.       | Diccionario resumido de variables . . . . .                                       | 51        |
| B.2.       | Cardinalidad y completitud . . . . .                                              | 57        |

## 1. Introducción

El cambio climático es uno de los mayores desafíos globales y su manifestación más directa es el aumento de las concentraciones atmosféricas de dióxido de carbono ( $CO_2$ ), con impactos sobre la criosfera, los extremos climáticos y los ecosistemas [1]. Los bosques actúan como sumideros naturales al fijar  $CO_2$  en biomasa vía fotosíntesis, por lo que su gestión resulta clave para la mitigación.

A lo largo de las últimas décadas, instrumentos internacionales como la *Convención Marco de las Naciones Unidas sobre el Cambio Climático (CMNUCC)* y el *Protocolo de Kioto* [2, 3] han establecido los marcos regulatorios para reducir las emisiones de gases de efecto invernadero mediante mecanismos basados en el mercado. En este contexto surgen los *créditos de carbono*, unidades que representan la cantidad de dióxido de carbono ( $CO_2$ ), habitualmente una tonelada, que ha sido capturada o cuya emisión ha sido evitada a través de proyectos certificados de mitigación.

Entre las actividades elegibles, la forestación y reforestación destacan por su capacidad de actuar como sumideros naturales de carbono, fijando  $CO_2$  en la biomasa y el suelo. No obstante, para que estas actuaciones puedan generar créditos de carbono válidos, deben cumplir una serie de criterios técnicos y legales establecidos en la normativa internacional sobre cambio climático y en su aplicación a nivel nacional. En particular, estos requisitos derivan de las reglas de contabilidad de sumideros forestales adoptadas en el marco de la Convención Marco de las Naciones Unidas sobre el Cambio Climático (CMNUCC) y del Protocolo de Kioto, concretadas en los Acuerdos de Marrakech, así como de la definición nacional de bosque comunicada por España para estos fines [4, 5]. Dichos criterios incluyen:

- **Intervención humana directa:** Los árboles deben ser el resultado de actividades de intervención humana directa, tales como la plantación, la siembra o el fomento deliberado de la regeneración natural. Este requisito se deriva de la definición de *forestación* y *reforestación* establecida en el Protocolo de Kioto, que excluye expresamente la regeneración natural no inducida por la acción humana [4].
- **Período mínimo de permanencia:** El proyecto debe garantizar la permanencia del sumidero de carbono durante un período prolongado (habitualmente del orden de 20-30 años), con el fin de asegurar que el carbono capturado no sea liberado de forma prematura a la atmósfera. Este criterio responde al principio de permanencia exigido en la contabilidad de sumideros forestales del régimen LULUCF y en los marcos de aplicación nacionales y europeos, lo que excluye cultivos de corta rotación cuyo carbono se libera tras la cosecha [4, 6].
- **Superficie mínima de 1 hectárea:** El área objeto del proyecto debe tener una extensión mínima de 1 hectárea. Este umbral procede de la definición nacional de bosque adoptada por España dentro de los rangos

permitidos por los Acuerdos de Marrakech (0,05–1 ha), comunicada oficialmente a la CMNUCC [5].

- **Fracción mínima de cabida cubierta del 20 %:** Para que un terreno sea considerado bosque, la cobertura de copas de las especies arbóreas debe alcanzar al menos el 20 % de la superficie. Este valor corresponde a la elección nacional realizada por España para la definición de bosque a efectos de contabilidad climática [5].
- **Altura mínima de los árboles maduros de 3 metros:** Las especies arbóreas deben ser capaces de alcanzar una altura mínima de 3 metros en su madurez. No es necesario que dicha altura se alcance en el momento inicial del proyecto, pero sí que sea alcanzable bajo condiciones normales de crecimiento. Este criterio forma igualmente parte de la definición nacional de bosque comunicada por España conforme a las decisiones adoptadas bajo la CMNUCC [5].

Este trabajo trata de obtener un modelo de inteligencia artificial para estimar la cantidad de carbono que capturará un cultivo forestal en España a partir de variables de vegetación, clima y terreno en un período de 20 a 30 años. Este enfoque innovador tiene el potencial de transformar la gestión de proyectos de forestación y reforestación, optimizando las prácticas de plantación y maximizando la cantidad de carbono que se puede capturar en estos ecosistemas.

La pregunta operativa es: *dadas las características iniciales de una plantación, ¿cuánto  $CO_2$  contendrá tras  $t$  años?, donde  $t$  es un número natural*. Para responderla, se integran datos del **Inventario Forestal Nacional** (IFN2–IFN4, MITECO) [7], reanálisis **ERA5-Land** [8] e **índices espectrales Landsat** (Collection 2, L2) [9] en una base de datos relacional jerárquica descrita en un trabajo complementario [10].

Este modelo no solo mejorará la comprensión del comportamiento de los sumideros de carbono, sino que también proporcionará herramientas útiles para la toma de decisiones estratégicas tanto en el ámbito empresarial como en el ambiental. De esta forma, el proyecto *GreenWest* contribuye a la transición hacia una economía baja en carbono, alineándose con los objetivos globales de sostenibilidad establecidos en el marco de la CMNUCC y el *Protocolo de Kioto*, y promoviendo la creación de un mercado de créditos de carbono más eficiente y accesible para los actores económicos involucrados en la gestión de los recursos naturales.

## 2. Objetivos y Justificación

El presente estudio tiene como objetivo principal desarrollar un modelo de inteligencia artificial capaz de predecir con precisión la capacidad de absorción de dióxido de carbono ( $CO_2$ ) en cultivos forestales españoles. Este modelo se basa en variables que describen la especie arbórea, las características del terreno y las condiciones climáticas y meteorológicas. A partir de este objetivo general se derivan varias metas específicas, que en conjunto justifican la relevancia y aplicabilidad del proyecto.

## 2.1. Objetivos específicos

Los principales objetivos se listan a continuación:

- **Desarrollar un modelo predictivo robusto:** Construir un modelo de aprendizaje automático que estime la cantidad de  $CO_2$  que será capturado a lo largo del tiempo por un cultivo forestal, a partir de datos como especie, tipo de suelo, clase diamétrica, clima y otras variables relevantes.
- **Asegurar la compatibilidad con las normativas internacionales:** Garantizar que las predicciones y salidas del modelo sean compatibles con los marcos normativos definidos por la *Convención Marco de las Naciones Unidas sobre el Cambio Climático* (CMNUCC) y el *Protocolo de Kioto*, cumpliendo así los criterios necesarios para la validación de créditos de carbono.
- **Analizar los factores determinantes del desarrollo forestal:** Estudiar la influencia de variables climáticas (como la temperatura y la precipitación) y edáficas (como el tipo de suelo o la pendiente) sobre el crecimiento forestal y su capacidad de capturar carbono.
- **Apoyar la toma de decisiones ambientales y empresariales:** Proporcionar una herramienta práctica y validada que permita a técnicos, gestores y empresas seleccionar las especies más adecuadas y planificar actuaciones de forestación con la mayor eficiencia posible en términos de secuestro de carbono.

## 2.2. Justificación


La necesidad de contar con herramientas predictivas para estimar la captura de  $CO_2$  se ha intensificado ante el crecimiento del mercado voluntario de créditos de carbono, y las obligaciones adquiridas: cada país debe reportar sus emisiones y absorciones de gases de efecto invernadero, y puede utilizar actividades de (re)forestación como mecanismos de compensación.

Para que estos proyectos sean elegibles, deben cumplir criterios específicos, los cuales hacen imprescindible disponer de modelos que no solo estimen el carbono actual, sino que sean capaces de prever su evolución a futuro con base en condiciones iniciales y variables predictoras.

Este trabajo busca cubrir ese vacío mediante el uso de inteligencia artificial aplicada a datos reales y multifuente. Integrar su manejo dentro del sistema de créditos de carbono puede representar una importante oportunidad para la economía local, lo que podría ser un apoyo para aquellas regiones donde la depoblación y el reto demográfico son un problema serio, y para la mitigación del cambio climático.

## 3. Revisión de la Literatura

La cuantificación precisa de los recursos forestales ha constituido, históricamente, una de las piedras angulares de la gestión territorial y la economía de recursos naturales. La evolución de las técnicas para medir el crecimiento de los árboles y, más recientemente, para estimar su biomasa y contenido de carbono, refleja una transformación profunda



**Figura 3.1:** Relación entre la biomasa total en kilogramos y el diámetro a la altura del pecho en centímetros para el bambú moso (*Phyllostachys edulis*). Visto en [12], siendo [14] la fuente original.

en las prioridades de la sociedad humana respecto a los ecosistemas forestales. Lo que comenzó en la Europa medieval como una necesidad logística para asegurar el suministro de leña y madera estructural ante el temor de la escasez, se ha metamorfoseado en el siglo XXI en una disciplina científica de alta tecnología impulsada por la urgencia climática global [11].

La dendrometría tradicional, pilar de los inventarios forestales modernos, se fundamenta en el uso de relaciones alométricas para estimar la biomasa ( $w$ ) y otros parámetros ecológicos a partir de variables de fácil medición en campo, principalmente el diámetro a la altura del pecho ( $D$ ) y la altura total ( $H$ ). Estas estimaciones suelen articularse mediante ecuaciones de la forma:

$$w = aD^bH^c \quad (3.1)$$


o sus transformaciones logarítmicas:

$$\lg w = a + b \lg D + c \lg H \quad (3.2)$$

donde los parámetros  $a$ ,  $b$  y  $c$  son coeficientes de regresión empíricos [12]. En este contexto, la precisión de las mediciones primarias es crítica, ya que, dada la naturaleza potencial de estas funciones, los errores en la toma de datos de  $D$  y  $H$  se propagan y magnifican en el cálculo final del volumen y el contenido de carbono. Pese a la aparente sencillez del ajuste, los resultados pueden llegar a ser muy buenos, como se muestra en la Figura 3.1. No obstante, existe una tensión en la literatura entre el uso de ecuaciones “pantropicales” o generalizadas y ecuaciones específicas de especie o sitio, ya que se pueden introducir sesgos si la arquitectura de los árboles locales difiere de la global [13].

La medición de la altura de los árboles ha supuesto históricamente un desafío mayor que la del diámetro. Hasta la década de 1990, predominaron hipsómetros mecánicos basados en trigonometría, que requerían medir manualmente






**Figura 3.2:** Diagrama de el escaneo de un árbol por un sistema LiDAR aerotransportado y los diversos pulsos reflejados. Imagen obtenida de [17].


la distancia al árbol y una línea de visión despejada [15]. Estos métodos sufrían limitaciones de precisión y ergonomía. La introducción de la electrónica marcó un punto de inflexión al utilizar ultrasonidos para medir distancias automáticamente, permitiendo trabajar en sotobosques densos y mejorando la precisión por debajo del 1 % [15]. Paralelamente, las forcípulas (aparato de medición de la distancia lineal entre dos tangentes paralelas al fuste del árbol) electrónicas modernas han digitalizado la toma de datos, integrando medición y registro de metadatos para minimizar errores de transcripción [15].

Posteriormente, la introducción de la tecnología de escaneo láser supuso una revolución en la mensura forestal, superando las limitaciones logísticas y de precisión de los métodos tradicionales. Esta tecnología se despliega principalmente en dos modalidades: el escaneo láser terrestre (TLS, por sus siglas en inglés), que captura la estructura tridimensional del bosque desde el suelo con detalle milimétrico [16], y el LiDAR aerotransportado. Este último consiste es un método que usa pulsos de luz para medir distancias. Los mapeos masivos suelen consistir en un sistema LiDAR montado en un avión, helicóptero, dron o satélite, el cuál mide la distancia a los objetos debajo de él. Una ventaja es que, al igual que la luz puede llegar al suelo a través de los huecos de las copas de los árboles, los pulsos láser del LiDAR también lo hacen, como podemos observar en la Figura 3.2. Esto hace que mediante un solo sobrevuelo se puedan captar diversas capas a varias alturas, lo que permite realizar reconstrucciones en 3D de las zona escaneada. El detalle que se puede lograr es tan alto que se pueden identificar los árboles individuales, como se ve en la Figura 3.3.

Las principales limitaciones del LiDAR aerotransportado residen en su elevado coste y complejidad logística. Estos factores dificultan la obtención de coberturas a gran escala con una periodicidad óptima, generando además una latencia significativa en la disponibilidad de datos regionales. Asimismo, el procesamiento de esta información es más exigente que en métodos previos, a lo que se suma el



**Figura 3.3:** Visualización de un bosque escaneado con LiDAR. Vemos las posibilidades de identificar árboles individuales en un entorno forestal denso [18].



**Figura 3.4:** Plan de adquisición de datos del Tercer ciclo del proyecto PNOA-LiDAR del Instituto Geográfico Nacional de España [19].

desafío técnico de gestionar y almacenar grandes volúmenes de datos. En la Figura 3.4 se muestra el plan de adquisición de datos del Tercer ciclo del proyecto PNOA-LiDAR del Instituto Geográfico Nacional de España, donde se puede apreciar la cadencia con la que se hacen los mapeos.

La integración de estos datos estructurales, junto a la teledetección satelital y la capacidad de procesamiento de grandes volúmenes de datos que ofrecen los algoritmos de aprendizaje automático ha inaugurado un nuevo paradigma: la capacidad de monitorear los recursos forestales a escala global con una precisión sin precedentes. Es en este contexto de “forestería de precisión” y observación terrestre a gran escala donde se enmarca la investigación actual, habiéndose logrado resultados muy prometedores que permiten abordar la complejidad de los ecosistemas forestales con una granularidad antes inalcanzable.

## 4. Estado del Arte

El secuestro de carbono en ecosistemas forestales ha cobrado una importancia creciente en la literatura científica, impulsada tanto por los compromisos internacionales en materia de cambio climático como por el auge de los mercados de créditos de carbono. Esto ha motivado el desarrollo de modelos orientados a cuantificar la biomasa forestal y estimar el contenido de carbono, aprovechando avances recientes en sensores remotos y técnicas de inteligencia artificial.

Una de las estrategias más consolidadas para la cuantificación del carbono forestal es la estimación del carbono almacenado en un momento dado a partir de datos de teledetección. Goetz et al. (2009) [20] revisan el uso de observaciones satelitales, incluyendo sensores ópticos como MODIS y Landsat, en modelos empíricos de biomasa aérea, destacando su aplicabilidad a escala regional, especialmente en ecosistemas boreales. Este tipo de estimaciones suele basarse en regresiones lineales o modelos de mínimos cuadrados generalizados, con coeficientes de determinación habitualmente entre 0.6 y 0.8, dependiendo de la resolución espacial y la heterogeneidad del ecosistema.

La aplicación de aprendizaje profundo ha permitido mejorar sustancialmente la precisión y resolución espacial de estas estimaciones. Por ejemplo, Zhang et al. (2022) [21] integran imágenes Sentinel-2 con redes neuronales convolucionales, alcanzando un  $R^2$  de 0.84 para estimar el carbono en bosques subtropicales. Del mismo modo, Jiang et al. (2022) [22] desarrollan el modelo *ForestCarbonAI*, entrenado con datos multispectrales y LiDAR, con el que generan mapas de carbono forestal de alta resolución (10 m), reportando errores medios absolutos (MAE) inferiores a 3.5 tC/ha en zonas templadas. Otros trabajos recientes, como Reiersen et al. (2022) [23] o Dong et al. (2023) [24], también demuestran la eficacia del *deep learning* para estimaciones estáticas, aunque se centran en contextos tropicales y no consideran el componente temporal.

Frente a estos enfoques descriptivos, algunas iniciativas han intentado proyectar la evolución del carbono a futuro. En el ámbito nacional, el Ministerio para la Transición Ecológica (MITECO) ha implementado herramientas como la calculadora *ex ante* de absorciones [25], que permite obtener estimaciones simplificadas del carbono que puede fijarse en una plantación forestal en función de la especie y la zona agroclimática. No obstante, este instrumento se basa en coeficientes tabulados y no incorpora variables edafoclimáticas reales ni técnicas de modelización basadas en datos, lo que limita su precisión y capacidad de adaptación a contextos específicos.

En el ámbito europeo destaca el trabajo de Fasihi et al. (2024) [26], que aplica un enfoque afín al propuesto en este estudio en la región de Friuli-Venezia Giulia (Italia). Su objetivo es estimar tanto el *stock* actual de carbono como su tasa de absorción anual (secuestro), basándose en datos de dendrocronología del Inventario Forestal Nacional italiano. Estas mediciones, realizadas entre 2017 y 2019, cuantifican el crecimiento radial de los últimos cinco años para estimar

la biomasa mediante ecuaciones alométricas y su conversión a carbono según directrices del IPCC. Luego, entrenan modelos predictivos utilizando variables meteorológicas, geomorfológicas, índices de vegetación y un modelo LiDAR de las copas de los árboles (CHM), intentando predecir los valores obtenidos con datos de campo.

Los autores evalúan diversos modelos de conjunto (*ensemble*), reportando que combinaciones de algoritmos como Random Forest, AdaBoost y CatBoost ofrecen el mejor rendimiento. En la predicción del *stock* de carbono, alcanzan un  $R^2$  de  $0,73 \pm 0,07$  y un RMSE de  $31,55 \pm 9,35$  tC/ha. Para la tasa de secuestro, los resultados son más modestos, con un  $R^2$  de  $0,42 \pm 0,08$  y un RMSE de  $0,90 \pm 0,08$  tC/ha/año. Un hallazgo clave del estudio es que la inclusión de datos LiDAR mejora drásticamente la precisión de las estimaciones.

En este escenario, el presente trabajo propone una metodología innovadora centrada en la predicción dinámica de carbono a largo plazo. A diferencia de los modelos anteriores, que estiman el carbono ya almacenado, este estudio se enfoca en anticipar cuánto carbono capturará un cultivo forestal en un horizonte temporal concreto. Para ello, se estudian diversos modelos de aprendizaje supervisado entrenados con datos históricos del Inventario Forestal Nacional (IFN2, IFN3 e IFN4) [7] incluyendo características edáficas, variables climáticas de Copernicus [27, 28] y métricas espectrales derivadas de imágenes Landsat [29]. Los detalles sobre la arquitectura del modelo, las variables utilizadas, los algoritmos implementados y las métricas de evaluación se desarrollan en las siguientes secciones.

## 5. Metodología

Esta sección describe el procedimiento seguido para el entrenamiento y validación de los modelos predictivos desarrollados. La metodología se fundamenta en la identificación de los factores que determinan el crecimiento forestal y, en consecuencia, la capacidad de los ecosistemas para capturar carbono a lo largo del tiempo. El enfoque integra información estructural, climática y espectral procedente del Inventario Forestal Nacional (IFN) y de otras fuentes ambientales, con el propósito de construir modelos robustos que permitan predecir el contenido de carbono acumulado en la biomasa viva.

El carbono fijado por los árboles se acumula progresivamente en su biomasa, en función del tamaño y vigor de los individuos, los cuales están condicionados por variables ambientales, topográficas y de competencia intraespecífica. Las condiciones meteorológicas, como la temperatura y la precipitación, inciden directamente en la fotosíntesis y en la disponibilidad hídrica; la orientación, la pendiente y la altitud modifican la radiación incidente y el microclima local; mientras que la densidad de árboles por unidad de superficie determina el nivel de competencia por los recursos, variando según la especie y su tolerancia ecológica [30].

A partir de estos fundamentos, se construyó una base de datos relacional que integra información forestal, climática y

espectral a nivel de parcela, especie y clase diamétrica. Esta estructura permite caracterizar con precisión la dinámica del bosque entre inventarios sucesivos y alimentar modelos predictivos capaces de estimar el contenido futuro de carbono a partir de las condiciones observadas en el pasado.

### 5.1. Origen y estructura de los datos

La base de datos empleada en este trabajo integra información forestal, climática y espectral estructurada en torno a la parcela como unidad básica. Cada parcela se describe mediante sus coordenadas geográficas, características edáficas y su evolución a través de distintos inventarios (IFN2, IFN3, IFN4).

Los datos forestales incluyen información por especie y clase diamétrica, como número de pies o carbono aéreo, radical y total. Estos valores permiten caracterizar con precisión la estructura y crecimiento de la vegetación.

A cada parcela se asocian también estadísticas climáticas y meteorológicas agregadas por estación e inventario: temperaturas (superficie, aire y subsuelo) y precipitaciones, resumidas mediante métricas como media, máxima, mínima y desviación típica, así como el índice de aridez de Martonne.

Finalmente, se incorporan estas mismas estadísticas sobre índices espectrales derivados de imágenes satelitales (NDVI, EVI, NDII, GNDVI), que permiten cuantificar propiedades biofísicas de la vegetación:

- **NDVI (Normalized Difference Vegetation Index):** estima la actividad fotosintética.
- **EVI (Enhanced Vegetation Index):** mejora la sensibilidad en zonas densamente vegetadas.
- **NDII (Normalized Difference Infrared Index):** refleja el contenido hídrico de la vegetación.
- **GNDVI (Green NDVI):** variante del NDVI basada en la banda verde, sensible a la cantidad de clorofila.

#### 5.1.1. Estructura de la base de datos

Estos datos se organizan en las siguientes entidades troncales (tablas):

- **parcelas:** contiene la información básica ligada a la localización de cada parcela (características edáficas, geográficas y climáticas).
- **parcela\_inventario:** describe el estado de cada parcela en un inventario determinado, incluyendo atributos edáficos y de contexto (p. ej., textura del suelo, fracción de cabida cubierta...).
- **parcela\_inventario\_especie:** detalla la presencia y condición de cada especie dentro de una parcela e inventario, incorporando descriptores de masa y tratamientos silvícolas.
- **parcela\_inventario\_especie\_cd:** describe las poblaciones arbóreas por parcela, especie y *clase diamétrica*: n.º de pies, área basimétrica, volúmenes, altura de los especímenes, carbono capturado...
- **parcela\_especie\_arbol:** caracteriza los pies mayores identificados por parcela y especie en el cuarto inventario. Recoge las características particulares de cada

pie como altura, diámetros, ubicación respecto del centro de la parcela, volumen y carbono capturado.

- **parcela\_inventario\_estacion:** almacena agregados climático-biofísicos por estación en la misma granularidad parcela-inventario, incluyendo variables como precipitación y temperatura, junto a índices de vegetación (NDVI, EVI, NDII, GNDVI).
- **especies y grupos:** recogen la información taxonómica y su clasificación jerárquica, estableciendo la relación entre especies individuales y grupos funcionales.

Cada variable categórica posee una tabla de catálogo propia (*cat\_*), donde se definen los valores posibles y sus descripciones. Por ejemplo, *cat\_textura*, *cat\_nivel1*, *cat\_tratmasa* o *cat\_origen*. Todas siguen un patrón uniforme: la clave primaria es el identificador de la variable (*<variable>\_id*), y las tablas troncales referencian este mismo campo como clave foránea. Además la base de datos incluye una tabla llamada *meta\_variables* que recoge los metadatos.


La Figura 5.1 muestra el esquema general de las tablas troncales y sus principales relaciones. Este diagrama resume la estructura interna de la base de datos y su jerarquía de dependencias.

### 5.2. Variables objetivo

El objetivo del modelo es estimar el **carbono total** que una parcela forestal capturará en un horizonte temporal de 20–30 años, a partir de las condiciones observadas en inventarios previos. Para ello se contemplan dos variables de respuesta complementarias, ambas derivadas de los datos del Inventario Forestal Nacional (IFN), que permiten analizar el contenido de carbono desde perspectivas distintas: una normalizada por superficie y otra en términos absolutos.

1. **c (tC/ha):** representa el **carbono total contenido en la biomasa viva aérea y subterránea** por unidad de superficie, expresado en *toneladas de carbono por hectárea*. Su cálculo se basa en la suma de las estimaciones de carbono aéreo (*ca*) y radical (*cr*) reportadas por el IFN. En los casos con valores faltantes, se completó la información mediante un modelo de *Random Forest Regressor* ajustado sobre variables dendrométricas observadas (Especie, CD, VSC, NPies, ABas, IAVC, VCC y VLE), alcanzando un rendimiento satisfactorio ( $R^2_{test} > 0,90$ ). Esta variable es coherente con los formatos internacionales de reporte de inventarios forestales y permite comparar el contenido de carbono entre parcelas o especies.
2. **carbono\_bruto (tC):** corresponde al **carbono total capturado por parcela y especie**, expresado en *toneladas de carbono totales*. Su estimación se realiza de forma trazable y físicamente interpretable a partir de variables medidas directamente en campo: número de pies (*npies*), altura media (*ht*), tipo de especie (*clase\_especie*) y clase diamétrica (*cd\_id*). El cálculo sigue un modelo alométrico adaptado de [31] y las directrices del IPCC [30], incorporando tanto la biomasa aérea como la biomasa radical mediante la relación Parte Radical:Parte Aérea (*R*). El resultado





**Figura 5.1:** Esquema relacional de las tablas principales de la base de datos. Tabla extraída de [10], donde se pueden consultar más detalles sobre las variables.

se expresa en toneladas de carbono totales por parcela, sin normalizar por superficie, lo que facilita la trazabilidad del proceso y la comparación entre inventarios sin depender de factores de expansión específicos del IFN. En coherencia con los criterios de proyectos de forestación y reforestación, las observaciones correspondientes a brinzales o plantones se consideran con valor de carbono nulo, dado que las fases tempranas de desarrollo no se contabilizan oficialmente como carbono capturado.

Estas dos variables resumen el contenido de carbono forestal desde enfoques complementarios: *c* (tC/ha) permite la comparación espacial y temporal entre masas forestales, mientras que *carbono\_bruto* (tC) ofrece una medida absoluta y directamente derivada de las observaciones de campo. Ambas constituyen los objetivos principales del modelado predictivo, orientado a estimar el carbono acumulado en el

**IFN4** a partir de las condiciones registradas en los inventarios anteriores (**IFN2** e **IFN3**).

Para mayor detalle sobre el origen de estas variables consultar [10].

### 5.3. Supuestos de elegibilidad y verificación externa


Como ya se ha introducido, para que un proyecto forestal sea elegible en programas de *créditos de carbono* en España debe cumplir algunos requisitos técnicos [30, 32]. A continuación se resume cada criterio y la forma en que se aborda en este estudio:

- **Intervención humana directa.** El incremento de carbono debe proceder de actuaciones planificadas (reforestación, restauración o manejo sostenible). En nuestro caso, el modelo se entrena sobre datos observacionales (IFN2–IFN3–IFN4); por tanto, la *verificación de intervención* no se deduce del modelo, sino que se contempla como *condición externa* de elegibilidad del proyecto a evaluar.
- **Permanencia mínima.** Para caracterizar el crecimiento de las parcelas forestales en los datos que alimentan el modelo, es necesario disponer de dos mediciones sucesivas de cada parcela, separadas por un intervalo temporal conocido. Estas mediciones permiten cuantificar la evolución de las variables forestales y, por tanto, estimar el incremento de carbono asociado al crecimiento del arbolado durante dicho periodo.


En este trabajo, el objetivo es predecir el contenido de carbono correspondiente al **IFN4**, utilizando como información explicativa las variables observadas en inventarios anteriores. Dado que los inventarios tercero y cuarto comparten una estructura homogénea y un conjunto de variables comparable, la elección más directa para el entrenamiento del modelo sería emplear exclusivamente estos dos inventarios. Esta estrategia aprovecha la coherencia estructural de los inventarios más recientes, que incluyen un mayor número de variables y una caracterización más detallada del terreno.

El intervalo de tiempo entre los inventarios **IFN3** e **IFN4** es relativamente corto: la Figura 5.2 muestra la distribución de la diferencia de años entre las mediciones del IFN3 y el IFN4. Como puede observarse, la mayoría de las parcelas presentan intervalos comprendidos entre 6 y 17 años, un rango demasiado estrecho para evaluar la estabilidad del modelo en horizontes más amplios.

Para ampliar la cobertura temporal y mejorar la capacidad de generalización del modelo, se optó por unificar la información de los inventarios **IFN2** e **IFN3** como base explicativa para la predicción del **IFN4**. Esta integración permite disponer de pares de mediciones de parcelas separadas por intervalos que oscilan entre 6 y 29 años, como se puede observar en la Figura 5.3, lo que constituye un rango mucho más



**Figura 5.2:** Distribución de la diferencia de años entre los inventarios tercero y cuarto.



**Figura 5.3:** Distribución de la diferencia de años entre los inventarios IFN2-IFN3 e IFN3-IFN4.

representativo del horizonte de 20–30 años establecido como referencia.

De esta forma, el modelo se entrena y valida sobre un conjunto de datos más diverso y equilibrado, tanto en estructura como en amplitud temporal, manteniendo la coherencia metodológica y la trazabilidad de las estimaciones.

- **Superficie mínima de 1 ha.** Este criterio se considera externo al alcance del modelo predictivo, ya que el aprendizaje se realiza a nivel de parcela e inventario y no sobre polígonos de superficie total. En la práctica, la verificación de la superficie se realiza *ex ante*, sobre la geometría declarada del proyecto forestal. En los terrenos forestales generados a partir de intervención humana directa, como plantaciones o repoblaciones, la extensión suele presentar una estructura homogénea, con una especie dominante, edades coetáneas y densidades estandarizadas. Bajo estas condiciones, el carbono total es proporcional a la superficie: duplicar el área de una masa forestal homogénea implica aproximadamente duplicar su carbono almacenado. Por tanto, la variable de superficie no afecta al ajuste interno del modelo y su cumplimiento puede evaluarse fácilmente a nivel de proyecto, sin comprometer la validez de las predicciones.
- **Fracción mínima de cabida cubierta del 20 %.** La base de datos dispone de *fccarb* (arbórea) y *fcctot*

(total). Este umbral se aplica como *filtro de elegibilidad* previo o posterior al modelado, sin modificar la arquitectura del modelo ( $fccarb > 20$ ).

- **Altura mínima de 3 m en la madurez.** Este requisito se refiere a la altura que alcanzan los árboles en su fase de pleno desarrollo, y no a la altura inicial de los plantones. Por tanto, las mediciones realizadas durante las etapas tempranas de crecimiento no determinan la elegibilidad del proyecto, siempre que las especies seleccionadas sean capaces de superar los 3 metros en la madurez. Este criterio se evalúa de forma externa al modelo, mediante la selección de especies forestales adecuadas y la verificación con fuentes auxiliares (catálogos silvícolas o tipologías de masa). En la práctica, el cumplimiento del requisito depende de una decisión de diseño del proyecto: no plantar especies cuyo tamaño adulto sea inferior a 3 metros. Por ello, la altura no interviene directamente en el entrenamiento, aunque sí condiciona la elegibilidad final del proyecto forestal.

#### 5.4. Preparación y tratamiento de los datos

Como ya se ha introducido, el entrenamiento se realiza en dos líneas según la variable objetivo: carbono en toneladas por hectárea (*c* de **IFN4**) o carbono en toneladas (carbono\_bruto de **IFN4**); y según la información que se usa como explicativa: **IFN3** o **IFN3** e **IFN2**. Se plantea la preparación y filtrado de los datos en términos generales.

##### 5.4.1. Filtrado de registros

Se descartan todas aquellas parcelas en las que el valor de carbono total (variable objetivo) en la segunda inventariación es inferior a la primera. Estos casos suelen deberse a episodios de deforestación, incendios u otras perturbaciones, y no representan un crecimiento forestal neto.

El conjunto de datos se restringe únicamente a las parcelas que presentan una *fccarb* (fracción de cabida cubierta arbórea) igual o superior al 20 % en el inventario explicativo. Este umbral define la proporción mínima de superficie ocupada por copas de árboles respecto al área total de la parcela, y constituye una de las condiciones esenciales para considerar una superficie como terreno forestal. La exclusión de parcelas con *fccarb* inferior al 20 % permite asegurar que las estimaciones de carbono se realicen sobre masas forestales consolidadas, evitando sesgos asociados a áreas agrícolas o matorrales. A los datos del **IFN2** no se les aplica dicho filtro porque no disponen de la variable *fccarb*.

##### 5.4.2. Cálculo y agregación de variables

Cada registro de entrada se genera a nivel de combinación parcela–especie, incorporando las variables correspondientes de la primera medición y la variable objetivo (carbono) de la segunda medición (**IFN4**). Las variables de parcela y parcela\_inventario se desdoblan para cada especie. Las entradas de la tabla *parcela\_inventario\_especie\_cd* se agrupan por parcela y especie y se comprimen en una única entrada creando un conjunto de variables para cada clase diamétrica.

| Resumen de Datos de Entrada del Modelo                                             |           |                                                   |                    |
|------------------------------------------------------------------------------------|-----------|---------------------------------------------------|--------------------|
| Variable                                                                           | Tipo      | Descripción                                       | Anexo              |
| parcela_id                                                                         | varchar   | Identificador único de parcela.                   | –                  |
| especie_id, tipo_especie, grupo_id                                                 | int (CF)  | Especie, tipo y grupo taxonómico.                 | A.17, A.16         |
| ocupa                                                                              | int       | Grado de ocupación (0–10).                        | –                  |
| estado_id, fpmasa_id, tratmasa_id, orgmasa1_id                                     | int (CF)  | Estado, forma de masa, tratamiento, organización. | A.2, A.3, A.4, A.5 |
| tipsuelo1–3_id                                                                     | int (CF)  | Tipos de suelo.                                   | Anexo A.6          |
| rocosidad_id, textura_id, matorg_id, modcomb_id, disesp_id, comesp_id, merosiva_id | int (CF)  | Variables edáficas y estructurales.               | Apéndices varios   |
| radio, orientacion, elevacion, pendiente                                           | float     | Topografía y geometría de parcela.                | –                  |
| martonneidx_id                                                                     | int (CF)  | Índice de aridez de Martonne.                     | –                  |
| nivel1_id, nivel2_id, fccarb, fcctot                                               | int/float | Niveles jerárquicos y cabida cubierta.            | A.14, A.15         |
| npies_{CD}                                                                         | float     | N.º de pies por clase diamétrica.                 | –                  |
| periodo                                                                            | int       | Años entre inventarios.                           | –                  |
| evi, gndvi, ndii, ndvi_{stat}_{est}                                                | float     | Índices de vegetación por estación.               | –                  |
| pr, skt, stl1–4, t2m_{stat}_{est}                                                  | float     | Variables climáticas por estación.                | –                  |
| c4, carbono_bruto4                                                                 | float     | Carbono IFN4 (t/ha y t).                          | –                  |

**Tabla 5.1**

Variables de entrada del modelo. Las variables en verde están disponibles en IFN2 e IFN3; el resto solo en IFN3.

La Tabla 5.1 resume las variables empleadas como entrada al modelo, integradas desde las distintas tablas que conforman la base de datos relacional.

#### 5.4.3. Reclasificación de las variables pendiente y orientacion

Las variables topográficas originales pendiente (en grados) y orientacion (acimut en grados) se registran de forma continua en las parcelas del IFN. Sin embargo, desde el punto de vista ecológico su efecto sobre la acumulación de carbono suele ser no lineal y está asociado a clases discretas (e.g. laderas suaves frente a escarpadas, exposición norte frente a sur), por lo que resulta más adecuado tratarlas como factores categóricos.

A partir de la distribución empírica y de criterios habituales en estudios de fisiografía forestal, se definió una variable categórica pendiente\_cat mediante cortes en grados:

- < 5°: *muy suave*,
- 5–10°: *suave*,
- 10–15°: *moderada*,
- 15–20°: *fuerte*,
- 20–30°: *muy fuerte*,
- 30–50°: *escarpada*,
- > 50°: *extrema*.

Esta reclasificación permite capturar diferencias funcionales relevantes (accesibilidad, estabilidad del suelo, escorrenría, profundidad efectiva del suelo) sin asumir una relación lineal entre la pendiente y el carbono almacenado.

De forma análoga, la variable orientacion se reclasificó en ocho sectores cardinales equiángulos: N, NE, E, SE, S, SO, O y NO. La nueva variable orientacion\_cat agrupa orientaciones con condiciones de insolación y balance hídrico similares, lo que facilita la interpretación ecológica y reduce el ruido asociado a pequeñas variaciones angulares.

#### 5.4.4. Agrupación de la variable periodo

Como se puede observar en la Figura 5.3, la distribución de la variable periodo, definida como el número de años transcurridos entre la medición de las variables explicativas y la observación de la variable objetivo, presenta cierta heterogeneidad en su frecuencia. Aunque el rango total de valores se extiende aproximadamente entre 0 y 34 años, algunos intervalos temporales aparecen representados por un número muy reducido de observaciones.

Esta escasez de datos en determinados valores de periodo puede introducir inestabilidad en el entrenamiento de los modelos, al forzar al algoritmo a aprender patrones a partir de muestras poco representativas. Para mitigar este efecto y mejorar la robustez de las predicciones, se optó por agrupar ciertos valores de periodo en categorías temporales

más amplias, dando lugar a una nueva variable denominada periodo\_agrupado.

El procedimiento de agrupación se diseñó de forma conservadora, manteniendo sin modificar aquellos valores con suficiente soporte muestral y agrupando únicamente los intervalos más escasos. En concreto, los valores inferiores a 6 años se agruparon en la categoría 5; los periodos entre 7 y 10 años se agruparon en 10; los comprendidos entre 18 y 21 años se agruparon en 20; y los valores iguales o superiores a 29 años se agruparon en 30. El resto de valores intermedios se mantuvieron sin modificación.

Cabe destacar que la variable periodo\_agrupado no conserva la granularidad completa de la variable original, pero sí retiene su significado temporal esencial. Los experimentos realizados muestran que esta representación resulta más estable desde el punto de vista estadístico y conduce a modelos con un comportamiento predictivo más robusto, al reducir la sensibilidad a intervalos temporales con baja frecuencia de observaciones.

### 5.5. Partición y validación

Para obtener una estimación imparcial del rendimiento y evitar *fugas de información* derivadas de la estructura jerárquica de los datos, el proceso de entrenamiento se organiza en dos niveles: (i) una partición externa *hold-out* para la evaluación final y (ii) una validación cruzada interna para la selección de hiperparámetros.

**Partición entrenamiento/test.** Los datos, ya filtrados, se separan en un 80 % para entrenamiento y un 20 % para test. Dicha separación se hace de forma que todas las observaciones asociadas a una misma parcela queden asignadas íntegramente a uno de los subconjuntos.

**Validación cruzada para selección de hiperparámetros.** La selección de hiperparámetros se lleva a cabo exclusivamente sobre el conjunto de entrenamiento mediante GridSearchCV con métrica de optimización  $R^2$ . Se utiliza GroupKFold con  $k = 5$  pliegues, imponiendo que no exista solape de parcelas entre pliegues (esto es, la agrupación se respeta tanto en el *hold-out* como en la validación interna).

**Métricas de evaluación.** En este estudio se emplea un conjunto de métricas complementarias para evaluar el rendimiento desde distintas perspectivas (precisión, sesgo, ajuste relativo). En las siguientes expresiones,  $y_i$  denota el valor observado,  $\hat{y}_i$  el valor predicho,  $\bar{y}$  la media de los valores observados y  $n$  el número de observaciones:

- **RMSE (Root Mean Squared Error):** raíz del error cuadrático medio. Mide la magnitud promedio de los errores penalizando fuertemente las grandes desviaciones. Se expresa en las mismas unidades que la variable objetivo.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (5.1)$$

- **RMSE Porcentual (RMSE %):** expresa el RMSE como porcentaje respecto a la media de los valores

observados. Facilita la interpretación relativa del error independientemente de la escala.

$$\text{RMSE}_{\%} = \frac{\text{RMSE}}{\bar{y}} \times 100 \quad (5.2)$$

- **$R^2$  (Coeficiente de determinación):** proporción de la varianza total de la variable objetivo que es explicada por el modelo. Valores cercanos a 1 indican un alto poder explicativo.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (5.3)$$

- **MAE (Mean Absolute Error):** media aritmética de las diferencias absolutas entre predicciones y observaciones. Es una métrica de error lineal, más robusta frente a valores atípicos que el RMSE y de fácil interpretación directa.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5.4)$$

- **MAPE (Mean Absolute Percentage Error):** promedio del error absoluto relativo al valor real, expresado en porcentaje. Permite evaluar la calidad de la predicción en términos relativos.

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \quad (5.5)$$

- **wMAPE (Weighted Mean Absolute Percentage Error):** variante ponderada del MAPE donde el error se normaliza por el volumen total de la variable real. Evita problemas de inestabilidad cuando los valores observados son cercanos a cero.

$$\text{wMAPE} = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{\sum_{i=1}^n |y_i|} \times 100 \quad (5.6)$$

- **SMAPE (Symmetric Mean Absolute Percentage Error):** error porcentual simétrico que normaliza la discrepancia por la magnitud media de los valores observados y predichos. Reduce la asimetría del MAPE y está acotado.

$$\text{SMAPE} = \frac{100}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2} \quad (5.7)$$

- **MedAE (Median Absolute Error):** mediana de los errores absolutos. Proporciona una medida de error robusta y resistente a la presencia de valores atípicos extremos (*outliers*).

$$\text{MedAE} = \text{mediana}(|y_1 - \hat{y}_1|, \dots, |y_n - \hat{y}_n|) \quad (5.8)$$

- **Bias (Sesgo Medio):** evalúa la tendencia sistemática del modelo a sobreestimar (valor positivo) o subestimar (valor negativo) las observaciones reales.

$$\text{Bias} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i) \quad (5.9)$$

### 5.5.1. Codificación y normalización

Con el fin de garantizar coherencia metodológica y evitar fugas de información durante la validación cruzada, todas las etapas de preprocesado se integran explícitamente dentro de un Pipeline junto con el modelo de regresión. De este modo, los parámetros asociados al preprocesado se estiman *exclusivamente* a partir de los datos de entrenamiento de cada pliegue, y se aplican posteriormente a los datos de validación o test.

Las variables se tratan de acuerdo con su naturaleza:

- **Variables numéricas continuas:** se imputan mediante la mediana para reducir la influencia de valores extremos y, posteriormente, se estandarizan mediante normalización *z-score* (media cero y desviación estándar unitaria). Este paso resulta especialmente relevante para modelos sensibles a la escala de las variables, como regresiones lineales, SVR o redes neuronales.
- **Variables estructurales de densidad** (*npies\_\**): al representar recuentos por clase diamétrica, se imputan con valor cero cuando están ausentes y se estandarizan de forma análoga a las variables numéricas, preservando su contribución relativa en el modelo.
- **Variables categóricas:** se imputan mediante la moda, se convierten explícitamente a tipo cadena y se codifican mediante *one-hot encoding*. Se utiliza la opción *handle\_unknown='ignore'* para garantizar la robustez del modelo frente a categorías no observadas durante el entrenamiento.

Esta estrategia asegura que la codificación, imputación y escalado de las variables se realicen de forma consistente en todos los modelos evaluados y que el rendimiento estimado refleje fielmente la capacidad de generalización del sistema, sin introducir sesgos derivados del acceso indebido a información del conjunto de evaluación.

## 5.6. Selección de variables explicativas

La selección de predictores se abordó mediante tres estrategias complementarias: (1) selección automática mediante *Featurewiz*, (2) selección basada en el criterio de mínima redundancia y máxima relevancia (*mRMR*) y (3) selección manual basada en criterios estadísticos y conceptuales.

### 5.6.1. Selección automática mediante *Featurewiz*

El algoritmo *Featurewiz* aplica un enfoque híbrido orientado a la relevancia predictiva. Primero ejecuta un filtrado por correlación, eliminando predictores altamente colineales (umbral  $|r| > 0,70$ ), y posteriormente refina el conjunto mediante modelos de *Gradient Boosting* para estimar la importancia relativa de cada variable. El resultado es un subconjunto compacto de predictores con contribución significativa al rendimiento del modelo.

### 5.6.2. Selección mediante *mRMR*

El método *mRMR* (minimum Redundancy–maximum Relevance) selecciona las variables que mejor explican la variabilidad del objetivo a la vez que minimizan la redundancia

informativa entre ellas. Para ello emplea información mutua, permitiendo capturar relaciones potencialmente no lineales. Este enfoque prioriza predictores que aportan información complementaria sobre el proceso ecológico modelado, evitando duplicidades entre atributos altamente correlacionados.

### 5.6.3. Selección manual basada en criterios estadísticos y conceptuales

La selección manual integró criterios estadísticos (correlaciones, ANOVA y análisis de redundancia) con criterios ecológicos y de interpretabilidad. Se descartaron predictores sin asociación significativa con la variable objetivo y se redujo la colinealidad reteniendo un único representante por cada grupo altamente correlacionado. Asimismo, se garantizaron variables que describieran dimensiones esenciales del sistema (estructura del arbolado, topografía, suelo, clima e índices espectrales), asegurando un equilibrio entre precisión predictiva y coherencia biogeográfica.

### 5.6.4. Selección Secuencial Supervisada basada en Rendimiento Predictivo (SSSRP)

El método SSSRP complementó las estrategias anteriores mediante un enfoque explícitamente orientado al rendimiento predictivo. Se partió de un *bloque base* de variables estructurales y se evaluó el impacto marginal de cada candidato añadiéndolo individualmente y comparando el cambio en  $R^2$  y RMSE mediante un modelo CatBoost con validación holdout estratificada por parcela. A continuación, se aplicó una estrategia de *forward selection* codiciosa, incorporando en cada iteración la variable que proporcionaba la mayor mejora y deteniendo el proceso cuando la ganancia resultaba inferior a un umbral predefinido ( $\Delta R^2 > 10^{-5}$ ). Este procedimiento produjo un conjunto final de predictores reducido, no redundante y específicamente optimizado para maximizar el rendimiento del modelo.

## 5.7. Modelos evaluados

A continuación se describe el procedimiento seguido para la selección, optimización y combinación de modelos. El objetivo es construir un conjunto de predictores base sólidos y posteriormente integrarlos en un *stack-ensemble* capaz de mejorar la capacidad de generalización.

### 5.7.1. Modelos ensemble

Se utilizaron diversos métodos de *ensemble learning* con el fin de aumentar la precisión y robustez del sistema predictivo. El principio fundamental consiste en combinar predicciones de múltiples modelos, aprovechando su diversidad para reducir varianza, sesgo o ambos.

#### Técnicas empleadas:

- **Bagging:** entrena modelos independientes sobre subconjuntos generados mediante muestreo bootstrap. Reduce varianza y mejora estabilidad.



- **Boosting:** construye modelos secuenciales donde cada uno corrige los errores del anterior. Tiende a reducir el sesgo y producir modelos altamente precisos.
- **Stacking:** integra múltiples modelos base mediante un meta-modelo entrenado sobre sus predicciones. Permite capturar relaciones no lineales entre las salidas de los modelos base.

### 5.7.2. *Boosting y aprendizaje secuencial*

El conjunto de modelos de boosting evaluados incluye:

- **XGBoost:** implementación avanzada del *gradient boosting*, que incorpora regularización L1/L2, optimización mediante segundo orden y manejo interno de valores faltantes.
- **LightGBM:** algoritmo especialmente eficiente, basado en crecimiento *leaf-wise*, capaz de manejar grandes volúmenes de datos y con soporte nativo para variables categóricas.
- **CatBoost:** optimizado para variables categóricas y robusto frente a ruido mediante técnicas como *ordered boosting*.
- **Gradient Boosting Decision Trees (GBDT):** implementación clásica del algoritmo basado en descenso por gradiente sobre residuos.
- **AdaBoost:** técnica que ajusta modelos simples (stumps) secuencialmente, asignando más peso a observaciones difíciles.

### 5.7.3. *Bagging*

Los modelos basados en bootstrap empleados fueron:

- **Random Forest:** conjunto de árboles de decisión que introduce aleatoriedad tanto en datos como en características. Suele ser robusto y relativamente estable.
- **Bagged Decision Trees (BaggedDT):** árboles no podados entrenados sobre muestras bootstrap, cuyas predicciones se promedian para reducir varianza.

### 5.7.4. *Otros modelos evaluados*

Además de los métodos ensemble, se evaluaron modelos representativos de paradigmas adicionales:

- **Support Vector Regression (SVR):** modelo de márgenes para regresión, evaluado con kernel lineal.
- **K-Nearest Neighbors (KNN):** modelo basado en vecinos más próximos; útil como referencia no paramétrica, aunque sensible a la escala.
- **Multi-Layer Perceptron (MLP):** red neuronal densa capaz de capturar relaciones no lineales.
- **Bayesian Neural Network (BayesianNN):** aproximación probabilística que permite cuantificar incertidumbre a través de regularización bayesiana.

### 5.7.5. *Configuración del stacking*

Tras evaluar todos los modelos anteriores, se construyeron diferentes configuraciones de modelos base (*base learners*) que se combinan mediante un meta-modelo. Estas combinaciones se diseñaron con dos criterios principales:

1. **Diversidad estructural:** mezclar métodos de boosting y bagging, así como variantes de boosting con distintas estrategias de crecimiento y regularización.
2. **Rendimiento individual:** incluir preferentemente los modelos con mayor  $R^2$  y menor error (RMSE, MAE) en las pruebas individuales.

Los meta-modelos utilizados para integrar las predicciones fueron:

- **Modelos lineales:** Regresión Lineal, Ridge.
- **Modelos basados en árboles:** Random Forest, Gradient Boosting Regressor.
- **Modelos kernel:** SVR lineal.
- **Red neuronal:** MLP con una capa oculta.

Esta selección permite comparar desde combinadores lineales simples hasta integradores no lineales capaces de capturar interacciones complejas entre predicciones.

### 5.7.6. *Comparación y justificación de modelos*

La evaluación exhaustiva de múltiples algoritmos permite identificar no solo el modelo individual con mejor rendimiento, sino también combinaciones sinérgicas para el *stacking*. La Tabla 5.2 resume los modelos finalmente entrenados y evaluados.

## 6. Implementación del pipeline

El desarrollo y la evaluación de los modelos predictivos se realizaron íntegramente en **Python**, utilizando librerías como *scikit-learn*, *cuML* y *PyTorch*, junto con implementaciones específicas de *gradient boosting* como *XGBoost*, *LightGBM* y *CatBoost*. El proceso de entrenamiento se llevó a cabo en dos fases diferenciadas.

Para los modelos entrenados exclusivamente con datos del IFN3 se utilizó un equipo local equipado con un procesador Intel Core i7 y 32 GB de memoria RAM. En cambio, los modelos que empleaban conjuntamente datos del IFN2 e IFN3 se entrenaron en el sistema de computación de alto rendimiento (HPC) de la Universidad de Salamanca. Esta elección se debió a la disponibilidad de tarjetas gráficas Nvidia H100, que permiten acelerar de forma significativa el entrenamiento de aquellos modelos compatibles con ejecución en GPU gracias a su elevada capacidad de paralelización.

No obstante, cabe señalar que el entrenamiento también podría haberse realizado en un equipo de escritorio convencional equipado con una tarjeta gráfica comercial, ya que los requisitos computacionales del problema no son especialmente elevados.

### 6.1. Ingeniería práctica del entrenamiento y la validación

Desde el punto de vista de la implementación, el proceso de entrenamiento y validación se apoyó fundamentalmente en el ecosistema de *scikit-learn*, complementado con librerías especializadas para modelos de *gradient boosting*. La gestión de los datos se realizó mediante *pandas* y *numpy*, mientras que el cálculo de métricas y estadísticas adicionales

| Modelo        | Tipo           | Características                                | Observaciones                  |
|---------------|----------------|------------------------------------------------|--------------------------------|
| Random Forest | Bagging        | Bootstrap con selección aleatoria de atributos | Robusto y estable              |
| BaggedDT      | Bagging        | Árboles sin poda sobre muestras bootstrap      | Mejora por agregación          |
| XGBoost       | Boosting       | Regularización L1/L2, segundo orden            | Muy preciso; sensible a tuning |
| LightGBM      | Boosting       | Crecimiento leaf-wise, muy eficiente           | Rápido; riesgo de sobreajuste  |
| CatBoost      | Boosting       | Codificación ordenada; robusto al ruido        | Excelente sin gran tuning      |
| GBDT          | Boosting       | Árboles secuenciales ajustados a residuos      | Buen rendimiento               |
| AdaBoost      | Boosting       | Aumenta peso de obs. mal predichas             | Menos robusto                  |
| KNN           | Instancia      | Predicción por proximidad                      | Sensible a escala y ruido      |
| MLP           | Red neuronal   | Captura relaciones no lineales                 | Requiere normalización         |
| SVR           | Márgenes       | Kernel lineal, gran margen                     | Robusto al sobreajuste         |
| BayesianNN    | Probabilístico | Cuantifica incertidumbre                       | Reduce sobreajuste             |

**Tabla 5.2**

Resumen de los modelos de aprendizaje supervisado evaluados.

del error se apoyó en `scipy` y los módulos de evaluación de `sklearn.metrics`.

A partir del conjunto de datos original, se aplicaron filtros de calidad sobre la variable objetivo utilizando operaciones vectorizadas de `pandas`, eliminando observaciones con valores nulos, inconsistentes o que no cumplieran los criterios definidos en la Sección 5.4.1.

La partición de los datos en conjuntos de entrenamiento y prueba se realizó mediante `GroupShuffleSplit` del módulo `sklearn.model_selection`, con una proporción 80/20. Este esquema garantizó que todas las observaciones asociadas a una misma parcela se asignaran íntegramente a un único subconjunto, evitando fugas de información derivadas de la correlación espacial intra-parcela. Sobre el conjunto de entrenamiento se definió una validación cruzada de cinco pliegues utilizando `GroupKFold`.

El preprocesado de las variables y el ajuste de los modelos se integraron en un único objeto `Pipeline`, combinando `ColumnTransformer`, `SimpleImputer`, `StandardScaler` y `OneHotEncoder`. Esta integración aseguró que todas las transformaciones se estimaran exclusivamente con los datos de entrenamiento de cada pliegue durante la validación cruzada. El ajuste de hiperparámetros se llevó a cabo mediante `GridSearchCV`, definiendo rejillas específicas para cada algoritmo y utilizando el coeficiente de determinación ( $R^2$ ) como métrica de selección.

Los modelos evaluados incluyen implementaciones de *gradient boosting* (XGBoost, LightGBM, CatBoost y `GradientBoostingRegressor`), métodos basados en *bagging* (`RandomForestRegressor`, `BaggingRegressor`), así como modelos de distinta naturaleza como `MLPRegressor`, `KNeighborsRegressor`, `LinearSVR`, `AdaBoostRegressor` y `BayesianRidge`. Para cada modelo se calcularon de forma sistemática las métricas de rendimiento sobre el conjunto de prueba:  $R^2$ , RMSE y MAE, junto con estadísticas adicionales del error absoluto (mediana y moda),

almacenándose los resultados en estructuras tabulares para su análisis comparativo.

## 6.2. Implementación del *stacking*

La agregación de modelos mediante *stacking* se implementó de forma manual utilizando utilidades básicas de `scikit-learn`, con el objetivo de mantener un control estricto sobre el flujo de entrenamiento y validación. A partir de los mejores modelos individuales se generaron predicciones fuera de pliegue (*out-of-fold*, OOF) sobre el conjunto de entrenamiento, empleando el mismo esquema de validación cruzada (`GroupKFold`).

Estas predicciones OOF se organizaron en matrices de meta-variables mediante `numpy` y se utilizaron como entrada para el entrenamiento de los metamodelos. En paralelo, cada modelo base se reentrenó sobre la totalidad del conjunto de entrenamiento para generar las correspondientes predicciones sobre el conjunto de test, que se emplearon posteriormente para la evaluación final del *stack*.

Los metamodelos considerados incluyen `LinearRegression`, `Ridge`, `GradientBoostingRegressor`, `RandomForestRegressor`, `SVR` con kernel lineal y `MLPRegressor`. Antes de su ajuste, las meta-variables se estandarizaron mediante `StandardScaler`, integrando este paso en un `Pipeline` específico del segundo nivel. La evaluación del *stacking* se realizó exclusivamente sobre el conjunto de test independiente, calculando las métricas habituales ( $R^2$ , RMSE y MAE) para cada combinación de modelos base y metamodelo.

## 6.3. Datos finales de entrenamiento


Tras aplicar los criterios de elegibilidad y filtrado descritos en la Sección ??, el conjunto de datos final utilizado para el ajuste de los modelos queda compuesto por:

- **IFN2:** Total de parcelas = **88.696**
  - Casos con  $c4 > c$ : **31.428**
  - Casos con  $carbónico\_bruto4 > carbónico\_bruto$ : **32.403**


**Tabla 6.1**

Estadísticos descriptivos del conjunto de datos depurado.

| Variable         | N       | Media | Desv. estándar | Mín. | Máx.   |
|------------------|---------|-------|----------------|------|--------|
| carbono_bruto4   | 133 119 | 20.79 | 35.09          | 0.00 | 420.50 |
| carbono_bruto    | 123 563 | 10.09 | 26.33          | 0.00 | 511.31 |
| c4               | 103 790 | 38.83 | 47.27          | 0.48 | 883.46 |
| c                | 131 942 | 29.58 | 40.62          | 0.44 | 873.36 |
| periodo_agrupado | 103 785 | 18.47 | 6.47           | 5.00 | 30.00  |



(a) Histograma de la variable c4 en escala logarítmica.



(b) Histograma de la variable carbono\_bruto4 en escala logarítmica.

**Figura 6.1:** Histograma de las variables c4 y carbono\_bruto4 en el conjunto depurado.


■ **IFN3:** Total de parcelas = **171.157**

- Casos con  $f_{ccarb} > 20$ : **158.434**
- Casos con  $f_{ccarb} > 20$  y  $c4 > c$ : **57.401**
- Casos con  $f_{ccarb} > 20$  y  $carbono\_bruto4 > carbono\_bruto$ : **76.617**


La Tabla ?? resume las principales estadísticas descriptivas de las variables objetivo utilizadas en el modelado.

Se observa que la variable carbono\_bruto4 presenta una media de 20.79 y una desviación estándar de 35.09, mientras que la variable c4 muestra valores notablemente superiores (media de 38.83 y desviación estándar de 47.27). Podemos encontrar un histograma de la distribución de las variables objetivo en la Figura 6.1.

En la Figura 6.2 podemos ver las distribuciones de las variables objetivo separadas por inventarios, y podemos



(a) Distribución de la variable c4 en escala logarítmica.



(b) Distribución de la variable carbono\_bruto4 en escala logarítmica.

**Figura 6.2:** Distribución de las variables c4 y carbono\_bruto4 en el conjunto depurado separadas por inventario.

ver que la variable c4 es más dispersa y heterogénea que carbono\_bruto4. En general, una mayor variabilidad en la variable objetivo se traduce en un problema de predicción más complejo, ya que el modelo debe capturar relaciones más inestables y sujetas a mayor ruido.

Por tanto, incluso antes de evaluar los modelos, es razonable esperar que una misma familia de algoritmos obtenga valores de  $R^2$  más elevados y errores más bajos (RMSE, MAE) al predecir carbono\_bruto4, cuya estructura estadística es menos dispersa, que al predecir c4.

### 6.3.1. Efecto del periodo sobre el carbono

La influencia del periodo sobre las variables de carbono se evaluó mediante ANOVA de un factor. Los análisis realizados muestran que el periodo ejerce un efecto significativo sobre ambas variables. En c4 se obtuvo un estadístico  $F = 143.49$  ( $p < 0.001$ ), mientras que en carbono\_bruto4 el valor fue  $F = 161.08$  ( $p < 0.001$ ). Estos resultados indican que las diferencias observadas entre periodos no son aleatorias,

sino que reflejan variaciones sistemáticas asociadas al momento de muestreo, confirmando que el *periodo* constituye un factor explicativo relevante en la dinámica del carbono forestal.

## 7. Entrenamiento y validación

El proceso de entrenamiento se estructuró en varias fases orientadas a optimizar tanto la selección de variables predictoras como la robustez del modelo final. En primer lugar, se llevó a cabo una etapa de **selección de variables**, en la que se evaluaron distintos subconjuntos de características definidos por bloques temáticos con significado ecológico y funcional. Para esta tarea se adoptó un enfoque sistemático basado en la comparación del desempeño predictivo de las distintas combinaciones mediante el algoritmo CatBoost, seleccionado tras pruebas preliminares que mostraron su alta capacidad de ajuste y estabilidad frente a la heterogeneidad de los datos. En todas las configuraciones se mantuvo constante la variable objetivo (carbono capturado) y los parámetros del modelo, de modo que las variaciones en el coeficiente de determinación ( $R^2$ ) y el error cuadrático medio (RMSE) reflejaran exclusivamente la contribución informativa de cada bloque. Los resultados de esta fase son preliminares ya que se emplearon entrenamientos más sencillos (sin validación cruzada para la selección de hiperparámetros).

Las configuraciones analizadas incorporaron progresivamente variables relacionadas con las características de la especie, las propiedades edáficas, el terreno, las condiciones climáticas y los índices de vegetación. A partir de los resultados obtenidos, se identificaron los bloques con mayor aporte marginal al rendimiento del modelo, priorizando aquellos cuya inclusión mejoró consistentemente el  $R^2$  sin aumentar de forma significativa la complejidad o redundancia del conjunto de predictores.

En una segunda fase, se procedió al **entrenamiento comparativo de modelos**, implementando un conjunto de algoritmos de aprendizaje supervisado con el fin de contrastar su capacidad predictiva. Cada modelo fue entrenado bajo las mismas condiciones experimentales, utilizando las configuraciones de variables seleccionadas en la fase anterior. Esta comparación permitió identificar los algoritmos con mejor ajuste global y menor error de predicción, destacando de nuevo el desempeño de CatBoost.

Posteriormente, se implementó una estrategia de **stacking**, combinando las predicciones de los modelos individuales mediante un metamodelo de segundo nivel, con el objetivo de aprovechar la complementariedad entre los distintos enfoques y mejorar la capacidad de generalización.

### 7.1. Elección de variables

#### 7.1.1. Resultados de la selección de variables manual

La selección manual de variables partió de una organización temática del conjunto de predictores, agrupando las variables según el tipo de información ecológica, estructural o climática que representan. Esta clasificación permitió estructurar el proceso de reducción dimensional en torno a los siguientes bloques conceptuales:

- **Bloque de variables fijas:** describe la estructura básica de la masa forestal y los atributos esenciales de identificación y caracterización general de cada parcela.
- **Bloque de variables de especie:** recoge información relativa a la composición, estado y características específicas de las formaciones forestales.
- **Bloque sustrato:** integra variables edáficas y de manejo susceptibles de variar en el tiempo.
- **Bloque de terreno:** agrupa propiedades físicas del medio que permanecen estables a escala temporal de inventarios (pendiente, orientación, tipo de suelo, etc.).
- **Bloque climático resumido:** representado por el índice de aridez de Martonne, que sintetiza la interacción entre temperatura y precipitación.
- **Bloque climático detallado:** incluye métricas estacionales explícitas de temperatura y precipitación.
- **Bloque de índices de vegetación:** recoge información espectral relacionada con el estado hídrico, vigor y actividad fotosintética de la vegetación.

En total, la base de datos contenía inicialmente 445 variables candidatas distribuidas entre estos bloques temáticos. Tras aplicar el procedimiento de selección manual, apoyado en criterios estadísticos, ecológicos y en la comparación del rendimiento del modelo, el conjunto se redujo a 44 variables representativas. Las variables finalmente seleccionadas dentro de cada bloque fueron las siguientes:

- **Bloque de variables fijas:** especie\_id, tipo\_especie, grupo\_id, periodo, radio, ocupa, npies\_1, npies\_2, npies\_5, npies\_10, npies\_15, npies\_20, npies\_25, npies\_30, npies\_35, npies\_40, npies\_45, npies\_50, npies\_55, npies\_60, npies\_65, npies\_70.
- **Bloque de variables de especie:** estado\_id, fccarb, disesp\_id.
- **Bloque sustrato (dinámico):** modcomb\_id, nivel2\_id, tratmasa\_id.
- **Bloque de terreno:** rocosidad\_id, orientacion\_cat, elevacion, pendiente\_cat.
- **Bloque climático resumido (Martonne):** martonneidx\_id.
- **Bloque climático detallado (temperatura y precipitación):** skt\_mean\_primavera, skt\_mean\_verano, skt\_std\_primavera, skt\_std\_verano, pr\_sum\_invierno, pr\_sum\_otoño, pr\_sum\_primavera, pr\_sum\_verano.
- **Bloque de índices de vegetación:** gndvi\_mean\_verano, ndii\_mean\_primavera, gndvi\_std\_primavera, evi\_mean\_primavera.

Este proceso permitió sintetizar la información original manteniendo una representación equilibrada de todos los ámbitos ecológicos implicados en la estimación del carbono.

La comparación de modelos entrenados con combinaciones incrementales de bloques mostró que todos ellos aportan información relevante, siguiendo el orden de contribución

aproximado: *variables fijas* > *variables de especie* > *sustrato* > *terreno* > *índices de vegetación* > *Martonne* > *temperatura* y *precipitación*. Es decir, la mayor parte de la capacidad predictiva se explica por la estructura y composición de la masa forestal, mientras que las condiciones edáficas, topográficas y climáticas actúan como moduladores adicionales de la acumulación de carbono.

### 7.1.2. Selección de variables mediante Featurewiz

Aplicado al conjunto completo de predictores, *Featurewiz* seleccionó **67 variables**. El patrón resultante muestra una clara preferencia por dos grandes grupos: (i) **índices de vegetación** derivados de Sentinel-2 y (ii) **variables térmicas estacionales**. El algoritmo retuvo numerosas estadísticas de NDII, EVI, GNDVI y NDVI (medias, máximos, mínimos, medianas y desviaciones estándar), especialmente durante primavera y verano, reflejando la relevancia del estado hídrico y el vigor fotosintético en la estimación del carbono.

Asimismo, se seleccionaron múltiples métricas de temperatura del aire y del suelo (*t2m\_\**, *skt\_\**, *stl\_\**) y diversas variables de precipitación (*pr\_sum\_\**, *pr\_max\_\**, *pr\_min\_\**), lo que muestra sensibilidad del método a las condiciones climáticas estacionales. El índice de aridez de Martonne también fue seleccionado, aportando una medida sintetizada del balance térmico-hídrico.

Finalmente, el algoritmo incluyó un conjunto contenido pero representativo de variables estructurales (número de pies por clase diamétrica), de especie y de terreno, indicando que dichas variables aportan información complementaria necesaria para la predicción.

### 7.1.3. Selección de variables mediante mRMR

El método *mRMR* seleccionó un total de **50 variables**, priorizando aquellas con alta información mutua respecto al carbono y baja redundancia entre sí. El conjunto final integra predictores estructurales (identificación de especie, radio, clases diamétricas, orientación y pendiente), variables topográficas y edáficas (rocosidad, tipos de suelo), métricas climáticas estacionales (temperatura del aire y del suelo, índice de Martonne) e índices de vegetación representativos del estado estacional de la copa.

La presencia sistemática de valores medios, máximos y medianos de NDII, GNDVI y EVI en verano y primavera confirma que la actividad fotosintética y el estado hídrico son predictores directos del carbono almacenado. De igual modo, la selección de múltiples métricas térmicas refleja la relevancia de los pulsos climáticos sobre la productividad forestal.

En conjunto, *mRMR* produjo un conjunto compacto y equilibrado, asegurando diversidad informativa y evitando redundancias, lo que lo convierte en un complemento eficaz a los métodos anteriores.

### 7.1.4. Discusión de la selección de variables

De los tres conjuntos de variables seleccionados se mantuvo la selección manual al demostrar un mejor rendimiento con mayor simplicidad.

**Tabla 7.1**

Configuraciones de modelos base para *stacking*.

| Config. | Modelos base                                               |
|---------|------------------------------------------------------------|
| 1       | LightGBM, Random Forest                                    |
| 2       | CatBoost, Random Forest, GBDT                              |
| 3       | LightGBM, XGBoost, GBDT                                    |
| 4       | CatBoost, LightGBM, Random Forest, GBDT                    |
| 5       | CatBoost, LightGBM, XGBoost, Random Forest, GBDT, BaggedDT |

## 7.2. Ensamblado tipo *stacking* de modelos de regresión

Con el objetivo de estudiar el compromiso entre diversidad del ensamble, coste computacional y rendimiento, se definieron cinco configuraciones de modelos base (Tabla 7.1). Los modelos AdaBoost, BayesianNN, SVR, MLP y KNN se descartaron como candidatos.

- **Configuración 1:** es la configuración más simple. LightGBM compite con CatBoost en rendimiento, mientras que Random Forest aporta un sesgo diferente al basarse en bagging en lugar de boosting. Esta configuración sirve como referencia de un ensamble muy ligero, con bajo coste computacional y, al mismo tiempo, razonablemente diverso.
- **Configuración 2:** combina un modelo de boosting basado en manejo robusto de variables categóricas (CatBoost) con Random Forest (bagging de árboles) y GBDT (boosting clásico). La idea es mezclar enfoques de bagging y boosting, manteniendo un número moderado de modelos y una buena diversidad estructural.
- **Configuración 3:** agrupa únicamente modelos de la familia de *gradient boosting*. El objetivo es analizar el efecto de combinar variantes de un mismo paradigma y evaluar hasta qué punto diferentes implementaciones de boosting proporcionan suficiente diversidad como para ser beneficiosa en un ensamble.
- **Configuración 4:** reduce el número de modelos en comparación con la configuración siguiente (que incluye todos los modelos competitivos), eliminando XGBoost y BaggedDT, que aportan menos mejora marginal respecto a sus alternativas (LightGBM y Random Forest). Esta combinación mantiene una buena diversidad con menor complejidad y coste computacional.
- **Configuración 5:** incluye todos los modelos con rendimiento competitivo. Esta configuración es la más rica en términos de variedad de arquitecturas, aunque también la más costosa computacionalmente y potencialmente más propensa al sobreajuste si no se controla adecuadamente.

El objetivo es que el meta-modelo reciba como entradas predicciones de alta calidad y suficientemente diversas, en lugar de introducir ruido procedente de modelos débiles.

Sobre las predicciones apiladas de cada configuración se entrenan distintos meta-modelos  $g(\cdot)$ , definidos en la Tabla 7.2.



**Tabla 7.2**

Meta-modelos utilizados en el *stacking* junto con sus parámetros.

| Meta-modelo       | Parámetros                                                                          |
|-------------------|-------------------------------------------------------------------------------------|
| Gradient Boosting | Configuración por defecto                                                           |
| Regresión Lineal  | Sin regularización                                                                  |
| Ridge             | Regularización L2 con validación cruzada ( $\alpha \in \{0,01, 0,1, 1, 10, 100\}$ ) |
| Random Forest     | 50 árboles                                                                          |
| SVR               | Kernel lineal                                                                       |
| MLP               | Una capa oculta con 50 neuronas, 500 iteraciones máximas                            |

Estos meta-modelos representan diferentes formas de combinar las predicciones de los modelos base:

- **Modelos lineales** (Regresión Lineal y Ridge): permiten comprobar si una combinación lineal de las predicciones base es suficiente para mejorar el rendimiento. Ridge añade regularización L2 para controlar el sobreajuste.
- **Modelos no lineales basados en árboles** (Gradient-BoostingRegressor, RandomForestRegressor): pueden capturar interacciones complejas entre las predicciones de los modelos base, a costa de una mayor complejidad.
- **Modelos de kernel** (SVR con kernel lineal): permiten una combinación robusta y, en algunos casos, menos sensible a valores extremos en las predicciones.
- **Red neuronal (MLPRegressor)**: introduce una capa adicional de flexibilidad, capaz de aproximar combinaciones no lineales complejas entre las salidas de los modelos base.

Al evaluar todas las combinaciones de *stack\_configs* con los diferentes *meta\_models*, se obtiene un conjunto de ensambles apilados que permiten estudiar de forma sistemática: (i) qué subconjuntos de modelos base son más complementarios, y (ii) qué tipo de meta-modelo aprovecha mejor la información contenida en sus predicciones.

## 8. Resultados

A continuación expondremos los resultados obtenidos a partir de varias métricas de evaluación de los modelos sobre el conjunto de datos de test. Dividiremos la sección según el origen de los datos de entrenamiento (IFN2, IFN3 o IFN2 e IFN3) y según la variable a predecir (toneladas de carbono o toneladas de carbono por hectárea).

### 8.1. Resultados IFN2

#### 8.1.1. Toneladas de carbono por hectárea

##### Modelos base

Una vez entrenados los modelos, algunos parámetros globales como el  $R^2$ , RMSE y MAE se presentan en la Tabla 8.1.

### Modelos con stacking

En la Tabla 8.2 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN2 como explicativo.

#### 8.1.2. Toneladas de carbono

##### Modelos base

En la Tabla 8.3 se muestra el resumen del rendimiento de los modelos para la predicción de la variable de carbono en toneladas (carbono\_bruto4) con el conjunto de datos que emplea IFN2 como explicativo.

### Modelos con stacking

En la Tabla 8.4 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en toneladas (carbono\_bruto4) con el conjunto de datos que emplea IFN2 como explicativo.

### 8.2. Resultados IFN3

#### 8.2.1. Toneladas de carbono por hectárea

##### Modelos base

Una vez entrenados los modelos, algunos parámetros globales como el  $R^2$ , RMSE y MAE se presentan en la Tabla 8.5.

### Modelos con stacking

En la Tabla 8.6 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN3 como explicativo.

#### 8.2.2. Toneladas de carbono

##### Modelos base

En la Tabla 8.7 se muestra el resumen del rendimiento de los modelos para la predicción de la variable de carbono en toneladas (carbono\_bruto4) con el conjunto de datos que emplea IFN3 como explicativo.

### Modelos con stacking

En la Tabla 8.8 se muestra el resumen del rendimiento de los modelos con stacking para la predicción de la variable de carbono en toneladas (carbono\_bruto4) con el conjunto de datos que emplea IFN3 como explicativo.

### 8.3. Resultados IFN2 e IFN3

#### 8.3.1. Toneladas de carbono por hectárea

##### Modelos base

Una vez entrenados los modelos, algunos parámetros globales como el  $R^2$ , RMSE y MAE se presentan en la Tabla 8.9

**Tabla 8.1**

Comparativa Modelos Base en IFN2 (c4)

| Modelo                           | $R^2_{\text{test}}$ | RMSE <sub>test</sub> (tC/ha) | MAE <sub>test</sub> (tC/ha) | wMAPE (%)     | SMAPE (%)     | Bias (tC/ha)  |
|----------------------------------|---------------------|------------------------------|-----------------------------|---------------|---------------|---------------|
| <b>LightGBM<sub>global</sub></b> | <b>0.719</b>        | <b>26.806</b>                | <b>14.689</b>               | <b>35.364</b> | <b>47.104</b> | <b>-0.021</b> |
| LightGBM                         | 0.712               | 26.435                       | 14.755                      | 35.823        | 47.593        | -0.401        |
| CatBoost <sub>global</sub>       | 0.708               | 27.359                       | 14.832                      | 35.710        | 47.895        | -0.135        |
| XGBoost <sub>global</sub>        | 0.708               | 27.361                       | 14.620                      | 35.198        | 46.910        | -0.171        |
| GBDT <sub>global</sub>           | 0.705               | 27.504                       | 14.772                      | 35.564        | 46.941        | -0.142        |
| XGBoost                          | 0.704               | 26.779                       | 14.773                      | 35.867        | 47.452        | -0.434        |
| CatBoost                         | 0.701               | 26.927                       | 15.066                      | 36.578        | 49.284        | -0.753        |
| MLP <sub>global</sub>            | 0.686               | 28.335                       | 15.668                      | 37.722        | 50.547        | 0.280         |
| BaggedDT                         | 0.676               | 28.036                       | 15.683                      | 38.075        | 49.869        | -0.195        |
| GBDT                             | 0.673               | 28.161                       | 15.614                      | 37.907        | 50.513        | -0.699        |
| RandomForest                     | 0.663               | 28.595                       | 15.807                      | 38.378        | 49.750        | -0.376        |
| BaggedDT <sub>global</sub>       | 0.658               | 29.574                       | 15.933                      | 38.361        | 50.974        | -0.599        |
| RandomForest <sub>global</sub>   | 0.653               | 29.803                       | 15.577                      | 37.502        | 48.386        | -1.499        |
| MLP                              | 0.637               | 29.650                       | 15.543                      | 37.735        | 49.907        | -7.176        |
| BayesianNN                       | 0.606               | 30.904                       | 17.384                      | 42.205        | 56.359        | -0.697        |
| BayesianNN <sub>global</sub>     | 0.588               | 32.482                       | 17.725                      | 42.675        | 56.630        | -0.732        |
| KNN                              | 0.565               | 32.480                       | 17.610                      | 42.755        | 54.696        | -5.373        |
| SVR <sub>global</sub>            | 0.465               | 37.013                       | 16.674                      | 40.145        | 49.745        | -8.320        |
| SVR                              | 0.445               | 36.667                       | 17.361                      | 42.150        | 52.112        | -8.338        |
| AdaBoost                         | -2.126              | 87.062                       | 81.700                      | 198.354       | 118.313       | 78.210        |

**Modelos con stacking**

En la Tabla 8.10 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN2 e IFN3 como explicativos.

**8.3.2. Toneladas de carbono****Modelos base**

En la Tabla 8.11 se muestra el resumen del rendimiento de los modelos para la predicción de la variable de carbono en toneladas con el conjunto de datos que emplea el IFN2 e IFN3 como explicativos.

**Modelos con stacking**

En la Tabla 8.12 se muestra el resumen del rendimiento de los modelos con stacking para la predicción de la variable de carbono en toneladas con el conjunto de datos que emplea el IFN2 e IFN3 como explicativos.

Tabla 8.2

Comparativa Modelos Stacking en IFN2 (c4)

| Modelo                                    | $R^2_{\text{test}}$ | RMSE <sub>test</sub> (tC/ha) | MAE <sub>test</sub> (tC/ha) | wMAPE (%)     | SMAPE (%)     | Bias (tC/ha)  |
|-------------------------------------------|---------------------|------------------------------|-----------------------------|---------------|---------------|---------------|
| <b>Stack5 GradientBoosting</b>            | <b>0.724</b>        | <b>25.889</b>                | <b>14.531</b>               | <b>35.280</b> | <b>47.157</b> | <b>-0.579</b> |
| Stack1 MLP <sub>global</sub>              | 0.722               | 26.683                       | 14.582                      | 35.106        | 46.515        | 0.117         |
| Stack2 MLP <sub>global</sub>              | 0.721               | 26.726                       | 14.475                      | 34.848        | 46.320        | -0.131        |
| Stack5 MLP <sub>global</sub>              | 0.721               | 26.742                       | 14.502                      | 34.913        | 46.347        | 0.077         |
| Stack3 GradientBoosting                   | 0.720               | 26.054                       | 14.847                      | 36.045        | 48.023        | -0.747        |
| Stack1 LinearRegression <sub>global</sub> | 0.719               | 26.827                       | 14.609                      | 35.173        | 46.712        | -0.140        |
| Stack1 Ridge <sub>global</sub>            | 0.719               | 26.829                       | 14.609                      | 35.172        | 46.709        | -0.142        |
| Stack5 MLP                                | 0.718               | 26.127                       | 14.452                      | 35.088        | 46.430        | -0.607        |
| Stack4 MLP <sub>global</sub>              | 0.718               | 26.852                       | 14.479                      | 34.859        | 46.260        | -0.328        |
| Stack2 LinearRegression <sub>global</sub> | 0.718               | 26.877                       | 14.505                      | 34.922        | 46.440        | -0.112        |
| Stack2 Ridge <sub>global</sub>            | 0.718               | 26.883                       | 14.507                      | 34.927        | 46.440        | -0.114        |
| Stack4 MLP                                | 0.717               | 26.177                       | 14.550                      | 35.326        | 46.579        | -0.495        |
| Stack5 LinearRegression <sub>global</sub> | 0.717               | 26.905                       | 14.552                      | 35.034        | 46.852        | -0.053        |
| Stack5 Ridge <sub>global</sub>            | 0.717               | 26.910                       | 14.547                      | 35.022        | 46.818        | -0.064        |
| Stack4 LinearRegression <sub>global</sub> | 0.717               | 26.912                       | 14.590                      | 35.127        | 46.948        | -0.056        |
| Stack4 Ridge <sub>global</sub>            | 0.717               | 26.913                       | 14.584                      | 35.112        | 46.912        | -0.066        |
| Stack5 LinearRegression                   | 0.716               | 26.247                       | 14.600                      | 35.445        | 47.345        | -0.545        |
| Stack5 Ridge                              | 0.716               | 26.247                       | 14.599                      | 35.445        | 47.344        | -0.545        |
| Stack1 MLP                                | 0.716               | 26.257                       | 14.669                      | 35.614        | 47.371        | -0.555        |
| Stack4 LinearRegression                   | 0.715               | 26.271                       | 14.621                      | 35.498        | 47.385        | -0.553        |
| Stack4 Ridge                              | 0.715               | 26.271                       | 14.621                      | 35.498        | 47.385        | -0.553        |
| Stack2 GradientBoosting <sub>global</sub> | 0.715               | 27.001                       | 14.536                      | 34.996        | 46.544        | -0.181        |
| Stack1 Ridge                              | 0.714               | 26.339                       | 14.689                      | 35.663        | 47.140        | -0.500        |
| Stack1 LinearRegression                   | 0.714               | 26.339                       | 14.689                      | 35.663        | 47.140        | -0.500        |
| Stack4 GradientBoosting                   | 0.713               | 26.383                       | 14.607                      | 35.464        | 47.377        | -0.674        |
| Stack2 MLP                                | 0.712               | 26.401                       | 14.587                      | 35.414        | 46.924        | -0.528        |
| Stack3 LinearRegression <sub>global</sub> | 0.712               | 27.155                       | 14.647                      | 35.265        | 47.109        | -0.126        |
| Stack3 Ridge <sub>global</sub>            | 0.712               | 27.157                       | 14.640                      | 35.248        | 47.066        | -0.138        |
| Stack2 LinearRegression                   | 0.712               | 26.429                       | 14.632                      | 35.523        | 47.316        | -0.535        |
| Stack2 Ridge                              | 0.712               | 26.429                       | 14.632                      | 35.523        | 47.316        | -0.535        |
| Stack3 MLP <sub>global</sub>              | 0.711               | 27.212                       | 14.529                      | 34.979        | 46.365        | -0.705        |
| Stack2 SVR <sub>global</sub>              | 0.711               | 27.212                       | 14.225                      | 34.247        | 45.732        | -2.514        |
| Stack4 SVR <sub>global</sub>              | 0.711               | 27.225                       | 14.249                      | 34.305        | 46.002        | -2.559        |
| Stack5 SVR <sub>global</sub>              | 0.710               | 27.237                       | 14.218                      | 34.232        | 45.909        | -2.549        |
| Stack1 SVR <sub>global</sub>              | 0.710               | 27.240                       | 14.307                      | 34.445        | 45.502        | -2.747        |
| Stack3 MLP                                | 0.709               | 26.544                       | 14.875                      | 36.114        | 47.914        | -0.401        |
| Stack5 SVR                                | 0.709               | 26.550                       | 14.241                      | 34.575        | 47.201        | -4.012        |
| Stack5 RandomForest                       | 0.708               | 26.594                       | 15.177                      | 36.847        | 48.063        | 0.095         |
| Stack4 SVR                                | 0.708               | 26.599                       | 14.320                      | 34.766        | 47.387        | -4.112        |
| Stack3 SVR <sub>global</sub>              | 0.706               | 27.453                       | 14.305                      | 34.441        | 46.147        | -2.626        |
| Stack1 SVR                                | 0.705               | 26.729                       | 14.400                      | 34.961        | 46.958        | -3.988        |
| Stack2 SVR                                | 0.704               | 26.784                       | 14.279                      | 34.667        | 47.082        | -4.027        |
| Stack3 LinearRegression                   | 0.703               | 26.832                       | 14.942                      | 36.276        | 48.431        | -0.664        |
| Stack3 Ridge                              | 0.703               | 26.832                       | 14.942                      | 36.276        | 48.431        | -0.664        |
| Stack4 RandomForest                       | 0.702               | 26.897                       | 15.442                      | 37.490        | 48.861        | -0.050        |
| Stack5 GradientBoosting <sub>global</sub> | 0.701               | 27.690                       | 14.571                      | 35.081        | 46.490        | -0.240        |
| Stack1 GradientBoosting <sub>global</sub> | 0.699               | 27.740                       | 14.641                      | 35.250        | 46.608        | -0.367        |
| Stack3 GradientBoosting <sub>global</sub> | 0.699               | 27.770                       | 14.642                      | 35.253        | 46.471        | -0.282        |
| Stack3 SVR                                | 0.696               | 27.146                       | 14.613                      | 35.477        | 48.257        | -4.409        |
| Stack1 GradientBoosting                   | 0.695               | 27.176                       | 14.815                      | 35.967        | 47.547        | -0.476        |
| Stack4 GradientBoosting <sub>global</sub> | 0.693               | 28.026                       | 14.640                      | 35.247        | 46.441        | -0.166        |
| Stack2 RandomForest <sub>global</sub>     | 0.690               | 28.187                       | 15.317                      | 36.876        | 47.788        | 0.139         |
| Stack2 GradientBoosting                   | 0.690               | 27.429                       | 14.710                      | 35.714        | 47.413        | -0.599        |
| Stack2 RandomForest                       | 0.688               | 27.488                       | 15.562                      | 37.782        | 48.807        | -0.134        |
| Stack3 RandomForest                       | 0.685               | 27.622                       | 15.914                      | 38.636        | 49.763        | -0.395        |
| Stack1 RandomForest <sub>global</sub>     | 0.681               | 28.578                       | 15.738                      | 37.891        | 48.764        | -0.085        |
| Stack5 RandomForest <sub>global</sub>     | 0.679               | 28.674                       | 15.225                      | 36.656        | 47.660        | 0.534         |
| Stack4 RandomForest <sub>global</sub>     | 0.673               | 28.956                       | 15.339                      | 36.929        | 47.706        | 0.394         |
| Stack1 RandomForest                       | 0.672               | 28.193                       | 16.193                      | 39.314        | 50.293        | -0.396        |
| Stack3 RandomForest <sub>global</sub>     | 0.667               | 29.218                       | 15.575                      | 37.499        | 48.075        | 0.408         |

**Tabla 8.3**

Comparativa Modelos Base en IFN2 (carbono\_bruto4)

| Modelo                           | $R^2_{\text{test}}$ | RMSE <sub>test</sub> (tC) | MAE <sub>test</sub> (tC) | wMAPE (%)     | SMAPE (%)     | Bias (tC)     |
|----------------------------------|---------------------|---------------------------|--------------------------|---------------|---------------|---------------|
| <b>CatBoost<sub>global</sub></b> | <b>0.765</b>        | <b>18.533</b>             | <b>10.402</b>            | <b>35.470</b> | <b>69.561</b> | <b>-0.342</b> |
| LightGBM <sub>global</sub>       | 0.762               | 18.627                    | 10.417                   | 35.522        | 69.531        | -0.313        |
| XGBoost <sub>global</sub>        | 0.762               | 18.644                    | 10.428                   | 35.559        | 69.353        | -0.384        |
| GBDT <sub>global</sub>           | 0.759               | 18.765                    | 10.474                   | 35.716        | 69.410        | -0.407        |
| CatBoost                         | 0.748               | 19.071                    | 11.036                   | 38.035        | 72.181        | 0.034         |
| MLP <sub>global</sub>            | 0.747               | 19.220                    | 10.732                   | 36.597        | 71.377        | -1.309        |
| LightGBM                         | 0.747               | 19.121                    | 10.858                   | 37.423        | 71.698        | 0.042         |
| XGBoost                          | 0.742               | 19.300                    | 10.962                   | 37.780        | 71.609        | -0.004        |
| BaggedDT <sub>global</sub>       | 0.738               | 19.550                    | 11.216                   | 38.246        | 71.630        | -0.749        |
| RandomForest <sub>global</sub>   | 0.734               | 19.694                    | 10.928                   | 37.264        | 68.279        | -1.503        |
| GBDT                             | 0.732               | 19.692                    | 11.550                   | 39.809        | 73.147        | 0.016         |
| RandomForest                     | 0.729               | 19.770                    | 11.294                   | 38.925        | 70.570        | 0.013         |
| BaggedDT                         | 0.728               | 19.832                    | 11.349                   | 39.114        | 70.434        | 0.182         |
| BayesianNN                       | 0.693               | 21.069                    | 12.830                   | 44.220        | 79.896        | -0.076        |
| MLP                              | 0.690               | 21.162                    | 11.419                   | 39.356        | 76.074        | -3.511        |
| BayesianNN <sub>global</sub>     | 0.683               | 21.530                    | 12.827                   | 43.741        | 78.379        | -0.859        |
| KNN                              | 0.632               | 23.046                    | 12.994                   | 44.784        | 76.109        | -3.677        |
| SVR <sub>global</sub>            | 0.577               | 24.861                    | 12.305                   | 41.961        | 75.324        | -7.293        |
| SVR                              | 0.566               | 25.034                    | 12.818                   | 44.177        | 77.708        | -6.476        |
| AdaBoost                         | -0.538              | 47.138                    | 41.856                   | 144.261       | 114.694       | 37.323        |

Tabla 8.4

Comparativa Modelos Stacking en IFN2 (carbono\_bruto4)

| Modelo                                    | $R^2_{\text{test}}$ | RMSE <sub>test</sub> (tC) | MAE <sub>test</sub> (tC) | wMAPE (%)     | SMAPE (%)     | Bias (tC)     |
|-------------------------------------------|---------------------|---------------------------|--------------------------|---------------|---------------|---------------|
| <b>Stack5 MLP<sub>global</sub></b>        | <b>0.768</b>        | <b>18.405</b>             | <b>10.210</b>            | <b>34.817</b> | <b>68.129</b> | <b>-0.195</b> |
| Stack5 LinearRegression <sub>global</sub> | 0.768               | 18.418                    | 10.306                   | 35.144        | 69.309        | -0.169        |
| Stack5 Ridge <sub>global</sub>            | 0.768               | 18.418                    | 10.306                   | 35.143        | 69.320        | -0.170        |
| Stack4 MLP <sub>global</sub>              | 0.767               | 18.433                    | 10.229                   | 34.881        | 68.095        | 0.030         |
| Stack4 LinearRegression <sub>global</sub> | 0.767               | 18.435                    | 10.297                   | 35.112        | 69.291        | -0.232        |
| Stack4 Ridge <sub>global</sub>            | 0.767               | 18.435                    | 10.296                   | 35.111        | 69.288        | -0.233        |
| Stack3 MLP <sub>global</sub>              | 0.767               | 18.450                    | 10.184                   | 34.726        | 67.782        | -0.295        |
| Stack5 GradientBoosting <sub>global</sub> | 0.767               | 18.457                    | 10.224                   | 34.863        | 68.228        | -0.393        |
| Stack3 Ridge <sub>global</sub>            | 0.767               | 18.466                    | 10.318                   | 35.185        | 69.212        | -0.277        |
| Stack3 LinearRegression <sub>global</sub> | 0.767               | 18.466                    | 10.318                   | 35.185        | 69.212        | -0.277        |
| Stack4 GradientBoosting <sub>global</sub> | 0.766               | 18.485                    | 10.216                   | 34.837        | 68.125        | -0.407        |
| Stack2 LinearRegression <sub>global</sub> | 0.765               | 18.521                    | 10.333                   | 35.236        | 69.359        | -0.252        |
| Stack2 Ridge <sub>global</sub>            | 0.765               | 18.521                    | 10.333                   | 35.236        | 69.360        | -0.253        |
| Stack3 GradientBoosting <sub>global</sub> | 0.765               | 18.529                    | 10.230                   | 34.886        | 68.141        | -0.463        |
| Stack2 MLP <sub>global</sub>              | 0.765               | 18.531                    | 10.285                   | 35.071        | 68.797        | -0.207        |
| Stack5 SVR <sub>global</sub>              | 0.763               | 18.595                    | 10.155                   | 34.628        | 68.878        | -1.814        |
| Stack4 SVR <sub>global</sub>              | 0.763               | 18.601                    | 10.169                   | 34.676        | 68.822        | -1.826        |
| Stack1 MLP <sub>global</sub>              | 0.763               | 18.602                    | 10.261                   | 34.989        | 67.896        | -0.730        |
| Stack1 Ridge <sub>global</sub>            | 0.763               | 18.606                    | 10.377                   | 35.385        | 69.330        | -0.345        |
| Stack1 LinearRegression <sub>global</sub> | 0.763               | 18.606                    | 10.377                   | 35.385        | 69.330        | -0.345        |
| Stack2 GradientBoosting <sub>global</sub> | 0.763               | 18.616                    | 10.297                   | 35.114        | 68.617        | -0.412        |
| Stack3 SVR <sub>global</sub>              | 0.762               | 18.643                    | 10.193                   | 34.758        | 68.689        | -1.883        |
| Stack1 GradientBoosting <sub>global</sub> | 0.761               | 18.676                    | 10.316                   | 35.177        | 68.372        | -0.484        |
| Stack2 SVR <sub>global</sub>              | 0.761               | 18.678                    | 10.222                   | 34.856        | 68.947        | -1.763        |
| Stack1 SVR <sub>global</sub>              | 0.758               | 18.821                    | 10.260                   | 34.986        | 68.943        | -2.023        |
| Stack5 RandomForest <sub>global</sub>     | 0.756               | 18.879                    | 10.606                   | 36.167        | 66.996        | 0.138         |
| Stack4 RandomForest <sub>global</sub>     | 0.756               | 18.886                    | 10.704                   | 36.501        | 67.217        | 0.084         |
| Stack4 MLP                                | 0.755               | 18.828                    | 10.636                   | 36.658        | 70.675        | 0.274         |
| Stack4 Ridge                              | 0.754               | 18.860                    | 10.734                   | 36.997        | 71.361        | 0.044         |
| Stack4 LinearRegression                   | 0.754               | 18.860                    | 10.734                   | 36.997        | 71.364        | 0.044         |
| Stack5 GradientBoosting                   | 0.753               | 18.880                    | 10.692                   | 36.852        | 70.603        | -0.022        |
| Stack5 MLP                                | 0.753               | 18.890                    | 10.632                   | 36.643        | 71.389        | 0.045         |
| Stack5 Ridge                              | 0.753               | 18.893                    | 10.746                   | 37.038        | 71.326        | 0.016         |
| Stack5 LinearRegression                   | 0.753               | 18.893                    | 10.747                   | 37.039        | 71.327        | -0.016        |
| Stack3 MLP                                | 0.753               | 18.896                    | 10.746                   | 37.036        | 71.008        | 0.081         |
| Stack4 GradientBoosting                   | 0.752               | 18.921                    | 10.654                   | 36.720        | 70.494        | 0.029         |
| Stack2 MLP                                | 0.751               | 18.954                    | 10.765                   | 37.102        | 70.755        | -0.001        |
| Stack3 Ridge                              | 0.751               | 18.977                    | 10.873                   | 37.473        | 71.697        | 0.076         |
| Stack3 LinearRegression                   | 0.751               | 18.978                    | 10.873                   | 37.474        | 71.695        | 0.076         |
| Stack2 GradientBoosting                   | 0.751               | 18.978                    | 10.769                   | 37.116        | 70.909        | 0.002         |
| Stack4 SVR                                | 0.750               | 18.988                    | 10.523                   | 36.267        | 72.240        | -2.179        |
| Stack2 Ridge                              | 0.750               | 18.989                    | 10.793                   | 37.200        | 71.359        | -0.048        |
| Stack2 LinearRegression                   | 0.750               | 18.989                    | 10.793                   | 37.200        | 71.357        | -0.048        |
| Stack5 SVR                                | 0.750               | 18.993                    | 10.530                   | 36.293        | 72.199        | -2.129        |
| Stack3 GradientBoosting                   | 0.749               | 19.027                    | 10.783                   | 37.164        | 70.757        | 0.076         |
| Stack1 MLP                                | 0.749               | 19.043                    | 10.736                   | 37.001        | 70.468        | -0.031        |
| Stack1 Ridge                              | 0.749               | 19.048                    | 10.777                   | 37.145        | 71.433        | -0.008        |
| Stack1 LinearRegression                   | 0.749               | 19.048                    | 10.777                   | 37.145        | 71.434        | -0.008        |
| Stack3 SVR                                | 0.747               | 19.116                    | 10.656                   | 36.726        | 72.643        | -2.243        |
| Stack2 SVR                                | 0.747               | 19.116                    | 10.602                   | 36.542        | 72.634        | -2.230        |
| Stack1 GradientBoosting                   | 0.746               | 19.174                    | 10.778                   | 37.146        | 70.768        | -0.046        |
| Stack3 RandomForest <sub>global</sub>     | 0.745               | 19.286                    | 10.840                   | 36.965        | 67.152        | -0.105        |
| Stack1 SVR                                | 0.745               | 19.187                    | 10.596                   | 36.521        | 72.624        | -2.197        |
| Stack2 RandomForest <sub>global</sub>     | 0.741               | 19.455                    | 10.979                   | 37.440        | 69.244        | -0.110        |
| Stack5 RandomForest                       | 0.734               | 19.588                    | 11.135                   | 38.377        | 68.643        | 0.589         |
| Stack1 RandomForest <sub>global</sub>     | 0.734               | 19.711                    | 11.235                   | 38.313        | 68.420        | -0.278        |
| Stack3 RandomForest                       | 0.727               | 19.848                    | 11.483                   | 39.578        | 69.750        | 0.543         |
| Stack4 RandomForest                       | 0.727               | 19.848                    | 11.194                   | 38.580        | 68.556        | 0.550         |
| Stack2 RandomForest                       | 0.720               | 20.098                    | 11.538                   | 39.768        | 71.966        | 0.196         |
| Stack1 RandomForest                       | 0.713               | 20.375                    | 11.767                   | 40.555        | 70.731        | 0.068         |



**Tabla 8.5**  
Comparativa Modelos Base en IFN3 (c4)

| Modelo                         | $R^2_{\text{test}}$ | RMSE <sub>test</sub> (tC/ha) | MAE <sub>test</sub> (tC/ha) | wMAPE (%)     | SMAPE (%)     | Bias (tC/ha) |
|--------------------------------|---------------------|------------------------------|-----------------------------|---------------|---------------|--------------|
| <b>LightGBM</b>                | <b>0.858</b>        | <b>17.816</b>                | <b>9.246</b>                | <b>24.609</b> | <b>37.327</b> | <b>0.017</b> |
| XGBoost                        | 0.851               | 18.232                       | 9.203                       | 24.494        | 37.033        | -0.021       |
| CatBoost                       | 0.849               | 18.385                       | 9.746                       | 25.941        | 40.139        | -0.114       |
| GBDT                           | 0.843               | 18.718                       | 9.893                       | 26.330        | 40.046        | 0.005        |
| MLP                            | 0.840               | 18.947                       | 9.296                       | 24.743        | 36.827        | -3.555       |
| GBDT <sub>global</sub>         | 0.839               | 19.408                       | 9.559                       | 25.792        | 38.647        | 0.378        |
| XGBoost <sub>global</sub>      | 0.839               | 19.424                       | 9.548                       | 25.763        | 39.032        | 0.206        |
| CatBoost <sub>global</sub>     | 0.838               | 19.500                       | 9.433                       | 25.451        | 39.540        | 0.056        |
| LightGBM <sub>global</sub>     | 0.836               | 19.580                       | 9.602                       | 25.909        | 39.178        | 0.237        |
| MLP <sub>global</sub>          | 0.833               | 19.791                       | 10.008                      | 27.005        | 44.150        | 0.107        |
| BaggedDT                       | 0.820               | 20.085                       | 10.699                      | 28.476        | 40.585        | 0.098        |
| BaggedDT <sub>global</sub>     | 0.800               | 21.649                       | 11.058                      | 29.838        | 44.515        | 1.538        |
| RandomForest                   | 0.796               | 21.353                       | 10.839                      | 28.849        | 40.827        | -0.092       |
| RandomForest <sub>global</sub> | 0.789               | 22.223                       | 11.109                      | 29.974        | 41.901        | 1.399        |
| BayesianNN                     | 0.774               | 22.507                       | 12.332                      | 32.823        | 55.074        | 0.201        |
| KNN                            | 0.756               | 23.357                       | 12.585                      | 33.495        | 48.029        | -5.178       |
| BayesianNN <sub>global</sub>   | 0.743               | 24.561                       | 12.643                      | 34.113        | 56.226        | 0.572        |
| SVR                            | 0.737               | 24.279                       | 9.877                       | 26.289        | 37.234        | -3.632       |
| SVR <sub>global</sub>          | 0.613               | 30.113                       | 11.708                      | 31.590        | 42.962        | -4.778       |
| AdaBoost                       | 0.314               | 39.189                       | 33.180                      | 88.310        | 91.289        | 22.855       |

Tabla 8.6

Comparativa Modelos Stacking en IFN3 (c4)

| Modelo                                    | $R^2_{\text{test}}$ | RMSE <sub>test</sub> (tC/ha) | MAE <sub>test</sub> (tC/ha) | wMAPE (%)     | SMAPE (%)     | Bias (tC/ha)  |
|-------------------------------------------|---------------------|------------------------------|-----------------------------|---------------|---------------|---------------|
| <b>Stack4 GradientBoosting</b>            | <b>0.866</b>        | <b>17.303</b>                | <b>9.134</b>                | <b>24.310</b> | <b>37.215</b> | <b>-0.009</b> |
| Stack5 GradientBoosting                   | 0.865               | 17.369                       | 9.037                       | 24.052        | 36.846        | -0.007        |
| Stack2 GradientBoosting                   | 0.863               | 17.537                       | 9.097                       | 24.211        | 37.106        | 0.005         |
| Stack5 MLP                                | 0.862               | 17.572                       | 8.950                       | 23.822        | 36.332        | -0.335        |
| Stack5 LinearRegression                   | 0.861               | 17.644                       | 9.049                       | 24.083        | 37.004        | -0.013        |
| Stack5 Ridge                              | 0.861               | 17.646                       | 9.050                       | 24.087        | 37.003        | -0.012        |
| Stack4 MLP                                | 0.861               | 17.647                       | 9.147                       | 24.346        | 36.813        | 0.171         |
| Stack2 MLP                                | 0.860               | 17.704                       | 9.038                       | 24.054        | 36.404        | -0.294        |
| Stack4 LinearRegression                   | 0.860               | 17.718                       | 9.190                       | 24.459        | 37.349        | 0.011         |
| Stack4 Ridge                              | 0.860               | 17.720                       | 9.191                       | 24.463        | 37.351        | 0.011         |
| Stack1 GradientBoosting                   | 0.859               | 17.740                       | 9.273                       | 24.681        | 37.369        | 0.029         |
| Stack2 LinearRegression                   | 0.859               | 17.767                       | 9.097                       | 24.213        | 36.750        | -0.004        |
| Stack2 Ridge                              | 0.859               | 17.773                       | 9.107                       | 24.240        | 36.785        | -0.004        |
| Stack5 SVR                                | 0.858               | 17.816                       | 8.879                       | 23.631        | 37.125        | -1.871        |
| Stack5 RandomForest                       | 0.858               | 17.819                       | 9.445                       | 25.139        | 37.517        | 0.362         |
| Stack1 MLP                                | 0.858               | 17.834                       | 9.264                       | 24.657        | 37.281        | 0.119         |
| Stack4 SVR                                | 0.858               | 17.851                       | 9.011                       | 23.984        | 37.554        | -1.902        |
| Stack1 LinearRegression                   | 0.857               | 17.873                       | 9.244                       | 24.604        | 36.837        | 0.023         |
| Stack1 Ridge                              | 0.857               | 17.875                       | 9.245                       | 24.606        | 36.831        | 0.023         |
| Stack2 SVR                                | 0.856               | 17.954                       | 8.935                       | 23.781        | 37.175        | -1.851        |
| Stack3 GradientBoosting                   | 0.855               | 18.026                       | 9.534                       | 25.375        | 38.431        | 0.002         |
| Stack1 SVR                                | 0.854               | 18.053                       | 9.114                       | 24.257        | 37.328        | -1.845        |
| Stack3 MLP                                | 0.852               | 18.171                       | 9.500                       | 25.285        | 37.589        | 0.001         |
| Stack4 RandomForest                       | 0.852               | 18.199                       | 9.748                       | 25.946        | 38.468        | 0.330         |
| Stack3 LinearRegression                   | 0.850               | 18.309                       | 9.580                       | 25.498        | 38.816        | 0.007         |
| Stack3 Ridge                              | 0.850               | 18.316                       | 9.581                       | 25.500        | 38.784        | 0.008         |
| Stack3 RandomForest                       | 0.849               | 18.375                       | 10.159                      | 27.039        | 39.787        | 0.336         |
| Stack5 MLP <sub>global</sub>              | 0.848               | 18.892                       | 9.178                       | 24.763        | 36.606        | 0.347         |
| Stack2 MLP <sub>global</sub>              | 0.847               | 18.943                       | 9.332                       | 25.180        | 37.530        | 0.382         |
| Stack3 SVR                                | 0.846               | 18.552                       | 9.397                       | 25.010        | 38.601        | -2.106        |
| Stack4 MLP <sub>global</sub>              | 0.845               | 19.067                       | 9.180                       | 24.770        | 36.741        | 0.146         |
| Stack5 Ridge <sub>global</sub>            | 0.844               | 19.100                       | 9.252                       | 24.965        | 38.537        | 0.140         |
| Stack5 LinearRegression <sub>global</sub> | 0.844               | 19.102                       | 9.253                       | 24.966        | 38.597        | 0.131         |
| Stack2 Ridge <sub>global</sub>            | 0.844               | 19.115                       | 9.355                       | 25.241        | 38.497        | 0.193         |
| Stack2 LinearRegression <sub>global</sub> | 0.844               | 19.117                       | 9.356                       | 25.244        | 38.525        | 0.191         |
| Stack4 Ridge <sub>global</sub>            | 0.843               | 19.154                       | 9.278                       | 25.033        | 38.451        | 0.184         |
| Stack4 LinearRegression <sub>global</sub> | 0.843               | 19.156                       | 9.277                       | 25.030        | 38.505        | 0.173         |
| Stack3 Ridge <sub>global</sub>            | 0.843               | 19.187                       | 9.305                       | 25.107        | 38.570        | 0.218         |
| Stack3 LinearRegression <sub>global</sub> | 0.843               | 19.188                       | 9.304                       | 25.104        | 38.641        | 0.205         |
| Stack3 MLP <sub>global</sub>              | 0.842               | 19.216                       | 9.188                       | 24.790        | 36.845        | -0.169        |
| Stack5 SVR <sub>global</sub>              | 0.840               | 19.367                       | 9.101                       | 24.557        | 40.002        | -2.063        |
| Stack2 SVR <sub>global</sub>              | 0.840               | 19.369                       | 9.185                       | 24.783        | 39.985        | -2.057        |
| Stack4 SVR <sub>global</sub>              | 0.839               | 19.400                       | 9.116                       | 24.597        | 39.978        | -2.045        |
| Stack3 SVR <sub>global</sub>              | 0.839               | 19.423                       | 9.137                       | 24.655        | 40.013        | -2.018        |
| Stack2 RandomForest                       | 0.839               | 18.988                       | 9.887                       | 26.314        | 38.705        | 0.293         |
| Stack1 MLP <sub>global</sub>              | 0.839               | 19.436                       | 9.564                       | 25.804        | 37.443        | 0.770         |
| Stack3 GradientBoosting <sub>global</sub> | 0.837               | 19.547                       | 9.290                       | 25.067        | 37.493        | 0.310         |
| Stack1 LinearRegression <sub>global</sub> | 0.837               | 19.564                       | 9.582                       | 25.854        | 38.721        | 0.337         |
| Stack1 Ridge <sub>global</sub>            | 0.837               | 19.565                       | 9.582                       | 25.854        | 38.714        | 0.339         |
| Stack1 RandomForest                       | 0.835               | 19.224                       | 10.450                      | 27.814        | 40.024        | 0.233         |
| Stack5 GradientBoosting <sub>global</sub> | 0.833               | 19.768                       | 9.291                       | 25.069        | 37.539        | 0.270         |
| Stack1 GradientBoosting <sub>global</sub> | 0.832               | 19.820                       | 9.600                       | 25.903        | 38.177        | 0.508         |
| Stack1 SVR <sub>global</sub>              | 0.832               | 19.852                       | 9.388                       | 25.330        | 39.687        | -1.927        |
| Stack4 GradientBoosting <sub>global</sub> | 0.830               | 19.940                       | 9.344                       | 25.213        | 37.491        | 0.304         |
| Stack2 GradientBoosting <sub>global</sub> | 0.826               | 20.206                       | 9.499                       | 25.631        | 38.253        | 0.331         |
| Stack5 RandomForest <sub>global</sub>     | 0.820               | 20.540                       | 9.871                       | 26.635        | 38.299        | 0.692         |
| Stack3 RandomForest <sub>global</sub>     | 0.807               | 21.266                       | 10.271                      | 27.713        | 39.177        | 0.574         |
| Stack4 RandomForest <sub>global</sub>     | 0.804               | 21.415                       | 10.123                      | 27.314        | 38.710        | 0.763         |
| Stack2 RandomForest <sub>global</sub>     | 0.802               | 21.562                       | 10.342                      | 27.905        | 39.864        | 0.540         |
| Stack1 RandomForest <sub>global</sub>     | 0.792               | 22.090                       | 10.962                      | 29.576        | 40.925        | 0.731         |

**Tabla 8.7**  
Comparativa Modelos Base en IFN3 (carbono\_bruto4)

| Modelo                         | $R^2_{\text{test}}$ | RMSE <sub>test</sub> (tC) | MAE <sub>test</sub> (tC) | wMAPE (%)     | SMAPE (%)      | Bias (tC)     |
|--------------------------------|---------------------|---------------------------|--------------------------|---------------|----------------|---------------|
| <b>LightGBM</b>                | <b>0.898</b>        | <b>10.641</b>             | <b>4.687</b>             | <b>27.801</b> | <b>110.183</b> | <b>-0.007</b> |
| CatBoost                       | 0.896               | 10.737                    | 4.789                    | 28.405        | 110.952        | -0.059        |
| XGBoost                        | 0.895               | 10.761                    | 4.713                    | 27.957        | 109.669        | -0.008        |
| CatBoost <sub>global</sub>     | 0.889               | 10.931                    | 4.812                    | 28.723        | 111.600        | -0.059        |
| GBDT                           | 0.888               | 11.134                    | 5.044                    | 29.920        | 111.422        | -0.042        |
| MLP                            | 0.885               | 11.287                    | 4.803                    | 28.488        | 111.603        | -0.544        |
| LightGBM <sub>global</sub>     | 0.884               | 11.153                    | 4.863                    | 29.023        | 111.679        | -0.073        |
| XGBoost <sub>global</sub>      | 0.883               | 11.230                    | 4.859                    | 28.999        | 111.190        | -0.036        |
| GBDT <sub>global</sub>         | 0.881               | 11.327                    | 4.937                    | 29.463        | 111.656        | -0.002        |
| MLP <sub>global</sub>          | 0.879               | 11.431                    | 5.122                    | 30.573        | 114.182        | -0.326        |
| BaggedDT                       | 0.873               | 11.830                    | 5.183                    | 30.745        | 99.986         | -0.135        |
| RandomForest                   | 0.870               | 11.965                    | 5.217                    | 30.944        | 109.139        | -0.239        |
| BaggedDT <sub>global</sub>     | 0.866               | 11.997                    | 5.410                    | 32.287        | 110.035        | 0.589         |
| RandomForest <sub>global</sub> | 0.865               | 12.053                    | 5.330                    | 31.814        | 105.593        | 0.434         |
| BayesianNN                     | 0.836               | 13.455                    | 6.773                    | 40.173        | 120.931        | 0.010         |
| BayesianNN <sub>global</sub>   | 0.824               | 13.774                    | 7.040                    | 42.020        | 121.650        | 0.265         |
| SVR                            | 0.810               | 14.504                    | 5.269                    | 31.256        | 112.607        | -2.176        |
| KNN                            | 0.793               | 15.128                    | 6.251                    | 37.078        | 102.871        | -2.897        |
| SVR <sub>global</sub>          | 0.730               | 17.033                    | 6.154                    | 36.728        | 114.785        | -2.987        |
| AdaBoost                       | 0.349               | 26.829                    | 23.857                   | 141.512       | 139.341        | 20.684        |

**Tabla 8.8**

Comparativa Modelos Stacking en IFN3 (carbono\_bruto4)

| Modelo                                    | $R^2_{test}$ | RMSE <sub>test</sub> (tC) | MAE <sub>test</sub> (tC) | wMAPE (%)     | SMAPE (%)      | Bias (tC)    |
|-------------------------------------------|--------------|---------------------------|--------------------------|---------------|----------------|--------------|
| <b>Stack4 MLP</b>                         | <b>0.902</b> | <b>10.407</b>             | <b>4.517</b>             | <b>26.795</b> | <b>107.868</b> | <b>0.049</b> |
| Stack5 GradientBoosting                   | 0.901        | 10.433                    | 4.540                    | 26.930        | 109.331        | 0.030        |
| Stack5 MLP                                | 0.901        | 10.447                    | 4.454                    | 26.417        | 107.446        | -0.368       |
| Stack4 GradientBoosting                   | 0.901        | 10.450                    | 4.541                    | 26.936        | 109.286        | 0.037        |
| Stack5 LinearRegression                   | 0.900        | 10.492                    | 4.624                    | 27.426        | 110.839        | 0.025        |
| Stack5 Ridge                              | 0.900        | 10.494                    | 4.624                    | 27.428        | 110.757        | 0.022        |
| Stack4 LinearRegression                   | 0.900        | 10.511                    | 4.648                    | 27.570        | 110.932        | 0.020        |
| Stack4 Ridge                              | 0.900        | 10.511                    | 4.648                    | 27.570        | 110.941        | 0.020        |
| Stack2 MLP                                | 0.899        | 10.540                    | 4.581                    | 27.173        | 108.573        | -0.035       |
| Stack2 LinearRegression                   | 0.899        | 10.572                    | 4.651                    | 27.590        | 110.865        | 0.011        |
| Stack3 MLP                                | 0.899        | 10.572                    | 4.611                    | 27.348        | 106.609        | 0.170        |
| Stack2 Ridge                              | 0.899        | 10.573                    | 4.654                    | 27.604        | 110.866        | 0.010        |
| Stack2 GradientBoosting                   | 0.899        | 10.582                    | 4.610                    | 27.343        | 109.772        | 0.004        |
| Stack1 MLP                                | 0.898        | 10.617                    | 4.579                    | 27.162        | 107.666        | -0.163       |
| Stack1 LinearRegression                   | 0.898        | 10.625                    | 4.667                    | 27.682        | 111.022        | 0.011        |
| Stack1 Ridge                              | 0.898        | 10.625                    | 4.667                    | 27.682        | 111.022        | 0.011        |
| Stack5 SVR                                | 0.898        | 10.638                    | 4.541                    | 26.938        | 110.810        | -0.758       |
| Stack4 SVR                                | 0.897        | 10.655                    | 4.556                    | 27.027        | 111.084        | -0.788       |
| Stack1 GradientBoosting                   | 0.897        | 10.660                    | 4.620                    | 27.406        | 109.313        | 0.021        |
| Stack3 GradientBoosting                   | 0.897        | 10.671                    | 4.637                    | 27.506        | 109.803        | 0.028        |
| Stack3 LinearRegression                   | 0.897        | 10.674                    | 4.757                    | 28.218        | 111.578        | 0.014        |
| Stack3 Ridge                              | 0.897        | 10.675                    | 4.757                    | 28.217        | 111.563        | 0.013        |
| Stack2 SVR                                | 0.896        | 10.706                    | 4.580                    | 27.167        | 110.761        | -0.744       |
| Stack5 RandomForest                       | 0.895        | 10.755                    | 4.721                    | 28.006        | 96.178         | 0.266        |
| Stack4 RandomForest                       | 0.895        | 10.782                    | 4.775                    | 28.322        | 98.323         | 0.216        |
| Stack1 SVR                                | 0.895        | 10.787                    | 4.613                    | 27.364        | 110.982        | -0.740       |
| Stack3 SVR                                | 0.893        | 10.865                    | 4.672                    | 27.712        | 111.457        | -0.870       |
| Stack4 MLP <sub>global</sub>              | 0.890        | 10.862                    | 4.621                    | 27.580        | 109.222        | 0.226        |
| Stack5 MLP <sub>global</sub>              | 0.890        | 10.866                    | 4.586                    | 27.369        | 107.939        | 0.041        |
| Stack3 MLP <sub>global</sub>              | 0.890        | 10.880                    | 4.544                    | 27.119        | 106.128        | -0.009       |
| Stack4 LinearRegression <sub>global</sub> | 0.890        | 10.890                    | 4.741                    | 28.298        | 111.854        | -0.075       |
| Stack4 Ridge <sub>global</sub>            | 0.890        | 10.891                    | 4.741                    | 28.297        | 111.872        | -0.075       |
| Stack5 GradientBoosting <sub>global</sub> | 0.890        | 10.905                    | 4.612                    | 27.525        | 109.827        | -0.006       |
| Stack5 LinearRegression <sub>global</sub> | 0.889        | 10.908                    | 4.747                    | 28.330        | 112.364        | -0.113       |
| Stack5 Ridge <sub>global</sub>            | 0.889        | 10.909                    | 4.747                    | 28.330        | 112.377        | -0.113       |
| Stack3 LinearRegression <sub>global</sub> | 0.889        | 10.921                    | 4.766                    | 28.443        | 112.073        | -0.047       |
| Stack3 Ridge <sub>global</sub>            | 0.889        | 10.921                    | 4.766                    | 28.443        | 112.073        | -0.047       |
| Stack3 GradientBoosting <sub>global</sub> | 0.888        | 10.959                    | 4.626                    | 27.612        | 109.664        | 0.036        |
| Stack4 GradientBoosting <sub>global</sub> | 0.888        | 10.978                    | 4.625                    | 27.605        | 109.591        | 0.007        |
| Stack3 RandomForest                       | 0.887        | 11.157                    | 4.967                    | 29.463        | 98.766         | 0.152        |
| Stack2 RandomForest                       | 0.887        | 11.165                    | 4.916                    | 29.157        | 98.358         | 0.133        |
| Stack4 SVR <sub>global</sub>              | 0.887        | 11.053                    | 4.682                    | 27.941        | 112.576        | -0.961       |
| Stack5 SVR <sub>global</sub>              | 0.886        | 11.056                    | 4.687                    | 27.976        | 112.536        | -0.956       |
| Stack2 MLP <sub>global</sub>              | 0.886        | 11.058                    | 4.709                    | 28.105        | 109.662        | 0.075        |
| Stack2 LinearRegression <sub>global</sub> | 0.886        | 11.065                    | 4.803                    | 28.663        | 112.597        | -0.094       |
| Stack2 Ridge <sub>global</sub>            | 0.886        | 11.065                    | 4.802                    | 28.662        | 112.594        | -0.094       |
| Stack3 SVR <sub>global</sub>              | 0.886        | 11.088                    | 4.701                    | 28.059        | 112.546        | -0.948       |
| Stack1 MLP <sub>global</sub>              | 0.885        | 11.102                    | 4.680                    | 27.934        | 107.602        | -0.133       |
| Stack2 GradientBoosting <sub>global</sub> | 0.885        | 11.108                    | 4.729                    | 28.224        | 110.752        | -0.005       |
| Stack1 Ridge <sub>global</sub>            | 0.885        | 11.111                    | 4.833                    | 28.842        | 112.219        | -0.040       |
| Stack1 LinearRegression <sub>global</sub> | 0.885        | 11.111                    | 4.833                    | 28.842        | 112.219        | -0.040       |
| Stack1 GradientBoosting <sub>global</sub> | 0.884        | 11.171                    | 4.732                    | 28.242        | 109.678        | 0.048        |
| Stack2 SVR <sub>global</sub>              | 0.883        | 11.220                    | 4.745                    | 28.321        | 112.576        | -0.971       |
| Stack1 SVR <sub>global</sub>              | 0.882        | 11.271                    | 4.760                    | 28.409        | 112.572        | -0.951       |
| Stack1 RandomForest                       | 0.881        | 11.483                    | 5.127                    | 30.409        | 95.521         | 0.089        |
| Stack5 RandomForest <sub>global</sub>     | 0.880        | 11.347                    | 4.848                    | 28.932        | 96.971         | 0.259        |
| Stack4 RandomForest <sub>global</sub>     | 0.879        | 11.429                    | 4.919                    | 29.356        | 96.704         | 0.192        |
| Stack3 RandomForest <sub>global</sub>     | 0.875        | 11.586                    | 5.023                    | 29.976        | 95.997         | 0.204        |
| Stack2 RandomForest <sub>global</sub>     | 0.873        | 11.692                    | 5.131                    | 30.625        | 102.247        | 0.209        |
| Stack1 RandomForest <sub>global</sub>     | 0.858        | 12.368                    | 5.383                    | 32.129        | 94.456         | 0.154        |

**Tabla 8.9**  
Modelos Base Globales (c4)

| Modelo                           | $R^2_{\text{test}}$ | RMSE <sub>test</sub> (tC/ha) | MAE <sub>test</sub> (tC/ha) | wMAPE (%)     | SMAPE (%)     | Bias (tC/ha) |
|----------------------------------|---------------------|------------------------------|-----------------------------|---------------|---------------|--------------|
| <b>LightGBM<sub>global</sub></b> | <b>0.787</b>        | <b>22.767</b>                | <b>11.650</b>               | <b>29.978</b> | <b>42.370</b> | <b>0.134</b> |
| XGBoost <sub>global</sub>        | 0.784               | 22.952                       | 11.590                      | 29.824        | 42.204        | 0.055        |
| CatBoost <sub>global</sub>       | 0.783               | 22.990                       | 11.607                      | 29.866        | 42.904        | -0.021       |
| GBDT <sub>global</sub>           | 0.783               | 23.014                       | 11.658                      | 29.998        | 41.987        | 0.169        |
| MLP <sub>global</sub>            | 0.771               | 23.606                       | 12.287                      | 31.617        | 46.726        | 0.177        |
| BaggedDT <sub>global</sub>       | 0.740               | 25.142                       | 13.021                      | 33.506        | 47.116        | 0.678        |
| RandomForest <sub>global</sub>   | 0.732               | 25.547                       | 12.908                      | 33.214        | 44.513        | 0.232        |
| BayesianNN <sub>global</sub>     | 0.678               | 28.021                       | 14.689                      | 37.797        | 56.389        | 0.047        |
| SVR <sub>global</sub>            | 0.551               | 33.065                       | 13.708                      | 35.272        | 45.693        | -6.204       |

**Tabla 8.10**  
Modelos Stacking Globales (c4)

| Modelo                                    | $R^2_{\text{test}}$ | RMSE <sub>test</sub> (tC/ha) | MAE <sub>test</sub> (tC/ha) | wMAPE (%)     | SMAPE (%)     | Bias (tC/ha) |
|-------------------------------------------|---------------------|------------------------------|-----------------------------|---------------|---------------|--------------|
| <b>Stack5 MLP<sub>global</sub></b>        | <b>0.794</b>        | <b>22.387</b>                | <b>11.321</b>               | <b>29.132</b> | <b>40.529</b> | <b>0.238</b> |
| Stack2 MLP <sub>global</sub>              | 0.794               | 22.405                       | 11.403                      | 29.341        | 41.069        | 0.176        |
| Stack4 MLP <sub>global</sub>              | 0.792               | 22.527                       | 11.314                      | 29.112        | 40.574        | -0.045       |
| Stack2 LinearRegression <sub>global</sub> | 0.791               | 22.565                       | 11.429                      | 29.409        | 41.712        | 0.069        |
| Stack2 Ridge <sub>global</sub>            | 0.791               | 22.566                       | 11.429                      | 29.409        | 41.696        | 0.069        |
| Stack5 LinearRegression <sub>global</sub> | 0.791               | 22.571                       | 11.387                      | 29.299        | 41.921        | 0.057        |
| Stack5 Ridge <sub>global</sub>            | 0.791               | 22.572                       | 11.384                      | 29.293        | 41.871        | 0.058        |
| Stack4 Ridge <sub>global</sub>            | 0.790               | 22.601                       | 11.414                      | 29.371        | 41.858        | 0.083        |
| Stack4 LinearRegression <sub>global</sub> | 0.790               | 22.602                       | 11.416                      | 29.375        | 41.905        | 0.081        |
| Stack1 MLP <sub>global</sub>              | 0.790               | 22.635                       | 11.584                      | 29.808        | 41.096        | 0.507        |
| Stack3 LinearRegression <sub>global</sub> | 0.788               | 22.735                       | 11.456                      | 29.477        | 42.051        | 0.072        |
| Stack3 Ridge <sub>global</sub>            | 0.788               | 22.735                       | 11.453                      | 29.471        | 41.991        | 0.074        |
| Stack1 LinearRegression <sub>global</sub> | 0.787               | 22.769                       | 11.606                      | 29.864        | 41.939        | 0.145        |
| Stack1 Ridge <sub>global</sub>            | 0.787               | 22.770                       | 11.606                      | 29.864        | 41.933        | 0.145        |
| Stack3 MLP <sub>global</sub>              | 0.787               | 22.776                       | 11.338                      | 29.175        | 40.679        | -0.384       |
| Stack2 SVR <sub>global</sub>              | 0.786               | 22.853                       | 11.214                      | 28.856        | 42.299        | -2.241       |
| Stack5 SVR <sub>global</sub>              | 0.785               | 22.864                       | 11.162                      | 28.721        | 42.381        | -2.258       |
| Stack4 SVR <sub>global</sub>              | 0.785               | 22.875                       | 11.183                      | 28.775        | 42.403        | -2.252       |
| Stack3 SVR <sub>global</sub>              | 0.783               | 22.996                       | 11.218                      | 28.866        | 42.483        | -2.263       |
| Stack1 SVR <sub>global</sub>              | 0.781               | 23.113                       | 11.369                      | 29.253        | 42.029        | -2.257       |
| Stack2 GradientBoosting <sub>global</sub> | 0.779               | 23.183                       | 11.527                      | 29.661        | 41.592        | 0.125        |
| Stack3 GradientBoosting <sub>global</sub> | 0.779               | 23.211                       | 11.445                      | 29.450        | 41.108        | 0.072        |
| Stack5 GradientBoosting <sub>global</sub> | 0.777               | 23.284                       | 11.417                      | 29.378        | 41.143        | 0.064        |
| Stack1 GradientBoosting <sub>global</sub> | 0.776               | 23.334                       | 11.630                      | 29.926        | 41.572        | 0.156        |
| Stack4 GradientBoosting <sub>global</sub> | 0.773               | 23.532                       | 11.477                      | 29.531        | 41.095        | 0.115        |
| Stack5 RandomForest <sub>global</sub>     | 0.761               | 24.147                       | 12.027                      | 30.947        | 42.068        | 0.628        |
| Stack2 RandomForest <sub>global</sub>     | 0.755               | 24.446                       | 12.345                      | 31.766        | 43.055        | 0.378        |
| Stack4 RandomForest <sub>global</sub>     | 0.749               | 24.730                       | 12.223                      | 31.452        | 42.332        | 0.614        |
| Stack3 RandomForest <sub>global</sub>     | 0.748               | 24.777                       | 12.407                      | 31.924        | 42.760        | 0.507        |
| Stack1 RandomForest <sub>global</sub>     | 0.745               | 24.907                       | 12.885                      | 33.155        | 44.082        | 0.402        |

**Tabla 8.11**

Modelos Base Globales (carbono\_bruto4)


| Modelo                           | $R^2_{\text{test}}$ | RMSE <sub>test</sub> (tC) | MAE <sub>test</sub> (tC) | wMAPE (%)     | SMAPE (%)     | Bias (tC)     |
|----------------------------------|---------------------|---------------------------|--------------------------|---------------|---------------|---------------|
| <b>CatBoost<sub>global</sub></b> | <b>0.845</b>        | <b>13.846</b>             | <b>6.615</b>             | <b>31.789</b> | <b>98.044</b> | <b>-0.150</b> |
| LightGBM <sub>global</sub>       | 0.841               | 14.006                    | 6.654                    | 31.977        | 98.088        | -0.150        |
| XGBoost <sub>global</sub>        | 0.840               | 14.054                    | 6.655                    | 31.980        | 97.699        | -0.148        |
| GBDT <sub>global</sub>           | 0.838               | 14.159                    | 6.722                    | 32.304        | 98.033        | -0.132        |
| MLP <sub>global</sub>            | 0.832               | 14.410                    | 6.931                    | 33.311        | 100.379       | -0.643        |
| BaggedDT <sub>global</sub>       | 0.821               | 14.858                    | 7.282                    | 34.995        | 97.651        | 0.158         |
| RandomForest <sub>global</sub>   | 0.819               | 14.950                    | 7.135                    | 34.291        | 93.561        | -0.191        |
| BayesianNN <sub>global</sub>     | 0.775               | 16.674                    | 8.906                    | 42.802        | 107.697       | -0.097        |
| SVR <sub>global</sub>            | 0.679               | 19.897                    | 8.137                    | 39.106        | 102.061       | -4.376        |

**Tabla 8.12**

Modelos Stacking Globales (carbono\_bruto4)

| Modelo                                    | $R^2_{\text{test}}$ | RMSE <sub>test</sub> (tC) | MAE <sub>test</sub> (tC) | wMAPE (%)     | SMAPE (%)     | Bias (tC)     |
|-------------------------------------------|---------------------|---------------------------|--------------------------|---------------|---------------|---------------|
| <b>Stack5 MLP<sub>global</sub></b>        | <b>0.847</b>        | <b>13.756</b>             | <b>6.399</b>             | <b>30.754</b> | <b>95.102</b> | <b>-0.035</b> |
| Stack4 MLP <sub>global</sub>              | 0.847               | 13.766                    | 6.429                    | 30.898        | 95.960        | 0.163         |
| Stack4 LinearRegression <sub>global</sub> | 0.846               | 13.782                    | 6.533                    | 31.394        | 98.129        | -0.126        |
| Stack4 Ridge <sub>global</sub>            | 0.846               | 13.782                    | 6.533                    | 31.394        | 98.140        | -0.126        |
| Stack3 MLP <sub>global</sub>              | 0.846               | 13.783                    | 6.362                    | 30.576        | 93.763        | -0.101        |
| Stack5 LinearRegression <sub>global</sub> | 0.846               | 13.785                    | 6.539                    | 31.426        | 98.481        | -0.131        |
| Stack5 Ridge <sub>global</sub>            | 0.846               | 13.785                    | 6.539                    | 31.426        | 98.493        | -0.131        |
| Stack5 GradientBoosting <sub>global</sub> | 0.846               | 13.799                    | 6.421                    | 30.860        | 96.413        | -0.131        |
| Stack3 LinearRegression <sub>global</sub> | 0.846               | 13.812                    | 6.556                    | 31.506        | 98.252        | -0.121        |
| Stack3 Ridge <sub>global</sub>            | 0.846               | 13.812                    | 6.556                    | 31.506        | 98.252        | -0.121        |
| Stack4 GradientBoosting <sub>global</sub> | 0.845               | 13.850                    | 6.428                    | 30.891        | 96.220        | -0.126        |
| Stack3 GradientBoosting <sub>global</sub> | 0.844               | 13.860                    | 6.433                    | 30.917        | 96.274        | -0.125        |
| Stack2 LinearRegression <sub>global</sub> | 0.843               | 13.913                    | 6.586                    | 31.650        | 98.655        | -0.145        |
| Stack2 Ridge <sub>global</sub>            | 0.843               | 13.913                    | 6.586                    | 31.650        | 98.653        | -0.145        |
| Stack2 MLP <sub>global</sub>              | 0.843               | 13.913                    | 6.507                    | 31.270        | 96.485        | -0.016        |
| Stack5 SVR <sub>global</sub>              | 0.843               | 13.940                    | 6.450                    | 30.999        | 98.458        | -1.233        |
| Stack4 SVR <sub>global</sub>              | 0.843               | 13.941                    | 6.451                    | 31.002        | 98.467        | -1.240        |
| Stack1 MLP <sub>global</sub>              | 0.842               | 13.968                    | 6.480                    | 31.140        | 94.798        | -0.326        |
| Stack1 Ridge <sub>global</sub>            | 0.842               | 13.974                    | 6.620                    | 31.816        | 98.389        | -0.138        |
| Stack1 LinearRegression <sub>global</sub> | 0.842               | 13.974                    | 6.620                    | 31.816        | 98.389        | -0.138        |
| Stack2 GradientBoosting <sub>global</sub> | 0.842               | 13.977                    | 6.524                    | 31.355        | 97.165        | -0.136        |
| Stack3 SVR <sub>global</sub>              | 0.842               | 13.977                    | 6.472                    | 31.103        | 98.404        | -1.249        |
| Stack1 GradientBoosting <sub>global</sub> | 0.840               | 14.037                    | 6.532                    | 31.393        | 96.359        | -0.123        |
| Stack2 SVR <sub>global</sub>              | 0.840               | 14.064                    | 6.511                    | 31.290        | 98.508        | -1.226        |
| Stack1 SVR <sub>global</sub>              | 0.838               | 14.153                    | 6.533                    | 31.398        | 98.503        | -1.297        |
| Stack5 RandomForest <sub>global</sub>     | 0.836               | 14.218                    | 6.705                    | 32.220        | 87.305        | 0.220         |
| Stack4 RandomForest <sub>global</sub>     | 0.835               | 14.266                    | 6.784                    | 32.603        | 87.196        | 0.157         |
| Stack3 RandomForest <sub>global</sub>     | 0.829               | 14.522                    | 6.898                    | 33.152        | 86.696        | 0.104         |
| Stack2 RandomForest <sub>global</sub>     | 0.826               | 14.652                    | 7.017                    | 33.722        | 91.605        | 0.106         |
| Stack1 RandomForest <sub>global</sub>     | 0.815               | 15.130                    | 7.270                    | 34.939        | 86.061        | 0.015         |





**Figura 9.1:** Evolución del error absoluto y el error absoluto porcentual en cuantiles en función del periodo para el modelo LightGBM (c4).

## 9. Discusión

En primer lugar se analizarán los modelos “globales”, es decir, aquellos entrenados con todos los datos (IFN2 e IFN3) al mismo tiempo. Posteriormente se analizarán los modelos entrenador solo con un inventario y se compararán con los globales.


### 9.1. Modelos globales

#### 9.1.1. Variable c4 (en toneladas de carbono por hectárea)

##### Modelos base

La variable periodo (el número de años entre la medición y la predicción) tiene una gran importancia en el estudio de los modelos. Es por esto que en la Figura 9.1 se incluyen métricas en función de esta variable, donde se muestra la evolución del RMSE y el %RMSE en cuantiles en función de la variable periodo, junto con un histograma que nos permite visualizar la cantidad de datos en el conjunto de entrenamiento para cada valor de periodo.


Podemos observar algo que podíamos prever: la dificultad de la predicción depende de una combinación entre cuán lejos se desea realizar la predicción y la calidad y cantidad de los datos de entrenamiento. Empezando en terreno del IFN3, podemos observar que para los primeros años (5, y 6), pese a tener pocos datos, los errores son comedidos. A medida que aumenta el periodo (entre 10 y 17 años) los errores medios y medianos se mantienen relativamente estables pese a disponer de, en general, más datos de entrenamiento. Los errores grandes extremos (cuantil 90) experimentan un aumento generalizado. Cuando entramos en el rango de años donde los datos de entrenamiento proceden del IFN2



**Figura 9.2:** Densidad de predicciones frente a valores reales para el modelo LightGBM (c4).

principalmente (el rango entre 20 y 30 años), aunque la mediana y los valores pequeños - medios (cuantil 25) se mantienen estables, los valores grandes - medios (cuantil 75) y los grandes (cuantil 90) aumentan en gran medida. Esto es un indicativo de que, aun disponiendo de una gran cantidad de datos de entrenamiento (especialmente para los años 27 y 28), la combinación entre la peor calidad de los datos (comparando siempre con el IFN3) y la predicción a valores lejanos dificultan la predicción del modelo. Además, como podemos observar en la Figura 6.2, los valores de los primeros años del IFN2 presentan una gran variabilidad, siendo en su mayoría valores más altos que los del IFN3 para esos mismos años, y con una mayor variabilidad. Esto, unido a que la cantidad de datos para esos años no es excesivamente grande, hace que el modelo obtenga peores predicciones.

El hecho de que los valores medianos se mantengan relativamente estables a lo largo de todos los periodos indica que el modelo asimila correctamente el comportamiento de la variable objetivo tanto con datos del IFN2 como del IFN3. Por otro lado, que los errores del cuantil 90 sean tan elevados se explica por varios factores: la alta variabilidad del conjunto de datos, el menor número de variables de campo recogidas en el IFN2 (lo que reduce la información disponible) y la mayor dificultad inherente a predecir a horizontes temporales lejanos. Esta combinación hace que los casos particulares o atípicos sean menos reconocibles por el modelo, especialmente cuando proceden del IFN2, donde la capacidad de discriminación es menor que en el IFN3. La variabilidad mencionada se observa claramente en la Figura 9.2, que muestra los valores predichos frente a los reales para el modelo con mejores métricas, junto con un histograma de distribución.




**Figura 9.3:** Evolución del error absoluto y el error absoluto porcentual en cuantiles en función del periodo para el modelo Stacking (Conf. 5, MLP) (c4).

### Modelos de stacking

La incorporación de esquemas de *stacking* no produce incrementos sustanciales, aunque sí sistemáticos, en el coeficiente de determinación respecto a los mejores modelos individuales. Fijándonos en la Tabla 8.10 podemos observar que los modelos de stacking presentan mejores métricas en la gran mayoría de casos, siempre comparando con los modelos bases. Los mejores parámetros los obtiene el modelo de stacking con configuración 5, que mantiene todos los modelos con rendimiento competitivo, junto con el metamodelo de la red neuronal.

El hecho de que todos los ensembles mejoren a los modelos base es un síntoma de que esta mejora no es una excepción estadística, sino una mejora real. Esto es, no se trata de que las métricas sean mejores por estocasticidad de los parámetros del metamodelo, sino porque el montaje realmente mejora el resultado final. Obviamente, reentrenar los metamodelos con otros parámetros haría variar las métricas, pero el hecho es que la función de mejorar las predicciones realmente se alcanza con los ensembles. No obstante, la mejora es pequeña, lo que puede hacer que según el caso se prefiera la simplicidad de emplear uno de los modelos base en comparación con uno de los ensembles.

En la Figura 9.3 se muestra la evolución del RMSE y el RMSE porcentual en cuantiles para el modelo ensemble con mejores métricas, el stacking con configuración 5 y metamodelo MLP. Podemos observar que el comportamiento es prácticamente idéntico a aquel del LightGBM, el que obtuvo mejores métricas de los modelos base. Por otro lado, en la Figura 9.4 podemos observar el gráfico de puntos de las predicciones frente a los valores reales para el modelo de stacking con configuración 5 y metamodelo MLP para la variable c4 (tC/ha).



**Figura 9.4:** Gráfico de puntos de las predicciones frente a los valores reales para el modelo Stacking (Conf. 5, MLP) (c4).


En cuanto a la estructura de los ensembles, los mejores resultados se obtienen cuando se combinan modelos base de alta calidad y naturaleza similar (principalmente variantes de *gradient boosting*) y se emplean metamodelos con complejidad moderada, como MLP o SVR lineal. Por el contrario, los *stacks* con pocos modelos base o aquellos que incorporan metamodelos excesivamente flexibles, como Random Forest en el segundo nivel, tienden a ofrecer un rendimiento inferior, probablemente debido a la baja dimensionalidad del espacio de meta-predictores o a un sobreajuste innecesario del ruido residual.

#### 9.1.2. Variable carbono\_bruto4 (en toneladas de carbono)


### Modelos base

De igual forma que en los apartados anteriores, en la Figura 9.5 se muestra la evolución del RMSE y el %RMSE en cuantiles en función de la variable periodo para el modelo CatBoost (aquel que obtuvo mejores métricas entre los modelos base) con IFN2 e IFN3 como explicativos para la variable en toneladas de carbono, junto con el histograma de distribución de los datos de entrenamiento en función de la variable periodo.


Atendiendo a la Figura 9.5 observamos el mismo comportamiento cualitativo que en el caso de la variable c4 (con la particularidad de que cambian las unidades y el rango de valores): el error entre los cuantiles 25 y 75 se mantiene en valores relativamente pequeños y constantes, si bien es verdad que empieza siendo menor y va aumentando ligeramente a medida que lo hace la variable periodo. Los errores extremos (cuantil 90) siguen siendo altos. De hecho, si nos fijamos en los valores más altos del RMSE porcentual para el cuantil 90, observamos que se alcanzan valores notablemente más altos que en el caso de la variable c4,



**Figura 9.5:** Evolución del error absoluto y el error absoluto porcentual en cuantiles en función del periodo para el modelo CatBoost (carbono\_bruto4).



**Figura 9.7:** Evolución del error absoluto y el error absoluto porcentual en cuantiles en función del periodo para el modelo Stacking (Conf. 5, MLP) (carbono\_bruto4).



**Figura 9.6:** Gráfico de puntos de las predicciones frente a los valores reales para el modelo CatBoost (carbono\_bruto4).

llegando hasta el 130% cuando para  $c_4$  apenas se superó el 100% para el peor de los casos. Esto es de destacar, ya que las métricas globales para las predicciones de la variable carbono\_bruto4 (ver Tabla 8.11) son sistemáticamente mejores que las de la variable  $c_4$  (ver Tabla 8.9). Esto es, la variable carbono\_bruto4 (toneladas) es más fácil de predecir en general para los modelos que la variable  $c_4$  (toneladas por hectárea), pero ocurre lo contrario en los casos particulares, donde los errores más altos se disparan de una manera más exagerada que en el mismo caso para la variable  $c_4$ . También se observa el aumento del error al pasar del rango de años

del IFN2 a IFN3, causado por el aumento de la variabilidad de los datos del segundo inventario (ver Figura 6.2).


Al igual que en los apartados anteriores, en la Figura 9.6 podemos observar un scatter plot de las predicciones frente a los valores reales para el modelo CatBoost del caso que estamos considerando.

### Modelos con stacking

Los resultados obtenidos en este apartado son muy similares a aquellos que se han obtenido con los modelos stacking para la variable  $c_4$  (tC/ha). Esto es, encontramos una mejora sistemática en todos los modelos de stacking frente a los base, pero esa mejora es pequeña. Esto causa que los resultados sean estrictamente mejores, como se puede ver en la Tabla 8.12 comparando con las métricas de los modelos base de la Tabla 8.11. De nuevo, que la mejora de los modelos stacking respecto a los base sea sistemática indica que no nos encontramos frente a un incidente estadístico, sino que el formato del stacking es capaz de mejorar las predicciones de los modelos escogiendo las mejores decisiones de cada uno de ellos. No obstante, como ya se comentó anteriormente, la complejidad de entrenar cinco modelos además del metamodelo puede resultar incómoda frente a la posibilidad de usar, por ejemplo, el mejor de los modelos individuales.

El modelo ensemble que mejores métricas proporciona para la predicción de la variable carbono\_bruto4 (tC) es la configuración 5 y metamodelo MLP, al igual que ocurrió con la variable  $c_4$  (tC/ha). La evolución del RMSE y el RMSE porcentual en cuantiles en función de la variable periodo para este modelo se puede visualizar en la Figura 9.7.

Por otro lado, en la Figura 9.8 se muestra un scatter plot de las predicciones frente a los valores reales para el modelo



**Figura 9.8:** Gráfico de puntos de las predicciones frente a los valores reales para el modelo Stacking (Conf. 5, MLP) (carbono\_bruto4).


de stacking con configuración 5 y metamodelo MLP y la variable carbono\_bruto4 (tC).

## 9.2. Modelos individuales entrenados solo con el IFN2 o IFN3.


Al comparar el rendimiento de los modelos “globales” (entrenados con el conjunto combinado de IFN2 e IFN3) frente a los modelos “locales” (entrenados exclusivamente con IFN2 o IFN3), se observa un comportamiento diferenciado según el inventario de prueba. En el caso del IFN3, los modelos locales superan a los globales en términos de métricas de precisión. Por el contrario, para el IFN2, los modelos globales muestran un desempeño superior.

Una posible explicación para este fenómeno radica en la calidad y cantidad de información contenida en cada inventario. Los datos del IFN2, al ser menos informativos o presentar menos variables, parecen beneficiarse del aprendizaje conjunto con los del IFN3, lo que permite a los modelos capturar patrones adicionales y mejorar su capacidad de generalización sobre el segundo inventario. En cambio, para el IFN3, cuyos datos poseen una mayor calidad intrínseca, la inclusión de registros del IFN2 durante el entrenamiento podría estar introduciendo ruido o variabilidad no deseada, lo que acaba penalizando la precisión de las predicciones del modelo final sobre este conjunto.

En la Figura 9.9 se muestra una comparativa entre los mejores modelos base globales vs. locales (arriba), mejores modelos de stacking globales vs. locales (medio) y mejor modelo base vs. mejor modelo de stacking (abajo). Observamos que en general los errores menores para el IFN2 los cometen los modelos globales, mientras que para el IFN3 son los locales los que realizan un mejor trabajo.




**Figura 9.9:** Comparación del error absoluto para c4 en el IFN2: mejores modelos base globales vs. locales, stacking globales vs. locales, y mejor modelo base vs. mejor stacking.




**Figura 9.10:** Comparación del error absoluto para c4 en el IFN3: mejores modelos base globales vs. locales, stacking globales vs. locales, y mejor modelo base vs. mejor stacking.

### 9.2.1. Asimilación del comportamiento de las variables objetivo

Con las métricas que hemos planteado y el análisis que se ha hecho en esta sección parece claro que, si bien los resultados no son ni mucho menos perfectos, los modelos son capaces de entender la lógica y el significado de cada variable para obtener una predicción con un grado de acierto que depende de la naturaleza de la instancia que se trate. Otra prueba que podemos hacer para comprobar si los resultados de los modelos son lógicos es la que mostramos en las Figuras 9.13 y 9.14. Estas figuras muestran la evolución




**Figura 9.11:** Comparación del error absoluto para carbon\_bruto4 en el IFN2: mejores modelos base globales vs. locales, stacking globales vs. locales, y mejor modelo base vs. mejor stacking.




**Figura 9.12:** Comparación del error absoluto para carbon\_bruto4 en el IFN3: mejores modelos base globales vs. locales, stacking globales vs. locales, y mejor modelo base vs. mejor stacking.

de varios casos particulares a medida que avanza el tiempo entre medida y predicción. Los casos seleccionados son reales dentro de los datos disponibles. Se seleccionaron con la idea de mostrar cómo se comportan los modelos para configuraciones de carbono inicial más o menos comunes. Para ello se sumaron, para cada instancia de los datos, las variables `npies_x`, y luego se seleccionaron los valores más cercanos a los percentiles 10, 35, 65 y 90 para la variable resultante. Así evitamos posibles problemas fruto de seleccionar ejemplos poco realistas.



**Figura 9.13:** Evolución de la cantidad de carbono en toneladas por hectárea (`c4`) para varios escenarios.



**Figura 9.14:** Evolución de la cantidad de carbono en toneladas (`carbono_bruto4`) para varios escenarios.

Podemos señalar las siguientes características:

- Las líneas de los modelos base y los ensembles para cada caso están muy cerca una de la otra, lo que concuerda con las métricas obtenidas, que eran muy similares entre sí.
- La tendencia general es ascendente, es decir, los modelos capturan de forma correcta el comportamiento del crecimiento de los árboles con el tiempo para los años estudiados.




- En el año 17 tenemos un crecimiento abrupto generalizado, el cual es más exagerado cuanto más pequeño es el percentil del caso de estudio. Esto es sencillo de entender mirando a los datos, ya que los valores de la variable a predecir experimentan un aumento generalizado al pasar de los años del IFN2 a aquellos del IFN3, como se puede ver en la Figura 6.2. Este cambio (que el modelo empiece a ingerir datos del IFN2 en lugar del IFN3) ocurre principalmente en el año 17. Esto puede verse en el histograma de la Figura 9.7, por ejemplo. La razón por la que ocurre el salto a percentiles pequeños es porque estos valores pequeños en los datos del IFN2 apenas existen o son menos comunes. El modelo ha visto que para esos años los valores de carbono son, en general, mayores, y eso es lo que predice. De hecho, en la Figura 6.2 se observa que para los años iniciales de los datos del IFN2 los valores de carbono aumentan para luego disminuir, y esto es justo lo que vemos en las predicciones: un aumento y una posterior disminución.
- También podemos ver una subida abrupta en muchos casos al pasar del año 29 al 30, sobre todo en el caso de la variable en toneladas de carbono bruto (Figura 9.14). Estos años coinciden con una carencia de datos, como podemos ver en el histograma de la Figura 6.2. Es de esperar que las predicciones de esos años sean menos fiables, sobre todo siendo un valor extremo.


### 9.2.2. Rendimiento de los modelos en función del valor de la variable objetivo

Si se analizan las métricas globales de las tablas de la sección 8 nos damos cuenta de que los valores del RMSE son notablemente mayores que los valores de MAE, concretamente cerca del doble en la mayoría de casos. Debido a que el RMSE penaliza mucho más los errores grandes que el MAE, esto es indicativo de la presencia de outliers en el error. Ya hemos visto a lo largo de esta sección que los mayores errores ocurren en el rango de años en que el IFN2 es la principal fuente de datos como podemos ver en las Figuras 9.1, 9.3, 9.5 y 9.7, y la principal conclusión que podemos sacar es que la calidad o cantidad de información contenida en este inventario es peor. No obstante, esto no responde del todo a la pregunta de en qué casos el modelo predice mejor, salvo la obviedad de que la predicción será mejor cuanto más cerca esté en el tiempo y más datos haya de ese año. Es por esto que las Figuras 9.15 y 9.16 nos pueden ser útiles. Estas figuras muestran la distribución de errores, concretamente el RMSE y el SMAPE, en función de la variable objetivo para  $c_4$  y  $\text{carbono\_bruto4}$  respectivamente, en deciles para los modelos base.

Rápidamente nos damos cuenta de lo siguiente: las predicciones para valores pequeños de carbono objetivo (primeros deciles) son malas (SMAPE grande) pese a ser aquellas con un error absoluto menor (RMSE pequeño). Luego, a medida que aumenta el carbono objetivo, el RMSE aumenta ligeramente mientras que el SMAPE disminuye mucho más rápido, llegando a valores cercanos al 25 %. En ambos casos



**Figura 9.15:** Distribución del SMAPE y RMSE en función de la variable objetivo para  $c_4$  en deciles.



**Figura 9.16:** Distribución del SMAPE y RMSE en función de la variable objetivo para  $\text{carbono\_bruto4}$  en deciles.

los mejores resultados se logran cuando el carbono objetivo es mayor, pese a que observamos un aumento significativo del RMSE entre el penúltimo y último decil. Como esto se produce para todos los modelos, sugiere que la dificultad de predicción no es homogénea para todas las situaciones o cantidades de carbono, y que pese a ser los percentiles de menor carbono aquellos con un RMSE menor, la precisión de los modelos no es la suficiente como para hacer una predicción decente en situaciones con poca biomasa. Esto era predecible, ya que un error absoluto mayor para una parcela de bosque mayor no implica necesariamente un peor error relativo.

También es llamativo el hecho de que los deciles iniciales tienen unos rangos de carbono muy cercanos, sobre todo en el caso de la variable  $\text{carbono\_bruto4}$ , donde el primer decil abarca desde 0,0003 tC hasta 0,0020 tC. Esta gran cantidad de valores no sirve a los modelos para obtener una buena predicción, por otra parte. Las densidades mayores para valores pequeños de carbono se ven claramente en las Figuras 9.2, 9.4, 9.6 y 9.8.

**Tabla 9.1**

Mean SHAP rank per variable across LightGBM, XGBoost, CatBoost, GBDT and MLP (n=2000 samples; rank 1 = most important).

| Variable            | Mean | IFN2<br>c4 | IFN2<br>carbono_b4 | IFN3<br>c4 | IFN3<br>carbono_b4 | IFN2+3<br>c4 | IFN2+3<br>carbono_b4 |
|---------------------|------|------------|--------------------|------------|--------------------|--------------|----------------------|
| npies* (Density)    | 1    | 1          | 1                  | 1          | 1                  | 1            | 1                    |
| especie_id*         | 2.2  | 2          | 2                  | 2.2        | 2.8                | 2.2          | 2.2                  |
| ocupa               | 2.9  | 3.2        | 3                  | 3          | 2.2                | 2.8          | 3                    |
| radio               | 4.2  | 4.2        | 4.2                | 4.2        | 4.2                | 4.2          | 4.4                  |
| gndvi_mean_verano   | 6.5  | 5.6        | 5                  | 7          | 7                  | 8            | 6.6                  |
| tipo_especie*       | 7.1  | 11.6       | 8.8                | 4.6        | 5.8                | 6            | 6                    |
| periodo_agrupado    | 8.4  | 13         | 8                  | 10.6       | 8.6                | 5.2          | 5                    |
| skt_mean_verano     | 9.6  | 6.8        | —                  | 10.4       | —                  | 11.6         | —                    |
| rocosidad_id*       | 11   | 9          | 7.6                | 17.2       | 12                 | 10.2         | 9.8                  |
| fccarb              | 11.4 | —          | —                  | 9          | 10                 | 14           | 12.6                 |
| evi_mean_primavera  | 11.8 | 12         | 10.6               | 13.6       | 11.2               | 13.2         | 10.4                 |
| elevacion           | 12.6 | 12.6       | 7.4                | 15.8       | 12.8               | 14.4         | 12.4                 |
| tratmasa_id*        | 13.2 | —          | —                  | 8          | 7.2                | 18.8         | 18.8                 |
| estado_id*          | 13.5 | 21.8       | 12.8               | 17.2       | 12.6               | 8.8          | 8                    |
| ndii_mean_primavera | 14.5 | 17         | 11.6               | 14.2       | 15.6               | 15.4         | 13.4                 |
| skt_mean_primavera  | 15.1 | 17.4       | —                  | 13.4       | —                  | 14.6         | —                    |
| pr_sum_otoño        | 15.7 | 16.4       | —                  | 14.4       | —                  | 16.4         | —                    |
| pr_sum_primavera    | 15.7 | 10.6       | —                  | 17.6       | —                  | 19           | —                    |
| pr_sum_invierno     | 16   | 8.6        | —                  | 21.8       | —                  | 17.6         | —                    |
| martonneidx_id*     | 16.4 | 18.2       | 10.2               | 24.2       | 13.4               | 20.6         | 11.8                 |
| skt_std_verano      | 18.4 | 13.2       | —                  | 22.8       | —                  | 19.2         | —                    |
| skt_std_primavera   | 18.4 | 15.8       | —                  | 20         | —                  | 19.4         | —                    |
| orientacion_cat*    | 18.9 | 19.8       | 14.4               | 23         | 17                 | 21.4         | 18                   |
| modcomb_id*         | 18.9 | —          | —                  | 18.8       | 14                 | 26           | 16.8                 |
| gndvi_std_primavera | 19.8 | 20.8       | 14.6               | 24         | 18                 | 24.8         | 16.6                 |
| pendiente_cat*      | 20   | 20.4       | 15.4               | 26.2       | 18                 | 23.8         | 16.4                 |
| pr_sum_verano       | 20.3 | 19.4       | —                  | 21.2       | —                  | 20.4         | —                    |
| nivel2_id*          | 20.6 | —          | —                  | 20.6       | 17.2               | 27           | 17.6                 |
| disesp_id*          | 23.3 | 24.6       | 16.4               | 29         | 20.4               | 29           | 20.2                 |

### 9.3. Interpretabilidad de los modelos: análisis SHAP


Gracias al análisis de valores SHAP podemos añadir explicabilidad a los modelos, averiguando a qué variables da más importancia el modelo y en qué casos estos valores hacen que la predicción del carbono sea mayor o menor. En la Tabla 9.1 podemos observar el puesto medio de importancia de las variables con mayor valor SHAP en valor absoluto, tanto promediado en todos los casos (primera columna “Mean”) como por inventario fuente y variable objetivo. En esta tabla vemos que las variables más importante consistentemente son npies, especie\_id, ocupa y radio, es decir, variables puramente relacionadas con la estructura del bosque. El resto de variables de la tabla tiene más variabilidad a lo largo de las distintas configuraciones, donde se van intercalando variables meteorológicas (que parecen ser más importantes que la variable climática que hemos añadido, el índice de Martonne) y edáficas, principalmente.

La variable meteorológica que consistentemente tiene más importancia según nuestro análisis es el valor medio del índice GNDVI en verano (gndvi\_mean\_verano), que destacada tanto por posición como por consistencia. Esto es esperado, ya que es en verano cuando la vegetación forestal tiene un mayor vigor, y el índice GNDVI es un indicador más útil en esta época comparado con otros con el NDVI, ya que no tiene problemas de saturación en doseles densos


[33, 19]. Además, este índice sirve para estimar la actividad fotosintética, variable directamente relacionada tanto con la cantidad de vegetación como con la salud de esta.

En las Figuras 9.17, 9.18 y 9.19 podemos ver una comparación entre los variables SHAP de las distintas configuraciones para el modelo LightGBM y la variable objetivo c4. Hay que destacar que para las dos variables más importantes para el análisis (npies, especie\_id y ocupa) la escala del eje x es distinta que para el resto, ya que su valor SHAP es notablemente mayor. Se hizo así para facilitar la visualización. Las variables cuyo está coloreado son variables categóricas (señaladas también con un asterisco, \*), y su color indica el tratamiento que se ha hecho para incluirla en la figura. En primer lugar, está npies. Esta variable son en realidad varias, una para cada clase diamétrica (npies\_5, npies\_10, npies\_15, etc). El color del texto verde indica que para cada clase diamétrica se ha hecho el análisis individualmente y luego se han juntado todas en la misma fila del gráfico. Esto es, cuando el color del punto indica que el valor de la variable es “alto”, esto está normalizado a cada clase diamétrica, ya que un valor alto de la variable npies\_5 no es comparable con un valor alto de npies\_70. El color del texto morado indica que la variable categórica es solo nominal, es decir, no tiene ningún orden pese a que al modelo se le haya pasado codificada en formato numérico. Esto ocurre con la variable especie\_id, donde un valor numérico más alto no indica, por ejemplo, una absorción de carbono mayor.






**Figura 9.17:** Análisis SHAP para el modelo LightGBM entrenado con datos del IFN2 y con variable objetivo c4 (tC/ha).



**Figura 9.19:** Análisis SHAP para el modelo LightGBM entrenado con datos del IFN2 y IFN3 y con variable objetivo c4 (tC/ha).



**Figura 9.18:** Análisis SHAP para el modelo LightGBM entrenado con datos del IFN3 y con variable objetivo c4 (tC/ha).


En este caso, el color de cada punto expresa la media de la variable objetivo para cada especie, de forma que todos los puntos de la misma especie tendrán el mismo color. Esto en muchos casos un resultado obvio: las especies que más carbono absorben serán las que tienen un mayor valor SHAP, y por tanto se localizarán en general a la derecha (como en efecto sucede). No obstante, es la única manera que se ha encontrado para incluir a esta variable en la figura, ya que tenía que estar presente por su elevada importancia para el modelo. Si el color del texto es naranja significa que la variable categórica es ordinal. Esto es, la categoría sigue un orden que tiene sentido representar por colores. Por ejemplo, la variable rocosidad\_id va del valor 1, “sin pedregosidad”, al 5, “roqueado”, teniendo relación el aumento de la variable con un aumento en la característica que indica. Por último, el color de texto negro indica que la variable es continua y se trata como se espera.

En las Figuras 9.17, 9.18 y 9.19 vemos que las dos variables más importantes siempre son npies y especie\_id,

como habíamos visto en la Tabla 9.1. El resto de variables cambian de orden en función del caso, pero si hablamos del conjunto, las variables identificadas como importantes suelen ser comunes en los tres casos de las Figuras. Es de señalar que, aunque las posiciones de las variables no coinciden exactamente entre los casos del modelo entrenado únicamente con los datos del IFN2 (Figura 9.17) y el modelo entrenado con los datos del IFN2 e IFN3 (Figura 9.19), las variables presentes en el top 15 expuesto son, en total, las prácticamente las mismas (a excepción de tratmasa\_id) y estado\_id que se intercambian. Aparecen además variables exclusivas del IFN3, como tratmasa\_id, lo que indica que estas nuevas variables que se han ido incorporando a los inventarios dan información útil para el estudio del bosque, y en concreto para estudiar la captura de carbono.

Si atendemos a los valores de las Figuras 9.17, 9.18 y 9.19 podemos destacar algunos resultados interesantes que apoyan la idea de que el modelo ha incorporado correctamente la información:

- Si atendemos a la variable npies, observamos que un valor mayor de árboles iniciales se corresponde con un valor mayor valor SHAP, es decir, de carbono.
- Como hemos dicho antes, para la variable gndvi\_mean\_verano obtiene un mayor índice SHAP para aquellos casos en los que su valor es también mayor. Esto es lógico, ya que el índice GNDVI mide la actividad fotosintética. Un valor mayor de este índice se corresponde con mayor presencia de vegetación activa, y por tanto mayor captura de carbono.
- La variable periodo\_agrupado indica el número de años entre la medición y el momento en que queremos hacer la estimación, por lo que es de esperar que un valor mayor se corresponda con un mayor valor SHAP, es decir, de carbono. Esto es lo que nos encontramos para el caso del IFN3 (Figura 9.18) e IFN2 y 3 (Figura 9.19). Curiosamente, para el caso de IFN2 (Figura 9.17) esta relación no queda tan clara, caso en



**Figura 9.20:** Análisis SHAP para el modelo LightGBM entrenado con datos del IFN2 e IFN3 y con variable objetivo *c4* (tC/ha) centrandonos en las especies. Se distingue entre conífera o frondosa.

que además coincide con que el modelo SHAP le da una menor importancia relativa.

- La variable *tipo\_especie* tiene una distinción muy clara en todos los casos. Esta es una variable binaria en la que el valor 0 corresponde a coníferas y el valor 1 corresponde a frondosas. Según el análisis, las especies de tipo frondosa obtiene en promedio un mayor índice SHAP, es decir, mayor cantidad de carbono asociado. Esto está de acuerdo con la literatura, y en concreto con estudios realizados con el Inventario Forestal Nacional Español, que cuantifican el *stock* de carbono medio en masas de frondosas en  $48,5 \pm 0,3$  Mg/ha frente a  $41,8 \pm 0,2$  Mg/ha en coníferas para la España peninsular [34].

Para mayor detalle, en la Figura 9.20 se presenta un desglose del índice SHAP por especie para el modelo LightGBM entrenado con datos de ambos inventarios y con *c4* como variable objetivo. Se observa que las frondosas ocupan casi todos los puestos en los que el carbono aumenta, destacando como primera especie el *Eucalyptus globulus*, especie que lleva años causando revuelo en el norte de España por su posible caracterización como especie invasora [35, 36]. No obstante, cabe señalar que este resultado refleja la biomasa inventariada en el IFN, y no implica que el eucalipto sea la opción más adecuada desde una perspectiva de gestión forestal sostenible, dado su alto consumo hídrico, su asociación con un mayor riesgo de incendio, la pérdida de biodiversidad que puede traer asociada, la dificultad de erradicación o el peligro asociado de la introducción involuntaria de especies asociadas, como insectos u hongos, desplazando otras especies nativas [35, 37, 38]

En resumen, el análisis SHAP no solo permite identificar qué variables son más relevantes para la predicción del carbono y cuantificar su importancia relativa, sino que también constituye una herramienta de validación ecológica del modelo. Los resultados obtenidos son coherentes con el conocimiento disponible en la literatura: variables como la densidad de pies, la actividad fotosintética, el tipo de especie o el tiempo transcurrido entre inventarios presentan el sentido esperado en sus valores SHAP, lo que indica que el modelo ha incorporado correctamente la información de entrada y que sus predicciones responden a procesos ecológicos reales.

## 10. Conclusiones

El objetivo principal de este trabajo es el desarrollo de modelos de inteligencia artificial capaces de predecir el carbono que una parcela forestal capturará en un horizonte temporal determinado, a partir de información estructural, edáfica, climática y espectral recogida en los Inventarios Forestales Nacionales y en fuentes de datos auxiliares. Los resultados obtenidos permiten afirmar que dicho objetivo se ha alcanzado de manera satisfactoria.

### Selección de variables y preprocesamiento

El proceso de selección manual de variables (sección 7) permitió reducir un conjunto inicial de 445 predictores candidatos a un subconjunto compacto de 44 variables (véase Tabla 5.1), manteniendo una representación equilibrada de todos los ámbitos ecológicos implicados: estructura de masa, composición de especie, propiedades edáficas, terreno, climatología e índices de vegetación espectral. Esta reducción no solo facilitó el entrenamiento de modelos más eficientes, sino que garantizó la interpretabilidad ecológica de los predictores seleccionados.

### Rendimiento de los modelos

Los modelos entrenados con los datos del IFN3 como variables explicativas obtienen, en general, las mejores métricas (véanse Tablas 8.5 y 8.7). Esto se explica por la mayor calidad, homogeneidad metodológica y riqueza de variables recogidas en este inventario frente al IFN2. Para predicciones a medio plazo (entre 5 y 17 años), los modelos alcanzan niveles de precisión compatibles con aplicaciones prácticas de planificación forestal.

En cuanto a la variable objetivo, la predicción del carbono en toneladas absolutas (*carbono\_bruto4*) resulta sistemáticamente más precisa en términos de métricas globales que la predicción del carbono por unidad de superficie (*c4*, tC/ha), como se puede observar comparando las Tablas 8.9 y 8.11. Sin embargo, el análisis por deciles (Figuras 9.15 y 9.16) revela que para instancias con valores de carbono muy bajos (primera biomasa), los errores relativos (SMAPE)

son elevados en ambas variables con independencia del modelo empleado. Los modelos ofrecen sus mejores resultados en el rango intermedio-alto de biomasa, donde el balance entre cantidad de datos, variabilidad intrínseca y magnitud de la variable objetivo es más favorable.

El análisis de la variable periodo (Figuras 9.1, 9.3, 9.5 y 9.7) muestra que el error crece con el horizonte temporal de predicción, especialmente cuando los datos de entrenamiento proceden del IFN2 (periodos superiores a 17 años). No obstante, los errores medianos (cuantil 50) se mantienen relativamente estables a lo largo de todos los periodos, lo que indica que los modelos asimilan correctamente el comportamiento medio del crecimiento forestal incluso para horizontes largos. Los errores extremos (cuantil 90) son los más sensibles a la calidad de los datos y al alejamiento temporal.

El análisis de sensibilidad sobre escenarios representativos (Figuras 9.13 y 9.14) confirma que los modelos capturan de forma cualitativa correcta la dinámica de crecimiento: la tendencia general es ascendente con el periodo, y los modelos reproducen los efectos de los cambios de inventario (IFN2 a IFN3) observados en los datos reales.

### Modelos globales frente a modelos locales

La comparación entre modelos “globales” (entrenados con IFN2 e IFN3 conjuntamente) y “locales” (entrenados con un único inventario), mostrada en las Figuras 9.9–9.12, revela un comportamiento diferenciado según el inventario de validación. Para el IFN3, los modelos locales superan a los globales, ya que la inclusión de datos del IFN2 introduce heterogeneidad que penaliza la predicción sobre datos de mayor calidad. Para el IFN2, en cambio, los modelos globales son superiores, pues se benefician de los patrones adicionales aprendidos con los datos del IFN3. Este resultado subraya que la elección del conjunto de entrenamiento debe adaptarse al horizonte temporal y al inventario de aplicación.

### Modelos de *stacking*

La incorporación de esquemas de *stacking* (Tablas 7.1 y 7.2) produce mejoras sistemáticas pero modestas respecto a los mejores modelos base (véanse Tablas 8.10 y 8.12 frente a Tablas 8.9 y 8.11). El conjunto de *stacking* con configuración 5 y metamodelo MLP es, de forma consistente, el que mejores métricas obtiene tanto para *c4* como para *carbono\_bruto4*. El hecho de que la mejora sea sistemática en todos los casos descarta que se trate de un artefacto estadístico, pero su magnitud limitada plantea la pregunta de si la complejidad adicional del *stacking* está justificada frente al uso del mejor modelo individual en un hipotético sistema en producción. Los algoritmos basados en *gradient boosting*, especialmente CatBoost y LightGBM, son los que ofrecen el mejor rendimiento como modelos base en todos los escenarios evaluados.

### Interpretabilidad

El análisis SHAP (Figuras ?? y ??) revela que la variable más influyente en las predicciones es la densidad arbórea (*npies*), seguida de la identidad de especie (*especie\_id*).

Las variables climáticas y los índices de vegetación actúan como moduladores secundarios, refinando la predicción especialmente a escala estacional. Este resultado es coherente con la ecología forestal: la densidad y la especie son los determinantes primarios de la acumulación de biomasa, mientras que el clima y el estado espectral de la vegetación condicionan su tasa de crecimiento.

### Comparación con la literatura

En trabajos similares, como el de Fasihi et al. [26] para el norte de Italia, se predicen valores de carbono forestal a partir de observaciones de teledetección sin uso de datos de campo medidos in situ. Aunque el contexto es distinto —ellos predicen el carbono presente en el momento de la medición, sin proyección temporal— los errores que reportan son notablemente superiores a los obtenidos en este trabajo, especialmente en el rango de predicción más corto (alrededor de 5 años), que es el más comparable. Esto pone de manifiesto el valor añadido de incorporar información estructural de campo (IFN) frente a enfoques basados exclusivamente en teledetección.

### Limitaciones

La principal limitación del estudio reside en la heterogeneidad e irregularidad de los datos disponibles. La distribución de instancias en función de la variable periodo es muy desigual: algunos años cuentan con miles de muestras mientras que otros tienen apenas unas pocas decenas. Esta irregularidad, inherente a la naturaleza de los Inventarios Forestales (levantados en periodos de tiempo distintos y con metodologías que evolucionan entre iteraciones), limita la capacidad del modelo para ciertos horizontes temporales, sobre todo en el rango de años con menos datos y donde la fuente principal es el IFN2. Pese a ello, los modelos demuestran capacidad de generalización razonable incluso en estas condiciones.

### Trabajo futuro y aplicabilidad

De cara a una posible aplicación en producción como sistema de apoyo a la recomendación de proyectos de carbono, sería necesario evaluar en qué medida las parcelas del IFN son representativas de plantaciones forestales destinadas a créditos de carbono, que pueden diferir en densidad, manejo y composición. Una extensión natural del modelo sería incorporar datos LiDAR, cuya capacidad para caracterizar la estructura tridimensional del dosel forestal ha demostrado en otros estudios mejorar significativamente las predicciones de biomasa y carbono [15]. Igualmente, la adaptación del modelo a otros contextos geográficos o su integración con datos del IFN4 como variable objetivo constituyen líneas de trabajo prometedoras.

## **11. Recomendaciones para Futuras Investigaciones**

### **Agradecimientos**

Investigación financiada por la subvención **TSI-100933-2023-1** de la **Convocatoria de Cátedras Universidad-Empresa (Cátedras ENIA 2022)**, **Ministerio de Transformación Digital y Función Pública de España**, y el **Plan de Recuperación y Resiliencia de la UE** (*NextGenerationEU/PRTR*).

## Referencias

- [1] I. P. on Climate Change, Climate Change 2007: Mitigation of Climate Change, Cambridge University Press, Cambridge, UK, 2007.
- [2] U. N. F. C. on Climate Change, The Kyoto protocol, 1997. URL: <https://unfccc.int/resource/docs/convkp/kpeng.pdf>.
- [3] U. N. F. C. on Climate Change, Paris agreement, 2015. URL: <https://unfccc.int/process-and-meetings/the-paris-agreement/the-paris-agreement>.
- [4] U. N. F. C. on Climate Change, Decision 16/cmp.1: Land use, land-use change and forestry, Conference of the Parties serving as the meeting of the Parties to the Kyoto Protocol, 2005. URL: <https://unfccc.int/resource/docs/2005/cmp1/eng/08a03.pdf>, acuerdos de Marrakech.
- [5] U. N. F. C. on Climate Change, Report of the individual review of the initial report of Spain under the Kyoto protocol, UNFCCC Secretariat, 2010. URL: [https://unfccc.int/files/kyoto\\_protocol/compliance/plenary/application/pdf/cc-ert-irr-2007-14\\_report\\_of\\_the\\_review\\_of\\_ir\\_of\\_spain.pdf](https://unfccc.int/files/kyoto_protocol/compliance/plenary/application/pdf/cc-ert-irr-2007-14_report_of_the_review_of_ir_of_spain.pdf), incluye la definición nacional de bosque de España: 1 ha, 20 % de cabida cubierta, 3 m de altura.
- [6] E. Union, Regulation (eu) 2018/841 on the inclusion of greenhouse gas emissions and removals from land use, land use change and forestry, Official Journal of the European Union, 2018. URL: <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX:32018R0841>, marco LULUCF y principios de permanencia y contabilidad de sumideros.
- [7] MITECO, Inventario forestal nacional (ifn2, ifn3, ifn4): metodología y bases de datos, Ministerio para la Transición Ecológica y el Reto Demográfico (España), 2023. URL: <https://www.miteco.gob.es/es/biodiversidad/servicios/banco-datos-naturaleza/informacion-disponible/ifn.aspx>.
- [8] J. Muñoz-Sabater, E. Dutra, A. Agustí-Panareda, C. Albergel, G. Arduini, G. Balsamo, et al., Era5-land: A state-of-the-art global reanalysis at land surfaces, EGU General Assembly / ECMWF (Copernicus Climate Data Store) (2021).
- [9] USGS, Landsat collection 2 level-2 science products: Surface reflectance, U.S. Geological Survey, 2021. URL: <https://www.usgs.gov/landsat-missions/landsat-collection-2-level-2-science-products>.
- [10] M. A. U. Jiménez, J. G. Vegas, A. de Luis Reboledo, B. P. Lancho, Greenwest-db: Base de datos integrada de atributos forestales, climáticos y espectrales para España, 2025. Manuscrito en preparación. Universidad de Salamanca, Grupo BISITE.
- [11] C. Brack, History of inventory, 2000. URL: <https://fennerschool-associated.anu.edu.au/mensuration/history.htm>, accessed: 2026-01-22.
- [12] L. Shi, S. Liu, Methods of estimating forest biomass: A review, Biomass Volume Estimation and Valorization for Energy 10 (2017) 65733.
- [13] Y. Shang, Y. Xia, X. Ran, X. Zheng, H. Ding, Y. Fang, Allometric equations for aboveground biomass estimation in natural forest trees: Generalized or species-specific?, Diversity 17 (2025) 493.
- [14] L. Qi, X. Liu, Z. Jiang, X. Yue, Z. Li, J. Fu, G. Liu, B. Guo, L. Shi, Combining diameter-distribution function with allometric equation in biomass estimates: a case study of *Phyllostachys edulis* forests in south anhui, China, Agroforestry Systems 90 (2016) 1113–1121.
- [15] J. Nyakudanga, The treemes story, 2018. URL: <https://saforestryonline.co.za/articles/the-treemes-story/>.
- [16] A. Kristiansen, The terrestrial laser scanning revolution in forest ecology, Royal Society Blog, 2018. URL: <https://royalsocietypublishing.org/blog/2018/02/the-terrestrial-laser-scanning-revolution-in-forest-ecology/>.
- [17] OpenTopography, What is lidar?, OpenTopography, 2024. URL: [https://opentopography.org/lidar\\_basics](https://opentopography.org/lidar_basics).
- [18] J.-R. Roussel, T. R. Goodbody, P. Tompalski, Individual tree detection and segmentation, 2024. URL: <https://r-lidar.github.io/lidRbook/itd.html>.
- [19] Instituto Geográfico Nacional, Tercera cobertura PNOA-LiDAR, Plan Nacional de Ortofotografía Aérea, 2023. URL: <https://pnoa.ign.es/web/portal/pnoa-lidar/tercera-cobertura>.
- [20] S. J. Goetz, A. Baccini, N. T. Laporte, T. Johns, W. Walker, J. Kellndorfer, R. A. Houghton, M. Sun, Mapping and monitoring carbon stocks with satellite observations: a comparison of methods, Carbon Balance and Management 4 (2009) 2.
- [21] J. Ren, L. Liu, Y. Wu, L. Ouyang, Z. Yu, Estimating forest carbon stock using enhanced resnet and sentinel-2 imagery, Forests 16 (2025) 1198. Submission received: 13 June 2025 / Revised: 15 July 2025 / Accepted: 18 July 2025 / Published: 20 July 2025.
- [22] F. Jiang, M. Deng, J. Tang, L. Fu, H. Sun, Integrating spaceborne lidar and sentinel-2 images to estimate forest aboveground biomass in northern China, Carbon Balance and Management 17 (2022) 12.
- [23] G. Reiersen, D. Dao, B. Lütjens, K. Klemmer, K. Amara, A. Steinegger, C. Zhang, X. Zhu, Reforestree: A dataset for estimating tropical forest carbon stock with deep learning and aerial imagery, arXiv preprint arXiv:2201.11192 (2022).
- [24] W. Dong, E. T. Mitchard, H. Yu, S. Hancock, C. M. Ryan, Forest aboveground biomass estimation using GEDI and earth observation data through attention-based deep learning, arXiv preprint arXiv:2311.03067 (2023).
- [25] Ministerio para la Transición Ecológica y el Reto Demográfico, Instrucciones de uso de la calculadora de absorciones de CO<sub>2</sub> ex ante de las especies forestales arbóreas españolas del Ministerio para la Transición Ecológica y el Reto Demográfico, 2023. URL: [https://www.miteco.gob.es/content/dam/miteco/es/cambio-climatico/temas/mitigacion-politicas-y-medidas/instruccionescalculadoraabaxante\\_tcm30-485629.pdf](https://www.miteco.gob.es/content/dam/miteco/es/cambio-climatico/temas/mitigacion-politicas-y-medidas/instruccionescalculadoraabaxante_tcm30-485629.pdf), accedido: 2025-07-16.
- [26] M. Fasihi, B. Portelli, L. Cadez, A. Tomao, A. Falcon, G. Alberti, G. Serra, Assessing ensemble models for carbon sequestration and storage estimation in forests using remote sensing data, Ecological Informatics 83 (2024) 102828.
- [27] J. Muñoz Sabater, Era5-land hourly data from 1950 to present, Copernicus Climate Change Service (C3S) Climate Data Store (CDS), 2019. URL: <https://cds.climate.copernicus.eu/cdsapp#!/dataset/reanalysis-era5-land?tab=overview>. doi:10.24381/cds.e2161bac, accedido: 07-07-2025.
- [28] P. Berg, C. Photiadou, L. Simonsson, E. Sjökvist, J. Thureson, R. Mook, Temperature and precipitation climate impact indicators from 1970 to 2100 derived from European climate projections, Copernicus Climate Change Service (C3S) Climate Data Store (CDS), 2021. URL: <https://cds.climate.copernicus.eu/cdsapp#!/dataset/sis-water-quantity-change?tab=overview>. doi:10.24381/cds.9eed87d5, accedido: 07-07-2025.
- [29] USGS, Usgs Landsat 5 level 2, collection 2, tier 1, 2025. URL: [https://developers.google.com/earth-engine/datasets/catalog/LANDSAT\\_LT05\\_C02\\_T1\\_L2](https://developers.google.com/earth-engine/datasets/catalog/LANDSAT_LT05_C02_T1_L2), accedido: 2025-07-08.
- [30] I. P. on Climate Change, 2006 IPCC Guidelines for National Greenhouse Gas Inventories, IPCC, Geneva, Switzerland, 2006.
- [31] J. Chave, M. Réjou-Méchain, A. Búrquez, E. Chidumayo, M. S. Colgan, W. B. C. Delitti, A. Duque, T. Eid, P. M. Fearnside, R. C. Goodman, M. Henry, A. Martínez-Yrizar, W. A. Mugasha, H. C. Muller-Landau, M. Mencuccini, B. W. Nelson, A. Ngomanda, E. M. Nogueira, E. Ortiz-Malavassi, R. Pélissier, P. Ploton, C. M. Ryan, J. G. Saldarriaga, G. Vieilledent, Improved allometric models to estimate the aboveground biomass of tropical trees, Global Change Biology 20 (2014) 3177–3190.
- [32] M. para la Transición Ecológica y el Reto Demográfico (MITECO), Guía para la estimación de absorciones de dióxido de carbono, 2021. URL: [https://www.miteco.gob.es/content/dam/miteco/es/cambio-climatico/temas/mitigacion-politicas-y-medidas/guiapa\\_tcm30-479094.pdf](https://www.miteco.gob.es/content/dam/miteco/es/cambio-climatico/temas/mitigacion-politicas-y-medidas/guiapa_tcm30-479094.pdf).
- [33] K. Sergieieva, Índices de vegetación y su aplicación en la agricultura digital, EOS Data Analytics, 2025. URL: <https://eos.com/es/blog/indices-de-vegetacion/>.
- [34] J. Vayreda, M. Gracia, J. G. Canadell, J. Retana, Spatial patterns and predictors of forest carbon stocks in Western Mediterranean, Ecosystems 15 (2012) 1258–1270.



- [35] Comité Científico del Comité de Flora y Fauna Silvestres, Dictamen del Comité Científico n.º CC 30/2017 sobre distintas especies del género *Eucalyptus*, Technical Report, Ministerio de Agricultura, Pesca, Alimentación y Medio Ambiente (MAPAMA), 2017. URL: [https://www.miteco.gob.es/content/dam/miteco/es/biodiversidad/temas/conservacion-de-especies/dictamencc302017eucalyptusvariasspp\\_tcm30-445705.pdf](https://www.miteco.gob.es/content/dam/miteco/es/biodiversidad/temas/conservacion-de-especies/dictamencc302017eucalyptusvariasspp_tcm30-445705.pdf).
- [36] Greenpeace España, WWF España, SEO/BirdLife, Ecologistas en Acción, et al., Declaración: Solicitud de ampliación de las vigentes moratorias a las plantaciones de eucalipto en el norte de España, Declaración conjunta de 25 organizaciones ecologistas, 2025. URL: <https://es.greenpeace.org/es/wp-content/uploads/sites/3/2025/06/DeclaEucalipto.docx.pdf>.
- [37] A. Cordero Rivera, S. Santolamazza Carbone, J. A. Andrés, Life cycle and biological control of the Eucalyptus snout beetle (Coleoptera, Curculionidae) by *Anaphes nitens* (Hymenoptera, Mymaridae) in north-west Spain, *Agricultural and Forest Entomology* 1 (1999) 103–109.
- [38] J. Díez, Invasion biology of Australian ectomycorrhizal fungi introduced with eucalypt plantations into the Iberian Peninsula, *Biological Invasions* 7 (2005) 3–15.
- [39] G. M. R. R.-P. y M. Muñoz, Producción de biomasa y fijación de CO<sub>2</sub> por los bosques españoles, Instituto Nacional de Investigación y Tecnología Agraria y Alimentaria (INIA), Madrid, España, 2009. Serie Forestal, 23.
- [40] M. d. R. y G. M. Ricardo Ruiz-Peinado, New models for estimating the carbon sink capacity of spanish softwood species, *Forest Systems* 20 (2011) 176–188.
- [41] Ministerio para la Transición Ecológica y el Reto Demográfico (MITECO), Manual de campo y base de datos del cuarto inventario forestal nacional (ifn4), 2017. URL: [https://www.miteco.gob.es/es/biodiversidad/temas/inventarios-nacionales/inventario-forestal-nacional/cuarto\\_inventario.html](https://www.miteco.gob.es/es/biodiversidad/temas/inventarios-nacionales/inventario-forestal-nacional/cuarto_inventario.html), subdirección General de Política Forestal y Lucha contra la Desertificación.



## A. Apéndices

### A.1. Origen y cálculo de las variables $ca$ y $cr$

Las variables  $ca$  (carbono arbóreo) y  $cr$  (carbono radical) incluidas en la base de datos del *Inventario Forestal Nacional* (IFN4) derivan de las ecuaciones alométricas de biomasa desarrolladas por el *Instituto Nacional de Investigación y Tecnología Agraria y Alimentaria* (INIA), en particular por *Gregorio Montero y Ricardo Ruiz-Peinado* [39, 40]. Estas ecuaciones fueron elaboradas a partir de datos de campo obtenidos mediante talas y pesadas directas de árboles de distintas especies representativas de la flora forestal española.

Cada ecuación estima la biomasa seca (en kilogramos) de los diferentes componentes del árbol en función del diámetro normal ( $D$ , en cm, medido a 1,3 m del suelo) y la altura total ( $H$ , en m). Para cada especie o grupo de especies similares se dispone de ecuaciones específicas de la forma:

$$W_i = a_i \cdot D^{b_i} \cdot H^{c_i}$$

donde  $W_i$  representa la biomasa del componente  $i$  (fuste, corteza, ramas, hojas, raíces, etc.), y  $a_i$ ,  $b_i$  y  $c_i$  son coeficientes empíricos obtenidos mediante regresión no lineal. En los casos en que una especie no dispone de ecuación propia, se utiliza la de otra especie considerada análoga por similitud morfológica o ecológica.

Los componentes de biomasa definidos en el IFN4 incluyen [41]:

- $W_s$ : biomasa del fuste (kg),
- $W_c$ : biomasa de la corteza del fuste (kg),
- $W_{b7}$ : biomasa de ramas mayores de 7 cm de diámetro (kg),
- $W_{b2-7}$ : biomasa de ramas entre 2 y 7 cm de diámetro (kg),
- $W_{b0,5-2}$ : biomasa de ramas entre 0,5 y 2 cm de diámetro (kg),
- $W_r$ : biomasa de ramas menores de 0,5 cm de diámetro (kg),
- $W_h$ : biomasa de hojas (kg),
- $W_{db}$ : biomasa de ramas muertas (kg),
- $W_T = W_s + W_c + W_{b7} + W_{b2-7} + W_{b0,5-2} + W_r + W_h$ : biomasa aérea total (kg),
- $W_r$ : biomasa radical (raíces, kg).

A partir de estas ecuaciones, el cálculo de biomasa y carbono en el IFN4 se realiza de la siguiente forma:

1. **Biomasa por árbol (kg):** en la tabla *Mayores\_exs* se incluyen las medidas de diámetro y altura de cada pie. Aplicando las ecuaciones alométricas correspondientes se obtiene la biomasa aérea ( $W_T$ ) y radical ( $W_r$ ) para cada árbol.
2. **Conversión a carbono (kg):** se aplica un factor de conversión estándar de 0,5, según las directrices del IPCC [30], de forma que:

$$CA = 0,5 \times W_T, \quad CR = 0,5 \times W_r$$

3. **Expansión a valores por hectárea (t/ha):** los valores por árbol se convierten a toneladas por hectárea mediante un *factor de expansión* ( $Fac$ ), que refleja la densidad de árboles por unidad de superficie dentro de cada clase diamétrica y especie. Este factor se calcula en función del número de pies inventariados y la superficie de muestreo, permitiendo expresar los resultados en términos comparables de biomasa o carbono por hectárea.
4. **Agregación por clases diamétricas y especie:** finalmente, en la tabla *Parcelas\_exs* se agrupan los valores por parcela, especie y clase diamétrica (CD), sumando las contribuciones individuales ya expandidas. El resultado son los valores medios de biomasa y carbono por hectárea (t/ha) para cada combinación de parcela y especie.

El mismo procedimiento se aplica tanto a la biomasa aérea (para obtener  $ca$ ) como a la biomasa radical (para  $cr$ ). De esta forma,  **$ca$  y  $cr$  representan el carbono almacenado en la biomasa viva, aérea y subterránea respectivamente, expresado en toneladas de carbono por hectárea (t/ha).**

Este enfoque metodológico se ajusta a las recomendaciones del *IPCC Guidelines for National Greenhouse Gas Inventories* [30], garantizando la coherencia con los métodos de reporte de carbono a nivel internacional y facilitando la comparación de los resultados con otros estudios y marcos regulatorios.

### A.2. Estado de las Poblaciones (*estado\_id*)

Se determinarán las fases de desarrollo de las *poblaciones* codificándose de la siguiente forma:

1. **Replantado.** Conjunto de pies que desde el estrato herbáceo llega hasta el subarborescente y los pies inician la tangencia de copas.
2. **Monte bravo.** Comprende desde el estrato y clase de edad anterior hasta el momento en que por efecto del crecimiento, los pies empiezan a perder las ramas inferiores; es decir que en esta clase de edad, las ramas se encuentran a lo largo de todo el fuste.
3. **Latizal.** Comprende desde la clase anterior hasta que los pies tienen 20 cm de diámetro normal; es decir, el diámetro de su fuste, medido a la altura de 1,30 m del suelo.
4. **Fustal.** Se caracteriza esta clase de edad, porque sus pies tienen diámetros normales superiores a 20 cm.

### A.3. Forma Principal de Masa (IFN3 e IFN4: *fpmasa\_id*)

1. **Coetánea.** Cuando al menos el 90 % de sus pies tienen la misma edad individual. Ejemplo típico: las repoblaciones.
2. **Regular.** Cuando al menos el 90 % de sus pies pertenecen a la misma clase artificial de edad o misma clase diamétrica en su defecto.
3. **Semirregular.** Cuando al menos el 90 % de sus pies pertenecen a dos clases artificiales de edad cíclicamente contiguas o dos clases diamétricas contiguas en su defecto.

4. **Irregular.** Cuando no se cumplen las condiciones anteriores, es decir, cuando en cualquier parte de la masa existen pies más o menos mezclados, de todas las clases de edad que tiene la masa o de varias clases diamétricas en su defecto.

#### A.4. Tratamiento de la Masa (IFN3 e IFN4: *tratmasa\_id*)

1. **Monte alto.** Cuando todos los pies proceden de semilla.
2. **Monte medio.** Cuando coexisten pies de la misma especie, unos procedentes de semilla (brinzales) y otros de brote (chirpiales).
3. **Monte bajo.** Cuando todos los pies proceden de brote de cepa o de raíz.

#### A.5. Origen de la Masa (IFN3 e IFN4: *orgmasa\_id*)

1. **Natural.** Bosque desarrollado espontáneamente, sin intervención humana directa.
2. **Artificial.** Plantado intencionadamente por el ser humano.
3. **Naturalizado.** Bosque originalmente plantado pero que ha evolucionado hacia una estructura más similar a un bosque natural.

#### A.6. Tipo de Suelo (*tipsuelo1\_id*, *tipsuelo2\_id*, *tipsuelo3\_id*)

Se utilizará la siguiente codificación para el tipo de suelo, diferenciando tres variables:

##### Tipo de suelo (I): Presencia de sales, yesos o hidromorfía

1. **No se observan sales, yesos ni procesos de hidromorfía.**
2. **Suelo salino.** Si presenta al menos dos de las siguientes características:
  - Presencia de eflorescencias en la superficie o a distintas profundidades.
  - Existencia de plantas halófitas.
  - Zonas llanas o endorreicas con climas secos que provocan gran evaporación.
3. **Suelo yesífero.** Si presenta alguna de las siguientes características:
  - Presencia de materia yesífera en superficie o a distintas profundidades.
  - Existencia de plantas gipsófilas.
4. **Suelo hidromorfo.** Si el suelo presenta síntomas de hidromorfía acusada, cumpliendo al menos dos de las siguientes:
  - Zona encharcada permanente o casi permanentemente de forma natural.
  - Zona llana o endorreica con climas húmedos.
  - Grietas en verano si no hay encharcamiento.
  - Presencia de vegetación indicadora de hidromorfismo.

Identificándose las siguientes:

- Formaciones vegetales indicadoras de hidromorfía:
  - Ribereñas: *saucedas*, *mimbreras*, *alisedas*.
  - Brezales con *Erica ciliaris*, *Erica tetralix*.
  - Turberas arboladas (excepto Cornisa Cantábrica y Pirineos).
  - Turberas de montaña con *Sphagnum*, *Erica tetralix*.
  - Cervunales con *Nardus stricta*.
  - Carrizales y espadañares (*Phragmites*, *Tipha*, *Cladium*).
  - Juncuales (*Scirpus*, *Juncus*).
  - Pastizales con cárices (*Carex spp.*).
  - Marismas.
- Formaciones vegetales gipsófilas:
  - Aznallar: matorral de *Ononis tridentata*.
  - Tomillares gipsófilos con:
    - *Lepidium subulatum*
    - *Gypsophila spp.*
    - *Matthiola fruticulosa*
- Formaciones vegetales indicadoras de suelos salinos:
  - Salicorniales: matas leñosas crasas (*Salicornia*, *Arthrocnemum*, *Halozyton*).
  - Bosques halófitos del género *Tamarix*.
  - Saladar o sosar: predominio de *Suaeda vera*.
  - Saladar blanco: predominio de *Atriplex halimus*.

##### Tipo de suelo (II y III): Composición del suelo (calizo o silíceo)

1. **Suelo calizo.** Más del 50 % de la vertical del perfil da efervescencia con ácido clorhídrico.
  - **Moderadamente básico:** pH en superficie  $\leq 8.5$ .
  - **Fuertemente básico:** pH en superficie  $> 8.5$ .

2. **Suelo silíceo.** Menos del 50 % de la vertical del perfil da efervescencia.

- **Moderadamente ácido:** pH  $\geq 5.5$ .
- **Fuertemente ácido:** pH  $< 5.5$ .

#### A.7. Roccosidad (rocosidad\_id)

Se considerará el conjunto de la parcela clasificando la rocosidad según la siguiente codificación:

1. **Sin pedregosidad:** la superficie de la parcela está completamente cubierta de vegetación.
2. **Poco pedregoso:** cuando la superficie de la parcela cubierta por rocas coherentes es menor del 25 %.
3. **Pedregoso:** cuando la superficie rocosa está comprendida entre el 25 % y el 50 %.
4. **Muy pedregoso:** cuando la superficie rocosa se sitúa entre el 50 % y el 75 %.
5. **Roquedo:** cuando la superficie de rocas es mayor del 75 %. En este caso, no se tomará ningún dato adicional correspondiente a suelos.

#### A.8. Textura del Suelo (textura\_id)

Se clasificará en función de la siguiente codificación:

1. **Suelo arenoso.** Si los cilindros se deshacen sin apenas formarse.
2. **Suelo franco.** Es posible hacer cilindros gruesos pero no delgados.
3. **Suelo arcilloso.** Se consiguen cilindros de unos 5 mm de diámetro.

#### A.9. Contenido en Materia Orgánica (IFN3 e IFN4: matorg\_id)

Según la siguiente clasificación:

1. **Suelo muy húmifero.** Cuando a 15 cm la pureza es menor de 4, o cuando la capa de broza sea de espesor mayor de 5 cm y a 15 cm de profundidad la pureza sea menor de 6.
2. **Suelo moderadamente húmifero.** Cuando a 15 cm la pureza sea menor de 6 con capa de broza nula o de escaso espesor, o cuando dicha capa tenga espesor mayor de 5 cm y a 15 cm de profundidad la pureza sea igual o mayor de 6.
3. **Suelo poco húmifero.** En los restantes casos.

#### A.10. Modelo de Combustible (IFN3 e IFN4: modcomb\_id)

Se determinará la clase de combustible que es más probable que propague el fuego si hubiese un incendio en la zona, hasta un máximo de 60m: pasto, matorral, hojarasca de bosque o deshechos o restos de corta. Se determinará el modelo de combustible a partir de la siguiente clave:

Tabla A.1: Descripción de los modelos de combustible del Inventario Forestal Nacional, clasificados por grupo funcional.

| GRUPO                                    | MOD. | DESCRIPCIÓN DEL MODELO                                                                                                                                                                  |
|------------------------------------------|------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Pastos                                   | 1    | Pasto fino, seco y bajo, que recubre completamente el suelo. Puede aparecer algunas plantas leñosas dispersas ocupando menos de 1/3 de la superficie.                                   |
|                                          | 2    | Pasto fino, seco y bajo, que recubre completamente el suelo. Las plantas leñosas dispersas cubren de 1/3 a 2/3 de la superficie; pero la propagación del fuego se realiza por el pasto. |
|                                          | 3    | Pasto grueso, denso, seco y alto (>1 m). Puede haber algunas plantas leñosas dispersas. Los campos de cereales son representativos de este modelo.                                      |
| Matorral                                 | 4    | Matorral o plantación joven muy densa; de más de 2 m de altura; con ramas muertas en su interior. Propagación del fuego por las copas de las plantas.                                   |
|                                          | 5    | Matorral disperso, denso y verde, de menos de 1 m de altura. Propagación del fuego por la hojarasca, el pasto, las ramillas y el matorral.                                              |
|                                          | 6    | Parecido al modelo 5, pero con especies más inflamables, de mayor talla, pudiéndose encontrar ramas gruesas en el suelo. Propagación del fuego con vientos moderados a fuertes.         |
|                                          | 7    | Matorral de especies muy inflamables; de 0.5 a 2 m de altura, situado como sotobosque en masas de coníferas.                                                                            |
| Hojarasca bajo arbolado                  | 8    | Bosque denso, sin matorral. Propagación del fuego por la hojarasca muy compacta, formada por acículas cortas (5 cm o menos) o por hojas planas no muy grandes.                          |
|                                          | 9    | Parecido al modelo 8, pero con hojarasca menos compacta, formada por acículas largas y rígidas (P. pinaster) o follaje de frondosas de hoja grande, caducas (castaño o robles).         |
|                                          | 10   | Bosque con gran cantidad de leña y árboles caídos, como consecuencia de vendavales, plagas intensas, etc.                                                                               |
| Restos de corta y operaciones selvícolas | 11   | Bosque claro y fuertemente aclarado. Restos de poda o aclareo ligeros (diámetro <7.5 cm).                                                                                               |
|                                          | 12   | Predominio de los restos sobre el arbolado. La hojarasca y el matorral presente ayudarán a la propagación del fuego.                                                                    |
|                                          | 13   | Grandes acumulaciones de restos gruesos y pesados, cubriendo todo el suelo.                                                                                                             |

**A.11. Distribución Espacial (disesp\_id)**

La disposición de la vegetación en el espacio se clasificará según la siguiente codificación:

1. **Uniforme.** Cuando el estrato arbóreo presenta continuidad en el espacio.
2. **Diseminada en bosquetes aislados.** Cuando la masa arbórea se encuentra dividida en porciones que tienen una superficie inferior a 0,5 ha.
3. **Diseminada en individuos aislados.** Cuando se trata de dehesas.
9. **Otras o no se sabe.** En caso diferente a los anteriores o si se desconoce el dato exacto.

**A.12. Composición Específica (comesp\_id)**

En función de las especies presentes:

1. **Masas homogéneas o puras.** Masas monoespecíficas con una única especie arbórea. La normativa española precisa que una masa es monoespecífica o pura cuando al menos el 90 % de los pies pertenecen a la misma especie.
2. **Masas heterogéneas o mezcladas pie a pie.** Masas de diferentes especies que se juntan o bien se entremezclan por golpes o grupos, siempre que tengan una altura similar.
3. **Masas heterogéneas o mezcladas con subpiso.** Las dos o más especies mezcladas, cuando alcancen el estado adulto y la estabilidad, presentarán alturas diferentes.
9. **Otras o no se sabe.** En caso diferente a los anteriores o desconocer el dato exacto.

**A.13. Manifestaciones Erosivas (merosiva\_id)**

Se observará la parcela y sus alrededores hasta una distancia de 60 metros desde el centro, y se codificará la existencia de manifestaciones erosivas según la siguiente clave:

1. **No hay ninguna manifestación.**
2. **Cuellos de raíces al descubierto:** los cuellos de las raíces están visibles, con acumulación de residuos aguas arriba de los tallos y obstáculos, así como abundancia superficial de piedras.
3. **Presencia de regueros:** canales paralelos de erosión con una profundidad máxima de un palmo (aproximadamente 20 cm).
4. **Cárcavas y barrancos en V:** erosión lineal más profunda que los regueros, con forma de “V”.
5. **Cárcavas y barrancos en U:** erosión avanzada con formas suavizadas y amplias en “U”.
6. **Deslizamientos del terreno:** desplazamientos de masas de tierra, ladera o materiales del suelo.

**A.14. Nivel de usos del suelo (IFN3 e IFN4: nivel1\_id)**

1. **Monte.** Toda superficie en la que vegetan especies arbóreas, arbustivas, de matorral o herbáceas, ya sea espontáneamente o procedan de siembra o plantación, siempre que no sean características de cultivo agrícola o fueran objeto del mismo.
2. **Agrícola.** Territorio o ecosistema poblado con siembras o plantaciones de herbáceas y/o leñosas, anuales o plurianuales que se laborean con una fuerte intervención humana, puede estar poblado por especies forestales de fruto (flor, hojas o en el futuro biomasa) siempre que la intervención humana sea importante. Incluye las dehesas, montes huecos o montes adehesados de base cultivo, siempre que la fracción de cabida cubierta de los árboles sea inferior al 5 %.
3. **Artificial.** Territorio o ecosistemas dominado por edificios, parques urbanos (aunque estén poblados de árboles), viveros fuera de los montes (aunque sean de especies forestales), carreteras (salvo las vías de servicio de los montes) u otras construcciones humanas que tengan superficies continuas.
4. **Humedal.** Lo constituyen las lagunas, charcas, zonas húmedas, marismas y corrientes discontinuas de agua en las que, al menos durante 6 meses del año, esté presente dicho líquido.
5. **Agua.** Es la parte de la tierra constituida por ríos, lagos, embalses, canales o estanques con superficies continuas de más de 0.26 ha y con agua prácticamente todo el año.

**A.15. Nivel morfoestructural (IFN3 e IFN4: nivel2\_id)**

Para el nivel de usos del suelo Monte se definirán los siguientes niveles morfoestructurales.

1. **Monte arbolado.** Territorio o ecosistema con especies forestales arbóreas como manifestación vegetal de estructura vertical dominante y con una fracción de cabida cubierta igual o superior al 20 %; incluye dehesas con base cultivo o pastizal con labores siempre que la fracción arbolada supere el 20 %, y excluye terrenos con fuerte intervención humana para obtener frutos, hojas, flores o varas.
2. **Monte arbolado ralo.** Terreno de uso forestal con especies arbóreas forestales dominantes y fracción de cabida cubierta entre el 10 % y 20 % (incluido el 10 %, excluido el 20 %); también aplica a terrenos con matorral o pastizal natural como dominantes, pero con presencia importante de árboles forestales, incluyendo dehesas de base de cultivo.

**Tabla A.2**

Relación de códigos de grupo taxonómico utilizados en la variable grupo\_id.

| Código | Grupo taxonómico | Código | Grupo taxonómico |
|--------|------------------|--------|------------------|
| 7      | Acacia           | 69     | Phoenix          |
| 15     | Crataegus        | 73     | Betula           |
| 19     | Coníferas        | 77     | Tilia            |
| 20     | Pinos            | 78     | Sorbus           |
| 31     | Abies            | 79     | Platanus         |
| 35     | Larix            | 80     | Laurisilva       |
| 40     | Quercus          | 91     | Buxus            |
| 53     | Tamarix          | 93     | Pistacia         |
| 57     | Salix            | 94     | Laurus           |
| 58     | Populus          | 95     | Prunus           |
| 60     | Eucalyptus       | 99     | Frondosas        |
| 65     | Ilex             | 399    | Morus            |
| 68     | Arbutus          | 455    | Fraxinus         |
| 917    | Cedrus           | 936    | Cupressus        |
| 937    | Juniperus        | 956    | Ulmus            |
| 975    | Juglans          | 976    | Acer             |
| 997    | Sambucus         |        |                  |

3. **Monte temporalmente desarbolado.** Terreno que fue monte arbolado recientemente y que casi con seguridad volverá a estar cubierto de árboles en un futuro próximo.
4. **Monte desarbolado.** Terreno con matorral y/o pastizal natural o débil intervención humana como cobertura dominante, con fracción de cabida cubierta por árboles forestales inferior al 5 %.
5. **Monte sin vegetación superior.** Terreno de uso forestal que no está poblado por vegetales superiores debido a condiciones actuales de suelo, clima o topografía, aunque podría estarlo en otras circunstancias.
6. **Árboles fuera del monte.** Incluye riberas arboladas no estructuradas con los montes, bosquetes de menos de 2.500 m<sup>2</sup>, alineaciones de especies arbóreas o arbustivas de menos de 25 m de anchura, y árboles sueltos en terreno forestal.
7. **Monte arbolado disperso.** Terreno forestal con especies arbóreas dominantes y fracción de cabida cubierta entre el 5 % y el 10 % (incluido el 5 %, excluido el 10 %); también terrenos con matorral o pastizal como cobertura dominante pero con presencia significativa de árboles forestales, incluyendo dehesas de base cultivo.

**A.16. Código de los grupos taxonómicos de las especies (grupo\_id)****A.17. Código de las especies (especie\_id)**

Tabla A.3: Relación de especies empleadas en el estudio y metadatos asociados.

| Cód. | Nombre                | Sinonimia                      | Tipo | Grupo |
|------|-----------------------|--------------------------------|------|-------|
| 307  | Acacia dealbata       | Acacia dealbata                | 1    | 7     |
| 207  | Acacia melanoxylon    | Acacia melanoxylon             | 1    | 7     |
| 7    | Acacia spp.           | -                              | 1    | 7     |
| 392  | Gleditsia triacanthos | Acacia gleditsia               | 1    | 7     |
| 92   | Robinia pseudoacacia  | Acacia robinia                 | 1    | 7     |
| 292  | Sophora japonica      | Acacia sofora                  | 1    | 7     |
| 515  | Crataegus azarolus    | Espino                         | 1    | 15    |
| 415  | Crataegus laciniata   | Majoleto                       | 1    | 15    |
| 315  | Crataegus laevigata   | Espino majuelo                 | 1    | 15    |
| 215  | Crataegus monogyna    | Majuelo                        | 1    | 15    |
| 15   | Crataegus spp.        | -                              | 1    | 15    |
| 30   | Mezcla de coníferas   | Coníferas l excepto pinos      | 0    | 19    |
| 19   | Otras coníferas       | -                              | 0    | 19    |
| 29   | Otros pinos           | -                              | 0    | 20    |
| 20   | Pinos                 | -                              | 0    | 20    |
| 27   | Pinus canariensis     | -                              | 0    | 20    |
| 24   | Pinus halepensis      | -                              | 0    | 20    |
| 25   | Pinus nigra           | Pinus laricio l Pinus clusiana | 0    | 20    |
| 26   | Pinus pinaster        | Pinus maritima                 | 0    | 20    |

Continúa en la siguiente página

Tabla A.3: Relación de especies (continuación).

| Cód. | Nombre                    | Sinonimia                           | Tipo | Grupo |
|------|---------------------------|-------------------------------------|------|-------|
| 23   | Pinus pinea               | -                                   | 0    | 20    |
| 28   | Pinus radiata             | Pinus insignis                      | 0    | 20    |
| 21   | Pinus sylvestris          | -                                   | 0    | 20    |
| 22   | Pinus uncinata            | Pinus montana   Pinus mugo          | 0    | 20    |
| 31   | Abies alba                | Abies pectinata                     | 0    | 31    |
| 32   | Abies pinsapo             | -                                   | 0    | 31    |
| 235  | Larix decidua             | Alerce común                        | 0    | 35    |
| 335  | Larix leptolepis          | Larix kaempferi   Alerce leptolepis | 0    | 35    |
| 35   | Larix spp.                | -                                   | 0    | 35    |
| 435  | Larix x eurolepis         | Alerce híbrido                      | 0    | 35    |
| 49   | Otros quercus             | -                                   | 1    | 40    |
| 344  | Quercus alpestris         | -                                   | 1    | 40    |
| 47   | Quercus canariensis       | Quercus lusitanica var. baetica     | 1    | 40    |
| 44   | Quercus faginea           | Quercus lusitanica var. faginea     | 1    | 40    |
| 45   | Quercus ilex ssp. ballota | Quercus rotundifolia                | 1    | 40    |
| 245  | Quercus ilex ssp. ilex    | -                                   | 1    | 40    |
| 244  | Quercus lusitanica        | Quercus fruticosa   Quejigueta      | 1    | 40    |
| 42   | Quercus petraea           | Quercus sessiliflora                | 1    | 40    |
| 243  | Quercus pubescens         | Quercus pubescens   Quercus humilis | 1    | 40    |
| 43   | Quercus pyrenaica         | Quercus toza                        | 1    | 40    |
| 41   | Quercus robur             | Quercus pedunculata                 | 1    | 40    |
| 48   | Quercus rubra             | Quercus borealis                    | 1    | 40    |
| 46   | Quercus suber             | -                                   | 1    | 40    |
| 253  | Tamarix canariensis       | Tarajal                             | 1    | 53    |
| 53   | Tamarix spp.              | -                                   | 1    | 53    |
| 257  | Salix alba                | Sauce blanco                        | 1    | 57    |
| 357  | Salix atrocinerea         | Bardaguera                          | 1    | 57    |
| 858  | Salix canariensis         | Sauce canario                       | 1    | 57    |
| 557  | Salix cantabrica          | Sauce cantábrico                    | 1    | 57    |
| 657  | Salix caprea              | Sauce cabruno                       | 1    | 57    |
| 757  | Salix elaeagnos           | Sarga                               | 1    | 57    |
| 857  | Salix fragilis            | Mimbre                              | 1    | 57    |
| 957  | Salix purpurea            | Mimbrera                            | 1    | 57    |
| 57   | Salix spp.                | -                                   | 1    | 57    |
| 51   | Populus alba              | -                                   | 1    | 58    |
| 58   | Populus nigra             | -                                   | 1    | 58    |
| 52   | Populus tremula           | -                                   | 1    | 58    |
| 258  | Populus x canadensis      | Populus x euroamericana             | 1    | 58    |
| 62   | Eucalyptus camaldulensis  | Eucalyptus rostrata                 | 1    | 60    |
| 61   | Eucalyptus globulus       | -                                   | 1    | 60    |
| 364  | Eucalyptus gomphocephalus | Eucalipto gonfo                     | 1    | 60    |
| 64   | Eucalyptus nitens         | -                                   | 1    | 60    |
| 464  | Eucalyptus robusta        | -                                   | 1    | 60    |
| 264  | Eucalyptus viminalis      | Eucalipto viminalis                 | 1    | 60    |
| 63   | Otros eucaliptos          | -                                   | 1    | 60    |
| 65   | Ilex aquifolium           | -                                   | 1    | 65    |
| 82   | Ilex canariensis          | -                                   | 1    | 65    |
| 282  | Ilex platyphylla          | Naranjero                           | 1    | 65    |
| 268  | Arbutus canariensis       | Madroño canario                     | 1    | 68    |
| 68   | Arbutus unedo             | -                                   | 1    | 68    |
| 469  | Phoenix canariensis       | Palmera                             | 1    | 69    |
| 69   | Phoenix spp.              | -                                   | 1    | 69    |
| 273  | Betula alba               | Betula verrucosa   Abedul pubescens | 1    | 73    |
| 373  | Betula pendula            | Betula hispanica   Abedul péndula   | 1    | 73    |
| 73   | Betula spp.               | -                                   | 1    | 73    |
| 277  | Tilia cordata             | Tilo cordata                        | 1    | 77    |
| 377  | Tilia platyphyllos        | Tilo común                          | 1    | 77    |
| 77   | Tilia spp.                | -                                   | 1    | 77    |
| 278  | Sorbus aria               | Mostajo                             | 1    | 78    |
| 378  | Sorbus aucuparia          | Serbal de cazadores                 | 1    | 78    |
| 778  | Sorbus chamaemespilus     | Serbal chame                        | 1    | 78    |
| 478  | Sorbus domestica          | Serbal común                        | 1    | 78    |
| 678  | Sorbus latifolia          | Serbal de hoja ancha                | 1    | 78    |
| 78   | Sorbus spp.               | -                                   | 1    | 78    |
| 578  | Sorbus torminalis         | Serbal torminal                     | 1    | 78    |
| 79   | Platanus hispanica        | Platanus hybrida                    | 1    | 79    |
| 279  | Platanus orientalis       | Plátano oriental                    | 1    | 79    |

Continúa en la siguiente página



Tabla A.3: Relación de especies (continuación).

| Cód. | Nombre                            | Sinonimia                                | Tipo | Grupo |
|------|-----------------------------------|------------------------------------------|------|-------|
| 80   | Laurisilva                        | -                                        | 1    | 80    |
| 89   | Otras laurisilvas                 | -                                        | 1    | 80    |
| 291  | Buxus balearica                   | Boj de Baleares                          | 1    | 91    |
| 91   | Buxus sempervirens                | -                                        | 1    | 91    |
| 293  | Pistacia atlantica                | Cornicabra canaria                       | 1    | 93    |
| 93   | Pistacia terebinthus              | Cornicabra                               | 1    | 93    |
| 294  | Laurus azorica                    | Laurel canario                           | 1    | 94    |
| 94   | Laurus nobilis                    | Laurel                                   | 1    | 94    |
| 395  | Prunus avium                      | Cerezo silvestre                         | 1    | 95    |
| 495  | Prunus lusitanica                 | Loro l hija                              | 1    | 95    |
| 595  | Prunus padus                      | Prunus                                   | 1    | 95    |
| 295  | Prunus spinosa                    | Espino negro                             | 1    | 95    |
| 95   | Prunus spp.                       | Prunus                                   | 1    | 95    |
| 70   | Mezcla de frondosas de gran porte | Frondosas de gran porte (H.t. >10 m)     | 1    | 99    |
| 90   | Mezcla de pequeñas frondosas      | Frondosas de pequeño porte (H.t. ≤ 10 m) | 1    | 99    |
| 99   | Otras frondosas                   | Otras frondosas                          | 1    | 99    |
| 499  | Morus alba                        | Morera                                   | 1    | 399   |
| 599  | Morus nigra                       | Morera                                   | 1    | 399   |
| 399  | Morus spp.                        | Morera                                   | 1    | 399   |
| 55   | Fraxinus angustifolia             | -                                        | 1    | 455   |
| 255  | Fraxinus excelsior                | Fresno excelsior                         | 1    | 455   |
| 355  | Fraxinus ornus                    | Fresno orno                              | 1    | 455   |
| 955  | Fraxinus spp.                     | Fresnos                                  | 1    | 455   |
| 17   | Cedrus atlantica                  | -                                        | 0    | 917   |
| 217  | Cedrus deodara                    | Cedrus deodara                           | 0    | 917   |
| 317  | Cedrus libani                     | Cedrus libani                            | 0    | 917   |
| 917  | Cedrus spp.                       | Cedrus spp.                              | 0    | 917   |
| 337  | Juniperus cedrus                  | Enebro canario                           | 0    | 917   |
| 236  | Cupressus arizonica               | Ciprés arizónica                         | 0    | 936   |
| 336  | Cupressus lusitanica              | Ciprés lambertiana                       | 0    | 936   |
| 436  | Cupressus macrocarpa              | Ciprés americano                         | 0    | 936   |
| 36   | Cupressus sempervirens            | -                                        | 0    | 936   |
| 936  | Cupressus spp.                    | Ciprés                                   | 0    | 936   |
| 37   | Juniperus communis                | -                                        | 0    | 937   |
| 237  | Juniperus oxycedrus               | Enebro oxicedro                          | 0    | 937   |
| 39   | Juniperus phoenicea               | -                                        | 0    | 937   |
| 239  | Juniperus sabina                  | Sabina rastrera                          | 0    | 937   |
| 937  | Juniperus spp.                    | Enebro y sabinas                         | 0    | 937   |
| 38   | Juniperus thurifera               | -                                        | 0    | 937   |
| 238  | Juniperus turbinata               | Sabina canaria                           | 0    | 937   |
| 256  | Ulmus glabra                      | Ulmus montana                            | 1    | 956   |
| 56   | Ulmus minor                       | Ulmus campestris                         | 1    | 956   |
| 356  | Ulmus pumila                      | Olmo pumilo                              | 1    | 956   |
| 956  | Ulmus spp.                        | Olmo                                     | 1    | 956   |
| 275  | Juglans nigra                     | Nogal                                    | 1    | 975   |
| 75   | Juglans regia                     | -                                        | 1    | 975   |
| 975  | Juglans spp.                      | -                                        | 1    | 975   |
| 76   | Acer campestre                    | -                                        | 1    | 976   |
| 276  | Acer monspessulanum               | Arce de Montpellier                      | 1    | 976   |
| 376  | Acer negundo                      | Negundo fraxinifolia l Arce negundo      | 1    | 976   |
| 476  | Acer opalus                       | Arce ópalus                              | 1    | 976   |
| 676  | Acer platanoides                  | Arce platanoides                         | 1    | 976   |
| 576  | Acer pseudoplatanus               | Arce pseudoplátano                       | 1    | 976   |
| 976  | Acer spp.                         | Arces                                    | 1    | 976   |
| 97   | Sambucus nigra                    | Saúco negro                              | 1    | 997   |
| 297  | Sambucus racemosa                 | Saúco racemosa                           | 1    | 997   |
| 997  | Sambucus spp.                     | -                                        | 1    | 997   |
| 11   | Ailanthus altissima               | Ailanthus glandulosa                     | 1    | -     |
| 54   | Alnus glutinosa                   | -                                        | 1    | -     |
| 2    | Amelanchier ovalis                | Guillomo                                 | 1    | -     |
| 88   | Apollonias barbuiana              | Apollonias canariensis                   | 1    | -     |
| 98   | Carpinus betulus                  | Carpe                                    | 1    | -     |
| 72   | Castanea sativa                   | Castanea vesca                           | 1    | -     |
| 13   | Celtis australis                  | -                                        | 1    | -     |
| 67   | Ceratonía siliqua                 | -                                        | 1    | -     |
| 18   | Chamaecyparis lawsoniana          | -                                        | 0    | -     |
| 369  | Chamaerops humilis                | Palmito                                  | 1    | -     |

Continúa en la siguiente página

**Tabla A.4**

Resumen del rendimiento de los modelos para la predicción de la variable de carbono en toneladas (carbono\_bruto4) con el conjunto de datos que emplea IFN2 e IFN3 como explicativos.

| Modelo          | $R^2_{\text{test}}$ | RMSE <sub>test</sub> | MAE <sub>test</sub> |
|-----------------|---------------------|----------------------|---------------------|
| <b>CatBoost</b> | <b>0.845</b>        | <b>13.846</b>        | <b>6.615</b>        |
| LightGBM        | 0.841               | 14.006               | 6.654               |
| XGBoost         | 0.840               | 14.054               | 6.655               |
| GBDT            | 0.838               | 14.159               | 6.722               |
| MLP             | 0.832               | 14.410               | 6.931               |
| BaggedDT        | 0.821               | 14.858               | 7.282               |
| Random Forest   | 0.819               | 14.950               | 7.135               |
| BayesianNN      | 0.775               | 16.674               | 8.906               |
| SVR             | 0.679               | 19.897               | 8.137               |

Tabla A.3: Relación de especies (continuación).

| Cód. | Nombre                      | Sinonimia                      | Tipo | Grupo |
|------|-----------------------------|--------------------------------|------|-------|
| 9    | Cornus sanguinea            | -                              | 1    | -     |
| 74   | Corylus avellana            | -                              | 1    | -     |
| 569  | Dracaena draco              | Drago                          | 1    | -     |
| 83   | Erica arborea               | -                              | 1    | -     |
| 283  | Erica scoparia              | Tejo l brezo arbóreo escopario | 1    | -     |
| 5    | Euonymus europaeus          | -                              | 1    | -     |
| 71   | Fagus sylvatica             | -                              | 1    | -     |
| 299  | Ficus carica                | Higuera                        | 1    | -     |
| 3    | Frangula alnus              | Rhamnus frangula               | 1    | -     |
| 1    | Heberdenia bahamensis       | Heberdenia excelsa             | 1    | -     |
| 12   | Malus sylvestris            | -                              | 1    | -     |
| 60   | Mezcla de eucaliptos        | Eucaliptos                     | 1    | -     |
| 50   | Mezcla de árboles de ribera | Árboles ripícolas              | 1    | -     |
| 81   | Myrica faya                 | -                              | 1    | -     |
| 281  | Myrica rivasmartinezii      | -                              | 1    | -     |
| 6    | Myrtus communis             | -                              | 1    | -     |
| 87   | Ocotea phoetens             | -                              | 1    | -     |
| 66   | Olea europaea               | Olea oleaster                  | 1    | -     |
| 59   | Otros árboles ripícolas     | -                              | 1    | -     |
| 84   | Persea indica               | -                              | 1    | -     |
| 8    | Phillyrea latifolia         | -                              | 1    | -     |
| 86   | Picconia excelsa            | Notelaea excelsa               | 1    | -     |
| 33   | Picea abies                 | Picea excelsa                  | 0    | -     |
| 289  | Pleiomeris canariensis      | Delfino                        | 1    | -     |
| 34   | Pseudotsuga menziesii       | Pseudotsuga douglasii          | 0    | -     |
| 16   | Pyrus spp.                  | -                              | 1    | -     |
| 40   | Quercus                     | -                              | 1    | -     |
| 4    | Rhamnus alaternus           | Aladierno                      | 1    | -     |
| 389  | Rhamnus glandulosa          | Sanguino                       | 1    | -     |
| 96   | Rhus coriaria               | Zumaque                        | 1    | -     |
| 457  | Salix babylonica            | Sauce llorón                   | 1    | -     |
| 85   | Sideroxylon marmulano       | -                              | 1    | -     |
| 10   | Sin asignar                 | Sin asignar                    | 1    | -     |
| 14   | Taxus baccata               | -                              | 0    | -     |
| 219  | Tetraclinis articulata      | Tetraclinis articulata         | 0    | -     |
| 319  | Thuja spp.                  | Thuja                          | 0    | -     |
| 489  | Visnea mocanera             | Mocan                          | 1    | -     |

## A.18. Resultados

### A.18.1. IFN2 e IFN3 como explicativos para carbono\_bruto4 (tC)

TODO: corregir las combinaciones para el stack. No coinciden con las descritas arriba ni con las entrenadas para IFN3 como explicativo. Debería ser stack1-6 modelos, satck2-4 modelos, stack3-3 modelos, stack4-3 modelos, stack5-2 modelos

### A.18.2. IFN2 e IFN3 como explicativos para c4 (tC/ha)

TODO: corregir las combinaciones para el stack. No coinciden con las descritas arriba ni con las entrenadas para IFN3 como explicativo. Debería ser stack1-6 modelos, satck2-4 modelos, stack3-3 modelos, stack4-3 modelos, stack5-2 modelos

| Stack         | Metamodelo       | Bases    | $R^2_{test}$ | RMSE <sub>test</sub> | MAE <sub>test</sub> |
|---------------|------------------|----------|--------------|----------------------|---------------------|
| stack1        | GradientBoosting | 2        | 0.840        | 14.042               | 6.532               |
| stack1        | LinearRegression | 2        | 0.842        | 13.974               | 6.621               |
| stack1        | Ridge            | 2        | 0.842        | 13.974               | 6.621               |
| stack1        | RandomForest     | 2        | 0.815        | 15.108               | 7.254               |
| stack1        | SVR              | 2        | 0.838        | 14.150               | 6.534               |
| <b>stack1</b> | <b>MLP</b>       | <b>2</b> | <b>0.842</b> | <b>13.969</b>        | <b>6.482</b>        |
| stack2        | GradientBoosting | 3        | 0.842        | 13.977               | 6.525               |
| stack2        | LinearRegression | 3        | 0.843        | 13.913               | 6.586               |
| stack2        | Ridge            | 3        | 0.843        | 13.913               | 6.586               |
| stack2        | RandomForest     | 3        | 0.826        | 14.652               | 7.017               |
| stack2        | SVR              | 3        | 0.840        | 14.064               | 6.511               |
| <b>stack2</b> | <b>MLP</b>       | <b>3</b> | <b>0.843</b> | <b>13.913</b>        | <b>6.507</b>        |
| stack3        | GradientBoosting | 4        | 0.844        | 13.862               | 6.440               |
| stack3        | LinearRegression | 4        | 0.846        | 13.813               | 6.557               |
| stack3        | Ridge            | 4        | 0.846        | 13.813               | 6.557               |
| stack3        | RandomForest     | 4        | 0.829        | 14.545               | 6.920               |
| stack3        | SVR              | 4        | 0.842        | 13.978               | 6.473               |
| <b>stack3</b> | <b>MLP</b>       | <b>4</b> | <b>0.846</b> | <b>13.785</b>        | <b>6.364</b>        |
| stack4        | GradientBoosting | 5        | 0.845        | 13.827               | 6.428               |
| stack4        | LinearRegression | 5        | 0.846        | 13.784               | 6.533               |
| stack4        | Ridge            | 5        | 0.846        | 13.784               | 6.533               |
| stack4        | RandomForest     | 5        | 0.834        | 14.309               | 6.771               |
| stack4        | SVR              | 5        | 0.843        | 13.943               | 6.452               |
| <b>stack4</b> | <b>MLP</b>       | <b>5</b> | <b>0.847</b> | <b>13.768</b>        | <b>6.458</b>        |
| stack5        | GradientBoosting | 6        | 0.846        | 13.812               | 6.423               |
| stack5        | LinearRegression | 6        | 0.846        | 13.787               | 6.541               |
| stack5        | Ridge            | 6        | 0.846        | 13.787               | 6.541               |
| stack5        | RandomForest     | 6        | 0.836        | 14.212               | 6.716               |
| stack5        | SVR              | 6        | 0.843        | 13.940               | 6.451               |
| <b>stack5</b> | <b>MLP</b>       | <b>6</b> | <b>0.847</b> | <b>13.759</b>        | <b>6.401</b>        |

**Tabla A.5**

Resultados de las diferentes configuraciones de stacking utilizando IFN2 e IFN3 como explicativos de la variable en toneladas de carbono.

**Tabla A.6**

Resumen del rendimiento de los modelos para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN2 e IFN3 como explicativos.

| Modelo          | $R^2_{test}$ | RMSE <sub>test</sub> | MAE <sub>test</sub> |
|-----------------|--------------|----------------------|---------------------|
| <b>LightGBM</b> | <b>0.787</b> | <b>22.767</b>        | <b>11.650</b>       |
| XGBoost         | 0.784        | 22.952               | 11.590              |
| CatBoost        | 0.783        | 22.990               | 11.607              |
| GBDT            | 0.783        | 23.014               | 11.658              |
| MLP             | 0.771        | 23.607               | 12.287              |
| BaggedDT        | 0.740        | 25.142               | 13.021              |
| Random Forest   | 0.732        | 25.547               | 12.908              |
| BayesianNN      | 0.678        | 28.021               | 14.689              |
| SVR             | 0.551        | 33.065               | 13.708              |

**A.18.3. IFN3 como explicativo para carbono\_bruto4 (tC)**

**A.18.4. IFN3 como explicativo para c4 (tC/ha)**

## **B. Base de datos: diccionario de variables y cardinalidad**

### **B.1. Diccionario resumido de variables**

| Stack         | Metamodelo       | Bases    | $R^2_{test}$ | RMSE <sub>test</sub> | MAE <sub>test</sub> |
|---------------|------------------|----------|--------------|----------------------|---------------------|
| stack1        | GradientBoosting | 2        | 0.770        | 23.648               | 11.663              |
| stack1        | LinearRegression | 2        | 0.787        | 22.768               | 11.607              |
| stack1        | Ridge            | 2        | 0.787        | 22.769               | 11.607              |
| stack1        | RandomForest     | 2        | 0.740        | 25.152               | 12.875              |
| stack1        | SVR              | 2        | 0.781        | 23.109               | 11.368              |
| <b>stack1</b> | <b>MLP</b>       | <b>2</b> | <b>0.789</b> | <b>22.650</b>        | <b>11.556</b>       |
| stack2        | GradientBoosting | 3        | 0.779        | 23.183               | 11.527              |
| stack2        | LinearRegression | 3        | 0.791        | 22.565               | 11.429              |
| stack2        | Ridge            | 3        | 0.791        | 22.566               | 11.429              |
| stack2        | RandomForest     | 3        | 0.755        | 24.446               | 12.345              |
| stack2        | SVR              | 3        | 0.786        | 22.853               | 11.214              |
| <b>stack2</b> | <b>MLP</b>       | <b>3</b> | <b>0.794</b> | <b>22.405</b>        | <b>11.403</b>       |
| stack3        | GradientBoosting | 4        | 0.774        | 23.442               | 11.477              |
| stack3        | LinearRegression | 4        | 0.788        | 22.735               | 11.456              |
| stack3        | Ridge            | 4        | 0.788        | 22.735               | 11.454              |
| stack3        | RandomForest     | 4        | 0.748        | 24.768               | 12.394              |
| stack3        | SVR              | 4        | 0.783        | 22.995               | 11.218              |
| <b>stack3</b> | <b>MLP</b>       | <b>4</b> | <b>0.787</b> | <b>22.774</b>        | <b>11.333</b>       |
| stack4        | GradientBoosting | 5        | 0.772        | 23.553               | 11.476              |
| stack4        | LinearRegression | 5        | 0.790        | 22.602               | 11.416              |
| stack4        | Ridge            | 5        | 0.790        | 22.601               | 11.415              |
| stack4        | RandomForest     | 5        | 0.751        | 24.650               | 12.208              |
| stack4        | SVR              | 5        | 0.785        | 22.873               | 11.183              |
| <b>stack4</b> | <b>MLP</b>       | <b>5</b> | <b>0.792</b> | <b>22.531</b>        | <b>11.315</b>       |
| stack5        | GradientBoosting | 6        | 0.773        | 23.492               | 11.421              |
| stack5        | LinearRegression | 6        | 0.791        | 22.571               | 11.387              |
| stack5        | Ridge            | 6        | 0.791        | 22.572               | 11.384              |
| stack5        | RandomForest     | 6        | 0.760        | 24.187               | 12.029              |
| stack5        | SVR              | 6        | 0.785        | 22.864               | 11.162              |
| <b>stack5</b> | <b>MLP</b>       | <b>6</b> | <b>0.794</b> | <b>22.387</b>        | <b>11.307</b>       |

**Tabla A.7**

Resultados de las diferentes configuraciones de stacking utilizando IFN2 e IFN3 como explicativos de la variable en tC/ha.

**Tabla A.8**

Resumen del rendimiento de los modelos para la predicción de la variable de carbono en tC con el conjunto de datos que emplea IFN3 como explicativo.

| Modelo          | $R^2_{test}$ | RMSE <sub>test</sub> | MAE <sub>test</sub> |
|-----------------|--------------|----------------------|---------------------|
| <b>LightGBM</b> | <b>0.909</b> | <b>10.662</b>        | <b>5.477</b>        |
| XGBoost         | 0.907        | 10.772               | 5.580               |
| CatBoost        | 0.907        | 10.807               | 5.570               |
| GBDT            | 0.904        | 10.942               | 5.732               |
| MLP             | 0.896        | 11.392               | 6.382               |
| BaggedDT        | 0.882        | 12.154               | 6.420               |
| Random Forest   | 0.872        | 12.643               | 6.533               |
| BayesianNN      | 0.842        | 14.079               | 7.890               |
| SVR             | 0.825        | 14.797               | 7.124               |
| KNN             | 0.788        | 16.270               | 8.166               |
| AdaBoost        | 0.575        | 23.056               | 19.535              |

| Stack         | Metamodelo       | Bases    | Test $R^2$    | RMSE           | MAE           |
|---------------|------------------|----------|---------------|----------------|---------------|
| stack1        | GradientBoosting | 6        | 0.9121        | 10.4852        | 5.2841        |
| stack1        | LinearRegression | 6        | 0.9122        | 10.4816        | 5.3798        |
| stack1        | Ridge            | 6        | 0.9122        | 10.4815        | 5.3798        |
| stack1        | RandomForest     | 6        | 0.9057        | 10.8580        | 5.5726        |
| stack1        | SVR              | 6        | 0.9098        | 10.6226        | 5.3112        |
| <b>stack1</b> | <b>MLP</b>       | <b>6</b> | <b>0.9140</b> | <b>10.3723</b> | <b>5.2515</b> |
| stack2        | GradientBoosting | 4        | 0.9124        | 10.4693        | 5.2930        |
| stack2        | LinearRegression | 4        | 0.9120        | 10.4914        | 5.3853        |
| stack2        | Ridge            | 4        | 0.9120        | 10.4914        | 5.3853        |
| stack2        | RandomForest     | 4        | 0.9050        | 10.9015        | 5.6023        |
| stack2        | SVR              | 4        | 0.9096        | 10.6341        | 5.3147        |
| <b>stack2</b> | <b>MLP</b>       | <b>4</b> | <b>0.9136</b> | <b>10.3941</b> | <b>5.2625</b> |
| stack3        | GradientBoosting | 3        | 0.9105        | 10.5796        | 5.3948        |
| stack3        | LinearRegression | 3        | 0.9112        | 10.5411        | 5.4317        |
| stack3        | Ridge            | 3        | 0.9112        | 10.5411        | 5.4317        |
| stack3        | RandomForest     | 3        | 0.8999        | 11.1916        | 5.8307        |
| stack3        | SVR              | 3        | 0.9089        | 10.6775        | 5.3694        |
| <b>stack3</b> | <b>MLP</b>       | <b>3</b> | <b>0.9122</b> | <b>10.4789</b> | <b>5.3739</b> |
| stack4        | GradientBoosting | 3        | 0.9084        | 10.7041        | 5.4036        |
| stack4        | LinearRegression | 3        | 0.9088        | 10.6822        | 5.5379        |
| stack4        | Ridge            | 3        | 0.9088        | 10.6822        | 5.5379        |
| stack4        | RandomForest     | 3        | 0.8983        | 11.2777        | 5.8314        |
| stack4        | SVR              | 3        | 0.9060        | 10.8425        | 5.4644        |
| <b>stack4</b> | <b>MLP</b>       | <b>3</b> | <b>0.9103</b> | <b>10.5951</b> | <b>5.3681</b> |
| stack5        | GradientBoosting | 2        | 0.9098        | 10.6245        | 5.4007        |
| stack5        | LinearRegression | 2        | 0.9092        | 10.6546        | 5.4719        |
| stack5        | Ridge            | 2        | 0.9092        | 10.6546        | 5.4718        |
| stack5        | RandomForest     | 2        | 0.8920        | 11.6247        | 6.1032        |
| stack5        | SVR              | 2        | 0.9069        | 10.7932        | 5.4151        |
| <b>stack5</b> | <b>MLP</b>       | <b>2</b> | <b>0.9101</b> | <b>10.6019</b> | <b>5.3545</b> |

**Tabla A.9**

Resultados de las diferentes configuraciones de stacking con el conjunto que emplea IFN3 como explicativo de la variable en tC.

**Tabla A.10**

Resumen del rendimiento de los modelos para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN3 como explicativo.

| Modelo          | $R^2_{\text{test}}$ | RMSE <sub>test</sub> | MAE <sub>test</sub> |
|-----------------|---------------------|----------------------|---------------------|
| <b>CatBoost</b> | <b>0.860</b>        | <b>17.709</b>        | <b>9.250</b>        |
| XGBoost         | 0.858               | 17.828               | 9.207               |
| LightGBM        | 0.858               | 17.841               | 9.159               |
| GBDT            | 0.853               | 18.141               | 9.463               |
| MLP             | 0.837               | 19.086               | 10.917              |
| BaggedDT        | 0.826               | 19.726               | 10.402              |
| Random Forest   | 0.826               | 19.730               | 10.489              |
| BayesianNN      | 0.775               | 22.454               | 12.260              |
| KNN             | 0.769               | 22.755               | 12.252              |
| SVR             | 0.734               | 24.403               | 11.219              |
| AdaBoost        | 0.473               | 34.336               | 26.295              |

| Stack         | Metamodelo       | Bases    | Test $R^2$    | RMSE           | MAE           |
|---------------|------------------|----------|---------------|----------------|---------------|
| stack1        | GradientBoosting | 6        | 0.8682        | 17.1742        | 8.9546        |
| stack1        | LinearRegression | 6        | 0.8639        | 17.4508        | 8.9676        |
| stack1        | Ridge            | 6        | 0.8639        | 17.4510        | 8.9677        |
| stack1        | RandomForest     | 6        | 0.8592        | 17.7459        | 9.3749        |
| stack1        | SVR              | 6        | 0.8612        | 17.6207        | 8.8012        |
| <b>stack1</b> | <b>MLP</b>       | <b>6</b> | <b>0.8656</b> | <b>17.3380</b> | <b>8.8789</b> |
| stack2        | GradientBoosting | 4        | 0.8599        | 17.7069        | 8.9856        |
| stack2        | LinearRegression | 4        | 0.8635        | 17.4725        | 8.9908        |
| stack2        | Ridge            | 4        | 0.8635        | 17.4727        | 8.9908        |
| stack2        | RandomForest     | 4        | 0.8523        | 18.1766        | 9.5079        |
| stack2        | SVR              | 4        | 0.8613        | 17.6142        | 8.8209        |
| <b>stack2</b> | <b>MLP</b>       | <b>4</b> | <b>0.8645</b> | <b>17.4083</b> | <b>8.8888</b> |
| stack3        | GradientBoosting | 3        | 0.8590        | 17.7638        | 9.0799        |
| stack3        | LinearRegression | 3        | 0.8615        | 17.6005        | 9.0450        |
| stack3        | Ridge            | 3        | 0.8615        | 17.6005        | 9.0450        |
| stack3        | RandomForest     | 3        | 0.8449        | 18.6308        | 9.7939        |
| stack3        | SVR              | 3        | 0.8592        | 17.7490        | 8.8749        |
| <b>stack3</b> | <b>MLP</b>       | <b>3</b> | <b>0.8619</b> | <b>17.5765</b> | <b>8.9734</b> |
| stack4        | GradientBoosting | 3        | 0.8520        | 18.1962        | 9.2188        |
| stack4        | LinearRegression | 3        | 0.8604        | 17.6722        | 9.1764        |
| stack4        | Ridge            | 3        | 0.8604        | 17.6723        | 9.1765        |
| stack4        | RandomForest     | 3        | 0.8396        | 18.9435        | 9.8789        |
| stack4        | SVR              | 3        | 0.8574        | 17.8597        | 9.0159        |
| <b>stack4</b> | <b>MLP</b>       | <b>3</b> | <b>0.8620</b> | <b>17.5712</b> | <b>9.0898</b> |
| stack5        | GradientBoosting | 2        | 0.8446        | 18.6435        | 9.1995        |
| stack5        | LinearRegression | 2        | 0.8578        | 17.8360        | 9.1252        |
| stack5        | Ridge            | 2        | 0.8578        | 17.8361        | 9.1252        |
| stack5        | RandomForest     | 2        | 0.8332        | 19.3163        | 10.2404       |
| stack5        | SVR              | 2        | 0.8552        | 17.9992        | 9.0003        |
| <b>stack5</b> | <b>MLP</b>       | <b>2</b> | <b>0.8579</b> | <b>17.8333</b> | <b>9.1459</b> |

**Tabla A.11**

Resultados de las diferentes configuraciones de stacking con el conjunto que emplea IFN3 como explicativo de la variable en tC/ha.



Tabla B.1: Resumen de variables principales por entidad. Tabla extraída de [10].

| Variable                                       | Descripción                                          | Unidad                 | Tipo de dato      |
|------------------------------------------------|------------------------------------------------------|------------------------|-------------------|
| <b>parcelas</b>                                |                                                      |                        |                   |
| parcela_id                                     | Identificador único de parcela (IFN).                | —                      | Identificador     |
| latitud, longitud                              | Coordenadas geográficas (WGS84).                     | °                      | Geográfico        |
| coorx, coory                                   | Coordenadas UTM; huso especifica zona.               | m (UTM)                | Geográfico        |
| elevacion                                      | Cota sobre el nivel del mar (NASADEM).               | m                      | Númérico          |
| pendiente                                      | Inclinación del terreno.                             | °                      | Númérico          |
| orientacion                                    | Orientación del terreno (0–360).                     | °                      | Númérico          |
| presencia_id                                   | Presencia en IFN → cat_presencia.                    | —                      | Catégorico        |
| tipsuelo1_id,<br>tipsuelo2_id,<br>tipsuelo3_id | Tipos de suelo → cat_tipsuelo*.                      | —                      | Catégorico        |
| rocosidad_id                                   | Rocosisdad → cat_rocosidad.                          | —                      | Catégorico        |
| martonneidx_id                                 | Índice de aridez de Martonne → cat_martonneidx.      | —                      | Catégorico        |
| radio, superficie                              | Radio de parcela y superficie derivada.              | m; ha                  | Númérico          |
| <b>parcela_inventario</b>                      |                                                      |                        |                   |
| parcela_id, inventario_<br>id                  | Clave compuesta (parcela-inventario).                | —                      | Identificador     |
| ano                                            | Año de apeo.                                         | año                    | Númérico          |
| nivel1_id, nivel2_id                           | Morfoestructura. → cat_nivel*.                       | —                      | Catégorico        |
| textura_id                                     | Textura de suelo → cat_textura.                      | —                      | Catégorico        |
| merosiva_id                                    | Manifestaciones erosivas → cat_merosiva.             | —                      | Catégorico        |
| matorg_id                                      | Materia orgánica → cat_matorg.                       | —                      | Catégorico        |
| modcomb_id                                     | Modelo de combustible → cat_modcomb.                 | —                      | Catégorico        |
| disezp_id                                      | Distribución espacial → cat_disezp.                  | —                      | Catégorico        |
| comesp_id                                      | Composición específica → cat_comesp.                 | —                      | Catégorico        |
| fccarb, fcctot                                 | Fracción de cabida cubierta (árboles).               | %                      | Númérico          |
| <b>parcela_inventario_especie</b>              |                                                      |                        |                   |
| parcela_id, inventario_<br>id, especie_id      | Clave compuesta (parcela-inventario-especie).        | —                      | Identificador     |
| ocupa                                          | Grado de ocupación de la especie.                    | (0–10)                 | Númérico          |
| estado_id                                      | Estado de desarrollo. → cat_estado.                  | —                      | Catégorico        |
| fpmasa_id                                      | Forma principal de masa → cat_fpmasa.                | —                      | Catégorico        |
| tratmasa_id                                    | Tratamientos selvícolas → cat_tratmasa.              | —                      | Catégorico        |
| orgmasa1_id                                    | Origen de masa (IFN3/4) → cat_orgmasa1.              | —                      | Catégorico        |
| masa_id                                        | Clasificación de masa → cat_masa.                    | —                      | Catégorico        |
| origen_id                                      | Origen de la masa (IFN2) → cat_origen.               | —                      | Catégorico        |
| <b>parcela_inventario_especie_cd</b>           |                                                      |                        |                   |
| parcela_id, inventario_<br>id, especie_id      | Clave compuesta (parcela-inventario-especie-cd).     | —                      | Identificador     |
| cd_id                                          | Clase diamétrica (CD) reglamento IFN.                | cm                     | Númérico discreto |
| npies                                          | Número de pies.                                      | pies/ha                | Númérico          |
| abas                                           | Área basimétrica.                                    | m <sup>2</sup> /ha     | Númérico          |
| vcc, vsc, vle                                  | Volúmenes (con/sin corteza; leñas).                  | m <sup>3</sup> /ha     | Númérico          |
| iavc                                           | Incremento anual del volumen con corteza.            | m <sup>3</sup> /ha-año | Númérico          |
| ca, cr                                         | Carbono aéreo y radical.                             | t/ha                   | Númérico          |
| ht                                             | Altura media (modelo CatBoost).                      | m                      | Númérico          |
| carbono_bruto                                  | Carbono total estimado (alometrías).                 | t                      | Númérico          |
| <b>parcela_especie_arbol</b>                   |                                                      |                        |                   |
| parcela_id, especie_id                         | Clave compuesta (parcela-especie-árbol).             | —                      | Identificador     |
| arbol_id                                       | Identificador del árbol dentro de parcela y especie. | —                      | Entero            |
| rumbo                                          | Rumbo desde el centro de la parcela al árbol.        | grados<br>centesimales | Númérico          |
| distancia                                      | Distancia desde el centro de la parcela al árbol.    | m                      | Númérico          |
| cd                                             | Clase diamétrica (reglamento IFN).                   | cm                     | Númérico discreto |
| ht                                             | Altura total del árbol inventariado.                 | m                      | Númérico          |
| dn1, dn2                                       | Diámetros normales perpendiculares.                  | mm                     | Númérico          |
| abas                                           | Área basimétrica del pie medido.                     | m <sup>2</sup>         | Númérico          |
| iavc                                           | Incremento anual del volumen con corteza.            | dm <sup>3</sup> /año   | Númérico          |
| vcc, vsc, vle                                  | Volúmenes (con corteza, sin corteza, leñas).         | dm <sup>3</sup>        | Númérico          |
| ca, cr                                         | Carbono aéreo y radical del árbol.                   | t                      | Númérico          |
| <b>parcela_inventario_estacion</b>             |                                                      |                        |                   |
| parcela_id, inventario_<br>id, estacion_id     | Clave compuesta (agregado estacional).               | —                      | Identificador     |

Continúa en la siguiente página

| Variable                          | Descripción                                               | Unidad                                         | Tipo de dato  |
|-----------------------------------|-----------------------------------------------------------|------------------------------------------------|---------------|
| PR_*                              | Estadísticos de precipitación (mean, max, min, std, sum). | mm/(m <sup>2</sup> ·día),<br>mm/m <sup>2</sup> | Numérico      |
| T2M_*, SKT_*                      | Aire 2 m y temperatura superficial (mean, max, min, std). | °C                                             | Numérico      |
| STL1_*–STL4_*                     | Temperatura del suelo por niveles (mean, max, min, std).  | °C                                             | Numérico      |
| NDVI_*, EVI_*, NDII_*,<br>GNDVI_* | Índices de vegetación (max, mean, median, min, std).      | adimensional                                   | Numérico      |
| <b>especies y grupos</b>          |                                                           |                                                |               |
| especie_id                        | Identificador de especie IFN.                             | –                                              | Identificador |
| nombre, sinonimia                 | Denominación IFN y sinónimos.                             | –                                              | Texto         |
| tipo_especie                      | 0 = conífera; 1 = frondosa.                               | –                                              | Categorico    |
| grupo_id                          | Grupo funcional → grupos.                                 | –                                              | Identificador |
| grupos.nombregrupo                | Nombre del grupo.                                         | –                                              | Texto         |

**Tabla B.2**

Cardinalidad de las tablas de la base de datos.

| Tabla                         | Número de registros |
|-------------------------------|---------------------|
| parcelas                      | 52 298              |
| parcela_inventario            | 147 995             |
| parcela_inventario_especie    | 417 106             |
| parcela_inventario_especie_cd | 1 191 070           |
| parcela_especie_arbol         | 855 860             |
| parcela_inventario_estacion   | 731 172             |
| especies                      | 190                 |
| grupos                        | 33                  |

**B.2. Cardinalidad y completitud**

El volumen de entradas por tabla es: