

Predicción de Créditos de Carbono mediante Modelos de Inteligencia Artificial en Proyectos de Forestación y Reforestación

Tu Nombre

15 de octubre de 2025

Resumen

Este artículo presenta un modelo de inteligencia artificial diseñado para predecir la cantidad de carbono capturado en proyectos de forestación y reforestación, a partir de variables estructurales, climáticas y espectrales. La motivación principal parte del hecho de que, durante su desarrollo, los árboles capturan dióxido de carbono (CO_2) en su biomasa; por tanto, modelar el crecimiento forestal permite inferir la cantidad de carbono absorbido a lo largo del tiempo.

El modelo desarrollado responde a la siguiente pregunta: *Dado un cultivo forestal con características concretas de vegetación, clima y terreno, ¿cuánto CO_2 contendrá pasados unos años?* Esta capacidad de predicción permite, además, integrarlo en marcos de optimización forestal, abordando cuestiones clave como:

- ¿Qué especie plantar en un terreno específico para maximizar la captura de carbono?
- ¿En qué terreno plantar una especie determinada para alcanzar mayor rendimiento en fijación de carbono?

El modelo se entrena sobre datos reales multifuente: registros históricos del Inventario Forestal Nacional (IFN2, IFN3 e IFN4), variables climáticas derivadas de Copernicus y métricas espectrales procedentes de imágenes Landsat. Los datos están limitados al territorio español, dando lugar a un modelo adaptado a las características ambientales y orográficas del país. La estructura jerárquica del modelo por parcela, especie y clase diamétrica permite estimaciones a alta resolución espacial y taxonómica. Se implementaron y evaluaron distintos enfoques de aprendizaje supervisado, incluyendo modelos basados en árboles, redes neuronales y técnicas probabilísticas, seleccionando finalmente la opción con mejor rendimiento general.

Palabras clave: créditos de carbono, inteligencia artificial, forestación, reforestación, modelado predictivo, cambio climático.

1. INTRODUCCIÓN

El cambio climático es uno de los mayores desafíos globales de la actualidad, y su impacto negativo se refleja principalmente en el aumento de las concentraciones de dióxido de carbono (CO_2) en la atmósfera. Este aumento contribuye a fenómenos críticos como el deshielo de los polos, el incremento de fenómenos climáticos extremos y el deterioro de los ecosistemas naturales [3]. Los sumideros de carbono naturales, como los bosques, juegan un papel crucial en mitigar estos efectos, ya que mediante la fotosíntesis, los árboles capturan CO_2 y lo almacenan en su biomasa, contribuyendo significativamente a la reducción de las concentraciones de este gas en la atmósfera.

A lo largo de las últimas décadas, instrumentos internacionales como el *Protocolo de Kioto* [5] y la *Convención Marco de las Naciones Unidas sobre el Cambio Climático (CMNUCC)* [4] han establecido mecanismos para reducir las emisiones de gases de efecto invernadero. En este marco, las actividades de forestación y reforestación han sido identificadas como fundamentales para la captura de CO_2 . Los *créditos de carbono*, que representan la cantidad de CO_2 en toneladas evitada o secuestrada por actividades como la forestación y reforestación de bosques, se han convertido en una herramienta clave para cumplir con los compromisos internacionales de reducción de emisiones.

Sin embargo, para que un proyecto de forestación o reforestación sea considerado válido para la obtención de créditos de carbono, existen diversas limitaciones legales que deben cumplirse. Según los requisitos establecidos por el *Protocolo de Kioto* y las normativas nacionales, las siguientes condiciones deben ser satisfechas:

- **Intervención humana directa:** Los árboles deben provenir de actividades de intervención humana, como la plantación, siembra o fomento de semilleros naturales. Esto significa que los cultivos forestales naturales no son elegibles para la contabilización de carbono.
- **Período mínimo de 30 años:** Para que un proyecto sea válido, debe garantizarse que los árboles permanezcan en el terreno durante un período mínimo de tiempo, generalmente 30 años, lo que excluye la absorción de carbono de cultivos estacionales, cuyo carbono es liberado nuevamente al ser cosechados.
- **Superficie mínima de 1 hectárea:** El proyecto debe abarcar al menos 1 hectárea de terreno para ser considerado.
- **Fracción mínima de cabida cubierta del 20 %:** Para que un área sea considerada como bosque, debe cubrir al menos el 20 % del área con especies arbóreas.
- **Altura mínima de los árboles maduros de 3 metros:** Los árboles deben alcanzar una altura mínima de 3 metros en su madurez, aunque no es necesario que alcancen esta altura al inicio de la plantación.

Satisfacer estas limitaciones legales es imprescindible para la correcta generación de créditos de carbono, y han sido tomadas en cuenta a lo largo del desarrollo del modelo predictivo del proyecto *GreenWest*.

El proyecto *GreenWest* tiene como objetivo principal predecir la capacidad de absorción de CO_2 en los cultivos forestales españoles, mediante el uso de modelos de inteligencia artificial. Este enfoque innovador tiene el potencial de transformar la gestión de proyectos de forestación y reforestación, optimizando las prácticas de plantación y maximizando la cantidad de carbono que se puede capturar en estos ecosistemas.

Para lograrlo, el proyecto desarrollará un modelo predictivo que analizará datos sobre las características del terreno, las especies de árboles y las condiciones climáticas para estimar con precisión la cantidad de carbono que podría ser absorbido por un cultivo forestal en un periodo determinado. Este modelo no solo mejorará la comprensión del comportamiento de los sumideros de carbono, sino que también proporcionará herramientas útiles para la toma de decisiones estratégicas tanto en el ámbito empresarial como en el ambiental.

De esta forma, el proyecto *GreenWest* contribuye a la transición hacia una economía baja en carbono, alineándose con los objetivos globales de sostenibilidad establecidos en el marco de la CMNUCC y el *Protocolo de Kioto*, y promoviendo la creación de un mercado de créditos de carbono más eficiente y accesible para los actores económicos involucrados en la gestión de los recursos naturales.

2. OBJETIVOS Y JUSTIFICACIÓN

El presente estudio tiene como objetivo principal desarrollar un modelo de inteligencia artificial capaz de predecir con precisión la capacidad de absorción de dióxido de carbono (CO_2) en cultivos forestales españoles. Este modelo se basa en variables que describen la especie arbórea, las características del terreno y las condiciones climáticas. A partir de este objetivo general se derivan varias metas específicas, que en conjunto justifican la relevancia y aplicabilidad del proyecto.

Objetivos específicos

- **Desarrollar un modelo predictivo robusto:** Construir un modelo de aprendizaje automático que estime la cantidad de CO_2 que será capturado a lo largo del tiempo por un cultivo forestal, a partir de datos como especie, tipo de suelo, clase diamétrica, clima y otras variables relevantes.
- **Optimizar la captura de carbono:** Utilizar el modelo para identificar combinaciones óptimas de especies y terrenos que maximicen la fijación de carbono, contribuyendo a la planificación eficiente de proyectos de forestación y reforestación.
- **Asegurar la compatibilidad con las normativas internacionales:** Garantizar que las predicciones y salidas del modelo sean compatibles con los marcos normativos definidos por la *Convención Marco de las Naciones Unidas sobre el Cambio Climático* (CMNUCC) y el *Protocolo de Kioto*, cumpliendo así los criterios necesarios para la validación de créditos de carbono [cmnucc1992, kioto1997].
- **Analizar los factores determinantes del desarrollo forestal:** Estudiar la influencia de variables climáticas (como la temperatura y la precipitación) y edáficas (como el tipo de suelo o la pendiente) sobre el crecimiento forestal y su capacidad de capturar carbono.
- **Apoyar la toma de decisiones ambientales y empresariales:** Proporcionar una herramienta práctica y validada que permita a técnicos, gestores y empresas seleccionar las especies más adecuadas y planificar actuaciones de forestación con la mayor eficiencia posible en términos de secuestro de carbono.

Justificación

La necesidad de contar con herramientas predictivas para estimar la captura de CO_2 se ha intensificado ante el crecimiento del mercado voluntario de créditos de carbono, y las obligaciones adquiridas en el marco de la CMNUCC y el Protocolo de Kioto. Según estos acuerdos, cada país debe reportar sus emisiones y absorciones de gases de efecto invernadero, y puede utilizar actividades de forestación y reforestación como mecanismos de compensación [cmnucc1992, kioto1997].

Para que estos proyectos sean elegibles, deben cumplir criterios específicos como intervención humana directa, permanencia de al menos 30 años, cobertura mínima del 20 %, superficie mínima de una hectárea y una altura mínima de los árboles maduros de 3 metros. Estos criterios hacen imprescindible disponer de modelos que no solo estimen el carbono actual, sino que sean capaces de prever su evolución a futuro con base en condiciones iniciales y variables predictoras.

Este trabajo busca cubrir ese vacío mediante el uso de inteligencia artificial aplicada a datos reales y multifuente. Integrar su manejo dentro del sistema de créditos de carbono puede representar una importante oportunidad para la economía local y para la mitigación del cambio climático.

3. REVISIÓN DE LA LITERATURA

El secuestro de carbono en ecosistemas forestales ha cobrado una importancia creciente en la literatura científica, impulsada tanto por los compromisos internacionales en materia de cambio climático [5, 4] como por el auge de los mercados de créditos de carbono. Esto ha motivado el desarrollo de modelos orientados a cuantificar la biomasa forestal y estimar el contenido de carbono, aprovechando avances recientes en sensores remotos y técnicas de inteligencia artificial (IA).

Una de las estrategias más consolidadas es la estimación del carbono almacenado en un momento dado a partir de datos de teledetección. Goetz et al. (2009) [7] revisan el uso de imágenes satelitales (MODIS, Landsat) en modelos empíricos de biomasa aérea, destacando su eficacia a escala regional en zonas boreales. Este tipo de estimaciones suele realizarse mediante regresiones lineales o algoritmos de mínimos cuadrados generalizados, con coeficientes de determinación (R^2) típicamente entre 0.6 y 0.8 según la resolución de entrada y la heterogeneidad del ecosistema.

La aplicación de aprendizaje profundo ha permitido mejorar sustancialmente la precisión y resolución espacial de estas estimaciones. Por ejemplo, Zhang et al. (2022) [14] integran imágenes Sentinel-2 con redes neuronales convolucionales, alcanzando un R^2 de 0.84 para estimar el carbono en bosques subtropicales. Del mismo modo, Yang et al. (2023) [13] desarrollan el modelo *ForestCarbonAI*, entrenado con datos multiespectrales y LIDAR, con el que generan mapas de carbono forestal de alta resolución (10 m), reportando errores medios absolutos (MAE) inferiores a 3.5 tC/ha en zonas templadas. Otros trabajos recientes, como Reiersen et al. (2022) [10] o Dong et al. (2023) [6], también demuestran la eficacia del deep learning para estimaciones estáticas, aunque se centran en contextos tropicales y no consideran el componente temporal.

Frente a estos enfoques descriptivos, algunas iniciativas han intentado proyectar la evolución del carbono a futuro. En el ámbito nacional, el Ministerio para la Transición Ecológica (MITECO) ha implementado herramientas como la calculadora ex ante de absorciones [8], que permite obtener estimaciones simplificadas del carbono que puede fijarse en una plantación forestal en función de la especie y la zona agroclimática. No obstante, este instrumento se basa en coeficientes tabulados y no incorpora variables edafoclimáticas reales ni técnicas de modelización basadas en datos, lo que limita su precisión y capacidad de adaptación a contextos específicos.

En este escenario, el presente trabajo propone una metodología innovadora centrada en la predicción dinámica de carbono a largo plazo. A diferencia de los modelos anteriores, que estiman el carbono ya almacenado, este estudio se enfoca en anticipar cuánto carbono capturará un cultivo forestal en un horizonte temporal de 20 a 30 años. Para ello, se estudian diversos modelos de aprendizaje supervisado entrenados con datos históricos del Inventario Forestal Nacional (IFN2, IFN3 e IFN4), variables climáticas de Copernicus, características edáficas y métricas espectrales derivadas de imágenes Landsat [12, 9, 11]. Los detalles sobre la arquitectura del modelo, las variables utilizadas, los algoritmos implementados y las métricas de evaluación se desarrollan en la siguiente sección.

4. METODOLOGÍA

Esta sección describe el procedimiento seguido para entrenar y validar los modelos predictivos desarrollados. La metodología se fundamenta en la identificación de los factores que condicionan el crecimiento forestal y, por tanto, la capacidad de captura de carbono en un periodo determinado. Para ello, se ha trabajado sobre una base de datos específicamente estructurada para facilitar su uso en tareas de modelización ecológica y análisis predictivo.

El carbono absorbido por los árboles se acumula en su biomasa a lo largo del tiempo. La cantidad almacenada depende del tamaño de los individuos, el cual está influenciado por múltiples variables ambientales y estructurales. Así, la estimación del carbono capturado entre dos momentos se realiza midiendo el crecimiento de los árboles y aplicando factores de conversión, considerando que aproximadamente el 50 % de la biomasa seca corresponde a carbono [MITECO2020].

La base de datos empleada recoge características forestales, climáticas y espectrales a nivel de parcela, especie y clase diamétrica. Esta estructura relacional permite capturar la evolución del bosque entre inventarios y alimentar modelos capaces de predecir el contenido futuro de carbono a partir de observaciones pasadas. El conjunto de variables integradas satisface los principales requisitos ecológicos y estadísticos del problema, garantizando una representación suficiente del entorno forestal.

El crecimiento de las especies arbóreas está condicionado por factores edáficos, climáticos, topográficos y de competencia intraespecífica. Las condiciones meteorológicas, como la temperatura o la precipitación, afectan a la fotosíntesis y la disponibilidad hídrica. La orientación, la pendiente y la altitud modifican la radiación recibida y la capacidad de retención de agua. A su vez, la densidad de árboles por superficie determina el nivel de competencia por los recursos, lo cual varía según la especie y su tolerancia ecológica [2, 1].

A partir de estos principios, la base de datos recoge un conjunto diverso de variables que incluyen:

- **Características del terreno:** textura, tipo de suelo, orientación, pendiente y elevación, que condicionan el entorno físico del crecimiento.
- **Estructura y composición forestal:** cobertura total y arbórea, ocupación específica por especie, forma y estado de la masa, y distribución espacial del arbolado.
- **Variables dendrométricas:** número de pies, área basimétrica y volumen por clase diamétrica, como indicadores directos de biomasa y densidad forestal.
- **Condiciones climáticas:** medias y extremos de temperatura y precipitación por estación, obtenidas a partir de registros satelitales y reanálisis.
- **Índices de vegetación:** métricas como NDVI, NDII, GNDVI y EVI, que capturan el vigor, humedad y densidad de la cubierta vegetal (véase Sección ??).

4.1. Origen de los datos

La base de datos empleada en este trabajo integra información forestal, climática y espectral estructurada en torno a la parcela como unidad básica. Cada parcela se des-

cribe mediante sus coordenadas geográficas, características edáficas y su evolución a través de distintos inventarios (IFN2, IFN3, IFN4).

Los datos forestales incluyen información por especie y clase diamétrica, como número de pies, volumen con y sin corteza, área basimétrica, carbono aéreo, radical y total. Estos valores permiten caracterizar con precisión la estructura y crecimiento de la vegetación.

A cada parcela se asocian también estadísticas climáticas agregadas por estación e inventario: temperaturas (superficie, aire y subsuelo) y precipitaciones, resumidas mediante métricas como media, máxima, mínima y desviación típica.

Finalmente, se incorporan índices espectrales derivados de imágenes satelitales (NDVI, EVI, NDII, GNDVI), que permiten cuantificar propiedades biofísicas de la vegetación:

- **NDVI (Normalized Difference Vegetation Index):** estima la actividad fotosintética.
- **EVI (Enhanced Vegetation Index):** mejora la sensibilidad en zonas densamente vegetadas.
- **NDII (Normalized Difference Infrared Index):** refleja el contenido hídrico de la vegetación.
- **GNDVI (Green NDVI):** variante del NDVI basada en la banda verde, sensible al clorofila.

Estos datos se organizan en cinco tablas relacionales (`parcelas`, `parcela_inventario`, `parcela_inventario_especie`, `parcela_inventario_especie_cd` y `parcela_inventario_estacion`) representadas esquemáticamente en la Figura 4.1:

- `parcelas`: contiene la información básica de localización y características edáficas de cada parcela.
- `parcela_inventario`: registra la información general recolectada por parcela en cada inventario.
- `parcela_inventario_especie`: añade el componente específico de cada especie presente en cada inventario y parcela.
- `parcela_inventario_especie_cd`: desagrega los datos por clases diamétricas para cada especie.
- `parcela_inventario_estacion`: integra estadísticas climáticas y espectrales a nivel estacional.

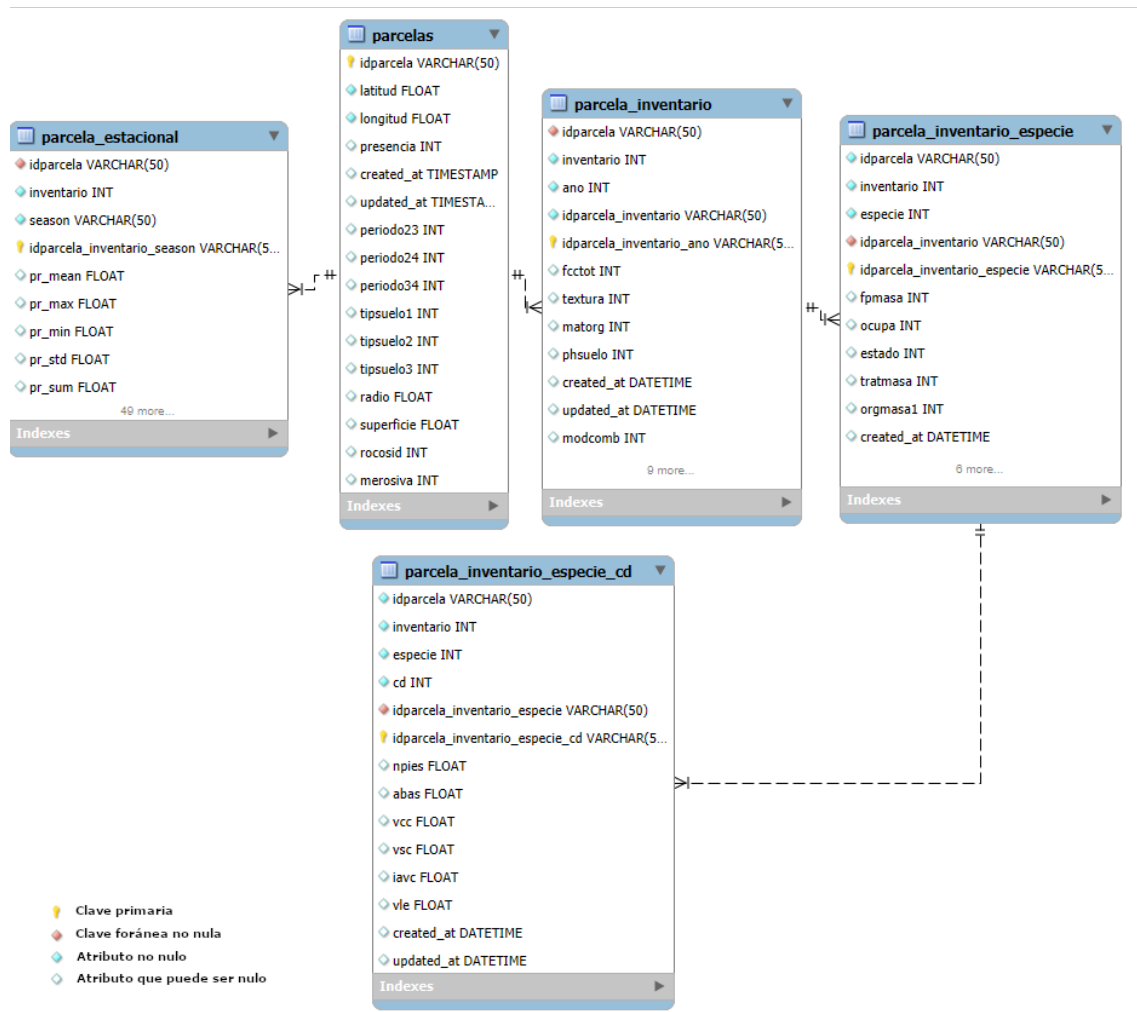


Figura 4.1: Estructura de la base de datos

parcelas: identificación, localización y caracterización básica de las parcelas forestales		
Variable	Tipo	Descripción
idparcela	varchar(50)	Identificador único de la parcela
latitud	float	Coordenada de latitud de la parcela
longitud	float	Coordenada de longitud de la parcela
created_at	timestamp	Fecha de creación del registro
updated_at	timestamp	Fecha de última modificación del registro
elevacion	?	?
orientacion	?	?
pendiente	?	?
periodo23	int	Años transcurridos entre el apeo de la parcela en el IFN2 y el apeo en el IFN3
periodo24	int	Años transcurridos entre el apeo de la parcela en el IFN2 y el apeo en el IFN4
periodo34	int	Años transcurridos entre el apeo de la parcela en el IFN3 y el apeo en el IFN3
tipsuelo1, tipsuelo2, tipsuelo3	int	Tipos de suelo identificados en la parcela (diferentes categorías o clases)
radio	float	Estimación del radio circular de la parcela (m)
superficie	float	Estimación de la superficie circular de la parcela (m^2)
rocosid	int	Grado de rocosidad del terreno
merosiva	int	Manifestaciones erosivas observadas en la parcela

Tabla 4.1: Estructura de la tabla parcelas. Contiene información general, geográfica y edáfica de cada unidad de muestreo en la base de datos. Se pueden consultar las claves de las variables en los anexos.

parcela_inventario: registros asociados a cada parcela para los inventarios IFN2, IFN3 e IFN4				
Campo	Tipo	Descripción	IFN2	IFN3/IFN4
idparcela_inventario_ano	varchar(50)	Identificador único por parcela y año	si	si
idparcela_inventario	varchar(50)	Identificador del inventario de la parcela	si	si
idparcela	varchar(50)	Identificador de la parcela	si	si
inventario	int	Número del inventario (2, 3 o 4)	si	si
ano	int	Año de apeo de la parcela e inventario	si	si
fcctot	int	Fracción de cabida cubierta total en la parcela e inventario	no	si
textura	int	Textura del suelo en la parcela e inventario	no	si
matorg	int	Contenido de materia orgánica en la parcela e inventario	no	si
phsuelo	int	pH del suelo en la parcela e inventario	no	si
modcomb	int	Modelo de combustible en la parcela e inventario	no	si
espcmue	int	Espesor de capa muerta en la parcela e inventario	no	si
fccarb	int	Fracción cubierta arbórea en la parcela e inventario	no	si
disesp	int	Distribución espacial de las especies en la parcela e inventario	si	si
comesp	int	Composición de las especies en la parcela e inventario	si	si
clasuelo	int	Clase del suelo (ifn2)	si	no
created_at	datetime	Fecha de creación del registro	si	si
updated_at	datetime	Fecha de última modificación del registro	si	si

Tabla 4.2: Estructura de la tabla `parcela_inventario`. Contiene los registros asociados a cada parcela en cada inventario (IFN2, IFN3, IFN4). Las columnas finales están destinadas a indicar la presencia o ausencia de cada variable en los inventarios IFN2 y IFN3/IFN4.

parcela_inventario_especie: información por especie forestal presente en cada parcela e inventario				
Campo	Tipo	Descripción	IFN2	IFN3/IFN4
idparcela	varchar(50)	Identificador de la parcela	si	si
inventario	int	Número del inventario (2, 3 o 4)	si	si
especie	int	Código de la especie forestal	si	si
idparcela_inventario	varchar(50)	Identificador del inventario de la parcela	si	si
idparcela_inventario_especie	varchar(50)	Identificador único por parcela, inventario y especie	si	si
ocupa	int	Ocupación de la especie en la parcela e inventario	si	si
estado	int	Estado general de la masa formada por la especie en la parcela e inventario	si	si
fpmasa	int	Forma principal de la masa formada por la especie en la parcela e inventario	no	si
tratmasa	int	Tipo de tratamiento aplicado a la masa formada por la especie en la parcela e inventario	no	si
orgmasa1	int	Origen principal de la masa formada por la especie en la parcela e inventario	no	si
masa	int	Tipo de masa forestal (ifn2)	si	no
origen	int	Origen de la masa formada por la especie en la parcela e inventario	si	no
ca	float	Carbono aéreo capturado por la especie en la parcela e inventario (t/ha)	si	si
cr	float	Carbono radical capturado por la especie en la parcela e inventario (t/ha)	si	si
c	float	Carbono total capturado por la especie en la parcela e inventario (t/ha)	si	si
created_at	datetime	Fecha de creación del registro	si	si
updated_at	datetime	Fecha de última modificación del registro	si	si

Tabla 4.3: Estructura de la tabla `parcela_inventario_especie`. Contiene información por especie forestal presente en cada parcela en cada inventario. Las columnas finales están destinadas a indicar la presencia o ausencia de cada variable en los inventarios IFN2 y IFN3/IFN4.

parcela_inventario_especie_cd: información por clase diamétrica para cada especie en cada parcela		
Campo	Tipo	Descripción
cd	int	Clase diamétrica del conjunto de árboles estudiado
idparcela_inventario_especie	varchar(50)	ID de especie por parcela e inventario
idparcela_inventario_especie_cd	varchar(50)	Identificador único del registro
npies	float	Número de pies de la clase diamétrica y especie en la parcela e inventario
abas	float	Área basal total del conjunto de árboles de la clase diamétrica y especie en la parcela e inventario
vcc	float	Volumen con corteza del conjunto de árboles de la clase diamétrica y especie en la parcela e inventario
vsc	float	Volumen sin corteza del conjunto de árboles de la clase diamétrica y especie en la parcela e inventario
iavc	float	Incremento anual del volumen con corteza del conjunto de árboles de la clase diamétrica y especie en la parcela e inventario
vle	float	Volumen de leñas del conjunto de árboles de la clase diamétrica y especie en la parcela e inventario
created_at	datetime	Fecha de creación del registro
updated_at	datetime	Fecha de última modificación del registro

Tabla 4.4: Estructura de la tabla `parcela_inventario_especie_cd`. Incluye información por clase diamétrica (CD) para cada especie presente en una parcela. Todas las variables se registran tanto para IFN2, como IFN3 e IFN.

parcela_inventario_estacion: métricas climáticas y espectrales por estación e inventario		
Campo	Tipo	Descripción
idparcela_inventario_season	varchar(50)	Identificador único por parcela e inventario por estación
idparcela	varchar(50)	Identificador de la parcela
inventario	int	Número del inventario (2, 3 o 4)
season	varchar(50)	Estación del año (e.g., invierno, primavera)
pr_mean, sum, max, min, std	float	Estadísticos de precipitación
t2m_mean, max, min, std	float	Estadísticos de temperatura del aire a 2m del suelo
skt_mean, max, min, std	float	Estadísticos de temperatura de la superficie del suelo
stl1-stl4_mean, max, min, std	float	Estadísticos de temperatura en 4 capas del subsuelo
evi-gndvi-ndii-ndvi_mean, max, min, std	float	Estadísticos de índices espectrales
created_at	datetime	Fecha de creación del registro
updated_at	datetime	Fecha de última modificación del registro

Tabla 4.5: Estructura de la tabla `parcela_inventario_estacion`. Contiene métricas climáticas y espectrales agregadas estacionalmente para cada parcela e inventario. Todas las variables se registran tanto para IFN2, como IFN3 e IFN.

4.2. Preparación y tratamiento de los datos

Para caracterizar el crecimiento de los árboles en los datos que se alimentan al modelo es necesario seleccionar dos inventarios distintos, permitiendo calcular la evolución de las variables forestales en el periodo transcurrido entre ambos. La variable `Periodo` cuantifica dicha diferencia en años. Dado que los inventarios IFN3 e IFN4 tienen una estructura similar y caracterizan mejor el terreno (más variables) la primera elección natural es emplear estos inventarios.

Filtrado de registros

Se descartan todas aquellas parcelas en las que el valor de carbono total (C) en el segundo inventario es inferior al del primero. Estos casos suelen deberse a episodios de deforestación, incendios u otras perturbaciones, y no representan un crecimiento forestal neto.

Cálculo y agregación de variables

Cada registro de entrada se genera a nivel de combinación parcela–especie, incorporando las variables correspondientes de la primera medición (IFN3 en la configuración empleada) y la variable objetivo *c* de la segunda medición (IFN4). Las variables de parcela y parcela_inventario se desdoblan para cada especie. Las entradas de la tabla parcela_inventario_especie_cd se agrupan por parcela y especie y se comprimen en una única entrada creando un conjunto de variables para cada clase diamétrica.

La Tabla 4.6 resume las variables empleadas como entrada al modelo, integradas desde las distintas tablas que conforman la base de datos relacional.

Resumen de Datos de Entrada del Modelo			
Variable	Tipo	Descripción	Anexo
Especie	int (CF)	Identificador de la especie arbórea en la parcela.	Anexo 10.21
Rocosid	int (CF)	Rociedad o presencia de rocas en el terreno de la parcela.	Anexo 10.2
TipSuelo1, TipSuelo2, TipSuelo3	int (CF)	Tipos de suelo identificados en la parcela.	Anexo 10.3
MErosiva	int (CF)	Manifestaciones erosivas observadas en el terreno.	Anexo 10.4
FccTot	int	Fracción de cabida cubierta total de la vegetación en la parcela.	–
FccArb	int	Fracción de cabida cubierta de la vegetación arbórea en la parcela.	–
DisEsp	int (CF)	Distribución espacial de las especies en la parcela.	Anexo 10.5
ComEsp	int (CF)	Composición específica de las especies en la parcela.	Anexo 10.6
Textura	int (CF)	Textura del suelo de la parcela (granulometría, por ejemplo, arcilloso, arenoso).	Anexo 10.7
MatOrg	int (CF)	Material orgánico en el suelo de la parcela.	Anexo 10.10
PhSuelo	int (CF)	pH del suelo de la parcela.	Anexo 10.2
EspCMue	int (CF)	Espesor de capa muerta en la parcela (material orgánico sobre el suelo).	Anexo 10.12
Ocupa	int	Grado de presencia de la especie en la parcela (de 0 a 10).	–
Estado	int (CF)	Fase de desarrollo de la especie arbórea en la parcela.	–
FPMasa	int (CF)	Forma principal de la masa forestal (coetánea, regular, etc.).	–
Superficie	float	Superficie de la parcela en hectáreas.	–
NPiesCD, ABasCD, VCCCD, VSCCD, IAVCCD, VLECD	float (dependiendo de la clase diamétrica CD)	Estos valores se repiten para cada clase diamétrica (CD) en cada especie y parcela, y describen el número de árboles, área basimétrica, volumen con y sin corteza, incremento anual del volumen con corteza y volumen de leña, respectivamente.	–
Periodo	int	Años transcurridos entre el primer inventario y el segundo empleados en el modelo.	–
Precipitaciones (varias estadísticas)	float	Estadísticas de las precipitaciones (suma, máx, mín, media, ...) para cada localización en el periodo de tiempo escogido (estación, año, mes, ...)	–
Temperaturas (varias estadísticas)	float	Estadísticas de las temperaturas (suma, máx, mín, media, ...) para cada localización en el periodo de tiempo (estación, año, mes, ...) y profundidades escogidos	–
Índices vegetales (NDVI, NDII, EVI, GNDVI)	float	Estadísticas de los índices vegetales (máx, mín, media, ...) para cada localización en el periodo de tiempo escogido (estación, año, mes, ...)	–
Elevación, orientación e inclinación	float	Elevación, orientación e inclinación de las coordenadas de cada parcela	–

Tabla 4.6: Resumen de las variables de entrada utilizadas en el modelo, correspondientes a las características de las parcelas e inventarios forestales. Las últimas variables (NPiesCD, ABasCD, VCCCD, VSCCD, IAVCCD, VLECD) se repiten tantas veces como valores de la clase diamétrica (CD) haya en la parcela.

Codificación y normalización

Las variables categóricas se codifican mediante *one-hot encoding*, generando variables binarias para cada clase. Esto facilita su uso en algoritmos de aprendizaje que no admiten directamente variables categóricas.

Las variables numéricas se escalan (normalización estándar o min-max, según el modelo) para asegurar que todas las magnitudes tengan el mismo orden de importancia durante el entrenamiento.

Partición del conjunto de datos

El conjunto total se divide aleatoriamente en dos subconjuntos:

- **Entrenamiento (80 %):** se utiliza para ajustar los modelos y seleccionar hiperparámetros.
- **Evaluación (20 %):** se reserva para validar la capacidad predictiva del modelo de forma independiente.

4.3. Definición del objetivo

El objetivo principal de este trabajo es predecir el **carbono total** (C) que será capturado por una parcela forestal en un periodo aproximado de 20 a 30 años. Esta variable se define como la suma del carbono aéreo (ca) y el carbono radical (cr almacenado en la biomasa de los árboles:

Como se ha introducido previamente, para que un proyecto sea elegible para la amortización de créditos de carbono, debe cumplir una serie de requisitos técnicos establecidos en los marcos regulatorios internacionales [MITECO2020, 2]. Entre los principales criterios se encuentran:

- **Intervención humana directa.**
- **Permanencia mínima de 30 años.**
- **Superficie mínima de 1 hectárea.**
- **Fracción mínima de cabida cubierta del 20 %.**
- **Altura mínima de los árboles de 3 metros en la madurez.**

De todos estos criterios, el único que presenta una limitación significativa en el entrenamiento del modelo es el periodo de 30 años. Esto se debe a que el modelo se entrena con las mediciones del IFN3 y el IFN4 y el intervalo de tiempo rara vez alcanza ese umbral. La distribución de los años transcurridos entre ambos inventarios se resume en la Tabla 4.7, donde se observa que el intervalo modal se sitúa entre 15 y 17 años.

Años entre IFN3 e IFN4	Porcentaje de parcelas (%)
16	21.13
17	17.48
15	16.65
11	14.69
12	7.00
9	6.81
13	5.26
14	3.54
6	3.27
18	2.41
10	1.48
< 0.01	< 0.01

Tabla 4.7: Distribución del número de años entre los inventarios IFN3 e IFN4 en las parcelas utilizadas.

Aunque los datos disponibles no alcanzan los 30 años requeridos por los estándares para proyectos de carbono, se considera que un modelo capaz de generalizar correctamente a horizontes de 20 años puede ser extrapolado con precaución a un escenario de 30 años, siempre que su desempeño se mantenga robusto a lo largo de distintos intervalos temporales.

Con el fin de evaluar esta capacidad de generalización, se ha implementado un esquema de **validación cruzada por grupos**, agrupando las observaciones según el número de años transcurridos entre inventarios. Esta estrategia permite comprobar si el modelo mantiene una buena capacidad predictiva al variar el horizonte temporal, lo que resulta fundamental para su aplicación en la estimación de proyectos de largo plazo como los que requieren los esquemas de compensación de carbono.

No se restringen los datos a cultivos artificiales por no disponer de bastantes registros. Cabe destacar que los cultivos forestales suelen caracterizarse por tener una misma especie dominante con estructura coetánea y densidades forestales estandarizadas, de forma que para los casos de interés en la predicción, tanto la superficie como la fracción de cabida cubierta mínima pueden ser ignoradas pues serán fácilmente generalizables (si se asumen unas características homogéneas de la parcela y una densidad forestal unificada).

4.4. Modelos evaluados

A continuación, se detalla el diseño general y las estrategias empleadas para la selección y optimización de modelos.

Entrenamiento y optimización

Se aplicó *RandomizedSearchCV*, una técnica de búsqueda aleatoria de hiperparámetros que evalúa distintas combinaciones utilizando validación cruzada. Este procedimiento permite optimizar el rendimiento de cada modelo sin incurrir en un coste computacional tan elevado como el de una búsqueda exhaustiva.

VALIDACIÓN CRUZADA POR GRUPOS. En algunas configuraciones probadas, se emplea la validación cruzada por grupos (*Group k-Fold Cross Validation*). Este método divide el área de estudio en k bloques, basados en una característica común de los datos, asegurando que los datos dentro de cada bloque estén relacionados. El modelo se entrena con $k - 1$ bloques y se valida con el bloque restante, repitiendo este proceso k veces.

Este enfoque es útil cuando los datos tienen agrupaciones naturales, como por ejemplo, diferentes parcelas o periodos de tiempo. Al mantener los datos relacionados en un mismo bloque, se evita la filtración de información entre los conjuntos de entrenamiento y validación, lo que permite una mejor evaluación de la capacidad de generalización del modelo. Así, se asegura que el modelo no se sobreajuste y sea robusto al ser evaluado en contextos no vistos previamente.

Modelos ensemble

Para mejorar la precisión y robustez, se emplearon diversos métodos de *ensemble learning*, que combinan múltiples modelos base (*base learners*) para generar una predicción agregada. Esta estrategia se inspira en la teoría de la sabiduría colectiva: la combinación de estimaciones independientes tiende a superar a cualquier estimador individual.

TÉCNICAS UTILIZADAS:

- **Voting y Averaging:** combinan modelos ya entrenados mediante votación mayoritaria o promedio.
- **Bagging y Boosting:** construyen modelos desde cero y los combinan. Bagging reduce la varianza al entrenar modelos en subconjuntos aleatorios; Boosting mejora el sesgo al entrenar secuencialmente, corrigiendo errores anteriores.
- **Stacking:** combina modelos optimizados usando un metamodelo que aprende a integrar sus predicciones.

Boosting y aprendizaje gradual

El *boosting* se basa en el aprendizaje secuencial, donde cada nuevo modelo intenta corregir los errores residuales del anterior. Esta técnica permite construir modelos fuertes a partir de modelos débiles, alcanzando gran precisión. Sin embargo, requiere una cuidadosa configuración de hiperparámetros para evitar el sobreajuste.

Entre las implementaciones destacadas se incluyen:

- **XGBoost:** modelo GBM que optimiza rendimiento con gradientes de primer y segundo orden, regularización L1/L2, manejo automático de valores faltantes, y técnicas de generalización como *shrinkage* y *column subsampling*.

- **LightGBM:** algoritmo eficiente para grandes volúmenes de datos, con crecimiento *leaf-wise* y soporte nativo para variables categóricas.
- **AdaBoost:** ajusta modelos simples secuencialmente, enfocando el aprendizaje en observaciones mal clasificadas.
- **CatBoost:** especializado en variables categóricas y robusto frente a datos ruidosos, usando codificación por orden aleatorio.
- **Gradient Boosting Decision Trees (GBDT):** construye árboles secuenciales ajustados a residuos, optimizando mediante descenso por gradiente.

Bagging

El *bagging* (Bootstrap Aggregating) entrena múltiples modelos independientes sobre subconjuntos de datos generados por muestreo con reemplazo. Las predicciones se combinan por promedio o votación. Esta técnica reduce la varianza y mejora la estabilidad de modelos inestables.

- **Random Forest:** combina árboles de decisión (CART) con selección aleatoria de características en cada división. Es escalable, robusto a datos faltantes, y menos propenso al sobreajuste.
- **Bagged Decision Trees (BaggedDT):** genera árboles sin poda entrenados en muestras bootstrap. Promedia sus predicciones para reducir la varianza.

Otros modelos utilizados

Además de los métodos ensemble, se evaluaron modelos representativos de distintos paradigmas de aprendizaje supervisado:

- **K-Nearest Neighbors (KNN):** modelo basado en instancia que predice a partir de los vecinos más cercanos. Sensible a la escala y a *outliers*.
- **Multi-Layer Perceptron (MLP):** red neuronal con una o más capas ocultas, capaz de modelar relaciones no lineales complejas.
- **Support Vector Regression (SVR):** modelo de márgenes para regresión, con soporte para kernels no lineales.
- **SVM con kernel:** modelo poderoso para clasificación y regresión no lineal, aunque costoso y sensible a hiperparámetros.
- **Bayesian Neural Network:** enfoque probabilístico que estima incertidumbre en las predicciones. Incluye variantes como la *Bayesian Ridge Regression*.
- **Naive Bayes:** clasificador probabilístico rápido y simple, útil en texto y alta dimensionalidad. Se evaluaron variantes:
 - *Gaussian Naive Bayes:* para datos continuos.
 - *Multinomial Naive Bayes:* para conteos y texto.
 - *Bernoulli Naive Bayes:* para variables binarias.

Comparación y justificación de modelos

La evaluación de múltiples modelos responde a la necesidad de identificar no solo el de mejor rendimiento, sino también el más adecuado según la naturaleza del problema y los datos disponibles. Se compararon algoritmos lineales, no lineales, basados en vecinos, redes neuronales, modelos probabilísticos y diferentes técnicas de *ensemble*. Vemos un resumen de los modelos aplicados en la tabla 4.8.

Modelo	Tipo / Técnica	Características destacadas	Observaciones
Random Forest	Bagging (Árboles)	Uso de bootstrap, selección aleatoria de atributos, reducción de varianza	Robusto y escalable; menor interpretabilidad
Bagged Decision Trees (BaggedDT)	Bagging	Árboles sin poda, entrenados en paralelo sobre muestras con reemplazo	Preciso pero costoso computacionalmente
XGBoost	Boosting (GBM)	Regularización L1/L2, manejo de valores faltantes, poda anticipada	Alto rendimiento, sensible a hiperparámetros
LightGBM	Boosting (Leaf-wise)	Crecimiento hoja a hoja, eficiente en grandes volúmenes	Rápido y preciso; riesgo de sobreajuste
AdaBoost	Boosting (Stumps)	Aumenta peso de errores, pondera modelos por precisión	Sencillo y efectivo con datos limpios
CatBoost	Boosting especializado	Codificación avanzada de variables categóricas, robustez a ruido	Ideal para datos heterogéneos
Gradient Boosting Decision Trees (GBDT)	Boosting	Árboles secuenciales ajustados a residuos	Buen rendimiento; mayor coste de entrenamiento
K-Nearest Neighbors (KNN)	Basado en instancia	No requiere entrenamiento, predice por proximidad	Sensible a escala y outliers
Multi-Layer Perceptron (MLP)	Red neuronal	Modela relaciones no lineales complejas	Requiere normalización y regularización
Support Vector Regression (SVR)	Kernel y márgenes	Predicción dentro de tolerancia ϵ , uso de kernels no lineales	Robusto; elevado coste computacional
SVM con kernel	SVM no lineal	Maximiza margen, admite distintos kernels (RBF, polinomial, etc.)	Alta precisión; sensible a hiperparámetros
Bayesian Neural Network / Ridge Regression	Probabilístico / Bayesiano	Predicción con incertidumbre, estimación automática de hiperparámetros	Útil para inferencia y regularización
Naive Bayes (Gaussian, Multinomial, Bernoulli)	Probabilístico	Asume independencia condicional, rápido y simple	Eficaz en texto y alta dimensionalidad

Tabla 4.8: Resumen de modelos de aprendizaje supervisado aplicados

4.5. Evaluación de los modelos

La evaluación del rendimiento de los modelos se realizó utilizando métricas específicas para tareas de predicción. En particular, se emplearon el *Root Mean Squared Error* (RMSE) y el coeficiente de determinación R^2 , ya que permiten cuantificar tanto la precisión absoluta de las predicciones como la proporción de la varianza explicada por el modelo.

Métricas utilizadas

- **RMSE (Root Mean Squared Error):** esta métrica representa la raíz cuadrada del error cuadrático medio entre los valores reales y las predicciones del modelo.

Está expresada en las mismas unidades que la variable objetivo, por lo que es fácilmente interpretable. Penaliza con mayor severidad los errores grandes, lo que la hace adecuada cuando se desea evitar desviaciones significativas en las predicciones. Un RMSE más bajo indica un mejor ajuste del modelo.

- **Coeficiente de determinación (R^2):** mide la proporción de la varianza total de la variable dependiente que es explicada por el modelo. Su valor oscila entre 0 y 1, donde valores cercanos a 1 indican un modelo que captura adecuadamente la estructura de los datos, y valores cercanos a 0 reflejan un modelo con escasa capacidad explicativa. En algunos casos, R^2 puede ser negativo si el modelo es peor que una predicción constante.

5. IMPLEMENTACIÓN DE LOS MODELOS

El desarrollo y evaluación de los modelos predictivos se realizó íntegramente en **Python** y el entorno de ejecución fue local, en un equipo con procesador Intel Core i7 y 32 GB de RAM, lo que permitió realizar experimentos de forma eficiente con un conjunto de datos de tamaño considerable (~80.000 muestras).

El preprocesamiento de datos se llevó a cabo mediante la librería `scikit-learn`, utilizando `Pipeline` y `ColumnTransformer` para combinar transformaciones numéricas y categóricas. En particular, las variables numéricas se imputaron con la mediana y se escalaron con `StandardScaler`, mientras que las variables categóricas se trataron mediante imputación por moda y codificación *one-hot*. La función objetivo a predecir fue el carbono total (CZ) acumulado en cada parcela.

Se implementaron y optimizaron diversos modelos de regresión supervisada, incluyendo:

- **Modelos basados en árboles:** `RandomForestRegressor`, `XGBoost`, `LightGBM`, `CatBoost`, `GradientBoosting`, `AdaBoost` y `Bagging`.
- **Modelos basados en instancias:** `KNeighborsRegressor`.
- **Modelos de redes neuronales:** `MLPRegressor`.
- **Modelos de soporte vectorial:** `SVR`.
- **Modelos probabilísticos:** `BayesianRidge`.

La optimización de hiperparámetros se realizó mediante `RandomizedSearchCV`, con validación cruzada de 5 particiones y búsqueda en espacios definidos manualmente para cada modelo. Los modelos fueron evaluados en términos de R^2 y **RMSE**, tanto en el conjunto de entrenamiento como en el de prueba.

Con el objetivo de mejorar el rendimiento predictivo, se evaluaron además varias configuraciones de `StackingRegressor`, combinando distintos subconjuntos de modelos base (previamente entrenados) con diversos meta-modelos (`LinearRegression`, `Ridge`, `GradientBoosting`, `SVR`, `MLP`, entre otros). Estas combinaciones permitieron comparar sinergias entre modelos complementarios.

El tiempo de entrenamiento varió según el modelo y la configuración de hiperparámetros. Gracias al uso de `n_jobs=-1` se aprovechó el paralelismo multinúcleo para acelerar la optimización.

6. RESULTADOS

Presentar los resultados obtenidos al aplicar el modelo a los datos de entrada. Incluir gráficos y tablas que ayuden a ilustrar el rendimiento del modelo.

7. DISCUSIÓN

Interpretar los resultados obtenidos, comparándolos con investigaciones previas. Discutir las limitaciones del modelo y las posibles áreas de mejora.

8. CONCLUSIONES

Recapitular las conclusiones más importantes del estudio. Resaltar la relevancia del modelo desarrollado y su aplicación en proyectos de forestación y reforestación.

9. RECOMENDACIONES PARA FUTURAS INVESTIGACIONES

Sugerir áreas que podrían beneficiarse de estudios adicionales o mejoras en la metodología.

AGRADECIMIENTOS

Agradecer a las personas o instituciones que hayan apoyado tu trabajo, como supervisores, financiadores, etc.

10. ANEXOS

10.1. Anexo: Códigos de provincias de España

Código	Provincia	Código	Provincia
01	Álava	27	Lugo
02	Albacete	28	Madrid
03	Alicante	29	Málaga
04	Almería	30	Murcia
05	Ávila	31	Navarra
06	Badajoz	32	Ourense
07	Baleares (Illes)	33	Asturias
08	Barcelona	34	Palencia
09	Burgos	35	Palmas (Las)
10	Cáceres	36	Pontevedra
11	Cádiz	37	Salamanca
12	Castellón	38	Santa Cruz de Tenerife
13	Ciudad Real	39	Cantabria
14	Córdoba	40	Segovia
15	Coruña (A)	41	Sevilla
16	Cuenca	42	Soria
17	Girona	43	Tarragona
18	Granada	44	Teruel
19	Guadalajara	45	Toledo
20	Guipúzcoa	46	Valencia
21	Huelva	47	Valladolid
22	Huesca	48	Vizcaya
23	Jaén	49	Zamora
24	León	50	Zaragoza
25	Lleida	51	Ceuta
26	La Rioja	52	Melilla

Tabla 10.1: Relación de códigos numéricos utilizados para las provincias españolas.

10.2. Anexo: Roccosidad

Se considerará el conjunto de la parcela clasificando la rocosidad según la siguiente codificación:

1. **Sin pedregosidad:** la superficie de la parcela está completamente cubierta de vegeta-

ción.

2. **Poco pedregoso:** cuando la superficie de la parcela cubierta por rocas coherentes es menor del 25 %.
3. **Pedregoso:** cuando la superficie rocosa está comprendida entre el 25 % y el 50 %.
4. **Muy pedregoso:** cuando la superficie rocosa se sitúa entre el 50 % y el 75 %.
5. **Roquedo:** cuando la superficie de rocas es mayor del 75 %. En este caso, no se tomará ningún dato adicional correspondiente a suelos.

10.3. Anexo: Tipo de Suelo

Se utilizará la siguiente codificación para el tipo de suelo, diferenciando tres variables:

Tipo de suelo (I): Presencia de sales, yesos o hidromorfía

1. **No se observan sales, yesos ni procesos de hidromorfía.**
2. **Suelo salino.** Si presenta al menos dos de las siguientes características:
 - Presencia de eflorescencias en la superficie o a distintas profundidades.
 - Existencia de plantas halófitas.
 - Zonas llanas o endorreicas con climas secos que provocan gran evaporación.
3. **Suelo yesífero.** Si presenta alguna de las siguientes características:
 - Presencia de materia yesífera en superficie o a distintas profundidades.
 - Existencia de plantas gipsófilas.
4. **Suelo hidromorfo.** Si el suelo presenta síntomas de hidromorfía acusada, cumpliendo al menos dos de las siguientes:
 - Zona encharcada permanente o casi permanentemente de forma natural.
 - Zona llana o endorreica con climas húmedos.
 - Grietas en verano si no hay encharcamiento.
 - Presencia de vegetación indicadora de hidromorfismo.

Identificándose las siguientes:

- Formaciones vegetales indicadoras de hidromorfía:
 - Ribereñas: *saucedas*, *mimbreras*, *alisedas*.
 - Brezales con *Erica ciliaris*, *Erica tetralix*.
 - Turberas arboladas (excepto Cornisa Cantábrica y Pirineos).
 - Turberas de montaña con *Sphagnum*, *Erica tetralix*.
 - Cervunales con *Nardus stricta*.
 - Carrizales y espadañares (*Phragmites*, *Tipha*, *Cladium*).
 - Juncuales (*Scirpus*, *Juncus*).
 - Pastizales con cárices (*Carex spp.*).
 - Marismas.
- Formaciones vegetales gipsófilas:
 - Aznallar: matorral de *Ononis tridentata*.
 - Tomillares gipsófilos con:
 - *Lepidium subulatum*
 - *Gypsophila spp.*
 - *Matthiola fruticulosa*
- Formaciones vegetales indicadoras de suelos salinos:
 - Salicorniales: matas leñosas crasas (*Salicornia*, *Arthrocnemum*, *Halozyllon*).
 - Bosques halófitos del género *Tamarix*.
 - Saladar o sosar: predominio de *Suaeda vera*.

- Saladar blanco: predominio de *Atriplex halimus*.

Tipo de suelo (II y III): Composición del suelo (calizo o silíceo)

1. **Suelo calizo.** Más del 50 % de la vertical del perfil da efervescencia con ácido clorhídrico.
 - **Moderadamente básico:** pH en superficie ≥ 8.5 .
 - **Fuertemente básico:** pH en superficie > 8.5 .
2. **Suelo silíceo.** Menos del 50 % de la vertical del perfil da efervescencia.
 - **Moderadamente ácido:** pH ≥ 5.5 .
 - **Fuertemente ácido:** pH < 5.5 .

10.4. Anexo: Manifestaciones Erosivas

Se observará la parcela y sus alrededores hasta una distancia de 60 metros desde el centro, y se codificará la existencia de manifestaciones erosivas según la siguiente clave:

1. **No hay ninguna manifestación.**
2. **Cuellos de raíces al descubierto:** los cuellos de las raíces están visibles, con acumulación de residuos aguas arriba de los tallos y obstáculos, así como abundancia superficial de piedras.
3. **Presencia de regueros:** canales paralelos de erosión con una profundidad máxima de un palmo (aproximadamente 20 cm).
4. **Cárcavas y barrancos en V:** erosión lineal más profunda que los regueros, con forma de “V”.
5. **Cárcavas y barrancos en U:** erosión avanzada con formas suavizadas y amplias en “U”.
6. **Deslizamientos del terreno:** desplazamientos de masas de tierra, ladera o materiales del suelo.

10.5. Anexo: Distribución Espacial

La disposición de la vegetación en el espacio se clasificará según la siguiente codificación:

1. **Uniforme.** Cuando el estrato arbóreo presenta continuidad en el espacio.
2. **Diseminada en bosquetes aislados.** Cuando la masa arbórea se encuentra dividida en porciones que tienen una superficie inferior a 0,5 ha.
3. **Diseminada en individuos aislados.** Cuando se trata de dehesas.
9. **Otras o no se sabe.** En caso diferente a los anteriores o si se desconoce el dato exacto.

10.6. Anexo: Composición Específica

En función de las especies presentes:

1. **Masas homogéneas o puras.** Masas monoespecíficas con una única especie arbórea. La normativa española precisa que una masa es monoespecífica o pura cuando al menos el 90 % de los pies pertenecen a la misma especie.
2. **Masas heterogéneas o mezcladas pie a pie.** Masas de diferentes especies que se juntan o bien se entremezclan por golpes o grupos, siempre que tengan una altura similar.
3. **Masas heterogéneas o mezcladas con subpiso.** Las dos o más especies mezcladas, cuando alcancen el estado adulto y la estabilidad, presentarán alturas diferentes.
9. **Otras o no se sabe.** En caso diferente a los anteriores o desconocer el dato exacto.

10.7. Anexo: Textura del Suelo

Se clasificará en función de la siguiente codificación:

1. **Suelo arenoso.** Si los cilindros se deshacen sin apenas formarse.
2. **Suelo franco.** Es posible hacer cilindros gruesos pero no delgados.
3. **Suelo arcilloso.** Se consiguen cilindros de unos 5 mm de diámetro.

10.8. Anexo: Nivel de usos del suelo

1. **Monte.** Toda superficie en la que vegetan especies arbóreas, arbustivas, de matorral o herbáceas, ya sea espontáneamente o procedan de siembra o plantación, siempre que no sean características de cultivo agrícola o fueran objeto del mismo.
2. **Agrícola.** Territorio o ecosistema poblado con siembras o plantaciones de herbáceas y/o leñosas, anuales o plurianuales que se laborean con una fuerte intervención humana, puede estar poblado por especies forestales de fruto (flor, hojas o en el futuro biomasa) siempre que la intervención humana sea importante. Incluye las dehesas, montes huecos o montes adehesados de base cultivo, siempre que la fracción de cabida cubierta de los árboles sea inferior al 5 %.
3. **Artificial.** Territorio o ecosistemas dominado por edificios, parques urbanos (aunque estén poblados de árboles), viveros fuera de los montes (aunque sean de especies forestales), carreteras (salvo las vías de servicio de los montes) u otras construcciones humanas que tengan superficies continuas.
4. **Humedal.** Lo constituyen las lagunas, charcas, zonas húmedas, marismas y corrientes discontinuas de agua en las que, al menos durante 6 meses del año, esté presente dicho líquido.
5. **Agua.** Es la parte de la tierra constituida por ríos, lagos, embalses, canales o estanques con superficies continuas de más de 0.26 ha y con agua prácticamente todo el año.

10.9. Anexo: Nivel morfoestructural

Para el nivel de usos del suelo Monte se definirán los siguientes niveles morfoestructurales.

1. **Monte arbolado.** Territorio o ecosistema con especies forestales arbóreas como manifestación vegetal de estructura vertical dominante y con una fracción de cabida cubierta igual o superior al 20%; incluye dehesas con base cultivo o pastizal con labores siempre que la fracción arbolada supere el 20%, y excluye terrenos con fuerte intervención humana para obtener frutos, hojas, flores o varas.
2. **Monte arbolado ralo.** Terreno de uso forestal con especies arbóreas forestales dominantes y fracción de cabida cubierta entre el 10 % y 20 % (incluido el 10 %, excluido el 20 %); también aplica a terrenos con matorral o pastizal natural como dominantes, pero con presencia importante de árboles forestales, incluyendo dehesas de base de cultivo.
3. **Monte temporalmente desarbolado.** Terreno que fue monte arbolado recientemente y que casi con seguridad volverá a estar cubierto de árboles en un futuro próximo.
4. **Monte desarbolado.** Terreno con matorral y/o pastizal natural o débil intervención humana como cobertura dominante, con fracción de cabida cubierta por árboles forestales inferior al 5 %.
5. **Monte sin vegetación superior.** Terreno de uso forestal que no está poblado por vegetales superiores debido a condiciones actuales de suelo, clima o topografía, aunque podría estarlo en otras circunstancias.

6. **Árboles fuera del monte.** Incluye riberas arboladas no estructuradas con los montes, bosquetes de menos de 2.500 m², alineaciones de especies arbóreas o arbustivas de menos de 25 m de anchura, y árboles sueltos en terreno forestal.
7. **Monte arbolado disperso.** Terreno forestal con especies arbóreas dominantes y fracción de cabida cubierta entre el 5 % y el 10 % (incluido el 5 %, excluido el 10 %); también terrenos con matorral o pastizal como cobertura dominante pero con presencia significativa de árboles forestales, incluyendo dehesas de base cultivo.

10.10. Anexo: Contenido en Materia Orgánica

Según la siguiente clasificación:

1. **Suelo muy húmifero.** Cuando a 15 cm la pureza es menor de 4, o cuando la capa de broza sea de espesor mayor de 5 cm y a 15 cm de profundidad la pureza sea menor de 6.
2. **Suelo moderadamente húmifero.** Cuando a 15 cm la pureza sea menor de 6 con capa de broza nula o de escaso espesor, o cuando dicha capa tenga espesor mayor de 5 cm y a 15 cm de profundidad la pureza sea igual o mayor de 6.
3. **Suelo poco húmifero.** En los restantes casos.

10.11. Anexo: Reacción del Suelo (pH)

En función del pH, el suelo se clasifica según la siguiente codificación:

Valores del pH de la solución del suelo	Clasificación del suelo	Codificación
1	Suelo extremadamente ácido	1
2	Suelo muy fuertemente ácido	2
3 – 4	Suelo fuertemente ácido	3
5 – 6	Suelo moderadamente ácido	4
7	Suelo neutro	5
8	Suelo moderadamente básico	6
9	Suelo fuertemente básico	7
10	Suelo extremadamente básico	8

Tabla 10.2: Clasificación del suelo según el pH de la solución del suelo.

10.12. Anexo: Espesor de la Capa Muerta, Césped, Musgo y Líquenes

Se anotará con la siguiente codificación:

- Espesor menor de 0,5 cm **00**
- Espesor de 0,5 a 1,4 cm **01**
- Espesor de 1,5 a 2,4 cm **02**
- Espesor de 2,5 a 3,4 cm **03**
- *Y así sucesivamente.*

Si en la parcela hay zonas con diferentes espesores de capa muerta, se anotará el valor medio estimado.

10.13. Anexo: Espesor de la Capa Muerta, Césped, Musgo y Líquenes

Se determinará la clase de combustible que es más probable que propague el fuego si hubiese un incendio en la zona, hasta un máximo de 60m: pasto, matorral, hojarasca de bosque o desechos o restos de corta. Se determinará el modelo de combustible a partir de la siguiente clave:

GRUPO	MOD. COMBUS-TIBLE	DESCRIPCIÓN DEL MODELO
PASTOS	1	Pasto fino, seco y bajo, que recubre completamente el suelo. Puede aparecer algunas plantas leñosas dispersas ocupando menos de 1/3 de la superficie.
	2	Pasto fino, seco y bajo, que recubre completamente el suelo. Las plantas leñosas dispersas cubren de 1/3 a 2/3 de la superficie; pero la propagación del fuego se realiza por el pasto.
	3	Pasto grueso, denso, seco y alto (>1 m). Puede haber algunas plantas leñosas dispersas. Los campos de cereales son representativos de este modelo.
MATORRAL	4	Matorral o plantación joven muy densa; de más de 2 m de altura; con ramas muertas en su interior. Propagación del fuego por las copas de las plantas.
	5	Matorral disperso, denso y verde, de menos de 1 m de altura. Propagación del fuego por la hojarasca, el pasto, las ramillas y el matorral.
	6	Parecido al modelo 5, pero con especies más inflamables, de mayor talla, pudiéndose encontrar ramas gruesas en el suelo. Propagación del fuego con vientos moderados a fuertes.
	7	Matorral de especies muy inflamables; de 0.5 a 2 m de altura, situado como sotobosque en masas de coníferas.
HOJARASCA BAJO ARBOLADO	8	Bosque denso, sin matorral. Propagación del fuego por la hojarasca muy compacta, formada por acículas cortas (5 cm o menos) o por hojas planas no muy grandes.
	9	Parecido al modelo 8, pero con hojarasca menos compacta, formada por acículas largas y rígidas (P. pinaster) o follaje de frondosas de hoja grande, caducas (castaño o robles).
	10	Bosque con gran cantidad de leña y árboles caídos, como consecuencia de vendavales, plagas intensas, etc.
RESTOS DE CORTA Y OPERACIONES SELVÍCOLAS	11	Bosque claro y fuertemente aclarado. Restos de poda o aclareo ligeros (diámetro <7.5 cm).
	12	Predominio de los restos sobre el arbolado. La hojarasca y el matorral presente ayudarán a la propagación del fuego.
	13	Grandes acumulaciones de restos gruesos y pesados, cubriendo todo el suelo.

Tabla 10.3: Descripción de los modelos de combustible del Inventario Forestal Nacional, clasificados por grupo funcional.

10.14. Anexo: Categoría de Desarrollo y Densidad

La categoría de desarrollo se identifica en función de la altura y el diámetro de los pies de las diferentes especies. Cuando el 85 % de los ejemplares pertenecen a una determinada categoría, se considerarán todos dentro de la misma.

1. Pies con altura inferior a 30 cm.
2. Pies con altura comprendida entre 30 y 130 cm.
3. Pies con altura superior a 130 cm y diámetro normal menor de 2,5 cm.

4. Pies con altura superior a 130 cm y diámetro normal comprendido entre 2,5 y 7,5 cm. Corresponde a los pies menores del IFN-2.

La densidad se cuantifica según la categoría de desarrollo:

Para las categorías 1, 2 y 3 (radio de parcela = 5 m):

1. **Escasa:** De 1 a 4 pies en la parcela.
2. **Normal:** De 5 a 15 pies en la parcela.
3. **Abundante:** Más de 15 pies en la parcela.

Para la categoría 4:

- Se cuenta el número exacto de pies por especie en la subparcela de 5 m de radio. Se registra en la casilla "N" y se calcula aproximadamente la altura media total de cada grupo.

Nota: Si aparecen más de 40 pies en las categorías 1, 2 o 3, el conteo puede ser estimado. Los pies menores muertos no se contabilizan. Para brotes de cepa, cada uno se considera como una planta.

Anexo: Tipo de Regeneración

Se identifica el origen de los pies con la siguiente clave:

1. **Siembra o semilla.**
2. **Plantación.**
3. **Brote de cepa o raíz.**
4. **Desconocido.**
5. **Dudoso.**
6. **Mixto.**

Anexo: Estado de las Poblaciones (IFN3 e IFN4)

Se determinará las fases de desarrollo de las *poblaciones* codificándose de la siguiente forma:

1. **Repoblado.** Conjunto de pies que desde el estrato herbáceo llega hasta el subarborescente y los pies inician la tangencia de copas.
2. **Monte bravo.** Comprende desde el estrato y clase de edad anterior hasta el momento en que por efecto del crecimiento, los pies empiezan a perder las ramas inferiores; es decir que en esta clase de edad, las ramas se encuentran a lo largo de todo el fuste.
3. **Latizal.** Comprende desde la clase anterior hasta que los pies tienen 20 cm de diámetro normal; es decir, el diámetro de su fuste, medido a la altura de 1,30 m del suelo.
4. **Fustal.** Se caracteriza esta clase de edad, porque sus pies tienen diámetros normales superiores a 20 cm.

10.15. Anexo: Forma Principal de Masa (IFN3 e IFN4)

1. **Coetánea.** Cuando al menos el 90 % de sus pies tienen la misma edad individual. Ejemplo típico: las repoblaciones.

2. **Regular.** Cuando al menos el 90 % de sus pies pertenecen a la misma clase artificial de edad o misma clase diamétrica en su defecto.
3. **Semirregular.** Cuando al menos el 90 % de sus pies pertenecen a dos clases artificiales de edad cíclicamente contiguas o dos clases diamétricas contiguas en su defecto.
4. **Irregular.** Cuando no se cumplen las condiciones anteriores, es decir, cuando en cualquier parte de la masa existen pies más o menos mezclados, de todas las clases de edad que tiene la masa o de varias clases diamétricas en su defecto.

10.16. Anexo: Tratamiento de la Masa (IFN3 e IFN4)

1. **Monte alto.** Cuando todos los pies proceden de semilla.
2. **Monte medio.** Cuando coexisten pies de la misma especie, unos procedentes de semilla (brinzales) y otros de brote (chirpiales).
3. **Monte bajo.** Cuando todos los pies proceden de brote de cepa o de raíz.

10.17. Anexo: Origen de la Masa (IFN3 e IFN4)

1. **Natural.** Bosque desarrollado espontáneamente, sin intervención humana directa.
2. **Artificial.** Plantado intencionadamente por el ser humano.
3. **Naturalizado.** Bosque originalmente plantado pero que ha evolucionado hacia una estructura más similar a un bosque natural.

10.18. Anexo: MASA (IFN2)

- 1. Artificial.
- 2. Natural regular.
- 3. Natural irregular.
- 9. Dudoso.

10.19. Anexo: Estado (IFN2)

- 0. Repoblado.
- 1. Monte bravo-repoblado.
- 2. Monte bravo.
- 3. Latizal-monte bravo.
- 4. Latizal.
- 5. Fustal-latizal.
- 6. Fustal.

10.20. Anexo: Origen (IFN2)

1. Siembra o semilla.
2. Plantación.
3. Brote de cepa o raíz.
4. Desconocido.
5. Dudoso.
6. Mixto.

10.21. Anexo: Código de las especies

Tabla 10.4: Relación de especies con claves IFN3 e IFN4. Esta tabla se construye cruzando información de las tablas CambioEspecie de la base de datos de Sig de IFN3 e IFN4 y la tabla ESPECIES ARBÓREAS Y ARBUSTIVAS incluida tanto en el documentador de Sig del IFN4 como en el documentador de Sig del IFN3.

Clave	Nombre especie	Sinonimias	Claves IFN3	Claves IFN4
1	Heberdenia bahamensis	Heberdenia excelsa		
2	Amelanchier ovalis	Guillomo		
3	Frangula alnus	Rhamnus frangula		
4	Rhamnus alaternus	Aladierno		
5	Euonymus europaeus			
6	Myrtus communis			
7	Acacia spp.		[7, 92, 207, 307]	[7, 90, 99, 207, 307]
8	Phillyrea latifolia			[8, 90, 99, 999]
9	Cornus sanguinea			
10	Sin asignar	Sin asignar		
11	Ailanthus altissima	Ailanthus glandulosa		
12	Malus sylvestris			[12, 70, 99, 999]
13	Celtis australis			[13, 99]
14	Taxus baccata			[14, 19, 21, 22]
15	Crataegus spp.		[4, 15, 95, 215, 295, 315]	[15, 99, 215]
16	Pyrus spp.			[16, 70, 99, 395, 999]
17	Cedrus atlantica			
18	Chamaecyparis lawsoniana		[18, 319]	[18, 19, 28, 34, 35]
19	Otras coníferas		[14, 17, 18, 19, 21, 22, 23, 24, 25, 26, 28, 31, 32, 33, 34, 35, 36, 37, 38, 39, 217, 219, 235, 236, 237, 238, 239, 319, 336, 337, 436, 926]	

Clave	Nombre especie	Sinonimias	Claves IFN3	Claves IFN4
20	Pinos			[20, 26]
21	<i>Pinus sylvestris</i>		[14, 17, 19, 21, 22, 25, 31, 32, 36, 37, 237]	[19, 21, 26]
22	<i>Pinus uncinata</i>	<i>Pinus montana</i> , <i>Pinus mugo</i>	[14, 22]	[19, 21, 22]
23	<i>Pinus pinea</i>		[14, 17, 20, 23, 24, 25, 26, 36, 37, 38, 39, 219, 236, 237, 317, 319, 436]	[19, 23, 24, 26]
24	<i>Pinus halepensis</i>		[17, 20, 21, 23, 24, 25, 26, 36, 37, 38, 39, 236, 237, 336]	[19, 24]
25	<i>Pinus nigra</i>	<i>Pinus laricio</i> , <i>Pinus clusiana</i>	[14, 17, 19, 21, 25, 26, 28, 34]	[19, 21, 25, 26]
26	<i>Pinus pinaster</i>	<i>Pinus maritima</i>	[14, 17, 18, 21, 23, 24, 25, 26, 27, 28, 29, 36, 37, 38, 39, 217, 219, 236, 237, 239, 317, 319, 336, 436, 826, 926]	[19, 24, 26, 28, 526, 626, 726, 826, 926]
27	<i>Pinus canariensis</i>		[27]	
28	<i>Pinus radiata</i>	<i>Pinus insignis</i>	[17, 19, 21, 23, 24, 25, 26, 27, 28, 33, 34, 35, 36, 236, 337, 436]	[19, 28]
29	Otros pinos			
30	Mezcla de coníferas	Coníferas, excepto pinos		
31	<i>Abies alba</i>	<i>Abies pectinata</i>	[31, 33]	[19, 31]
32	<i>Abies pinsapo</i>			
33	<i>Picea abies</i>	<i>Picea excelsa</i>		[19, 28, 33, 34, 35]
34	<i>Pseudotsuga menziesii</i>	<i>Pseudotsuga douglasii</i>	[19, 28, 31, 33, 34, 35]	[19, 28, 34, 35]
35	<i>Larix</i> spp.		[33, 34, 35, 235, 335]	[19, 35]

Clave	Nombre especie	Sinonimias	Claves IFN3	Claves IFN4
36	Cupressus sempervirens			[19, 21, 24, 26, 36]
37	Juniperus communis			[21, 37, 237]
38	Juniperus thurifera		[37, 38, 39, 237, 239]	[26, 38]
39	Juniperus phoenicea		[36, 37, 38, 39, 237]	[26, 39, 237]
40	Quercus		[41, 42, 43, 44, 45, 46, 48, 243]	[40, 41, 44, 999]
41	Quercus robur	Quercus pedunculata	[41, 42, 43, 44, 46, 48, 243]	[41, 999]
42	Quercus petraea	Quercus sessiliflora	[41, 42, 48]	[41, 42, 43, 999]
43	Quercus pyrenaica	Quercus toza	[41, 42, 43, 44, 45, 46, 47, 48, 243, 746, 846, 946]	[43, 99, 999]
44	Quercus faginea	Quercus lusitanica var. faginea	[40, 42, 43, 44, 46, 47, 49, 243, 946]	[43, 44, 45, 999]
45	Quercus ilex ssp. ballota	Quercus rotundifolia	[2, 4, 40, 44, 45, 46, 47, 49, 66, 67, 68, 75, 91, 93, 95, 215, 269, 276, 295, 378, 476]	[41, 45, 99, 245]
46	Quercus suber		[43, 44, 45, 46, 47, 144, 846, 946]	[43, 45, 46, 99, 646, 746, 846, 946]
47	Quercus canariensis	Quercus lusitanica var. baetica	[44, 47, 49]	[47]
48	Quercus rubra	Quercus borealis		[41, 42, 43, 48, 99, 999]
49	Otros quercus			[44, 999]
50	Mezcla de árboles de ribera	Árboles ripícolas	[2, 3, 4, 6, 7, 9, 51, 52, 53, 54, 55, 56, 57, 58, 59, 61, 62, 63, 69, 74, 79, 92, 94, 97, 253, 255, 256, 257, 258, 297, 299, 307, 355, 357, 392, 457, 657, 757, 857, 957]	

Clave	Nombre especie	Sinonimias	Claves IFN3	Claves IFN4
51	Populus alba		[51, 53, 55, 57, 58, 62, 255, 257, 258, 357, 657, 757, 857, 957]	[50, 51, 58, 99, 258, 999]
52	Populus tremula			[50, 51, 52, 58, 99, 258, 999]
53	Tamarix spp.			[50, 51, 53, 999]
54	Alnus glutinosa		[7, 52, 53, 54]	[54, 99, 999]
55	Fraxinus angustifolia		[55, 255]	[50, 55, 99, 255, 999]
56	Ulmus minor	Ulmus campestris		[50, 56, 70, 99, 256, 999]
57	Salix spp.		[3, 4, 7, 9, 51, 52, 53, 54, 55, 57, 58, 79, 92, 97, 207, 257, 258, 297, 357, 457, 557, 657, 757, 857, 957]	[57, 99, 357, 657, 999]
58	Populus nigra			[50, 58, 99, 258, 999]
59	Otros árboles ripícolas			[54, 59]
60	Mezcla de eucaliptos	Eucaliptos	[61, 62, 63, 64]	
61	Eucalyptus globulus		[60, 61, 62, 63, 64, 264, 364]	[61, 99]
62	Eucalyptus camaldulensis	Eucalyptus rostrata	[60, 61, 62, 63, 64, 364]	[61, 62, 64, 99, 264]
63	Otros eucaliptos			[61, 63, 64, 99, 264]
64	Eucalyptus nitens		[62, 64]	[61, 64, 99, 264]
65	Ilex aquifolium			[65, 99, 999]
66	Olea europaea	Olea oleaster	[66, 67]	[45, 66, 99, 999]
67	Ceratonía siliqua			[45, 67]

Clave	Nombre especie	Sinonimias	Claves IFN3	Claves IFN4
68	Arbutus unedo		[2, 3, 4, 5, 8, 9, 12, 13, 15, 16, 56, 65, 66, 68, 72, 76, 93, 95, 97, 99, 215, 256, 275, 276, 295, 297, 299, 315, 369, 376, 395, 399, 578]	[45, 68, 99, 999]
69	Phoenix spp.			
70	Mezcla de frondosas de gran porte	Frondosas de gran porte (H.t. >10 m)	[11, 12, 13, 16, 42, 56, 66, 71, 72, 73, 74, 75, 76, 77, 78, 256, 273, 275, 276, 277, 278, 356, 373, 376, 377, 378, 476, 478, 576, 578, 676, 678]	
71	Fagus sylvatica			[71, 99]
72	Castanea sativa	Castanea vesca	[11, 16, 42, 46, 66, 72, 75, 92, 99, 299, 399, 858]	[72, 99, 999]
73	Betula spp.		[73, 273, 373]	[73, 99, 273, 999]
74	Corylus avellana			[74, 99, 999]
75	Juglans regia			[70, 75, 99, 256, 999]
76	Acer campestre		[76, 276, 376, 476, 576, 676]	[70, 76, 99, 576, 999]
77	Tilia spp.		[77, 277, 377]	[70, 77, 377, 999]
78	Sorbus spp.		[12, 16, 78, 278, 378, 478, 578, 678]	[50, 70, 78, 99, 278, 378, 999]
79	Platanus hispanica	Platanus hybrida		[50, 58, 79, 99, 258, 999]
80	Laurisilva			
81	Myrica faya			
82	Ilex canariensis		[82, 282]	
83	Erica arborea		[83, 283]	

Clave	Nombre especie	Sinonimias	Claves IFN3	Claves IFN4
84	Persea indica			
85	Sideroxylon marmulano			
86	Picconia excelsa	Notelaea excelsa		
87	Ocotea phoetens			
88	Apollonias barbujana	Apollonias canariensis		
89	Otras laurisilvas		[1, 86, 87, 88, 89, 95, 389, 489, 495]	
90	Mezcla de pequeñas frondosas	Frondosas de pequeño porte (H.t. \leq 10 m)	[1, 2, 3, 4, 5, 6, 7, 8, 9, 11, 12, 13, 15, 16, 65, 66, 67, 68, 69, 74, 78, 91, 92, 93, 94, 95, 96, 97, 99, 215, 269, 278, 295, 297, 299, 307, 369, 378, 395, 399, 478, 495, 499, 578, 595, 599]	
91	Buxus sempervirens			
92	Robinia pseudoacacia	Acacia robinia	[7, 56, 61, 64, 72, 73, 75, 77, 79, 92, 256, 273, 373, 377]	[50, 58, 92, 99, 207, 258, 999]
93	Pistacia terebinthus	Cornicabra		
94	Laurus nobilis	Laurel		[90, 94, 99]
95	Prunus spp.	Prunus	[4, 5, 9, 95, 295]	[45, 90, 95, 99, 395, 999]
96	Rhus coriaria	Zumaque		[50, 96]
97	Sambucus nigra	Saúco negro		[50, 90, 97, 99, 657, 999]
98	Carpinus betulus	Carpe	[43, 44, 46, 47, 51, 53, 54, 55, 57, 58, 60, 62, 63, 64, 72, 75, 144, 257, 357, 657]	[71, 273]

Clave	Nombre especie	Sinonimias	Claves IFN3	Claves IFN4
99	Otras frondosas	Otras frondosas	[1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 51, 52, 53, 54, 55, 56, 57, 58, 59, 60, 61, 62, 64, 65, 66, 67, 68, 69, 71, 72, 73, 74, 75, 76, 77, 78, 79, 82, 83, 84, 86, 87, 88, 89, 91, 92, 93, 94, 95, 96, 97, 99, 207, 215, 217, 243, 253, 255, 256, 257, 258, 264, 269, 273, 275, 276, 277, 278, 279, 291, 292, 293, 295, 297, 299, 307, 315, 355, 356, 357, 364, 369, 373, 375, 376, 377, 378, 389, 392, 395, 399, 415, 457, 469, 476, 478, 489, 492, 495, 499, 557, 569, 576, 578, 592, 595, 657, 676, 678, 757, 778, 857, 858, 957]	[90, 99, 999]
207	Acacia melanoxydon	Acacia melanoxydon		[7, 99, 207, 307]
215	Crataegus monogyna	Majuelo	[15, 215, 315, 415]	[15, 45, 99, 215]
217	Cedrus deodara	Cedrus deodara		[17, 26, 217]
219	Tetraclinis articulata	Tetraclinis articulata		[26, 219]
235	Larix decidua	Alerce común		[19, 34, 35, 235]
236	Cupressus arizonica	Ciprés arizónica		[19, 24, 26, 36, 236]
237	Juniperus oxycedrus	Enebro oxicedro	[36, 37, 38, 39, 236, 237, 239]	[21, 26, 39, 237]

Clave	Nombre especie	Sinonimias	Claves IFN3	Claves IFN4
238	Juniperus turbinata	Sabina canaria	[238, 337]	[38]
239	Juniperus sabina	Sabina rastrera		
243	Quercus pubescens	Quercus pubescens, Quercus humilis	[42, 43, 44, 47, 243]	[43, 243, 999]
244	Quercus lusitanica	Quercus fruticosa, Queji- gueta		
245				[45, 245]
253	Tamarix canariensis	Tarajal		[53]
255	Fraxinus excelsior	Fresno excelsior	[55, 255, 355]	[50, 55, 99, 255, 999]
256	Ulmus glabra	Ulmus montana		[70, 99, 256, 999]
257	Salix alba	Sauce blanco		[57, 99, 257, 357, 657, 999]
258	Populus x canadensis	Populus x euroamerica- na	[58, 258]	[50, 58, 99, 258, 999]
264	Eucalyptus viminalis	Eucalipto viminalis		[64, 99, 264]
268	Arbutus canariensis	Madroño canario		[68]
273	Betula alba	Betula verrucosa, Abedul pubescens		[73, 99, 273, 999]
275	Juglans nigra	Nogal		[256, 275]
276	Acer monspessulanum	Arce de Montpellier		[45, 70, 276, 999]
277	Tilia cordata	Tilo cordata		[277, 377, 999]
278	Sorbus aria	Mostajo		[70, 99, 278, 378, 999]
279	Platanus orientalis	Plátano oriental		[58, 999]
281				
282	Ilex platyphylla	Naranjero		[82]
283	Erica scoparia	Tejo, brezo arbóreo esco- pario		[83]
289	Pleiomeris canariensis	Delfino		[89]
291	Buxus balearica	Boj de Baleares		

Clave	Nombre especie	Sinonimias	Claves IFN3	Claves IFN4
292	Sophora japonica	Acacia sofora		
293	Pistacia atlantica	Cornicabra canaria		[93]
294	Laurus azorica	Laurel canario	[68, 268, 294]	[94]
295	Prunus spinosa	Espino negro		
297	Sambucus racemosa	Saúco racemosa		
299	Ficus carica	Higuera		[90, 99, 299, 999]
307	Acacia dealbata	Acacia dealbata		[7, 90, 99, 207, 307]
315	Crataegus laevigata	Espino majuelo		[215, 315]
317	Cedrus libani	Cedrus libani		
319	Thuja spp.	Thuja		[19, 28, 319]
335	Larix leptolepis	Larix kaempferi, Alerce leptolepis		
336	Cupressus lusitanica	Ciprés lambertiana		[26, 36]
337	Juniperus cedrus	Enebro canario		[37]
344				
355	Fraxinus ornus	Fresno orno		
356	Ulmus pumila	Olmo pumilo		[70, 356]
357	Salix atrocinerea	Bardaguera		[57, 99, 357, 657, 999]
364	Eucalyptus gomphocephalus	Eucalipto gonfo	[62, 63, 64, 264, 364]	[64, 264, 364]
369	Chamaerops humilis	Palmito		
373	Betula pendula	Betula hispanica, Abedul péndula		[73, 273, 373, 999]
376	Acer negundo	Negundo fraxinifolia, Arce negundo		[76, 99, 276, 376, 999]
377	Tilia platyphyllos	Tilo común		[70, 377, 999]
378	Sorbus aucuparia	Serbal de cazadores		[45, 50, 70, 78, 99, 278, 378, 999]
389	Rhamnus glandulosa	Sanguino		[89]

Clave	Nombre especie	Sinonimias	Claves IFN3	Claves IFN4
392	Gleditsia triacanthos	Acacia gleditsia		
395	Prunus avium	Cerezo silvestre		[90, 95, 99, 395, 999]
399	Morus spp.	Morera		
415	Crataegus laciniata	Majoleto		
435	Larix x eurolepis	Alerce híbrido		
436	Cupressus macrocarpa	Ciprés americano		[26, 36, 436]
455				
456				[70, 456]
457	Salix babylonica	Sauce llorón		[57, 357, 457, 657]
464				[61, 64, 99, 464]
469	Phoenix canariensis	Palmera	[469, 569]	[69]
476	Acer opalus	Arce ópalus		[45, 70, 276, 476, 576, 999]
478	Sorbus domestica	Serbal común		[278, 478, 999]
489	Visnea mocanera	Mocan		[89]
495	Prunus lusitanica	Loro, hija		[95, 495]
499	Morus alba	Morera		
515	Crataegus azarolus	Espino		
557	Salix cantabrica	Sauce cantábrico		[357, 557]
569	Dracaena draco	Drago		
576	Acer pseudoplatanus	Arce seudoplátano		[70, 76, 99, 276, 576, 999]
578	Sorbus torminalis	Serbal torminal		[70, 278, 378, 578, 999]
595	Prunus padus	Prunus		
599	Morus nigra	Morera		
657	Salix caprea	Sauce cabruno		[57, 99, 357, 657, 999]
676	Acer platanoides	Arce platanoide		[70, 99, 276, 576, 676, 999]
678	Sorbus latifolia	Serbal de hoja ancha		[278, 678, 999]
757	Salix elaeagnos	Sarga		[99, 357, 657, 757, 999]

Clave	Nombre especie	Sinonimias	Claves IFN3	Claves IFN4
776				
778	Sorbus chamaemespilus	Serbal chame		
857	Salix fragilis	Mimbre		[357, 657, 857, 999]
858	Salix canariensis	Sauce canario		[58]
917	Cedrus spp.	Cedrus spp.		
936	Cupressus spp.	Cipres		
937	Juniperus spp.	Enebros y sabinas	[36, 37, 38, 39, 236, 237, 239, 336]	
955	Fraxinus spp.	Fresnos	[55, 255]	
956	Ulmus spp.	Olmo		
957	Salix purpurea	Mimbrera		[99, 357, 657, 957, 999]
975	Juglans spp.			
976	Acer spp.	Arces	[71, 72, 76, 276, 278, 307, 378, 476, 478, 492, 576, 578, 676]	
997	Sambucus spp.			

REFERENCIAS

- [1] T. Buchholz. “Artificial Intelligence and Machine Learning in Environmental Science”. En: *Environmental Modelling Software* 56 (2014), págs. 60-69.
- [2] Intergovernmental Panel on Climate Change. *2006 IPCC Guidelines for National Greenhouse Gas Inventories*. Geneva, Switzerland: IPCC, 2006.
- [3] Intergovernmental Panel on Climate Change. *Climate Change 2007: Mitigation of Climate Change*. Cambridge, UK: Cambridge University Press, 2007.
- [4] United Nations Framework Convention on Climate Change. *Paris Agreement*. <https://unfccc.int/process-and-meetings/the-paris-agreement/the-paris-agreement>. Accessed: 2023-07-09. 2015.
- [5] United Nations Framework Convention on Climate Change. *The Kyoto Protocol*. <https://unfccc.int/resource/docs/convkp/kpeng.pdf>. Accessed: 2023-07-09. 1997.
- [6] W. Dong et al. “Forest aboveground biomass estimation using GEDI and earth observation data through attention-based deep learning”. En: *arXiv preprint* (2023). arXiv: 2311.03067 [cs.CV]. URL: <https://arxiv.org/abs/2311.03067>.
- [7] Scott J. Goetz y Ralph O. Dubayah. “Remote sensing of forest structure, carbon, and biodiversity”. En: *Remote Sensing of Environment* 113 (2009), S1-S3. DOI: 10.1016/j.rse.2008.12.002.
- [8] Ministerio para la Transición Ecológica y el Reto Demográfico. *INSTRUCCIONES DE USO DE LA CALCULADORA DE ABSORCIONES DE CO2 EX ANTE DE LAS ESPECIES FORESTALES ARBÓREAS ESPAÑOLAS*. Accedido: 2025-07-16. 2023. URL: https://www.miteco.gob.es/content/dam/miteco/es/cambio-climatico/temas/mitigacion-politicas-y-medidas/instruccionescalculadoraabexante_tcm30-485629.pdf.
- [9] J. Muñoz Sabater. *ERA5-Land hourly data from 1950 to present*. Copernicus Climate Change Service (C3S) Climate Data Store (CDS). DOI: 10.24381/cds.e2161bac (Accessed on 07-07-2025). 2019. URL: <https://cds.climate.copernicus.eu/cdsapp#!/dataset/reanalysis-era5-land?tab=overview>.
- [10] G. Reiersen et al. “ReforesTree: A dataset for estimating tropical forest carbon stock with deep learning and aerial imagery”. En: *arXiv preprint* (2022). arXiv: 2201.11192 [cs.LG]. URL: <https://arxiv.org/abs/2201.11192>.
- [11] Ministerio para la Transición Ecológica (MITECO). *Guía para la estimación de absorciones de dióxido de carbono*. Inf. téc. Accedido: 2025-07-10. Ministerio para la Transición Ecológica y el Reto Demográfico, 2021. URL: <https://www.miteco.gob.es>.
- [12] USGS. *USGS Landsat 5 Level 2, Collection 2, Tier 1*. Accedido: 8 de julio de 2025. 2025. URL: https://developers.google.com/earth-engine/datasets/catalog/LANDSAT_LT05_C02_T1_L2.
- [13] Tao Yang et al. “ForestCarbonAI: A deep learning model for high-resolution forest carbon mapping from remote sensing data”. En: *Remote Sensing* 15.3 (2023), pág. 765. DOI: 10.3390/rs15030765.

- [14] Huan Zhang et al. "Carbon stock estimation in forest ecosystems using deep learning and Sentinel-2 imagery". En: *Ecological Indicators* 143 (2022), pág. 109372. DOI: 10.1016/j.ecolind.2022.109372.