

Estimación basada en datos del stock de carbono forestal en España: un enfoque de aprendizaje automático utilizando datos del Inventario Forestal Nacional

Jaime Gabriel-Vegas^{a,*}, Maider Araceli Urbón Jiménez^a, Ana de Luis Reboredo^a, Belén Pérez Lancho^a and Ana-Belén Gil-González^a

^aGrupo B1, Equipo de investigación BISITE, Universidad de Salamanca, Facultad de Ciencias, Salamanca, España

ARTICLE INFO

Keywords:

créditos de carbono
inteligencia artificial
forestación
reforestación
modelado predictivo
cambio climático

Resumen

Los bosques son sumideros naturales de CO_2 y su gestión está adquiriendo un papel central en los marcos normativos de compensación de emisiones y en los mercados voluntarios de créditos de carbono. Sin embargo, la estimación fiable del carbono que una parcela forestal acumulará en un horizonte temporal determinado sigue siendo un reto metodológico, especialmente cuando se requiere proyección temporal a partir de condiciones iniciales. Este trabajo presenta *GreenWest*, un sistema de aprendizaje automático para predecir el carbono forestal futuro en España a partir de datos de estructura de masa, suelo, clima y teledetección. Los datos proceden del Inventario Forestal Nacional (IFN2 e IFN3), reanálisis climático ERA5-Land, índices espectrales Landsat y variables edáficas y topográficas, integrados en una base de datos relacional multifuente. Mediante selección manual de variables se redujo un conjunto inicial de 445 predictores a 44 variables ecológicamente relevantes, modelando dos variables objetivo: la densidad de carbono (c_4 , $tC\ ha^{-1}$) y el carbono total de la parcela ($carbono_bruto_4$, tC). Se entrenaron y compararon modelos de *gradient boosting* (LightGBM, XGBoost, CatBoost) y redes neuronales como modelos base, así como ensambles de *stacking* con distintas configuraciones de metamodelo. Los mejores resultados se obtienen con LightGBM y CatBoost (R^2 entre 0.72 para IFN2/ c_4 y 0.90 para IFN3/ $carbono_bruto_4$), con mejoras sistemáticas aunque modestas al incorporar *stacking*. Los modelos entrenados con el conjunto combinado IFN2+IFN3 superan a los locales en el IFN2, mientras que para el IFN3 ocurre lo contrario. El análisis SHAP revela que la densidad de pies, la especie y la fracción de cabida cubierta son los predictores dominantes, con el índice GNDVI estival como principal predictor espectral; los valores SHAP son coherentes con el conocimiento ecológico, validando la capacidad del modelo para aprender relaciones con significado real.

1. Introducción

El cambio climático es uno de los mayores desafíos globales y su manifestación más directa es el aumento de las concentraciones atmosféricas de dióxido de carbono (CO_2), con impactos sobre la criosfera, los extremos climáticos y los ecosistemas [1]. Los bosques actúan como sumideros naturales al fijar CO_2 en biomasa vía fotosíntesis, por lo que su gestión resulta clave para la mitigación.

A lo largo de las últimas décadas, instrumentos internacionales como la *Convención Marco de las Naciones Unidas sobre el Cambio Climático (CMNUCC)* y el *Protocolo de Kioto* [2, 3] han establecido los marcos regulatorios para reducir las emisiones de gases de efecto invernadero mediante mecanismos basados en el mercado. En este contexto surgen los *créditos de carbono*, unidades que representan la cantidad de dióxido de carbono (CO_2), habitualmente una tonelada, que ha sido capturada o cuya emisión ha sido evitada a través de proyectos certificados de mitigación.

Entre las actividades elegibles, la forestación y reforestación destacan por su capacidad de actuar como sumideros naturales de carbono, fijando CO_2 en la biomasa y el suelo.

No obstante, para que estas actuaciones puedan generar créditos de carbono válidos, deben cumplir una serie de criterios técnicos y legales establecidos en la normativa internacional sobre cambio climático y en su aplicación a nivel nacional. En particular, estos requisitos derivan de las reglas de contabilidad de sumideros forestales adoptadas en el marco de la Convención Marco de las Naciones Unidas sobre el Cambio Climático (CMNUCC) y del Protocolo de Kioto, concretadas en los Acuerdos de Marrakech, así como de la definición nacional de bosque comunicada por España para estos fines [4, 5]. Dichos criterios incluyen:

- **Intervención humana directa:** Los árboles deben ser el resultado de actividades de intervención humana directa, tales como la plantación, la siembra o el fomento deliberado de la regeneración natural. Este requisito se deriva de la definición de *forestación* y *reforestación* establecida en el Protocolo de Kioto, que excluye expresamente la regeneración natural no inducida por la acción humana [4].
- **Período mínimo de permanencia:** El proyecto debe garantizar la permanencia del sumidero de carbono durante un período prolongado (habitualmente del orden de 20-30 años), con el fin de asegurar que el carbono capturado no sea liberado de forma prematura a la atmósfera. Este criterio responde al principio de permanencia exigido en la contabilidad de sumideros

*Autor de correspondencia

✉ JaimeGabrielVegas@usal.es (J. Gabriel-Vegas); murbon001@usal.es (M.A.U. Jiménez); adeluis@usal.es (A.d.L. Reboredo); lancho@usal.es (B.P. Lancho); abg@usal.es (A. Gil-González)
ORCID(s):

forestales del régimen LULUCF y en los marcos de aplicación nacionales y europeos, lo que excluye cultivos de corta rotación cuyo carbono se libera tras la cosecha [4, 6].

- **Superficie mínima de 1 hectárea:** El área objeto del proyecto debe tener una extensión mínima de 1 hectárea. Este umbral procede de la definición nacional de bosque adoptada por España dentro de los rangos permitidos por los Acuerdos de Marrakech (0,05–1 ha), comunicada oficialmente a la CMNUCC [5].
- **Fracción mínima de cabida cubierta del 20 %:** Para que un terreno sea considerado bosque, la cobertura de copas de las especies arbóreas debe alcanzar al menos el 20 % de la superficie. Este valor corresponde a la elección nacional realizada por España para la definición de bosque a efectos de contabilidad climática [5].
- **Altura mínima de los árboles maduros de 3 metros:** Las especies arbóreas deben ser capaces de alcanzar una altura mínima de 3 metros en su madurez. No es necesario que dicha altura se alcance en el momento inicial del proyecto, pero sí que sea alcanzable bajo condiciones normales de crecimiento. Este criterio forma igualmente parte de la definición nacional de bosque comunicada por España conforme a las decisiones adoptadas bajo la CMNUCC [5].

Este trabajo trata de obtener un modelo de inteligencia artificial para estimar la cantidad de carbono que capturará un cultivo forestal en España a partir de variables de vegetación, clima y terreno en un período de 20 a 30 años. Este enfoque innovador tiene el potencial de transformar la gestión de proyectos de forestación y reforestación, optimizando las prácticas de plantación y maximizando la cantidad de carbono que se puede capturar en estos ecosistemas.

La pregunta operativa es: *dadas las características iniciales de una plantación, ¿cuánto CO_2 contendrá tras t años?, donde t es un número natural*. Para responderla, se integran datos del **Inventario Forestal Nacional** (IFN2–IFN4, MITECO) [7], reanálisis **ERA5-Land** [8] e **índices espectrales Landsat** (Collection 2, L2) [9] en una base de datos relacional jerárquica descrita en un trabajo complementario [10].

Este modelo no solo mejorará la comprensión del comportamiento de los sumideros de carbono, sino que también proporcionará herramientas útiles para la toma de decisiones estratégicas tanto en el ámbito empresarial como en el ambiental. De esta forma, el proyecto *GreenWest* contribuye a la transición hacia una economía baja en carbono, alineándose con los objetivos globales de sostenibilidad establecidos en el marco de la CMNUCC y el *Protocolo de Kioto*, y promoviendo la creación de un mercado de créditos de carbono más eficiente y accesible para los actores económicos involucrados en la gestión de los recursos naturales.

2. Objetivos y Justificación

El presente estudio tiene como objetivo principal desarrollar un modelo de inteligencia artificial capaz de predecir

con precisión la capacidad de absorción de dióxido de carbono (CO_2) en cultivos forestales españoles. Este modelo se basa en variables que describen la especie arbórea, las características del terreno y las condiciones climáticas y meteorológicas. A partir de este objetivo general se derivan varias metas específicas, que en conjunto justifican la relevancia y aplicabilidad del proyecto.

2.1. Objetivos específicos

Los principales objetivos se listan a continuación:

- **Desarrollar un modelo predictivo robusto:** Construir un modelo de aprendizaje automático que estime la cantidad de CO_2 que será capturado a lo largo del tiempo por un cultivo forestal, a partir de datos como especie, tipo de suelo, clase diamétrica, clima y otras variables relevantes.
- **Asegurar la compatibilidad con las normativas internacionales:** Garantizar que las predicciones y salidas del modelo sean compatibles con los marcos normativos definidos por la *Convención Marco de las Naciones Unidas sobre el Cambio Climático* (CMNUCC) y el *Protocolo de Kioto*, cumpliendo así los criterios necesarios para la validación de créditos de carbono.
- **Analizar los factores determinantes del desarrollo forestal:** Estudiar la influencia de variables climáticas (como la temperatura y la precipitación) y edáficas (como el tipo de suelo o la pendiente) sobre el crecimiento forestal y su capacidad de capturar carbono.
- **Apoyar la toma de decisiones ambientales y empresariales:** Proporcionar una herramienta práctica y validada que permita a técnicos, gestores y empresas seleccionar las especies más adecuadas y planificar actuaciones de forestación con la mayor eficiencia posible en términos de secuestro de carbono.

2.2. Justificación

La necesidad de contar con herramientas predictivas para estimar la captura de CO_2 se ha intensificado ante el crecimiento del mercado voluntario de créditos de carbono, y las obligaciones adquiridas: cada país debe reportar sus emisiones y absorciones de gases de efecto invernadero, y puede utilizar actividades de (re)forestación como mecanismos de compensación.

Para que estos proyectos sean elegibles, deben cumplir criterios específicos, los cuales hacen imprescindible disponer de modelos que no solo estimen el carbono actual, sino que sean capaces de prever su evolución a futuro con base en condiciones iniciales y variables predictoras.

Este trabajo busca cubrir ese vacío mediante el uso de inteligencia artificial aplicada a datos reales y multifuente. Integrar su manejo dentro del sistema de créditos de carbono puede representar una importante oportunidad para la economía local, lo que podría ser un apoyo para aquellas regiones donde la depoblación y el reto demográfico son un problema serio, y para la mitigación del cambio climático.

3. Revisión de la Literatura

La cuantificación precisa de los recursos forestales ha constituido, históricamente, una de las piedras angulares de la gestión territorial y la economía de recursos naturales. La evolución de las técnicas para medir el crecimiento de los árboles y, más recientemente, para estimar su biomasa y contenido de carbono, refleja una transformación profunda en las prioridades de la sociedad humana respecto a los ecosistemas forestales. Lo que comenzó en la Europa medieval como una necesidad logística para asegurar el suministro de leña y madera estructural ante el temor de la escasez, se ha metamorfoseado en el siglo XXI en una disciplina científica de alta tecnología impulsada por la urgencia climática global [11].

La dendrometría tradicional, pilar de los inventarios forestales modernos, se fundamenta en el uso de relaciones alométricas para estimar la biomasa (w) y otros parámetros ecológicos a partir de variables de fácil medición en campo, principalmente el diámetro a la altura del pecho (D) y la altura total (H). Estas estimaciones suelen articularse mediante ecuaciones de la forma:

$$w = aD^b H^c \quad (3.1)$$

o sus transformaciones logarítmicas:

$$\lg w = a + b \lg D + c \lg H \quad (3.2)$$

donde los parámetros a , b y c son coeficientes de regresión empíricos [12]. En este contexto, la precisión de las mediciones primarias es crítica, ya que, dada la naturaleza potencial de estas funciones, los errores en la toma de datos de D y H se propagan y magnifican en el cálculo final del volumen y el contenido de carbono. Pese a la aparente sencillez del ajuste, los resultados pueden llegar a ser muy buenos, como se muestra en la Figura 3.1. No obstante, existe una tensión en la literatura entre el uso de ecuaciones “pantropicales” o generalizadas y ecuaciones específicas de especie o sitio, ya que se pueden introducir sesgos si la arquitectura de los árboles locales difiere de la global [13].

La medición de la altura de los árboles ha supuesto históricamente un desafío mayor que la del diámetro. Hasta la década de 1990, predominaron hipsómetros mecánicos basados en trigonometría, que requerían medir manualmente la distancia al árbol y una línea de visión despejada [15]. Estos métodos sufrían limitaciones de precisión y ergonomía. La introducción de la electrónica marcó un punto de inflexión al utilizar ultrasonidos para medir distancias automáticamente, permitiendo trabajar en sotobosques densos y mejorando la precisión por debajo del 1 % [15]. Paralelamente, las forcípulas (aparato de medición de la distancia lineal entre dos tangentes paralelas al fuste del árbol) electrónicas modernas han digitalizado la toma de datos, integrando medición y registro de metadatos para minimizar errores de transcripción [15].

Posteriormente, la introducción de la tecnología de escaneo láser supuso una revolución en la mensura forestal, superando las limitaciones logísticas y de precisión de los




Figura 3.1: Relación entre la biomasa total en kilogramos y el diámetro a la altura del pecho en centímetros para el bambú moso (*Phyllostachys edulis*). Visto en [12], siendo [14] la fuente original.




Figura 3.2: Diagrama de el escaneo de un árbol por un sistema LiDAR aerotransportado y los diversos pulsos reflejados. Imagen obtenida de [17].

métodos tradicionales. Esta tecnología se despliega principalmente en dos modalidades: el escaneo láser terrestre (TLS, por sus siglas en inglés), que captura la estructura tridimensional del bosque desde el suelo con detalle milimétrico [16], y el LiDAR aerotransportado. Este último consiste es un método que usa pulsos de luz para medir distancias. Los mapeos masivos suelen consistir en un sistema LiDAR montado en un avión, helicóptero, dron o satélite, el cuál mide la distancia a los objetos debajo de él. Una ventaja es que, al igual que la luz puede llegar al suelo a través de los huecos de las copas de los árboles, los pulsos láser del LiDAR también lo hacen, como podemos observar en la Figura 3.2. Esto hace que mediante un solo sobrevuelo se puedan captar diversas capas a varias alturas, lo que permite realizar reconstrucciones en 3D de las zona escaneada. El detalle que se puede lograr es tan alto que se pueden identificar los árboles individuales, como se ve en la Figura 3.3.




Figura 3.3: Visualización de un bosque escaneado con LiDAR. Vemos las posibilidades de identificar árboles individuales en un entorno forestal denso [18].



Figura 3.4: Plan de adquisición de datos del Tercer ciclo del proyecto PNOA-LiDAR del Instituto Geográfico Nacional de España [19].

Las principales limitaciones del LiDAR aerotransportado residen en su elevado coste y complejidad logística. Estos factores dificultan la obtención de coberturas a gran escala con una periodicidad óptima, generando además una latencia significativa en la disponibilidad de datos regionales. Asimismo, el procesamiento de esta información es más exigente que en métodos previos, a lo que se suma el desafío técnico de gestionar y almacenar grandes volúmenes de datos. En la Figura 3.4 se muestra el plan de adquisición de datos del Tercer ciclo del proyecto PNOA-LiDAR del Instituto Geográfico Nacional de España, donde se puede apreciar la cadencia con la que se hacen los mapeos.

La integración de estos datos estructurales, junto a la teledetección satelital y la capacidad de procesamiento de grandes volúmenes de datos que ofrecen los algoritmos de aprendizaje automático ha inaugurado un nuevo paradigma: la capacidad de monitorear los recursos forestales a escala

global con una precisión sin precedentes. Es en este contexto de “forestería de precisión” y observación terrestre a gran escala donde se enmarca la investigación actual, habiéndose logrado resultados muy prometedores que permiten abordar la complejidad de los ecosistemas forestales con una granularidad antes inalcanzable.

4. Estado del Arte

El secuestro de carbono en ecosistemas forestales ha cobrado una importancia creciente en la literatura científica, impulsada tanto por los compromisos internacionales en materia de cambio climático como por el auge de los mercados de créditos de carbono. Esto ha motivado el desarrollo de modelos orientados a cuantificar la biomasa forestal y estimar el contenido de carbono, aprovechando avances recientes en sensores remotos y técnicas de inteligencia artificial.

Una de las estrategias más consolidadas para la cuantificación del carbono forestal es la estimación del carbono almacenado en un momento dado a partir de datos de teledetección. Goetz et al. (2009) [20] revisan el uso de observaciones satelitales, incluyendo sensores ópticos como MODIS y Landsat, en modelos empíricos de biomasa aérea, destacando su aplicabilidad a escala regional, especialmente en ecosistemas boreales. Este tipo de estimaciones suele basarse en regresiones lineales o modelos de mínimos cuadrados generalizados, con coeficientes de determinación habitualmente entre 0.6 y 0.8, dependiendo de la resolución espacial y la heterogeneidad del ecosistema.

La aplicación de aprendizaje profundo ha permitido mejorar sustancialmente la precisión y resolución espacial de estas estimaciones. Por ejemplo, Zhang et al. (2022) [21] integran imágenes Sentinel-2 con redes neuronales convolucionales, alcanzando un R^2 de 0.84 para estimar el carbono en bosques subtropicales. Del mismo modo, Jiang et al. (2022) [22] desarrollan el modelo *ForestCarbonAI*, entrenado con datos multiespectrales y LiDAR, con el que generan mapas de carbono forestal de alta resolución (10 m), reportando errores medios absolutos (MAE) inferiores a 3.5 tC/ha en zonas templadas. Otros trabajos recientes, como Reiersen et al. (2022) [23] o Dong et al. (2023) [24], también demuestran la eficacia del *deep learning* para estimaciones estáticas, aunque se centran en contextos tropicales y no consideran el componente temporal.

Frente a estos enfoques descriptivos, algunas iniciativas han intentado proyectar la evolución del carbono a futuro. En el ámbito nacional, el Ministerio para la Transición Ecológica (MITECO) ha implementado herramientas como la calculadora *ex ante* de absorciones [25], que permite obtener estimaciones simplificadas del carbono que puede fijarse en una plantación forestal en función de la especie y la zona agroclimática. No obstante, este instrumento se basa en coeficientes tabulados y no incorpora variables edafoclimáticas reales ni técnicas de modelización basadas en datos, lo que limita su precisión y capacidad de adaptación a contextos específicos.

En el ámbito europeo destaca el trabajo de Fasihi et al. (2024) [26], que aplica un enfoque afín al propuesto en este estudio en la región de Friuli-Venezia Giulia (Italia). Su objetivo es estimar tanto el *stock* actual de carbono como su tasa de absorción anual (secuestro), basándose en datos de dendrocronología del Inventario Forestal Nacional italiano. Estas mediciones, realizadas entre 2017 y 2019, cuantifican el crecimiento radial de los últimos cinco años para estimar la biomasa mediante ecuaciones alométricas y su conversión a carbono según directrices del IPCC. Luego, entrenan modelos predictivos utilizando variables meteorológicas, geomorfológicas, índices de vegetación y un modelo LiDAR de las copas de los árboles (CHM) ,intentando predecir los valores obtenidos con datos de campo.

Los autores evalúan diversos modelos de conjunto (*ensemble*), reportando que combinaciones de algoritmos como Random Forest, AdaBoost y CatBoost ofrecen el mejor rendimiento. En la predicción del *stock* de carbono, alcanzan un R^2 de $0,73 \pm 0,07$ y un RMSE de $31,55 \pm 9,35$ tC/ha. Para la tasa de secuestro, los resultados son más modestos, con un R^2 de $0,42 \pm 0,08$ y un RMSE de $0,90 \pm 0,08$ tC/ha/año. Un hallazgo clave del estudio es que la inclusión de datos LiDAR mejora drásticamente la precisión de las estimaciones.

En este escenario, el presente trabajo propone una metodología innovadora centrada en la predicción dinámica de carbono a largo plazo. A diferencia de los modelos anteriores, que estiman el carbono ya almacenado, este estudio se enfoca en anticipar cuánto carbono capturará un cultivo forestal en un horizonte temporal concreto. Para ello, se estudian diversos modelos de aprendizaje supervisado entrenados con datos históricos del Inventario Forestal Nacional (IFN2, IFN3 e IFN4) [7] incluyendo características edáficas, variables climáticas de Copernicus [27, 28] y métricas espectrales derivadas de imágenes Landsat [29]. Los detalles sobre la arquitectura del modelo, las variables utilizadas, los algoritmos implementados y las métricas de evaluación se desarrollan en las siguientes secciones.

5. Metodología

Esta sección describe el procedimiento seguido para el entrenamiento y validación de los modelos predictivos. La metodología se fundamenta en los factores que determinan el crecimiento forestal: las condiciones meteorológicas (temperatura, precipitación) inciden sobre la fotosíntesis y la disponibilidad hídrica; la orientación, la pendiente y la altitud modulan la radiación incidente y el microclima local; y la densidad arbórea determina la competencia intraespecífica [30]. El enfoque integra información estructural, climática y espectral procedente del IFN y de fuentes ambientales complementarias para predecir el carbono acumulado en la biomasa viva.

5.1. Origen y estructura de los datos

La base de datos integra información forestal, climática y espectral a nivel de parcela, especie y clase diamétrica, estructurada en torno a los inventarios IFN2, IFN3 e

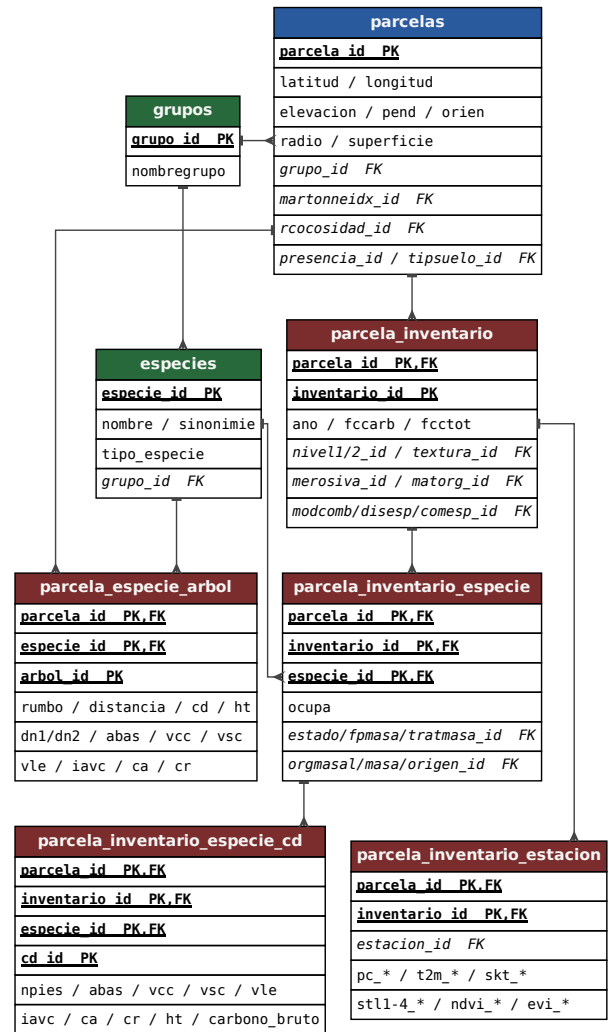


Figura 5.1: Esquema relacional de las tablas principales de la base de datos. Tabla extraída de [10], donde se pueden consultar más detalles sobre las variables.

IFN4. Además de las variables dendrométricas del IFN, cada parcela incorpora estadísticas climáticas estacionales (temperatura, precipitación, índice de Martonne) e índices espectrales derivados de imágenes satelitales (NDVI, EVI, NDII, GNDVI). La Figura 5.1 muestra el esquema relacional de las tablas principales; un diccionario completo de variables se recoge en [10].

5.2. Variables objetivo

El objetivo del modelo es estimar el **carbono total** que una parcela forestal capturará en un horizonte temporal de 20–30 años, a partir de las condiciones observadas en inventarios previos. Para ello se contemplan dos variables de respuesta complementarias, ambas derivadas de los datos del Inventario Forestal Nacional (IFN), que permiten analizar el contenido de carbono desde perspectivas distintas: una normalizada por superficie y otra en términos absolutos.

1. c (tC/ha): representa el **carbono total contenido en la biomasa viva aérea y subterránea** por unidad de superficie, expresado en *toneladas de carbono por hectárea*. Su cálculo se basa en la suma de las estimaciones de carbono aéreo (c_a) y radical (c_r) reportadas por el IFN. En los casos con valores faltantes, se completó la información mediante un modelo de *Random Forest Regressor* ajustado sobre variables dendrométricas observadas (Especie, CD, VSC, NPies, ABas, IAVC, VCC y VLE), alcanzando un rendimiento satisfactorio ($R^2_{test} > 0,90$). Esta variable es coherente con los formatos internacionales de reporte de inventarios forestales y permite comparar el contenido de carbono entre parcelas o especies.
2. **carbono_bruto** (tC): corresponde al **carbono total capturado por parcela y especie**, expresado en *toneladas de carbono totales*. Su estimación se realiza de forma trazable y físicamente interpretable a partir de variables medidas directamente en campo: número de pies ($npies$), altura media (ht), tipo de especie ($clase_especie$) y clase diamétrica (cd_id). El cálculo sigue un modelo alométrico adaptado de [31] y las directrices del IPCC [30], incorporando tanto la biomasa aérea como la biomasa radical mediante la relación Parte Radical:Parte Aérea (R). El resultado se expresa en toneladas de carbono totales por parcela, sin normalizar por superficie, lo que facilita la trazabilidad del proceso y la comparación entre inventarios sin depender de factores de expansión específicos del IFN. En coherencia con los criterios de proyectos de forestación y reforestación, las observaciones correspondientes a brinzales o plantones se consideran con valor de carbono nulo, dado que las fases tempranas de desarrollo no se contabilizan oficialmente como carbono capturado.

Estas dos variables resumen el contenido de carbono forestal desde enfoques complementarios: c (tC/ha) permite la comparación espacial y temporal entre masas forestales, mientras que **carbono_bruto** (tC) ofrece una medida absoluta y directamente derivada de las observaciones de campo. Ambas constituyen los objetivos principales del modelado predictivo, orientado a estimar el carbono acumulado en el **IFN4** a partir de las condiciones registradas en los inventarios anteriores (**IFN2** e **IFN3**).

Para mayor detalle sobre el origen de estas variables consultar [10].

5.3. Supuestos de elegibilidad y verificación externa

Como ya se ha introducido, para que un proyecto forestal sea elegible en programas de *créditos de carbono* en España debe cumplir algunos requisitos técnicos [30, 32]. A continuación se resume cada criterio y la forma en que se aborda en este estudio:




Figura 5.2: Distribución de la diferencia de años entre los inventarios tercero y cuarto.




Figura 5.3: Distribución de la diferencia de años entre los inventarios IFN2-IFN3 e IFN3-IFN4.

- **Intervención humana directa.** El incremento de carbono debe proceder de actuaciones planificadas (reforestación, restauración o manejo sostenible). En nuestro caso, el modelo se entrena sobre datos observacionales (IFN2-IFN3-IFN4); por tanto, la *verificación de intervención* no se deduce del modelo, sino que se contempla como *condición externa* de elegibilidad del proyecto a evaluar.
- **Permanencia mínima.** El intervalo entre IFN3 e IFN4 se sitúa mayoritariamente entre 6 y 17 años (Figura 5.2), un rango demasiado estrecho para el horizonte de 20–30 años de referencia. Para ampliar la cobertura temporal se integró también el par IFN2-IFN3, obteniendo intervalos de 6 a 29 años (Figura 5.3), más representativos del horizonte objetivo.
- **Superficie mínima de 1 ha.** Criterio externo al modelo, verificable *ex ante* sobre la geometría declarada del proyecto. En masas homogéneas el carbono total es aproximadamente proporcional a la superficie, por lo que este requisito no afecta al ajuste del modelo.
- **Fracción mínima de cabida cubierta del 20 %.** La base de datos dispone de f_{ccarb} (arbórea) y f_{ccot} (total). Este umbral se aplica como *filtro de elegibilidad* previo al modelado ($f_{ccarb} \geq 20$).
- **Altura mínima de 3 m en la madurez.** Referido a la altura adulta de la especie, no a los plantones en el momento del inventario. Se evalúa externamente mediante la selección de especies adecuadas y no interviene en el entrenamiento del modelo.

5.4. Preparación y tratamiento de los datos

Como ya se ha introducido, el entrenamiento se realiza en dos líneas según la variable objetivo: carbono en toneladas por hectárea (c de IFN4) o carbono en toneladas (carbono_bruto de IFN4); y según la información que se usa como explicativa: IFN3 o IFN3 e IFN2. Se plantea la preparación y filtrado de los datos en términos generales.

5.4.1. Filtrado de registros

Se descartan todas aquellas parcelas en las que el valor de carbono total (variable objetivo) en la segunda inventariación es inferior a la primera. Estos casos suelen deberse a episodios de deforestación, incendios u otras perturbaciones, y no representan un crecimiento forestal neto.

El conjunto de datos se restringe únicamente a las parcelas que presentan una fccarb (fracción de cabida cubierta arbórea) igual o superior al 20 % en el inventario explicativo. Este umbral define la proporción mínima de superficie ocupada por copas de árboles respecto al área total de la parcela, y constituye una de las condiciones esenciales para considerar una superficie como terreno forestal. La exclusión de parcelas con fccarb inferior al 20 % permite asegurar que las estimaciones de carbono se realicen sobre masas forestales consolidadas, evitando sesgos asociados a áreas agrícolas o matorrales. A los datos del IFN2 no se les aplica dicho filtro porque no disponen de la variable fccarb.

5.4.2. Cálculo y agregación de variables

Cada registro de entrada se genera a nivel de combinación parcela–especie, incorporando las variables correspondientes de la primera medición y la variable objetivo (carbono) de la segunda medición (IFN4). Las variables de parcela y parcela_inventario se desdoblan para cada especie. Las entradas de la tabla parcela_inventario_especie_cd se agrupan por parcela y especie y se comprimen en una única entrada creando un conjunto de variables para cada clase diamétrica.

5.4.3. Reclasificación de las variables pendiente y orientacion

Dado que el efecto ecológico de la pendiente y la orientación sobre la acumulación de carbono es no lineal, ambas variables se reclasificaron como factores categóricos. La variable pendiente_cat se definió mediante siete intervalos (< 5°, 5–10°, 10–15°, 15–20°, 20–30°, 30–50°, > 50°); la variable orientacion_cat en ocho sectores cardinales equiángulos (N, NE, E, SE, S, SO, O, NO).

5.4.4. Agrupación de la variable periodo

Como se puede observar en la Figura 5.3, la distribución de la variable periodo, definida como el número de años transcurridos entre la medición de las variables explicativas y la observación de la variable objetivo, presenta cierta heterogeneidad en su frecuencia. Aunque el rango total de valores se extiende aproximadamente entre 0 y 34 años, algunos intervalos temporales aparecen representados por un número muy reducido de observaciones.

Esta escasez de datos en determinados valores de periodo puede introducir inestabilidad en el entrenamiento de los modelos, al forzar al algoritmo a aprender patrones a partir de muestras poco representativas. Para mitigar este efecto y mejorar la robustez de las predicciones, se optó por agrupar ciertos valores de periodo en categorías temporales más amplias, dando lugar a una nueva variable denominada periodo_agrupado.

El procedimiento de agrupación se diseñó de forma conservadora, manteniendo sin modificar aquellos valores con suficiente soporte muestral y agrupando únicamente los intervalos más escasos. En concreto, los valores inferiores a 6 años se agruparon en la categoría 5; los periodos entre 7 y 10 años se agruparon en 10; los comprendidos entre 18 y 21 años se agruparon en 20; y los valores iguales o superiores a 29 años se agruparon en 30. El resto de valores intermedios se mantuvieron sin modificación.

Cabe destacar que la variable periodo_agrupado no conserva la granularidad completa de la variable original, pero sí retiene su significado temporal esencial. Los experimentos realizados muestran que esta representación resulta más estable desde el punto de vista estadístico y conduce a modelos con un comportamiento predictivo más robusto, al reducir la sensibilidad a intervalos temporales con baja frecuencia de observaciones.

5.5. Partición y validación

Para obtener una estimación imparcial del rendimiento y evitar fugas de información derivadas de la estructura jerárquica de los datos, el proceso de entrenamiento se organiza en dos niveles: (i) una partición externa *hold-out* para la evaluación final y (ii) una validación cruzada interna para la selección de hiperparámetros.

Partición entrenamiento/test. Los datos, ya filtrados, se separan en un 80 % para entrenamiento y un 20 % para test. Dicha separación se hace de forma que todas las observaciones asociadas a una misma parcela queden asignadas íntegramente a uno de los subconjuntos.

Validación cruzada para selección de hiperparámetros. La selección de hiperparámetros se lleva a cabo exclusivamente sobre el conjunto de entrenamiento mediante GridSearchCV con métrica de optimización R^2 . Se utiliza GroupKFold con $k = 5$ pliegues, imponiendo que no exista solape de parcelas entre pliegues (esto es, la agrupación se respeta tanto en el *hold-out* como en la validación interna).

Métricas de evaluación. Las métricas principales empleadas son RMSE, RMSE %, R^2 , MAE y SMAPE. En las siguientes expresiones, y_i es el valor observado, $\hat{y}_i$ el predicho, $\bar{y}$ la media observada y n el número de observaciones:

- **RMSE:** raíz del error cuadrático medio, en las mismas unidades que la variable objetivo.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (5.1)$$

- **RMSE %:** RMSE expresado como porcentaje de la media observada.

$$\text{RMSE}_{\%} = \frac{\text{RMSE}}{\bar{y}} \times 100 \quad (5.2)$$

- **MAE (error absoluto medio):** promedio de los errores absolutos; más robusto que el RMSE frente a valores atípicos al penalizar por igual todos los residuos.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5.3)$$

- **R^2 (coeficiente de determinación):** proporción de varianza explicada por el modelo.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (5.4)$$

- **SMAPE:** error porcentual simétrico, acotado y robusto frente a la asimetría del MAPE.

$$\text{SMAPE} = \frac{100}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2} \quad (5.5)$$

Como métricas de apoyo para el análisis de residuos y detección de sesgos se calculan también MAE, MAPE, wMAPE, MedAE y Bias.

5.5.1. Codificación y normalización

Con el fin de garantizar coherencia metodológica y evitar fugas de información durante la validación cruzada, todas las etapas de preprocesado se integran explícitamente dentro de un Pipeline junto con el modelo de regresión. De este modo, los parámetros asociados al preprocesado se estiman *exclusivamente* a partir de los datos de entrenamiento de cada pliegue, y se aplican posteriormente a los datos de validación o test.

Las variables se tratan de acuerdo con su naturaleza:

- **Variables numéricas continuas:** se imputan mediante la mediana para reducir la influencia de valores extremos y, posteriormente, se estandarizan mediante normalización *z-score* (media cero y desviación estándar unitaria). Este paso resulta especialmente relevante para modelos sensibles a la escala de las variables, como regresiones lineales, SVR o redes neuronales.
- **Variables estructurales de densidad** (`npies_*`): al representar recuentos por clase diamétrica, se imputan con valor cero cuando están ausentes y se estandarizan de forma análoga a las variables numéricas, preservando su contribución relativa en el modelo.
- **Variables categóricas:** se imputan mediante la moda, se convierten explícitamente a tipo cadena y se codifican mediante *one-hot encoding*. Se utiliza la opción `handle_unknown='ignore'` para garantizar la robustez del modelo frente a categorías no observadas durante el entrenamiento.

Esta estrategia asegura que la codificación, imputación y escalado de las variables se realicen de forma consistente en todos los modelos evaluados y que el rendimiento estimado refleje fielmente la capacidad de generalización del sistema, sin introducir sesgos derivados del acceso indebido a información del conjunto de evaluación.

5.6. Selección de variables explicativas

La selección de predictores combinó métodos automáticos y criterios expertos. Entre los métodos automáticos se emplearon *Featurewiz*, que elimina predictores con correlación alta ($|r| > 0,70$) y refina la selección mediante *Gradient Boosting*, y *mRMR* (minimum Redundancy–maximum Relevance), que maximiza la relevancia de cada predictor respecto al objetivo minimizando la redundancia entre ellos mediante información mutua.

Estos resultados se integraron con una selección manual basada en criterios estadísticos (correlaciones, ANOVA, análisis de redundancia) y ecológicos, garantizando la representación de las dimensiones esenciales del sistema (estructura del arbolado, topografía, suelo, clima e índices espectrales). Adicionalmente, se aplicó un procedimiento secuencial supervisado (SSSRP) de *forward selection* sobre un modelo CatBoost, incorporando en cada iteración la variable con mayor ganancia en R^2 hasta alcanzar $\Delta R^2 < 10^{-5}$. El resultado final fue un conjunto de 44 variables seleccionadas a partir de 445 candidatas.

5.7. Modelos evaluados

Se evaluaron nueve algoritmos representativos de distintos paradigmas: métodos de *boosting* (XGBoost, LightGBM, CatBoost, GBDT), métodos de *bagging* (Random Forest, BaggedDT) y modelos de referencia (SVR, MLP, BayesianNN). Sus características principales se recogen en la Tabla 5.1. Los mejores modelos base se combinaron posteriormente en configuraciones de *stacking*.

5.7.1. Configuración del stacking

Tras evaluar todos los modelos anteriores, se construyeron diferentes configuraciones de modelos base (*base learners*) que se combinan mediante un meta-modelo. Estas combinaciones se diseñaron con dos criterios principales:

1. **Diversidad estructural:** mezclar métodos de boosting y bagging, así como variantes de boosting con distintas estrategias de crecimiento y regularización.
2. **Rendimiento individual:** incluir preferentemente los modelos con mayor R^2 y menor error (RMSE, MAE) en las pruebas individuales.

Los meta-modelos utilizados para integrar las predicciones fueron:

- **Modelos lineales:** Regresión Lineal, Ridge.
- **Modelos basados en árboles:** Random Forest, Gradient Boosting Regressor.
- **Modelos kernel:** SVR lineal.
- **Red neuronal:** MLP con una capa oculta.

Modelo	Tipo	Características	Observaciones
Random Forest	Bagging	Bootstrap con selección aleatoria de atributos	Robusto y estable
BaggedDT	Bagging	Árboles sin poda sobre muestras bootstrap	Mejora por agregación
XGBoost	Boosting	Regularización L1/L2, segundo orden	Muy preciso; sensible a tuning
LightGBM	Boosting	Crecimiento leaf-wise, muy eficiente	Rápido; riesgo de sobreajuste
CatBoost	Boosting	Codificación ordenada; robusto al ruido	Excelente sin gran tuning
GBDT	Boosting	Árboles secuenciales ajustados a residuos	Buen rendimiento
MLP	Red neuronal	Captura relaciones no lineales	Requiere normalización
SVR	Márgenes	Kernel lineal, gran margen	Robusto al sobreajuste
BayesianNN	Probabilístico	Cuantifica incertidumbre	Reduce sobreajuste

Tabla 5.1

Modelos de aprendizaje supervisado evaluados.

Esta selección permite comparar desde combinadores lineales simples hasta integradores no lineales capaces de capturar interacciones complejas entre predicciones.

5.7.2. Comparación y justificación de modelos

La evaluación exhaustiva de múltiples algoritmos permite identificar no solo el modelo individual con mejor rendimiento, sino también combinaciones sinérgicas para el *stacking*. La Tabla 5.1 resume los modelos finalmente entrenados y evaluados.

6. Implementación del pipeline

El desarrollo y la evaluación de los modelos predictivos se realizaron íntegramente en **Python**, utilizando *scikit-learn*, *cuML*, *PyTorch* y las librerías de *gradient boosting* *XGBoost*, *LightGBM* y *CatBoost*. Los modelos entrenados exclusivamente con datos del IFN3 se ejecutaron en un equipo local (Intel Core i7, 32 GB RAM), mientras que los que emplean conjuntamente IFN2 e IFN3 se entrenaron en el sistema de computación de alto rendimiento (HPC) de la Universidad de Salamanca, aprovechando tarjetas gráficas Nvidia H100 para acelerar el entrenamiento de los modelos compatibles con GPU.

6.1. Selección de variables

6.1.1. Selección manual

La selección manual de variables partió de una organización temática del conjunto de predictores, agrupando las variables según el tipo de información ecológica, estructural o climática que representan. Esta clasificación permitió estructurar el proceso de reducción dimensional en torno a los siguientes bloques conceptuales:

- **Bloque de variables fijas:** describe la estructura básica de la masa forestal y los atributos esenciales de identificación y caracterización general de cada parcela.
- **Bloque de variables de especie:** recoge información relativa a la composición, estado y características específicas de las formaciones forestales.
- **Bloque sustrato:** integra variables edáficas y de manejo susceptibles de variar en el tiempo.

- **Bloque de terreno:** agrupa propiedades físicas del medio que permanecen estables a escala temporal de inventarios (pendiente, orientación, tipo de suelo, etc.).
- **Bloque climático resumido:** representado por el índice de aridez de Martonne, que sintetiza la interacción entre temperatura y precipitación.
- **Bloque climático detallado:** incluye métricas estacionales explícitas de temperatura y precipitación.
- **Bloque de índices de vegetación:** recoge información espectral relacionada con el estado hídrico, vigor y actividad fotosintética de la vegetación.

En total, la base de datos contenía inicialmente 445 variables candidatas distribuidas entre estos bloques temáticos. Tras aplicar el procedimiento de selección manual, apoyado en criterios estadísticos, ecológicos y en la comparación del rendimiento del modelo, el conjunto se redujo a 44 variables representativas. Las variables finalmente seleccionadas dentro de cada bloque fueron las siguientes:

- **Bloque de variables fijas:** *especie_id*, *tipo_especie*, *grupo_id*, *periodo*, *radio*, *ocupa*, *npies_1*, *npies_2*, *npies_5*, *npies_10*, *npies_15*, *npies_20*, *npies_25*, *npies_30*, *npies_35*, *npies_40*, *npies_45*, *npies_50*, *npies_55*, *npies_60*, *npies_65*, *npies_70*.
- **Bloque de variables de especie:** *estado_id*, *fccarb*, *disesp_id*.
- **Bloque sustrato (dinámico):** *modcomb_id*, *nivel2_id*, *tratmasa_id*.
- **Bloque de terreno:** *rocosidad_id*, *orientacion_cat*, *elevacion*, *pendiente_cat*.
- **Bloque climático resumido (Martonne):** *martonneidx_id*.
- **Bloque climático detallado (temperatura y precipitación):** *skt_mean_primavera*, *skt_mean_verano*, *skt_std_primavera*, *skt_std_verano*, *pr_sum_invierno*, *pr_sum_otoño*, *pr_sum_primavera*, *pr_sum_verano*.
- **Bloque de índices de vegetación:** *gndvi_mean_verano*, *ndii_mean_primavera*, *gndvi_std_primavera*, *evi_mean_primavera*.

La comparación de modelos entrenados con combinaciones incrementales de bloques mostró que todos ellos aportan información relevante, siguiendo el orden de contribución

aproximado: *variables fijas* > *variables de especie* > *sustrato* > *terreno* > *índices de vegetación* > *Martonne* > *temperatura* y *precipitación*. Es decir, la mayor parte de la capacidad predictiva se explica por la estructura y composición de la masa forestal, mientras que las condiciones edáficas, topográficas y climáticas actúan como moduladores adicionales de la acumulación de carbono.

6.1.2. Selección automática

Featurewiz seleccionó **67 variables**, con preferencia por índices de vegetación derivados de Sentinel-2 (NDII, EVI, GNDVI y NDVI, con estadísticos de media, máximo, mínimo, mediana y desviación estándar, especialmente en primavera y verano) y variables térmicas y de precipitación estacionales (t2m_*, skt_*, stl_*, pr_sum_*, pr_max_*, pr_min_*). El índice de aridez de Martonne y un conjunto representativo de variables estructurales (pies por clase diamétrica), de especie y de terreno completaron la selección.

mRMR seleccionó **50 variables** priorizando alta información mutua con el carbono y baja redundancia interna. El conjunto integra predictores estructurales (especie, radio, clases diamétricas, orientación y pendiente), variables edáficas (rocosidad, tipos de suelo), métricas climáticas estacionales y medias estacionales de NDII, GNDVI y EVI, confirmando que la actividad fotosintética y el estado hídrico actúan como predictores directos del carbono almacenado.

6.1.3. Resultado de la selección

De los tres conjuntos de variables seleccionados se mantuvo la selección manual al demostrar un mejor rendimiento con mayor simplicidad.

6.2. Configuración del *stacking*

La agregación mediante *stacking* se implementó con predicciones fuera de pliegue (*out-of-fold*, OOF) generadas sobre el conjunto de entrenamiento con el mismo esquema GroupKFold; cada modelo base se reentrenó sobre la totalidad del conjunto de entrenamiento para producir las predicciones finales sobre test. Las meta-variables se estandarizaron mediante *StandardScaler* antes de ajustar el meta-modelo.

Con el objetivo de estudiar el compromiso entre diversidad del ensamble, coste computacional y rendimiento, se definieron cinco configuraciones de modelos base (Tabla 6.1). Los modelos BayesianNN, SVR y MLP se descartaron como candidatos por su menor rendimiento individual.

Las configuraciones van desde la más ligera (Config. 1, dos modelos con paradigmas distintos) hasta la más completa (Config. 5, todos los modelos con rendimiento competitivo), permitiendo analizar el efecto de la diversidad estructural y el coste computacional sobre el rendimiento del ensamble. Sobre las predicciones apiladas de cada configuración se entrenaron los meta-modelos recogidos en la Tabla 6.2.

Al evaluar todas las combinaciones de configuraciones de modelos base con los diferentes meta-modelos se obtiene un conjunto de ensambles que permiten estudiar de forma

Tabla 6.1

Configuraciones de modelos base para *stacking*.

Config.	Modelos base
1	LightGBM, Random Forest
2	LightGBM, XGBoost, GBDT
3	CatBoost, Random Forest, GBDT
4	CatBoost, LightGBM, Random Forest, GBDT
5	CatBoost, LightGBM, XGBoost, Random Forest, GBDT, BaggedDT

Tabla 6.2

Meta-modelos utilizados en el *stacking* junto con sus parámetros.

Meta-modelo	Parámetros
Gradient Boosting	Configuración por defecto
Regresión Lineal	Sin regularización
Ridge	Regularización L2 con validación cruzada ($\alpha \in \{0.01, 0.1, 1, 10, 100\}$)
Random Forest	50 árboles
SVR	Kernel lineal
MLP	Una capa oculta con 50 neuronas, 500 iteraciones máximas

sistemática qué subconjuntos de modelos base son más complementarios y qué tipo de meta-modelo aprovecha mejor la información contenida en sus predicciones.

6.3. Datos finales de entrenamiento

Tras aplicar los criterios de elegibilidad y filtrado descritos en la Sección 5.4.1, el conjunto de datos final utilizado para el ajuste de los modelos queda compuesto por:

- **IFN2:** Total de parcelas = **88.696**
 - Casos con $c4 > c$: **41.761**
 - Casos con $\text{carbono_bruto4} > \text{carbono_bruto}$: **43.539**
- **IFN3:** Total de parcelas = **171.157**
 - Casos con $fccarb \geq 20$: **164.364**
 - Casos con $fccarb \geq 20$ y $c4 > c$: **62.029**
 - Casos con $fccarb \geq 20$ y $\text{carbono_bruto4} > \text{carbono_bruto}$: **89.580**


La Tabla 6.3 resume las principales estadísticas descriptivas de las variables objetivo utilizadas en el modelado. Se observa que la variable *carbono_bruto4* presenta una media de 20.79 y una desviación estándar de 35.09, mientras que la variable *c4* muestra valores notablemente superiores (media de 38.83 y desviación estándar de 47.27). Podemos encontrar un histograma de la distribución de las variables objetivo en la Figura 6.1.

Por otro lado, en la Figura 6.2 podemos ver las distribuciones de las variables objetivo separadas por inventarios. Podemos observar que el histograma de la variable *carbono_bruto4* está notablemente más concentrado en valores bajos que aquella correspondiente a *c4*, para la que se ha estandarizado en una cantidad de carbono por superficie


Tabla 6.3

Estadísticos descriptivos del conjunto de datos depurado.

Variable	N	Media	Desv. estándar	Mín.	Máx.
carbono_bruto4	133 119	20.79	35.09	0.00	420.50
carbono_bruto	123 563	10.09	26.33	0.00	511.31
c4	103 790	38.83	47.27	0.48	883.46
c	131 942	29.58	40.62	0.44	873.36



(a) Histograma de la variable c4 en escala logarítmica.



(b) Histograma de la variable carbono_bruto4 en escala logarítmica.


Figura 6.1: Histograma de las variables c4 y carbono_bruto4 en el conjunto depurado.

6.3.1. Efecto del periodo sobre el carbono


La influencia del *periodo* sobre las variables de carbono se evaluó mediante ANOVA de un factor. Los análisis realizados muestran que el *periodo* ejerce un efecto significativo sobre ambas variables. En c4 se obtuvo un estadístico $F = 143,49$ ($p < 0,001$), mientras que en carbono_bruto4 el valor fue $F = 161,08$ ($p < 0,001$). Estos resultados indican que las diferencias observadas entre periodos no son aleatorias, sino que reflejan variaciones sistemáticas asociadas al momento de muestreo, confirmando que el *periodo* constituye un factor explicativo relevante en la dinámica del carbono forestal.

7. Resultados

A continuación se presentan los resultados obtenidos sobre el conjunto de datos de test, organizados según el



(a) Distribución de la variable c4 a lo largo de los valores de la variable periodo_agrupado.



(b) Distribución de la variable carbono_bruto4 a lo largo de los valores de la variable periodo_agrupado.

Figura 6.2: Distribución de las variables c4 y carbono_bruto4 en el conjunto depurado (tras aplicar los filtros) separadas por inventario.

inventario fuente (IFN2, IFN3 o IFN2+IFN3) y la variable objetivo (carbono en tC/ha o en tC totales). Para cada combinación se muestran los tres mejores modelos base y los tres mejores modelos de ensamble con *stacking*, ordenados por R^2 descendente. La columna de la izquierda indica el inventario de evaluación, es decir, el inventario sobre el que se han realizado las predicciones. Cuando el modelo lleva el subíndice *global*, indica que ha sido entrenado con datos conjuntos IFN2+IFN3, aunque se haya evaluado sobre un inventario únicamente. Los modelos sin subíndice han sido entrenados únicamente con el inventario en el que han sido evaluados.

Las tablas completas con todos los modelos evaluados se recogen en el Apéndice A.

Tabla 7.1

Top-3 modelos base y de *stacking* por inventario fuente y variable objetivo, ordenados por R^2 descendente. Los modelos con subíndice *global* fueron entrenados con datos conjuntos IFN2+IFN3.

Inventario de evaluación	#	Modelo	Tipo	R^2	RMSE	MAE
<i>Variable objetivo: c4 (tC/ha)</i>						
IFN2	1	LightGBM _{global}	Base	0.719	26.806	14.689
	2	LightGBM	Base	0.712	26.435	14.755
	3	CatBoost _{global}	Base	0.708	27.359	14.832
	1	Stack5 GradientBoosting	Stacking	0.724	25.889	14.531
	2	Stack1 MLP _{global}	Stacking	0.722	26.683	14.582
	3	Stack2 MLP _{global}	Stacking	0.721	26.726	14.475
IFN3	1	LightGBM	Base	0.858	17.816	9.246
	2	XGBoost	Base	0.851	18.232	9.203
	3	CatBoost	Base	0.849	18.385	9.746
	1	Stack4 GradientBoosting	Stacking	0.866	17.303	9.134
	2	Stack5 GradientBoosting	Stacking	0.865	17.369	9.037
	3	Stack2 GradientBoosting	Stacking	0.863	17.537	9.097
IFN2+IFN3	1	LightGBM _{global}	Base	0.787	22.767	11.650
	2	XGBoost _{global}	Base	0.784	22.952	11.590
	3	CatBoost _{global}	Base	0.783	22.990	11.607
	1	Stack5 MLP _{global}	Stacking	0.794	22.387	11.321
	2	Stack2 MLP _{global}	Stacking	0.794	22.405	11.403
	3	Stack4 MLP _{global}	Stacking	0.792	22.527	11.314
<i>Variable objetivo: carbono_bruto4 (tC)</i>						
IFN2	1	CatBoost _{global}	Base	0.765	18.533	10.402
	2	LightGBM _{global}	Base	0.762	18.627	10.417
	3	XGBoost _{global}	Base	0.762	18.644	10.428
	1	Stack5 MLP _{global}	Stacking	0.768	18.405	10.210
	2	Stack5 LinearReg _{global}	Stacking	0.768	18.418	10.306
	3	Stack4 MLP _{global}	Stacking	0.767	18.433	10.229
IFN3	1	LightGBM	Base	0.898	10.641	4.687
	2	CatBoost	Base	0.896	10.737	4.789
	3	XGBoost	Base	0.895	10.761	4.713
	1	Stack4 MLP	Stacking	0.902	10.407	4.517
	2	Stack5 GradientBoosting	Stacking	0.901	10.433	4.540
	3	Stack5 MLP	Stacking	0.901	10.447	4.454
IFN2+IFN3	1	CatBoost _{global}	Base	0.845	13.846	6.615
	2	LightGBM _{global}	Base	0.841	14.006	6.654
	3	XGBoost _{global}	Base	0.840	14.054	6.655
	1	Stack5 MLP _{global}	Stacking	0.847	13.756	6.399
	2	Stack4 MLP _{global}	Stacking	0.847	13.766	6.429
	3	Stack4 Lin.Reg _{global}	Stacking	0.846	13.782	6.533

8. Discusión

En primer lugar se analizarán los modelos “globales”, es decir, aquellos entrenados con todos los datos (IFN2 e IFN3) al mismo tiempo. Posteriormente se analizarán los modelos entrenador solo con un inventario y se compararán con los globales.

8.1. Modelos globales

8.1.1. Variable c_4 (en toneladas de carbono por hectárea)

Modelos base

La variable periodo (el número de años entre la medición y la predicción) tiene una gran importancia en el estudio de los modelos. Es por esto que en la Figura 8.1a se incluyen métricas en función de esta variable, donde se muestra la evolución del RMSE y el %RMSE en cuantiles en función de la variable periodo, junto con un histograma que nos permite visualizar la cantidad de datos en el conjunto de entrenamiento para cada valor de periodo.

Podemos observar algo que podíamos prever: la dificultad de la predicción depende de una combinación entre cuán lejos se desea realizar la predicción y la calidad y cantidad de los datos de entrenamiento. Empezando en terreno del IFN3, podemos observar que para los primeros años (5, y 6), pese a tener pocos datos, los errores son comidos. A medida que aumenta el periodo (entre 10 y 17 años) los errores medios y medianos se mantienen relativamente estables pese a disponer de, en general, más datos de entrenamiento. Los errores grandes extremos (cuantil 90) experimentan un aumento generalizado. Cuando entramos en el rango de años donde los datos de entrenamiento proceden del IFN2 principalmente (el rango entre 20 y 30 años), aunque la mediana y los valores pequeños - medios (cuantil 25) se mantienen estables, los valores grandes - medios (cuantil 75) y los grandes (cuantil 90) aumentan en gran medida. Esto es un indicativo de que, aun disponiendo de una gran cantidad de datos de entrenamiento (especialmente para los años 27 y 28), la combinación entre la peor calidad de los datos (comparando siempre con el IFN3) y la predicción a valores lejanos dificultan la predicción del modelo. Además, como podemos observar en la Figura 6.2, los valores de los primeros años del IFN2 presentan una gran variabilidad, siendo en su mayoría valores más altos que los del IFN3 para esos mismos años, y con una mayor variabilidad. Esto, unido a que la cantidad de datos para esos años no es excesivamente grande, hace que el modelo obtenga peores predicciones.

El hecho de que los valores medianos se mantengan relativamente estables a lo largo de todos los periodos indica que el modelo asimila correctamente el comportamiento de la variable objetivo tanto con datos del IFN2 como del IFN3. Por otro lado, que los errores del cuantil 90 sean tan elevados se explica por varios factores: la alta variabilidad del conjunto de datos, el menor número de variables de campo recogidas en el IFN2 (lo que reduce la información disponible) y la mayor dificultad inherente a predecir a horizontes temporales lejanos. Esta combinación hace que

los casos particulares o atípicos sean menos reconocibles por el modelo, especialmente cuando proceden del IFN2, donde la capacidad de discriminación es menor que en el IFN3. La variabilidad mencionada se observa claramente en la Figura 8.2a, que muestra los valores predichos frente a los reales para el modelo con mejores métricas, junto con un histograma de distribución.

Modelos de stacking

La incorporación de esquemas de *stacking* no produce incrementos sustanciales, aunque sí sistemáticos, en el coeficiente de determinación respecto a los mejores modelos individuales. Fijándonos en la Tabla A.10 podemos observar que los modelos de stacking presentan mejores métricas en la gran mayoría de casos, siempre comparando con los modelos bases. Los mejores parámetros los obtiene el modelo de stacking con configuración 5, que mantiene todos los modelos con rendimiento competitivo, junto con el metamodelo de la red neuronal.

El hecho de que todos los ensembles mejoren a los modelos base es un síntoma de que esta mejora no es una excepción estadística, sino una mejora real. Esto es, no se trata de que las métricas sean mejores por estocasticidad de los parámetros del metamodelo, sino porque el montaje realmente mejora el resultado final. Obviamente, reentrenar los metamodelos con otros parámetros haría variar las métricas, pero el hecho es que la función de mejorar las predicciones realmente se alcanza con los ensembles. No obstante, la mejora es pequeña, lo que puede hacer que según el caso se prefiera la simplicidad de emplear uno de los modelos base en comparación con uno de los ensembles.

En la Figura 8.1b se muestra la evolución del RMSE y el RMSE porcentual en cuantiles para el modelo ensemble con mejores métricas, el stacking con configuración 5 y metamodelo MLP. Podemos observar que el comportamiento es prácticamente idéntico a aquel del LightGBM, el que obtuvo mejores métricas de los modelos base. Por otro lado, en la Figura 8.2b podemos observar el gráfico de puntos de las predicciones frente a los valores reales para el modelo de stacking con configuración 5 y metamodelo MLP para la variable c_4 (tC/ha).

En cuanto a la estructura de los ensambles, los mejores resultados se obtienen cuando se combinan modelos base de alta calidad y naturaleza similar (principalmente variantes de *gradient boosting*) y se emplean metamodelos con complejidad moderada, como MLP o SVR lineal. Por el contrario, los *stacks* con pocos modelos base o aquellos que incorporan metamodelos excesivamente flexibles, como Random Forest en el segundo nivel, tienden a ofrecer un rendimiento inferior, probablemente debido a la baja dimensionalidad del espacio de meta-predictores o a un sobreajuste innecesario del ruido residual.






Figura 8.1: Evolución del error absoluto y el error absoluto porcentual en cuantiles en función del periodo para los mejores modelos globales (IFN2+IFN3), base y de *stacking*, en cada variable objetivo.

8.1.2. Variable carbono_bruto4 (en toneladas de carbono)



Modelos base

De igual forma que en los apartados anteriores, en la Figura 8.1c se muestra la evolución del RMSE y el %RMSE en cuantiles en función de la variable periodo para el modelo CatBoost (aquel que obtuvo mejores métricas entre los modelos base) con IFN2 e IFN3 como explicativos para la variable en toneladas de carbono, junto con el histograma de distribución de los datos de entrenamiento en función de la variable periodo.

Atendiendo a la Figura 8.1c observamos el mismo comportamiento cualitativo que en el caso de la variable c4 (con la particularidad de que cambian las unidades y el rango de valores): el error entre los cuantiles 25 y 75 se mantiene en valores relativamente pequeños y constantes, si bien es verdad que empieza siendo menor y va aumentando ligeramente a medida que lo hace la variable periodo. Los errores extremos (cuantil 90) siguen siendo altos. De hecho, si nos fijamos en los valores más altos del RMSE porcentual para el cuantil 90, observamos que se alcanzan valores notablemente más altos que en el caso de la variable c4, llegando hasta el 130 % cuando para c4 apenas se superó


 (a) LightGBM_{global}, c4 (tC/ha).


(b) Stacking global (Conf. 5, MLP), c4 (tC/ha).


 (c) CatBoost_{global}, carbono_bruto4 (tC).


(d) Stacking global (Conf. 5, MLP), carbono_bruto4 (tC).

Figura 8.2: Densidad de predicciones frente a valores reales para los mejores modelos globales (IFN2+IFN3), base y de *stacking*, en cada variable objetivo.

el 100 % para el peor de los casos. Esto es de destacar, ya que las métricas globales para las predicciones de la variable carbono_bruto4 (ver Tabla A.11) son sistemáticamente mejores que las de la variable c4 (ver Tabla A.9). Esto es, la variable carbono_bruto4 (toneladas) es más fácil de predecir en general para los modelos que la variable c4 (toneladas por hectárea), pero ocurre lo contrario en los casos particulares, donde los errores más altos se disparan de una manera más exagerada que en el mismo caso para la variable c4. También se observa el aumento del error al pasar del rango de años del IFN2 a IFN3, causado por el aumento de la variabilidad de los datos del segundo inventario (ver Figura 6.2).

Al igual que en los apartados anteriores, en la Figura 8.2c podemos observar un scatter plot de las predicciones frente

a los valores reales para el modelo CatBoost del caso que estamos considerando.

Modelos con stacking

Los resultados obtenidos en este apartado son muy similares a aquellos que se han obtenido con los modelos stacking para la variable c4 (tC/ha). Esto es, encontramos una mejora sistemática en todos los modelos de stacking frente a los base, pero esa mejora es pequeña. Esto causa que los resultados sean estrictamente mejores, como se puede ver en la Tabla A.12 comparando con las métricas de los modelos base de la Tabla A.11. De nuevo, que la mejora de los modelos stacking respecto a los base sea sistemática indica

que no nos encontramos frente a un incidente estadístico, sino que el formato del stacking es capaz de mejorar las predicciones de los modelos escogiendo las mejores decisiones de cada uno de ellos. No obstante, como ya se comentó anteriormente, la complejidad de entrenar cinco modelos además del metamodelo puede resultar incómoda frente a la posibilidad de usar, por ejemplo, el mejor de los modelos individuales.

El modelo ensemble que mejores métricas proporciona para la predicción de la variable `carbono_bruto4` (tC) es la configuración 5 y metamodelo MLP, al igual que ocurrió con la variable `c4` (tC/ha). La evolución del RMSE y el RMSE porcentual en cuantiles en función de la variable `periodo` para este modelo se puede visualizar en la Figura 8.1d.

Por otro lado, en la Figura 8.2d se muestra un scatter plot de las predicciones frente a los valores reales para el modelo de stacking con configuración 5 y metamodelo MLP y la variable `carbono_bruto4` (tC).

8.2. Modelos individuales entrenados solo con el IFN2 o IFN3.

Al comparar el rendimiento de los modelos “globales” (entrenados con el conjunto combinado de IFN2 e IFN3) frente a los modelos “locales” (entrenados exclusivamente con IFN2 o IFN3), se observa un comportamiento diferenciado según el inventario de prueba. En el caso del IFN3, los modelos locales superan a los globales en términos de métricas de precisión. Por el contrario, para el IFN2, los modelos globales muestran un desempeño superior.

Una posible explicación para este fenómeno radica en la calidad y cantidad de información contenida en cada inventario. Los datos del IFN2, al ser menos informativos o presentar menos variables, parecen beneficiarse del aprendizaje conjunto con los del IFN3, lo que permite a los modelos capturar patrones adicionales y mejorar su capacidad de generalización sobre el segundo inventario. En cambio, para el IFN3, cuyos datos poseen una mayor calidad intrínseca, la inclusión de registros del IFN2 durante el entrenamiento podría estar introduciendo ruido o variabilidad no deseada, lo que acaba penalizando la precisión de las predicciones del modelo final sobre este conjunto.

En la Figura 8.3a se muestra una comparativa entre los mejores modelos base globales vs. locales (arriba), mejores modelos de stacking globales vs. locales (medio) y mejor modelo base vs. mejor modelo de stacking (abajo). Observamos que en general los errores menores para el IFN2 los cometen los modelos globales, mientras que para el IFN3 son los locales los que realizan un mejor trabajo.

8.2.1. Asimilación del comportamiento de las variables objetivo

Con las métricas que hemos planteado y el análisis que se ha hecho en esta sección parece claro que, si bien los resultados no son ni mucho menos perfectos, los modelos son capaces de entender la lógica y el significado de cada variable para obtener una predicción con un grado de acierto que depende de la naturaleza de la instancia que se trate. Otra

prueba que podemos hacer para comprobar si los resultados de los modelos son lógicos es la que mostramos en las Figuras 8.4 y 8.5. Estas figuras muestran la evolución de varios casos particulares a medida que avanza el tiempo entre medida y predicción. Los casos seleccionados son reales dentro de los datos disponibles. Se seleccionaron con la idea de mostrar cómo se comportan los modelos para configuraciones de carbono inicial más o menos comunes. Para ello se sumaron, para cada instancia de los datos, las variables `npies_x`, y luego se seleccionaron los valores más cercanos a los percentiles 10, 35, 65 y 90 para la variable resultante. Así evitamos posibles problemas fruto de seleccionar ejemplos poco realistas.

Podemos señalar las siguientes características:

- Las líneas de los modelos base y los ensembles para cada caso están muy cerca una de la otra, lo que concuerda con las métricas obtenidas, que eran muy similares entre sí.
- La tendencia general es ascendente, es decir, los modelos capturan de forma correcta el comportamiento del crecimiento de los árboles con el tiempo para los años estudiados.
- En el año 17 tenemos un crecimiento abrupto generalizado, el cual es más exagerado cuanto más pequeño es el percentil del caso de estudio. Esto es sencillo de entender mirando a los datos, ya que los valores de la variable a predecir experimentan un aumento generalizado al pasar de los años del IFN2 a aquellos del IFN3, como se puede ver en la Figura 6.2. Este cambio (que el modelo empiece a ingerir datos del IFN2 en lugar del IFN3) ocurre principalmente en el año 17. Esto puede verse en el histograma de la Figura 8.1d, por ejemplo. La razón por la que ocurre el salto a percentiles pequeños es porque estos valores pequeños en los datos del IFN2 apenas existen o son menos comunes. El modelo ha visto que para esos años los valores de carbono son, en general, mayores, y eso es lo que predice. De hecho, en la Figura 6.2 se observa que para los años iniciales de los datos del IFN2 los valores de carbono aumentan para luego disminuir, y esto es justo lo que vemos en las predicciones: un aumento y una posterior disminución.
- También podemos ver una subida abrupta en muchos casos al pasar del año 29 al 30, sobre todo en el caso de la variable en toneladas de carbono bruto (Figura 8.5). Estos años coinciden con una carencia de datos, como podemos ver en el histograma de la Figura 6.2. Es de esperar que las predicciones de esos años sean menos fiables, sobre todo siendo un valor extremo.

8.2.2. Rendimiento de los modelos en función del valor de la variable objetivo

Si se analizan las métricas globales de las tablas de la sección 7 nos damos cuenta de que los valores del RMSE son notablemente mayores que los valores de MAE, concretamente cerca del doble en la mayoría de casos. Debido a que el RMSE penaliza mucho más los errores grandes que

Estimación del stock de carbono forestal en España




Figura 8.3: Comparación del error absoluto por inventario y variable objetivo: mejores modelos base globales vs. locales, stacking globales vs. locales, y mejor modelo base vs. mejor stacking.

el MAE, esto es indicativo de la presencia de outliers en el error. Ya hemos visto a lo largo de esta sección que los mayores errores ocurren en el rango de años en que el IFN2 es la principal fuente de datos como podemos ver en las Figuras 8.1a, 8.1b, 8.1c y 8.1d, y la principal conclusión que podemos sacar es que la calidad o cantidad de información contenida en este inventario es peor. No obstante, esto no responde del todo a la pregunta de en qué casos el modelo predice mejor, salvo la obviedad de que la predicción será mejor cuanto más cerca esté en el tiempo y más datos haya de ese año. Es por esto que las Figuras 8.6 y 8.7 nos pueden ser útiles. Estas figuras muestran la distribución de errores, concretamente el RMSE y el SMAPE, en función de la

variable objetivo para c4 y carbono_bruto4 respectivamente, en deciles para los modelos base.

Rápidamente nos damos cuenta de lo siguiente: las predicciones para valores pequeños de carbono objetivo (primeros deciles) son malas (SMAPE grande) pese a ser aquellas con un error absoluto menor (RMSE pequeño). Luego, a medida que aumenta el carbono objetivo, el RMSE aumenta ligeramente mientras que el SMAPE disminuye mucho más rápido, llegando a valores cercanos al 25 %. En ambos casos los mejores resultados se logran cuando el carbono objetivo es mayor, pese a que observamos un aumento significativo del RMSE entre el penúltimo y último decil. Como esto se produce para todos los modelos, sugiere que la dificultad de predicción no es homogénea para todas las situaciones




Figura 8.4: Evolución de la cantidad de carbono en toneladas por hectárea (c4) para varios escenarios.




Figura 8.5: Evolución de la cantidad de carbono en toneladas (carbono_bruto4) para varios escenarios.

o cantidades de carbono, y que pese a ser los percentiles de menor carbono aquellos con un RMSE menor, la precisión de los modelos no es la suficiente como para hacer una predicción decente en situaciones con poca biomasa. Esto era predecible, ya que un error absoluto mayor para una parcela de bosque mayor no implica necesariamente un peor error relativo.

También es llamativo el hecho de que los deciles iniciales tienen unos rangos de carbono muy cercanos, sobre todo




Figura 8.6: Distribución del SMAPE y RMSE en función de la variable objetivo para c4 en deciles.




Figura 8.7: Distribución del SMAPE y RMSE en función de la variable objetivo para carbono_bruto4 en deciles.

en el caso de la variable carbono_bruto4, donde el primer decil abarca desde 0,0003 tC hasta 0,0020 tC. Esta gran cantidad de valores no sirve a los modelos para obtener una buena predicción, por otra parte. Las densidades mayores para valores pequeños de carbono se ven claramente en las Figuras 8.2a, 8.2b, 8.2c y 8.2d.

8.3. Interpretabilidad de los modelos: análisis SHAP

Gracias al análisis de valores SHAP podemos añadir explicabilidad a los modelos, averiguando a qué variables da más importancia el modelo y en qué casos estos valores hacen que la predicción del carbono sea mayor o menor. En la Tabla 8.1 podemos observar el puesto medio de importancia de las variables con mayor valor SHAP en valor absoluto, tanto promediado en todos los casos (primera columna “Mean”) como por inventario fuente y variable objetivo. En esta tabla vemos que las variables más importante consistentemente son npies, especie_id, ocupa y radio, es decir, variables puramente relacionadas con la estructura

Tabla 8.1

Mean SHAP rank per variable across LightGBM, XGBoost, CatBoost, GBDT and MLP (n=2000 samples; rank 1 = most important).

Variable	Mean	IFN2 c4	IFN2 carbono_b4	IFN3 c4	IFN3 carbono_b4	IFN2+3 c4	IFN2+3 carbono_b4
npies* (Density)	1	1	1	1	1	1	1
especie_id*	2.2	2	2	2.2	2.8	2.2	2.2
ocupa	2.9	3.2	3	3	2.2	2.8	3
radio	4.2	4.2	4.2	4.2	4.2	4.2	4.4
gndvi_mean_verano	6.5	5.6	5	7	7	8	6.6
tipo_especie*	7.1	11.6	8.8	4.6	5.8	6	6
periodo_agrupado	8.4	13	8	10.6	8.6	5.2	5
skt_mean_verano	9.6	6.8	—	10.4	—	11.6	—
rocosidad_id*	11	9	7.6	17.2	12	10.2	9.8
fccarb	11.4	—	—	9	10	14	12.6
evi_mean_primavera	11.8	12	10.6	13.6	11.2	13.2	10.4
elevacion	12.6	12.6	7.4	15.8	12.8	14.4	12.4
tratmasa_id*	13.2	—	—	8	7.2	18.8	18.8
estado_id*	13.5	21.8	12.8	17.2	12.6	8.8	8
ndii_mean_primavera	14.5	17	11.6	14.2	15.6	15.4	13.4
skt_mean_primavera	15.1	17.4	—	13.4	—	14.6	—
pr_sum_otoño	15.7	16.4	—	14.4	—	16.4	—
pr_sum_primavera	15.7	10.6	—	17.6	—	19	—
pr_sum_invierno	16	8.6	—	21.8	—	17.6	—
martonneidx_id*	16.4	18.2	10.2	24.2	13.4	20.6	11.8
skt_std_verano	18.4	13.2	—	22.8	—	19.2	—
skt_std_primavera	18.4	15.8	—	20	—	19.4	—
orientacion_cat*	18.9	19.8	14.4	23	17	21.4	18
modcomb_id*	18.9	—	—	18.8	14	26	16.8
gndvi_std_primavera	19.8	20.8	14.6	24	18	24.8	16.6
pendiente_cat*	20	20.4	15.4	26.2	18	23.8	16.4
pr_sum_verano	20.3	19.4	—	21.2	—	20.4	—
nivel2_id*	20.6	—	—	20.6	17.2	27	17.6
disesp_id*	23.3	24.6	16.4	29	20.4	29	20.2

del bosque. El resto de variables de la tabla tiene más variabilidad a lo largo de las distintas configuraciones, donde se van intercalando variables meteorológicas (que parecen ser más importantes que la variable climática que hemos añadido, el índice de Martonne) y edáficas, principalmente.

La variable meteorológica que consistentemente tiene más importancia según nuestro análisis es el valor medio del índice GNDVI en verano (*gndvi_mean_verano*), que destacada tanto por posición como por consistencia. Esto es esperado, ya que es en verano cuando la vegetación forestal tiene un mayor vigor, y el índice GNDVI es un indicador más útil en esta época comparado con otros con el NDVI, ya que no tiene problemas de saturación en doseles densos [33, 19]. Además, este índice sirve para estimar la actividad fotosintética, variable directamente relacionada tanto con la cantidad de vegetación como con la salud de esta.

En las Figuras 8.8, 8.9 y 8.10 podemos ver una comparación entre los variables SHAP de las distintas configuraciones para el modelo LightGBM y la variable objetivo *c4*. Hay que destacar que para las dos variables más importantes para el análisis (*npies*, *especie_id* y *ocupa*) la escala del eje x es distinta que para el resto, ya que su valor SHAP es notablemente mayor. Se hizo así para facilitar la visualización. Las variables cuyo está coloreado son variables categóricas (señaladas también con un asterisco, *), y su color indica el tratamiento que se ha hecho para incluirla en la figura. En primer lugar, está *npies*. Esta variable son en realidad

varias, una para cada clase diamétrica (*npies_5*, *npies_10*, *npies_15*, etc). El color del texto verde indica que para cada clase diamétrica se ha hecho el análisis individualmente y luego se han juntado todas en la misma fila del gráfica. Esto es, cuando el color del punto indica que el valor de la variable es “alto”, esto está normalizado a cada clase diamétrica, ya que un valor alto de la variable *npies_5* no es comparable con un valor alto de *npies_70*. El color del texto morado indica que la variable categórica es solo nominal, es decir, no tiene ningún orden pese a que al modelo se le haya pasado codificada en formato numérico. Esto ocurre con la variable *especie_id*, donde un valor numérico más alto no indica, por ejemplo, una absorción de carbono mayor. En este caso, el color de cada punto expresa la media de la variable objetivo para cada especie, de forma que todos los puntos de la misma especie tendrán el mismo color. Esto en muchos casos un resultado obvio: las especies que más carbono absorben serán las que tienen un mayor valor SHAP, y por tanto se localizarán en general a la derecha (como en efecto sucede). No obstante, es la única manera que se ha encontrado para incluir a esta variable en la figura, ya que tenía que estar presente por su elevada importancia para el modelo. Si el color del texto es naranja significa que la variable categórica es ordinal. Esto es, la categoría sigue un orden que tiene sentido representar por colores. Por ejemplo, la variable *rocosidad_id* va del valor 1, “sin pedregosidad”, al 5, “roqueado”, teniendo relación el aumento de la variable




Figura 8.8: Análisis SHAP para el modelo LightGBM entrenado con datos del IFN2 y con variable objetivo c_4 (tC/ha).




Figura 8.10: Análisis SHAP para el modelo LightGBM entrenado con datos del IFN2 y IFN3 y con variable objetivo c_4 (tC/ha).




Figura 8.9: Análisis SHAP para el modelo LightGBM entrenado con datos del IFN3 y con variable objetivo c_4 (tC/ha).

con un aumento en la característica que indica. Por último, el color de texto negro indica que la variable es continua y se trata como se espera.

En las Figuras 8.8, 8.9 y 8.10 vemos que las dos variables más importantes siempre son *npies* y *especie_id*, como habíamos visto en la Tabla 8.1. El resto de variables cambian de orden en función del caso, pero si hablamos del conjunto, las variables identificadas como importantes suelen ser comunes en los tres casos de las Figuras. Es de señalar que, aunque las posiciones de las variables no coinciden exactamente entre los casos del modelo entrenado únicamente con los datos del IFN2 (Figura 8.8) y el modelo entrenado con los datos del IFN2 e IFN3 (Figura 8.10), las variables presentes en el top 15 expuesto son, en total, las prácticamente las mismas (a excepción de *tratmasa_id*) y *estado_id* que se intercambian. Aparecen además variables exclusivas del IFN3, como *tratmasa_id*, lo que indica que estas nuevas variables que se han ido incorporando a los

inventarios dan información útil para el estudio del bosque, y en concreto para estudiar la captura de carbono.

Si atendemos a los valores de las Figuras 8.8, 8.9 y 8.10 podemos destacar algunos resultados interesantes que apoyan la idea de que el modelo ha incorporado correctamente la información:

- Si atendemos a la variable *npies*, observamos que un valor mayor de árboles iniciales se corresponde con un mayor valor SHAP, es decir, de carbono.
- Como hemos dicho antes, para la variable *gndvi_mean_verano* obtiene un mayor índice SHAP para aquellos casos en los que su valor es también mayor. Esto es lógico, ya que el índice GNDVI mide la actividad fotosintética. Un valor mayor de este índice se corresponde con mayor presencia de vegetación activa, y por tanto mayor captura de carbono.
- La variable *periodo_agrupado* indica el número de años entre la medición y el momento en que queremos hacer la estimación, por lo que es de esperar que un valor mayor se corresponda con un mayor valor SHAP, es decir, de carbono. Esto es lo que nos encontramos para el caso del IFN3 (Figura 8.9) e IFN2 y 3 (Figura 8.10). Curiosamente, para el caso de IFN2 (Figura 8.8) esta relación no queda tan clara, caso en que además coincide con que el modelo SHAP le da una menor importancia relativa.
- La variable *tipo_especie* tiene una distinción muy clara en todos los casos. Esta es una variable binaria en la que el valor 0 corresponde a coníferas y el valor 1 corresponde a frondosas. Según el análisis, las especies de tipo frondosa obtiene en promedio un mayor índice SHAP, es decir, mayor cantidad de carbono asociado. Esto está de acuerdo con la literatura, y en concreto con estudios realizados con el Inventario Forestal Nacional Español, que cuantifican el *stock* de carbono medio en masas de frondosas en $48,5 \pm 0,3$




Figura 8.11: Análisis SHAP para el modelo LightGBM entrenado con datos del IFN2 e IFN3 y con variable objetivo c_4 (tC/ha) centrandonos en las especies. Se distingue entre conífera o frondosa.

Mg/ha frente a $41,8 \pm 0,2$ Mg/ha en coníferas para la España peninsular [34].

Para mayor detalle, en la Figura 8.11 se presenta un desglose del índice SHAP por especie para el modelo LightGBM entrenado con datos de ambos inventarios y con c_4 como variable objetivo. Se observa que las frondosas ocupan casi todos los puestos en los que el carbono aumenta, destacando como primera especie el *Eucalyptus globulus*, especie que lleva años causando revuelo en el norte de España por su posible caracterización como especie invasora [35, 36]. No obstante, cabe señalar que este resultado refleja la biomasa inventariada en el IFN, y no implica que el eucalipto sea la opción más adecuada desde una perspectiva de gestión forestal sostenible, dado su alto consumo hídrico, su asociación con un mayor riesgo de incendio, la pérdida de biodiversidad que puede traer asociada, la dificultad de erradicación o el peligro asociado de la introducción involuntaria de especies asociadas, como insectos u hongos, desplazando otras especies nativas [35, 37, 38].

En resumen, el análisis SHAP no solo permite identificar qué variables son más relevantes para la predicción del carbono y cuantificar su importancia relativa, sino que también constituye una herramienta de validación ecológica del modelo. Los resultados obtenidos son coherentes con el conocimiento disponible en la literatura: variables como la densidad de pies, la actividad fotosintética, el tipo de especie o el tiempo transcurrido entre inventarios presentan el sentido esperado en sus valores SHAP, lo que indica que el modelo ha incorporado correctamente la información de entrada y que sus predicciones responden a procesos ecológicos reales.

9. Conclusiones

El objetivo principal de este trabajo es el desarrollo de modelos de inteligencia artificial capaces de predecir el carbono que una parcela forestal capturará en un horizonte temporal determinado, a partir de información estructural, edáfica, climática y espectral recogida en los Inventarios Forestales Nacionales y en fuentes de datos auxiliares. Los resultados obtenidos permiten afirmar que dicho objetivo se ha alcanzado de manera satisfactoria.

Selección de variables y preprocesamiento

El proceso de selección manual de variables (sección 6.1) permitió reducir un conjunto inicial de 445 predictores candidatos a un subconjunto compacto de 44 variables, manteniendo una representación equilibrada de todos los ámbitos ecológicos implicados: estructura de masa, composición de especie, propiedades edáficas, terreno, climatología e índices de vegetación espectral. Esta reducción no solo facilitó el entrenamiento de modelos más eficientes, sino que garantizó la interpretabilidad ecológica de los predictores seleccionados.

Rendimiento de los modelos

Los modelos entrenados con los datos del IFN3 como variables explicativas obtienen, en general, las mejores métricas (véanse Tabla 7.1). Esto se explica por la mayor calidad, homogeneidad metodológica y riqueza de variables recogidas en este inventario frente al IFN2.

En cuanto a la variable objetivo, la predicción del carbono en toneladas absolutas (carbono_bruto4) resulta sistemáticamente más precisa en términos de métricas globales que la predicción del carbono por unidad de superficie (c_4 , tC/ha), como se puede observar comparando la Tabla 7.1. Sin embargo, el análisis por deciles (Figuras 8.6 y 8.7) revela que para instancias con valores de carbono muy bajos (primera biomasa), los errores relativos (SMAPE) son elevados en ambas variables con independencia del modelo empleado. Los modelos ofrecen sus mejores resultados en el rango intermedio-alto de biomasa, donde el balance entre cantidad de datos, variabilidad intrínseca y magnitud de la variable objetivo es más favorable.

El análisis de la variable periodo (Figuras 8.1a, 8.1b, 8.1c y 8.1d) muestra que el error crece con el horizonte temporal de predicción, especialmente cuando los datos de entrenamiento proceden del IFN2 (periodos superiores a 17 años). No obstante, los errores medianos (cuantil 50) se mantienen relativamente estables a lo largo de todos los periodos, lo que indica que los modelos asimilan correctamente el comportamiento medio del crecimiento forestal incluso para horizontes largos. Los errores extremos (cuantil 90) son los más sensibles a la calidad de los datos y al alejamiento temporal.

El análisis de sensibilidad sobre escenarios representativos (Figuras 8.4 y 8.5) confirma que los modelos capturan de forma cualitativamente correcta la dinámica de crecimiento: la tendencia general es ascendente con el periodo, y los modelos reproducen los efectos de los cambios de inventario (IFN2 a IFN3) observados en los datos reales.

Modelos globales frente a modelos locales

La comparación entre modelos “globales” (entrenados con IFN2 e IFN3 conjuntamente) y “locales” (entrenados con un único inventario), mostrada en las Figuras 8.3a–8.3d y en la Tabla 7.1, revela un comportamiento diferenciado según el inventario de validación. Para el IFN3, los modelos locales superan a los globales, ya que la inclusión de datos del IFN2 introduce heterogeneidad que penaliza la predicción sobre datos de mayor calidad. Para el IFN2, en cambio, los modelos globales son superiores, pues se benefician de los patrones adicionales aprendidos con los datos del IFN3. Este resultado subraya que la elección del conjunto de entrenamiento debe adaptarse al horizonte temporal y al inventario de aplicación.

Modelos de *stacking*

La incorporación de esquemas de *stacking* produce mejoras sistemáticas pero modestas respecto a los mejores modelos base (véanse Tabla 7.1). El conjunto de *stacking* con configuración 5 y metamodelo MLP es, de forma consistente, el que mejores métricas obtiene tanto para *c4* como para *carbono_bruto4*. El hecho de que la mejora sea sistemática en todos los casos descarta que se trate de un artefacto estadístico, pero su magnitud limitada plantea la pregunta de si la complejidad adicional del *stacking* está justificada frente al uso del mejor modelo individual en un hipotético sistema en producción. Los algoritmos basados en *gradient boosting*, especialmente CatBoost y LightGBM, son los que ofrecen el mejor rendimiento como modelos base en todos los escenarios evaluados.

Interpretabilidad

El análisis de valores SHAP (sección 8.3, Tabla 8.1) confirma que las variables estructurales del arbolado —densidad de pies (*npies*), especie (*especie_id*), fracción de cabida cubierta (*ocupa*) y radio de parcela (*radio*)— son los predictores dominantes con independencia del inventario fuente o la variable objetivo considerada. Entre las variables auxiliares, el índice GNDVI estival (*gndvi_mean_verano*) emerge como el predictor espectral más informativo, coherente con su capacidad de estimar la actividad fotosintética sin saturación en doseles densos. El sentido de los valores SHAP es en todos los casos consistente con el conocimiento ecológico disponible: mayor densidad arbórea, mayor actividad fotosintética y mayor horizonte temporal conllevan mayor carbono predicho; las frondosas superan sistemáticamente a las coníferas, en línea con los *stocks* medios reportados en la literatura para la España peninsular [34]. Ello indica que los modelos no solo son precisos numéricamente, sino que han aprendido relaciones con significado ecológico real, lo

que refuerza su interpretabilidad y confianza de cara a una posible aplicación práctica.

Comparación con la literatura

En trabajos similares, como el de Fasihi et al. [26] para el norte de Italia, se predicen valores de carbono forestal a partir de observaciones de teledetección sin uso de datos de campo medidos in situ. Aunque el contexto es distinto —ellos predicen el carbono presente en el momento de la medición, sin proyección temporal— los errores que reportan son notablemente superiores a los obtenidos en este trabajo, especialmente en el rango de predicción más corto (alrededor de 5 años), que es el más comparable. Esto pone de manifiesto el valor añadido de incorporar información estructural de campo (IFN) frente a enfoques basados exclusivamente en teledetección.

Limitaciones

La principal limitación del estudio reside en la heterogeneidad e irregularidad de los datos disponibles. La distribución de instancias en función de la variable periodo es muy desigual: algunos años cuentan con miles de muestras mientras que otros tienen apenas unas pocas decenas. Esta irregularidad, inherente a la naturaleza de los Inventarios Forestales (levantados en periodos de tiempo distintos y con metodologías que evolucionan entre iteraciones), limita la capacidad del modelo para ciertos horizontes temporales, sobre todo en el rango de años con menos datos y donde la fuente principal es el IFN2. Pese a ello, los modelos demuestran capacidad de generalización razonable incluso en estas condiciones.

Trabajo futuro y aplicabilidad

De cara a una posible aplicación en producción como sistema de apoyo a la recomendación de proyectos de carbono, sería necesario evaluar en qué medida las parcelas del IFN son representativas de plantaciones forestales destinadas a créditos de carbono, que pueden diferir en densidad, manejo y composición. Una extensión natural del modelo sería incorporar datos LiDAR, cuya capacidad para caracterizar la estructura tridimensional del dosel forestal ha demostrado en otros estudios mejorar significativamente las predicciones de biomasa y carbono [15]. Igualmente, la adaptación del modelo a otros contextos geográficos o su integración con datos del IFN4 como variable objetivo constituyen líneas de trabajo prometedoras.

Agradecimientos

Investigación financiada por la subvención **TSI-100933-2023-1** de la **Convocatoria de Cátedras Universidad-Empresa (Cátedras ENIA 2022)**, **Ministerio de Transformación Digital y Función Pública de España**, y el **Plan de Recuperación y Resiliencia de la UE (NextGenerationEU/PRTR)**.

Referencias

- [1] I. P. on Climate Change, Climate Change 2007: Mitigation of Climate Change, Cambridge University Press, Cambridge, UK, 2007.
- [2] U. N. F. C. on Climate Change, The Kyoto protocol, 1997. URL: <https://unfccc.int/resource/docs/convkp/kpeng.pdf>.
- [3] U. N. F. C. on Climate Change, Paris agreement, 2015. URL: <https://unfccc.int/process-and-meetings/the-paris-agreement/the-paris-agreement>.
- [4] U. N. F. C. on Climate Change, Decision 16/cmp.1: Land use, land-use change and forestry, Conference of the Parties serving as the meeting of the Parties to the Kyoto Protocol, 2005. URL: <https://unfccc.int/resource/docs/2005/cmp1/eng/08a03.pdf>, acuerdos de Marrakech.
- [5] U. N. F. C. on Climate Change, Report of the individual review of the initial report of Spain under the Kyoto protocol, UNFCCC Secretariat, 2010. URL: https://unfccc.int/files/kyoto_protocol/compliance/plenary/application/pdf/cc-ert-irr-2007-14_report_of_the_review_of_ir_of_spain.pdf, incluye la definición nacional de bosque de España: 1 ha, 20 % de cabida cubierta, 3 m de altura.
- [6] E. Union, Regulation (eu) 2018/841 on the inclusion of greenhouse gas emissions and removals from land use, land use change and forestry, Official Journal of the European Union, 2018. URL: <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX:32018R0841>, marco LULUCF y principios de permanencia y contabilidad de sumideros.
- [7] MITECO, Inventario forestal nacional (ifn2, ifn3, ifn4): metodología y bases de datos, Ministerio para la Transición Ecológica y el Reto Demográfico (España), 2023. URL: <https://www.miteco.gob.es/es/biodiversidad/servicios/banco-datos-naturaleza/informacion-disponible/ifn.aspx>.
- [8] J. Muñoz-Sabater, E. Dutra, A. Agustí-Panareda, C. Albergel, G. Arduini, G. Balsamo, et al., Era5-land: A state-of-the-art global reanalysis at land surfaces, EGU General Assembly / ECMWF (Copernicus Climate Data Store) (2021).
- [9] USGS, Landsat collection 2 level-2 science products: Surface reflectance, U.S. Geological Survey, 2021. URL: <https://www.usgs.gov/landsat-missions/landsat-collection-2-level-2-science-products>.
- [10] M. A. U. Jiménez, J. G. Vegas, A. de Luis Reboledo, B. P. Lancho, Greenwest-db: Base de datos integrada de atributos forestales, climáticos y espectrales para España, 2025. Manuscrito en preparación. Universidad de Salamanca, Grupo BISITE.
- [11] C. Brack, History of inventory, 2000. URL: <https://fennerschool-associated.anu.edu.au/mensuration/history.htm>, accessed: 2026-01-22.
- [12] L. Shi, S. Liu, Methods of estimating forest biomass: A review, Biomass Volume Estimation and Valorization for Energy 10 (2017) 65733.
- [13] Y. Shang, Y. Xia, X. Ran, X. Zheng, H. Ding, Y. Fang, Allometric equations for aboveground biomass estimation in natural forest trees: Generalized or species-specific?, Diversity 17 (2025) 493.
- [14] L. Qi, X. Liu, Z. Jiang, X. Yue, Z. Li, J. Fu, G. Liu, B. Guo, L. Shi, Combining diameter-distribution function with allometric equation in biomass estimates: a case study of *Phyllostachys edulis* forests in south anhui, China, Agroforestry Systems 90 (2016) 1113–1121.
- [15] J. Nyakudanga, The treemes story, 2018. URL: <https://saforestryonline.co.za/articles/the-treemes-story/>.
- [16] A. Kristiansen, The terrestrial laser scanning revolution in forest ecology, Royal Society Blog, 2018. URL: <https://royalsociety.org/blog/2018/02/the-terrestrial-laser-scanning-revolution-in-forest-ecology/>.
- [17] OpenTopography, What is lidar?, OpenTopography, 2024. URL: https://opentopography.org/lidar_basics.
- [18] J.-R. Roussel, T. R. Goodbody, P. Tompalski, Individual tree detection and segmentation, 2024. URL: <https://r-lidar.github.io/lidRbook/itd.html>.
- [19] Instituto Geográfico Nacional, Tercera cobertura PNOA-LiDAR, Plan Nacional de Ortofotografía Aérea, 2023. URL: <https://pnoa.ign.es/web/portal/pnoa-lidar/tercera-cobertura>.
- [20] S. J. Goetz, A. Baccini, N. T. Laporte, T. Johns, W. Walker, J. Kellndorfer, R. A. Houghton, M. Sun, Mapping and monitoring carbon stocks with satellite observations: a comparison of methods, Carbon Balance and Management 4 (2009) 2.
- [21] J. Ren, L. Liu, Y. Wu, L. Ouyang, Z. Yu, Estimating forest carbon stock using enhanced resnet and sentinel-2 imagery, Forests 16 (2025) 1198. Submission received: 13 June 2025 / Revised: 15 July 2025 / Accepted: 18 July 2025 / Published: 20 July 2025.
- [22] F. Jiang, M. Deng, J. Tang, L. Fu, H. Sun, Integrating spaceborne lidar and sentinel-2 images to estimate forest aboveground biomass in northern China, Carbon Balance and Management 17 (2022) 12.
- [23] G. Reiersen, D. Dao, B. Lütjens, K. Klemmer, K. Amara, A. Steinegger, C. Zhang, X. Zhu, Reforestree: A dataset for estimating tropical forest carbon stock with deep learning and aerial imagery, arXiv preprint arXiv:2201.11192 (2022).
- [24] W. Dong, E. T. Mitchard, H. Yu, S. Hancock, C. M. Ryan, Forest aboveground biomass estimation using GEDI and earth observation data through attention-based deep learning, arXiv preprint arXiv:2311.03067 (2023).
- [25] Ministerio para la Transición Ecológica y el Reto Demográfico, Instrucciones de uso de la calculadora de absorciones de CO₂ ex ante de las especies forestales arbóreas españolas del Ministerio para la Transición Ecológica y el Reto Demográfico, 2023. URL: https://www.miteco.gob.es/content/dam/miteco/es/cambio-climatico/temas/mitigacion-politicas-y-medidas/instruccionescalculadoraabaxante_tcm30-485629.pdf, accedido: 2025-07-16.
- [26] M. Fasihi, B. Portelli, L. Cadez, A. Tomao, A. Falcon, G. Alberti, G. Serra, Assessing ensemble models for carbon sequestration and storage estimation in forests using remote sensing data, Ecological Informatics 83 (2024) 102828.
- [27] J. Muñoz Sabater, Era5-land hourly data from 1950 to present, Copernicus Climate Change Service (C3S) Climate Data Store (CDS), 2019. URL: <https://cds.climate.copernicus.eu/cdsapp#!/dataset/reanalysis-era5-land?tab=overview>. doi:10.24381/cds.e2161bac, accedido: 07-07-2025.
- [28] P. Berg, C. Photiadou, L. Simonsson, E. Sjökvist, J. Thureson, R. Mook, Temperature and precipitation climate impact indicators from 1970 to 2100 derived from European climate projections, Copernicus Climate Change Service (C3S) Climate Data Store (CDS), 2021. URL: <https://cds.climate.copernicus.eu/cdsapp#!/dataset/sis-water-quantity-change?tab=overview>. doi:10.24381/cds.9eed87d5, accedido: 07-07-2025.
- [29] USGS, Usgs Landsat 5 level 2, collection 2, tier 1, 2025. URL: https://developers.google.com/earth-engine/datasets/catalog/LANDSAT_LT05_C02_T1_L2, accedido: 2025-07-08.
- [30] I. P. on Climate Change, 2006 IPCC Guidelines for National Greenhouse Gas Inventories, IPCC, Geneva, Switzerland, 2006.
- [31] J. Chave, M. Réjou-Méchain, A. Búrquez, E. Chidumayo, M. S. Colgan, W. B. C. Delitti, A. Duque, T. Eid, P. M. Fearnside, R. C. Goodman, M. Henry, A. Martínez-Yrizar, W. A. Mugasha, H. C. Muller-Landau, M. Mencuccini, B. W. Nelson, A. Ngomanda, E. M. Nogueira, E. Ortiz-Malavassi, R. Pélissier, P. Ploton, C. M. Ryan, J. G. Saldarriaga, G. Vieilledent, Improved allometric models to estimate the aboveground biomass of tropical trees, Global Change Biology 20 (2014) 3177–3190.
- [32] M. para la Transición Ecológica y el Reto Demográfico (MITECO), Guía para la estimación de absorciones de dióxido de carbono, 2021. URL: https://www.miteco.gob.es/content/dam/miteco/es/cambio-climatico/temas/mitigacion-politicas-y-medidas/guiapa_tcm30-479094.pdf.
- [33] K. Sergieieva, Índices de vegetación y su aplicación en la agricultura digital, EOS Data Analytics, 2025. URL: <https://eos.com/es/blog/indices-de-vegetacion/>.
- [34] J. Vayreda, M. Gracia, J. G. Canadell, J. Retana, Spatial patterns and predictors of forest carbon stocks in Western Mediterranean, Ecosystems 15 (2012) 1258–1270.

- [35] Comité Científico del Comité de Flora y Fauna Silvestres, Dictamen del Comité Científico n.º CC 30/2017 sobre distintas especies del género *Eucalyptus*, Technical Report, Ministerio de Agricultura, Pesca, Alimentación y Medio Ambiente (MAPAMA), 2017. URL: https://www.miteco.gob.es/content/dam/miteco/es/biodiversidad/temas/conservacion-de-especies/dictamencc302017eucalyptusvariasspp_tcm30-445705.pdf.
- [36] Greenpeace España, WWF España, SEO/BirdLife, Ecologistas en Acción, et al., Declaración: Solicitud de ampliación de las vigentes moratorias a las plantaciones de eucalipto en el norte de España, Declaración conjunta de 25 organizaciones ecologistas, 2025. URL: <https://es.greenpeace.org/es/wp-content/uploads/sites/3/2025/06/DeclaEucalipto.docx.pdf>.
- [37] A. Cordero Rivera, S. Santolamazza Carbone, J. A. Andrés, Life cycle and biological control of the Eucalyptus snout beetle (Coleoptera, Curculionidae) by *Anaphes nitens* (Hymenoptera, Mymaridae) in north-west Spain, *Agricultural and Forest Entomology* 1 (1999) 103–109.
- [38] J. Díez, Invasion biology of Australian ectomycorrhizal fungi introduced with eucalypt plantations into the Iberian Peninsula, *Biological Invasions* 7 (2005) 3–15.

Tabla A.1

Comparativa Modelos Base en IFN2 (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
LightGBM_{global}	0.719	26.806	14.689	35.364	47.104	-0.021
LightGBM	0.712	26.435	14.755	35.823	47.593	-0.401
CatBoost _{global}	0.708	27.359	14.832	35.710	47.895	-0.135
XGBoost _{global}	0.708	27.361	14.620	35.198	46.910	-0.171
GBDT _{global}	0.705	27.504	14.772	35.564	46.941	-0.142
XGBoost	0.704	26.779	14.773	35.867	47.452	-0.434
CatBoost	0.701	26.927	15.066	36.578	49.284	-0.753
MLP _{global}	0.686	28.335	15.668	37.722	50.547	0.280
BaggedDT	0.676	28.036	15.683	38.075	49.869	-0.195
GBDT	0.673	28.161	15.614	37.907	50.513	-0.699
RandomForest	0.663	28.595	15.807	38.378	49.750	-0.376
BaggedDT _{global}	0.658	29.574	15.933	38.361	50.974	-0.599
RandomForest _{global}	0.653	29.803	15.577	37.502	48.386	-1.499
MLP	0.637	29.650	15.543	37.735	49.907	-7.176
BayesianNN	0.606	30.904	17.384	42.205	56.359	-0.697
BayesianNN _{global}	0.588	32.482	17.725	42.675	56.630	-0.732
SVR _{global}	0.465	37.013	16.674	40.145	49.745	-8.320
SVR	0.445	36.667	17.361	42.150	52.112	-8.338

A. Resultados

A continuación expondremos los resultados obtenidos a partir de varias métricas de evaluación de los modelos sobre el conjunto de datos de test. Dividiremos la sección según el origen de los datos de entrenamiento (IFN2, IFN3 o IFN2 e IFN3) y según la variable a predecir (toneladas de carbono o toneladas de carbono por hectárea).

A.1. IFN2 como explicativo para c4 (tC/ha)

A.1.1. Modelos base

Una vez entrenados los modelos, algunos parámetros globales como el R^2 , RMSE y MAE se presentan en la Tabla A.1.

A.1.2. Modelos con stacking

En la Tabla A.2 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN2 como explicativo.

Tabla A.2

Comparativa Modelos Stacking en IFN2 (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
Stack5 GradientBoosting	0.724	25.889	14.531	35.280	47.157	-0.579
Stack1 MLP _{global}	0.722	26.683	14.582	35.106	46.515	0.117
Stack2 MLP _{global}	0.721	26.726	14.475	34.848	46.320	-0.131
Stack5 MLP _{global}	0.721	26.742	14.502	34.913	46.347	0.077
Stack3 GradientBoosting	0.720	26.054	14.847	36.045	48.023	-0.747
Stack1 LinearRegression _{global}	0.719	26.827	14.609	35.173	46.712	-0.140
Stack1 Ridge _{global}	0.719	26.829	14.609	35.172	46.709	-0.142
Stack5 MLP	0.718	26.127	14.452	35.088	46.430	-0.607
Stack4 MLP _{global}	0.718	26.852	14.479	34.859	46.260	-0.328
Stack2 LinearRegression _{global}	0.718	26.877	14.505	34.922	46.440	-0.112
Stack2 Ridge _{global}	0.718	26.883	14.507	34.927	46.440	-0.114
Stack4 MLP	0.717	26.177	14.550	35.326	46.579	-0.495
Stack5 LinearRegression _{global}	0.717	26.905	14.552	35.034	46.852	-0.053
Stack5 Ridge _{global}	0.717	26.910	14.547	35.022	46.818	-0.064
Stack4 LinearRegression _{global}	0.717	26.912	14.590	35.127	46.948	-0.056
Stack4 Ridge _{global}	0.717	26.913	14.584	35.112	46.912	-0.066
Stack5 LinearRegression	0.716	26.247	14.600	35.445	47.345	-0.545
Stack5 Ridge	0.716	26.247	14.599	35.445	47.344	-0.545
Stack1 MLP	0.716	26.257	14.669	35.614	47.371	-0.555
Stack4 LinearRegression	0.715	26.271	14.621	35.498	47.385	-0.553
Stack4 Ridge	0.715	26.271	14.621	35.498	47.385	-0.553
Stack2 GradientBoosting _{global}	0.715	27.001	14.536	34.996	46.544	-0.181
Stack1 Ridge	0.714	26.339	14.689	35.663	47.140	-0.500
Stack1 LinearRegression	0.714	26.339	14.689	35.663	47.140	-0.500
Stack4 GradientBoosting	0.713	26.383	14.607	35.464	47.377	-0.674
Stack2 MLP	0.712	26.401	14.587	35.414	46.924	-0.528
Stack3 LinearRegression _{global}	0.712	27.155	14.647	35.265	47.109	-0.126
Stack3 Ridge _{global}	0.712	27.157	14.640	35.248	47.066	-0.138
Stack2 LinearRegression	0.712	26.429	14.632	35.523	47.316	-0.535
Stack2 Ridge	0.712	26.429	14.632	35.523	47.316	-0.535
Stack3 MLP _{global}	0.711	27.212	14.529	34.979	46.365	-0.705
Stack2 SVR _{global}	0.711	27.212	14.225	34.247	45.732	-2.514
Stack4 SVR _{global}	0.711	27.225	14.249	34.305	46.002	-2.559
Stack5 SVR _{global}	0.710	27.237	14.218	34.232	45.909	-2.549
Stack1 SVR _{global}	0.710	27.240	14.307	34.445	45.502	-2.747
Stack3 MLP	0.709	26.544	14.875	36.114	47.914	-0.401
Stack5 SVR	0.709	26.550	14.241	34.575	47.201	-4.012
Stack5 RandomForest	0.708	26.594	15.177	36.847	48.063	0.095
Stack4 SVR	0.708	26.599	14.320	34.766	47.387	-4.112
Stack3 SVR _{global}	0.706	27.453	14.305	34.441	46.147	-2.626
Stack1 SVR	0.705	26.729	14.400	34.961	46.958	-3.988
Stack2 SVR	0.704	26.784	14.279	34.667	47.082	-4.027
Stack3 LinearRegression	0.703	26.832	14.942	36.276	48.431	-0.664
Stack3 Ridge	0.703	26.832	14.942	36.276	48.431	-0.664
Stack4 RandomForest	0.702	26.897	15.442	37.490	48.861	-0.050
Stack5 GradientBoosting _{global}	0.701	27.690	14.571	35.081	46.490	-0.240
Stack1 GradientBoosting _{global}	0.699	27.740	14.641	35.250	46.608	-0.367
Stack3 GradientBoosting _{global}	0.699	27.770	14.642	35.253	46.471	-0.282
Stack3 SVR	0.696	27.146	14.613	35.477	48.257	-4.409
Stack1 GradientBoosting	0.695	27.176	14.815	35.967	47.547	-0.476
Stack4 GradientBoosting _{global}	0.693	28.026	14.640	35.247	46.441	-0.166
Stack2 RandomForest _{global}	0.690	28.187	15.317	36.876	47.788	0.139
Stack2 GradientBoosting	0.690	27.429	14.710	35.714	47.413	-0.599
Stack2 RandomForest	0.688	27.488	15.562	37.782	48.807	-0.134
Stack3 RandomForest	0.685	27.622	15.914	38.636	49.763	-0.395
Stack1 RandomForest _{global}	0.681	28.578	15.738	37.891	48.764	-0.085
Stack5 RandomForest _{global}	0.679	28.674	15.225	36.656	47.660	0.534
Stack4 RandomForest _{global}	0.673	28.956	15.339	36.929	47.706	0.394
Stack1 RandomForest	0.672	28.193	16.193	39.314	50.293	-0.396
Stack3 RandomForest _{global}	0.667	29.218	15.575	37.499	48.075	0.408

Tabla A.3

Comparativa Modelos Base en IFN2 (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
CatBoost_{global}	0.765	18.533	10.402	35.470	69.561	-0.342
LightGBM _{global}	0.762	18.627	10.417	35.522	69.531	-0.313
XGBoost _{global}	0.762	18.644	10.428	35.559	69.353	-0.384
GBDT _{global}	0.759	18.765	10.474	35.716	69.410	-0.407
CatBoost	0.748	19.071	11.036	38.035	72.181	0.034
MLP _{global}	0.747	19.220	10.732	36.597	71.377	-1.309
LightGBM	0.747	19.121	10.858	37.423	71.698	0.042
XGBoost	0.742	19.300	10.962	37.780	71.609	-0.004
BaggedDT _{global}	0.738	19.550	11.216	38.246	71.630	-0.749
RandomForest _{global}	0.734	19.694	10.928	37.264	68.279	-1.503
GBDT	0.732	19.692	11.550	39.809	73.147	0.016
RandomForest	0.729	19.770	11.294	38.925	70.570	0.013
BaggedDT	0.728	19.832	11.349	39.114	70.434	0.182
BayesianNN	0.693	21.069	12.830	44.220	79.896	-0.076
MLP	0.690	21.162	11.419	39.356	76.074	-3.511
BayesianNN _{global}	0.683	21.530	12.827	43.741	78.379	-0.859
SVR _{global}	0.577	24.861	12.305	41.961	75.324	-7.293
SVR	0.566	25.034	12.818	44.177	77.708	-6.476

A.2. IFN2 como explicativo para carbono_bruto4 (tC)**A.2.1. Modelos base**

En la Tabla A.3 se muestra el resumen del rendimiento de los modelos para la predicción de la variable de carbono en toneladas (carbono_bruto4) con el conjunto de datos que emplea IFN2 como explicativo.

A.2.2. Modelos con stacking

En la Tabla A.4 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en toneladas (carbono_bruto4) con el conjunto de datos que emplea IFN2 como explicativo.

Tabla A.4

Comparativa Modelos Stacking en IFN2 (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
Stack5 MLP_{global}	0.768	18.405	10.210	34.817	68.129	-0.195
Stack5 LinearRegression _{global}	0.768	18.418	10.306	35.144	69.309	-0.169
Stack5 Ridge _{global}	0.768	18.418	10.306	35.143	69.320	-0.170
Stack4 MLP _{global}	0.767	18.433	10.229	34.881	68.095	0.030
Stack4 LinearRegression _{global}	0.767	18.435	10.297	35.112	69.291	-0.232
Stack4 Ridge _{global}	0.767	18.435	10.296	35.111	69.288	-0.233
Stack3 MLP _{global}	0.767	18.450	10.184	34.726	67.782	-0.295
Stack5 GradientBoosting _{global}	0.767	18.457	10.224	34.863	68.228	-0.393
Stack3 Ridge _{global}	0.767	18.466	10.318	35.185	69.212	-0.277
Stack3 LinearRegression _{global}	0.767	18.466	10.318	35.185	69.212	-0.277
Stack4 GradientBoosting _{global}	0.766	18.485	10.216	34.837	68.125	-0.407
Stack2 LinearRegression _{global}	0.765	18.521	10.333	35.236	69.359	-0.252
Stack2 Ridge _{global}	0.765	18.521	10.333	35.236	69.360	-0.253
Stack3 GradientBoosting _{global}	0.765	18.529	10.230	34.886	68.141	-0.463
Stack2 MLP _{global}	0.765	18.531	10.285	35.071	68.797	-0.207
Stack5 SVR _{global}	0.763	18.595	10.155	34.628	68.878	-1.814
Stack4 SVR _{global}	0.763	18.601	10.169	34.676	68.822	-1.826
Stack1 MLP _{global}	0.763	18.602	10.261	34.989	67.896	-0.730
Stack1 Ridge _{global}	0.763	18.606	10.377	35.385	69.330	-0.345
Stack1 LinearRegression _{global}	0.763	18.606	10.377	35.385	69.330	-0.345
Stack2 GradientBoosting _{global}	0.763	18.616	10.297	35.114	68.617	-0.412
Stack3 SVR _{global}	0.762	18.643	10.193	34.758	68.689	-1.883
Stack1 GradientBoosting _{global}	0.761	18.676	10.316	35.177	68.372	-0.484
Stack2 SVR _{global}	0.761	18.678	10.222	34.856	68.947	-1.763
Stack1 SVR _{global}	0.758	18.821	10.260	34.986	68.943	-2.023
Stack5 RandomForest _{global}	0.756	18.879	10.606	36.167	66.996	0.138
Stack4 RandomForest _{global}	0.756	18.886	10.704	36.501	67.217	0.084
Stack4 MLP	0.755	18.828	10.636	36.658	70.675	0.274
Stack4 Ridge	0.754	18.860	10.734	36.997	71.361	0.044
Stack4 LinearRegression	0.754	18.860	10.734	36.997	71.364	0.044
Stack5 GradientBoosting	0.753	18.880	10.692	36.852	70.603	-0.022
Stack5 MLP	0.753	18.890	10.632	36.643	71.389	0.045
Stack5 Ridge	0.753	18.893	10.746	37.038	71.326	0.016
Stack5 LinearRegression	0.753	18.893	10.747	37.039	71.327	-0.016
Stack3 MLP	0.753	18.896	10.746	37.036	71.008	0.081
Stack4 GradientBoosting	0.752	18.921	10.654	36.720	70.494	0.029
Stack2 MLP	0.751	18.954	10.765	37.102	70.755	-0.001
Stack3 Ridge	0.751	18.977	10.873	37.473	71.697	0.076
Stack3 LinearRegression	0.751	18.978	10.873	37.474	71.695	0.076
Stack2 GradientBoosting	0.751	18.978	10.769	37.116	70.909	0.002
Stack4 SVR	0.750	18.988	10.523	36.267	72.240	-2.179
Stack2 Ridge	0.750	18.989	10.793	37.200	71.359	-0.048
Stack2 LinearRegression	0.750	18.989	10.793	37.200	71.357	-0.048
Stack5 SVR	0.750	18.993	10.530	36.293	72.199	-2.129
Stack3 GradientBoosting	0.749	19.027	10.783	37.164	70.757	0.076
Stack1 MLP	0.749	19.043	10.736	37.001	70.468	-0.031
Stack1 Ridge	0.749	19.048	10.777	37.145	71.433	-0.008
Stack1 LinearRegression	0.749	19.048	10.777	37.145	71.434	-0.008
Stack3 SVR	0.747	19.116	10.656	36.726	72.643	-2.243
Stack2 SVR	0.747	19.116	10.602	36.542	72.634	-2.230
Stack1 GradientBoosting	0.746	19.174	10.778	37.146	70.768	-0.046
Stack3 RandomForest _{global}	0.745	19.286	10.840	36.965	67.152	-0.105
Stack1 SVR	0.745	19.187	10.596	36.521	72.624	-2.197
Stack2 RandomForest _{global}	0.741	19.455	10.979	37.440	69.244	-0.110
Stack5 RandomForest	0.734	19.588	11.135	38.377	68.643	0.589
Stack1 RandomForest _{global}	0.734	19.711	11.235	38.313	68.420	-0.278
Stack3 RandomForest	0.727	19.848	11.483	39.578	69.750	0.543
Stack4 RandomForest	0.727	19.848	11.194	38.580	68.556	0.550
Stack2 RandomForest	0.720	20.098	11.538	39.768	71.966	0.196
Stack1 RandomForest	0.713	20.375	11.767	40.555	70.731	0.068

Tabla A.5

Comparativa Modelos Base en IFN3 (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
LightGBM	0.858	17.816	9.246	24.609	37.327	0.017
XGBoost	0.851	18.232	9.203	24.494	37.033	-0.021
CatBoost	0.849	18.385	9.746	25.941	40.139	-0.114
GBDT	0.843	18.718	9.893	26.330	40.046	0.005
MLP	0.840	18.947	9.296	24.743	36.827	-3.555
GBDT _{global}	0.839	19.408	9.559	25.792	38.647	0.378
XGBoost _{global}	0.839	19.424	9.548	25.763	39.032	0.206
CatBoost _{global}	0.838	19.500	9.433	25.451	39.540	0.056
LightGBM _{global}	0.836	19.580	9.602	25.909	39.178	0.237
MLP _{global}	0.833	19.791	10.008	27.005	44.150	0.107
BaggedDT	0.820	20.085	10.699	28.476	40.585	0.098
BaggedDT _{global}	0.800	21.649	11.058	29.838	44.515	1.538
RandomForest	0.796	21.353	10.839	28.849	40.827	-0.092
RandomForest _{global}	0.789	22.223	11.109	29.974	41.901	1.399
BayesianNN	0.774	22.507	12.332	32.823	55.074	0.201
BayesianNN _{global}	0.743	24.561	12.643	34.113	56.226	0.572
SVR	0.737	24.279	9.877	26.289	37.234	-3.632
SVR _{global}	0.613	30.113	11.708	31.590	42.962	-4.778

A.3. IFN3 como explicativo para c4 (tC/ha)**A.3.1. Modelos base**

Una vez entrenados los modelos, algunos parámetros globales como el R^2 , RMSE y MAE se presentan en la Tabla A.5.

A.3.2. Modelos con stacking

En la Tabla A.6 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN3 como explicativo.

Tabla A.6
Comparativa Modelos Stacking en IFN3 (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
Stack4 GradientBoosting	0.866	17.303	9.134	24.310	37.215	-0.009
Stack5 GradientBoosting	0.865	17.369	9.037	24.052	36.846	-0.007
Stack2 GradientBoosting	0.863	17.537	9.097	24.211	37.106	0.005
Stack5 MLP	0.862	17.572	8.950	23.822	36.332	-0.335
Stack5 LinearRegression	0.861	17.644	9.049	24.083	37.004	-0.013
Stack5 Ridge	0.861	17.646	9.050	24.087	37.003	-0.012
Stack4 MLP	0.861	17.647	9.147	24.346	36.813	0.171
Stack2 MLP	0.860	17.704	9.038	24.054	36.404	-0.294
Stack4 LinearRegression	0.860	17.718	9.190	24.459	37.349	0.011
Stack4 Ridge	0.860	17.720	9.191	24.463	37.351	0.011
Stack1 GradientBoosting	0.859	17.740	9.273	24.681	37.369	0.029
Stack2 LinearRegression	0.859	17.767	9.097	24.213	36.750	-0.004
Stack2 Ridge	0.859	17.773	9.107	24.240	36.785	-0.004
Stack5 SVR	0.858	17.816	8.879	23.631	37.125	-1.871
Stack5 RandomForest	0.858	17.819	9.445	25.139	37.517	0.362
Stack1 MLP	0.858	17.834	9.264	24.657	37.281	0.119
Stack4 SVR	0.858	17.851	9.011	23.984	37.554	-1.902
Stack1 LinearRegression	0.857	17.873	9.244	24.604	36.837	0.023
Stack1 Ridge	0.857	17.875	9.245	24.606	36.831	0.023
Stack2 SVR	0.856	17.954	8.935	23.781	37.175	-1.851
Stack3 GradientBoosting	0.855	18.026	9.534	25.375	38.431	0.002
Stack1 SVR	0.854	18.053	9.114	24.257	37.328	-1.845
Stack3 MLP	0.852	18.171	9.500	25.285	37.589	0.001
Stack4 RandomForest	0.852	18.199	9.748	25.946	38.468	0.330
Stack3 LinearRegression	0.850	18.309	9.580	25.498	38.816	0.007
Stack3 Ridge	0.850	18.316	9.581	25.500	38.784	0.008
Stack3 RandomForest	0.849	18.375	10.159	27.039	39.787	0.336
Stack5 MLP _{global}	0.848	18.892	9.178	24.763	36.606	0.347
Stack2 MLP _{global}	0.847	18.943	9.332	25.180	37.530	0.382
Stack3 SVR	0.846	18.552	9.397	25.010	38.601	-2.106
Stack4 MLP _{global}	0.845	19.067	9.180	24.770	36.741	0.146
Stack5 Ridge _{global}	0.844	19.100	9.252	24.965	38.537	0.140
Stack5 LinearRegression _{global}	0.844	19.102	9.253	24.966	38.597	0.131
Stack2 Ridge _{global}	0.844	19.115	9.355	25.241	38.497	0.193
Stack2 LinearRegression _{global}	0.844	19.117	9.356	25.244	38.525	0.191
Stack4 Ridge _{global}	0.843	19.154	9.278	25.033	38.451	0.184
Stack4 LinearRegression _{global}	0.843	19.156	9.277	25.030	38.505	0.173
Stack3 Ridge _{global}	0.843	19.187	9.305	25.107	38.570	0.218
Stack3 LinearRegression _{global}	0.843	19.188	9.304	25.104	38.641	0.205
Stack3 MLP _{global}	0.842	19.216	9.188	24.790	36.845	-0.169
Stack5 SVR _{global}	0.840	19.367	9.101	24.557	40.002	-2.063
Stack2 SVR _{global}	0.840	19.369	9.185	24.783	39.985	-2.057
Stack4 SVR _{global}	0.839	19.400	9.116	24.597	39.978	-2.045
Stack3 SVR _{global}	0.839	19.423	9.137	24.655	40.013	-2.018
Stack2 RandomForest	0.839	18.988	9.887	26.314	38.705	0.293
Stack1 MLP _{global}	0.839	19.436	9.564	25.804	37.443	0.770
Stack3 GradientBoosting _{global}	0.837	19.547	9.290	25.067	37.493	0.310
Stack1 LinearRegression _{global}	0.837	19.564	9.582	25.854	38.721	0.337
Stack1 Ridge _{global}	0.837	19.565	9.582	25.854	38.714	0.339
Stack1 RandomForest	0.835	19.224	10.450	27.814	40.024	0.233
Stack5 GradientBoosting _{global}	0.833	19.768	9.291	25.069	37.539	0.270
Stack1 GradientBoosting _{global}	0.832	19.820	9.600	25.903	38.177	0.508
Stack1 SVR _{global}	0.832	19.852	9.388	25.330	39.687	-1.927
Stack4 GradientBoosting _{global}	0.830	19.940	9.344	25.213	37.491	0.304
Stack2 GradientBoosting _{global}	0.826	20.206	9.499	25.631	38.253	0.331
Stack5 RandomForest _{global}	0.820	20.540	9.871	26.635	38.299	0.692
Stack3 RandomForest _{global}	0.807	21.266	10.271	27.713	39.177	0.574
Stack4 RandomForest _{global}	0.804	21.415	10.123	27.314	38.710	0.763
Stack2 RandomForest _{global}	0.802	21.562	10.342	27.905	39.864	0.540
Stack1 RandomForest _{global}	0.792	22.090	10.962	29.576	40.925	0.731

Tabla A.7

Comparativa Modelos Base en IFN3 (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
LightGBM	0.898	10.641	4.687	27.801	110.183	-0.007
CatBoost	0.896	10.737	4.789	28.405	110.952	-0.059
XGBoost	0.895	10.761	4.713	27.957	109.669	-0.008
CatBoost _{global}	0.889	10.931	4.812	28.723	111.600	-0.059
GBDT	0.888	11.134	5.044	29.920	111.422	-0.042
MLP	0.885	11.287	4.803	28.488	111.603	-0.544
LightGBM _{global}	0.884	11.153	4.863	29.023	111.679	-0.073
XGBoost _{global}	0.883	11.230	4.859	28.999	111.190	-0.036
GBDT _{global}	0.881	11.327	4.937	29.463	111.656	-0.002
MLP _{global}	0.879	11.431	5.122	30.573	114.182	-0.326
BaggedDT	0.873	11.830	5.183	30.745	99.986	-0.135
RandomForest	0.870	11.965	5.217	30.944	109.139	-0.239
BaggedDT _{global}	0.866	11.997	5.410	32.287	110.035	0.589
RandomForest _{global}	0.865	12.053	5.330	31.814	105.593	0.434
BayesianNN	0.836	13.455	6.773	40.173	120.931	0.010
BayesianNN _{global}	0.824	13.774	7.040	42.020	121.650	0.265
SVR	0.810	14.504	5.269	31.256	112.607	-2.176
SVR _{global}	0.730	17.033	6.154	36.728	114.785	-2.987

A.4. IFN3 como explicativo para carbono_bruto4 (tC)**A.4.1. Modelos base**

En la Tabla A.7 se muestra el resumen del rendimiento de los modelos para la predicción de la variable de carbono en toneladas (carbono_bruto4) con el conjunto de datos que emplea IFN3 como explicativo.

A.4.2. Modelos con stacking

En la Tabla A.8 se muestra el resumen del rendimiento de los modelos con stacking para la predicción de la variable de carbono en toneladas (carbono_bruto4) con el conjunto de datos que emplea IFN3 como explicativo.

Tabla A.8

Comparativa Modelos Stacking en IFN3 (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
Stack4 MLP	0.902	10.407	4.517	26.795	107.868	0.049
Stack5 GradientBoosting	0.901	10.433	4.540	26.930	109.331	0.030
Stack5 MLP	0.901	10.447	4.454	26.417	107.446	-0.368
Stack4 GradientBoosting	0.901	10.450	4.541	26.936	109.286	0.037
Stack5 LinearRegression	0.900	10.492	4.624	27.426	110.839	0.025
Stack5 Ridge	0.900	10.494	4.624	27.428	110.757	0.022
Stack4 LinearRegression	0.900	10.511	4.648	27.570	110.932	0.020
Stack4 Ridge	0.900	10.511	4.648	27.570	110.941	0.020
Stack2 MLP	0.899	10.540	4.581	27.173	108.573	-0.035
Stack2 LinearRegression	0.899	10.572	4.651	27.590	110.865	0.011
Stack3 MLP	0.899	10.572	4.611	27.348	106.609	0.170
Stack2 Ridge	0.899	10.573	4.654	27.604	110.866	0.010
Stack2 GradientBoosting	0.899	10.582	4.610	27.343	109.772	0.004
Stack1 MLP	0.898	10.617	4.579	27.162	107.666	-0.163
Stack1 LinearRegression	0.898	10.625	4.667	27.682	111.022	0.011
Stack1 Ridge	0.898	10.625	4.667	27.682	111.022	0.011
Stack5 SVR	0.898	10.638	4.541	26.938	110.810	-0.758
Stack4 SVR	0.897	10.655	4.556	27.027	111.084	-0.788
Stack1 GradientBoosting	0.897	10.660	4.620	27.406	109.313	0.021
Stack3 GradientBoosting	0.897	10.671	4.637	27.506	109.803	0.028
Stack3 LinearRegression	0.897	10.674	4.757	28.218	111.578	0.014
Stack3 Ridge	0.897	10.675	4.757	28.217	111.563	0.013
Stack2 SVR	0.896	10.706	4.580	27.167	110.761	-0.744
Stack5 RandomForest	0.895	10.755	4.721	28.006	96.178	0.266
Stack4 RandomForest	0.895	10.782	4.775	28.322	98.323	0.216
Stack1 SVR	0.895	10.787	4.613	27.364	110.982	-0.740
Stack3 SVR	0.893	10.865	4.672	27.712	111.457	-0.870
Stack4 MLP _{global}	0.890	10.862	4.621	27.580	109.222	0.226
Stack5 MLP _{global}	0.890	10.866	4.586	27.369	107.939	0.041
Stack3 MLP _{global}	0.890	10.880	4.544	27.119	106.128	-0.009
Stack4 LinearRegression _{global}	0.890	10.890	4.741	28.298	111.854	-0.075
Stack4 Ridge _{global}	0.890	10.891	4.741	28.297	111.872	-0.075
Stack5 GradientBoosting _{global}	0.890	10.905	4.612	27.525	109.827	-0.006
Stack5 LinearRegression _{global}	0.889	10.908	4.747	28.330	112.364	-0.113
Stack5 Ridge _{global}	0.889	10.909	4.747	28.330	112.377	-0.113
Stack3 LinearRegression _{global}	0.889	10.921	4.766	28.443	112.073	-0.047
Stack3 Ridge _{global}	0.889	10.921	4.766	28.443	112.073	-0.047
Stack3 GradientBoosting _{global}	0.888	10.959	4.626	27.612	109.664	0.036
Stack4 GradientBoosting _{global}	0.888	10.978	4.625	27.605	109.591	0.007
Stack3 RandomForest	0.887	11.157	4.967	29.463	98.766	0.152
Stack2 RandomForest	0.887	11.165	4.916	29.157	98.358	0.133
Stack4 SVR _{global}	0.887	11.053	4.682	27.941	112.576	-0.961
Stack5 SVR _{global}	0.886	11.056	4.687	27.976	112.536	-0.956
Stack2 MLP _{global}	0.886	11.058	4.709	28.105	109.662	0.075
Stack2 LinearRegression _{global}	0.886	11.065	4.803	28.663	112.597	-0.094
Stack2 Ridge _{global}	0.886	11.065	4.802	28.662	112.594	-0.094
Stack3 SVR _{global}	0.886	11.088	4.701	28.059	112.546	-0.948
Stack1 MLP _{global}	0.885	11.102	4.680	27.934	107.602	-0.133
Stack2 GradientBoosting _{global}	0.885	11.108	4.729	28.224	110.752	-0.005
Stack1 Ridge _{global}	0.885	11.111	4.833	28.842	112.219	-0.040
Stack1 LinearRegression _{global}	0.885	11.111	4.833	28.842	112.219	-0.040
Stack1 GradientBoosting _{global}	0.884	11.171	4.732	28.242	109.678	0.048
Stack2 SVR _{global}	0.883	11.220	4.745	28.321	112.576	-0.971
Stack1 SVR _{global}	0.882	11.271	4.760	28.409	112.572	-0.951
Stack1 RandomForest	0.881	11.483	5.127	30.409	95.521	0.089
Stack5 RandomForest _{global}	0.880	11.347	4.848	28.932	96.971	0.259
Stack4 RandomForest _{global}	0.879	11.429	4.919	29.356	96.704	0.192
Stack3 RandomForest _{global}	0.875	11.586	5.023	29.976	95.997	0.204
Stack2 RandomForest _{global}	0.873	11.692	5.131	30.625	102.247	0.209
Stack1 RandomForest _{global}	0.858	12.368	5.383	32.129	94.456	0.154

Tabla A.9

Modelos Base Globales (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
LightGBM_{global}	0.787	22.767	11.650	29.978	42.370	0.134
XGBoost _{global}	0.784	22.952	11.590	29.824	42.204	0.055
CatBoost _{global}	0.783	22.990	11.607	29.866	42.904	-0.021
GBDT _{global}	0.783	23.014	11.658	29.998	41.987	0.169
MLP _{global}	0.771	23.606	12.287	31.617	46.726	0.177
BaggedDT _{global}	0.740	25.142	13.021	33.506	47.116	0.678
RandomForest _{global}	0.732	25.547	12.908	33.214	44.513	0.232
BayesianNN _{global}	0.678	28.021	14.689	37.797	56.389	0.047
SVR _{global}	0.551	33.065	13.708	35.272	45.693	-6.204

Tabla A.10

Modelos Stacking Globales (c4)

Modelo	R^2_{test}	RMSE _{test} (tC/ha)	MAE _{test} (tC/ha)	wMAPE (%)	SMAPE (%)	Bias (tC/ha)
Stack5 MLP_{global}	0.794	22.387	11.321	29.132	40.529	0.238
Stack2 MLP _{global}	0.794	22.405	11.403	29.341	41.069	0.176
Stack4 MLP _{global}	0.792	22.527	11.314	29.112	40.574	-0.045
Stack2 LinearRegression _{global}	0.791	22.565	11.429	29.409	41.712	0.069
Stack2 Ridge _{global}	0.791	22.566	11.429	29.409	41.696	0.069
Stack5 LinearRegression _{global}	0.791	22.571	11.387	29.299	41.921	0.057
Stack5 Ridge _{global}	0.791	22.572	11.384	29.293	41.871	0.058
Stack4 Ridge _{global}	0.790	22.601	11.414	29.371	41.858	0.083
Stack4 LinearRegression _{global}	0.790	22.602	11.416	29.375	41.905	0.081
Stack1 MLP _{global}	0.790	22.635	11.584	29.808	41.096	0.507
Stack3 LinearRegression _{global}	0.788	22.735	11.456	29.477	42.051	0.072
Stack3 Ridge _{global}	0.788	22.735	11.453	29.471	41.991	0.074
Stack1 LinearRegression _{global}	0.787	22.769	11.606	29.864	41.939	0.145
Stack1 Ridge _{global}	0.787	22.770	11.606	29.864	41.933	0.145
Stack3 MLP _{global}	0.787	22.776	11.338	29.175	40.679	-0.384
Stack2 SVR _{global}	0.786	22.853	11.214	28.856	42.299	-2.241
Stack5 SVR _{global}	0.785	22.864	11.162	28.721	42.381	-2.258
Stack4 SVR _{global}	0.785	22.875	11.183	28.775	42.403	-2.252
Stack3 SVR _{global}	0.783	22.996	11.218	28.866	42.483	-2.263
Stack1 SVR _{global}	0.781	23.113	11.369	29.253	42.029	-2.257
Stack2 GradientBoosting _{global}	0.779	23.183	11.527	29.661	41.592	0.125
Stack3 GradientBoosting _{global}	0.779	23.211	11.445	29.450	41.108	0.072
Stack5 GradientBoosting _{global}	0.777	23.284	11.417	29.378	41.143	0.064
Stack1 GradientBoosting _{global}	0.776	23.334	11.630	29.926	41.572	0.156
Stack4 GradientBoosting _{global}	0.773	23.532	11.477	29.531	41.095	0.115
Stack5 RandomForest _{global}	0.761	24.147	12.027	30.947	42.068	0.628
Stack2 RandomForest _{global}	0.755	24.446	12.345	31.766	43.055	0.378
Stack4 RandomForest _{global}	0.749	24.730	12.223	31.452	42.332	0.614
Stack3 RandomForest _{global}	0.748	24.777	12.407	31.924	42.760	0.507
Stack1 RandomForest _{global}	0.745	24.907	12.885	33.155	44.082	0.402

A.5. IFN2+IFN3 como explicativos para c4 (tC/ha)**A.5.1. Modelos base**

Una vez entrenados los modelos, algunos parámetros globales como el R^2 , RMSE y MAE se presentan en la Tabla A.9.

A.5.2. Modelos con stacking

En la Tabla A.10 se muestra el resumen del rendimiento de los modelos de stacking para la predicción de la variable de carbono en tC/ha con el conjunto de datos que emplea IFN2 e IFN3 como explicativos.

Tabla A.11

Modelos Base Globales (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
CatBoost_{global}	0.845	13.846	6.615	31.789	98.044	-0.150
LightGBM _{global}	0.841	14.006	6.654	31.977	98.088	-0.150
XGBoost _{global}	0.840	14.054	6.655	31.980	97.699	-0.148
GBDT _{global}	0.838	14.159	6.722	32.304	98.033	-0.132
MLP _{global}	0.832	14.410	6.931	33.311	100.379	-0.643
BaggedDT _{global}	0.821	14.858	7.282	34.995	97.651	0.158
RandomForest _{global}	0.819	14.950	7.135	34.291	93.561	-0.191
BayesianNN _{global}	0.775	16.674	8.906	42.802	107.697	-0.097
SVR _{global}	0.679	19.897	8.137	39.106	102.061	-4.376

Tabla A.12

Modelos Stacking Globales (carbono_bruto4)

Modelo	R^2_{test}	RMSE _{test} (tC)	MAE _{test} (tC)	wMAPE (%)	SMAPE (%)	Bias (tC)
Stack5 MLP_{global}	0.847	13.756	6.399	30.754	95.102	-0.035
Stack4 MLP _{global}	0.847	13.766	6.429	30.898	95.960	0.163
Stack4 LinearRegression _{global}	0.846	13.782	6.533	31.394	98.129	-0.126
Stack4 Ridge _{global}	0.846	13.782	6.533	31.394	98.140	-0.126
Stack3 MLP _{global}	0.846	13.783	6.362	30.576	93.763	-0.101
Stack5 LinearRegression _{global}	0.846	13.785	6.539	31.426	98.481	-0.131
Stack5 Ridge _{global}	0.846	13.785	6.539	31.426	98.493	-0.131
Stack5 GradientBoosting _{global}	0.846	13.799	6.421	30.860	96.413	-0.131
Stack3 LinearRegression _{global}	0.846	13.812	6.556	31.506	98.252	-0.121
Stack3 Ridge _{global}	0.846	13.812	6.556	31.506	98.252	-0.121
Stack4 GradientBoosting _{global}	0.845	13.850	6.428	30.891	96.220	-0.126
Stack3 GradientBoosting _{global}	0.844	13.860	6.433	30.917	96.274	-0.125
Stack2 LinearRegression _{global}	0.843	13.913	6.586	31.650	98.655	-0.145
Stack2 Ridge _{global}	0.843	13.913	6.586	31.650	98.653	-0.145
Stack2 MLP _{global}	0.843	13.913	6.507	31.270	96.485	-0.016
Stack5 SVR _{global}	0.843	13.940	6.450	30.999	98.458	-1.233
Stack4 SVR _{global}	0.843	13.941	6.451	31.002	98.467	-1.240
Stack1 MLP _{global}	0.842	13.968	6.480	31.140	94.798	-0.326
Stack1 Ridge _{global}	0.842	13.974	6.620	31.816	98.389	-0.138
Stack1 LinearRegression _{global}	0.842	13.974	6.620	31.816	98.389	-0.138
Stack2 GradientBoosting _{global}	0.842	13.977	6.524	31.355	97.165	-0.136
Stack3 SVR _{global}	0.842	13.977	6.472	31.103	98.404	-1.249
Stack1 GradientBoosting _{global}	0.840	14.037	6.532	31.393	96.359	-0.123
Stack2 SVR _{global}	0.840	14.064	6.511	31.290	98.508	-1.226
Stack1 SVR _{global}	0.838	14.153	6.533	31.398	98.503	-1.297
Stack5 RandomForest _{global}	0.836	14.218	6.705	32.220	87.305	0.220
Stack4 RandomForest _{global}	0.835	14.266	6.784	32.603	87.196	0.157
Stack3 RandomForest _{global}	0.829	14.522	6.898	33.152	86.696	0.104
Stack2 RandomForest _{global}	0.826	14.652	7.017	33.722	91.605	0.106
Stack1 RandomForest _{global}	0.815	15.130	7.270	34.939	86.061	0.015

A.6. IFN2+IFN3 como explicativos para carbono_bruto4 (tC)**A.6.1. Modelos base**

En la Tabla A.11 se muestra el resumen del rendimiento de los modelos para la predicción de la variable de carbono en toneladas con el conjunto de datos que emplea el IFN2 e IFN3 como explicativos.

A.6.2. Modelos con stacking

En la Tabla A.12 se muestra el resumen del rendimiento de los modelos con stacking para la predicción de la variable de carbono en toneladas con el conjunto de datos que emplea el IFN2 e IFN3 como explicativos.